



2025 秋 初等概率论 统计推断 课程笔记

作者：招财鱼

组织：清华大学

时间：2025 Fall

If you're dissatisfied with the world, change yourself. -- Kusanagi Motoko

目录

第一部分 初等概率论	1
第 1 节 古典概型和概率空间	2
1.1 概率模型	2
1.2 概率的性质	3
1.3 随机抽样与随机分配	5
1.4 概率空间	6
1.5 概率的连续性	8
1.6 条件概率	9
1.7 乘法公式	9
1.8 全概率公式	11
1.9 Bayes 准则	11
第 2 节 随机变量和概率分布	12
2.1 事件的独立性	12
2.2 随机变量	13
2.3 随机变量的独立性	14
2.4 常见离散型随机变量	15
2.5 常见连续型随机变量	17
2.6 随机变量函数的分布	21
第 3 节 随机向量和概率分布	23
3.1 离散型随机向量	23
3.2 连续型随机向量	25
3.3 条件分布和条件密度	26
3.3.1 离散型条件分布	26
3.3.2 连续型条件分布	27
3.4 概率向量函数的分布	29
3.4.1 多个函数的联合密度	30
3.5 次序统计量	31
3.6 随机变量的 p 分位数	33
第 4 节 期望、方差、条件期望等数字特征	35
4.1 随机变量的数学期望	35
4.2 期望的性质	37
4.3 方差	39
4.3.1 方差的性质	40
4.3.2 标准差与标准化	40
4.4 常用的期望方差不等式	40
4.5 条件在事件上的条件期望	43
4.6 条件在随机变量上的条件期望	45
4.7 条件方差	48

4.8 协方差	48
4.9 相关系数	49
4.10 随机向量的期望与协方差矩阵	51
第5节 特征函数和概率极限定理	52
5.1 概率母函数	52
5.1.1 常见分布的概率母函数	52
5.1.2 随机向量的概率母函数	53
5.2 矩母函数	54
5.2.1 部分常见随机变量的矩母函数	55
5.2.2 随机向量的矩母函数	56
5.3 特征函数	56
5.3.1 常见分布的特征函数	57
5.3.2 混合分布的特征函数	59
5.3.3 随机向量的特征函数	59
5.4 大数定律	60
5.5 收敛性的一些定义	62
5.6 各种收敛之间的关系	63
5.7 常见的收敛性相关定理	65
5.8 中心极限定理	66
5.8.1 中心极限定理的离散修正	67
5.9 多元正态分布	68

第一部分

初等概率论

第 1 节 古典概型和概率空间

1.1 概率模型

样本空间是一个集合：每一个概率模型都关联着一个试验，这个试验将产生一个试验结果。该试验的所有可能结果形成样本空间，记作 Ω 。

- 样本空间的试验结果必须满足：互斥，并且完整。
- 样本空间的试验结果可能有限，也可能无限。

事件：样本空间的子集，即某些试验结果的集合。

定义 1.1 (概率模型的基本构成)

- 样本空间 Ω ：一个试验的所有可能结果的集合；
- 概率：概率就是为试验结果的集合 A (称之为事件) 确定一个非负数 $P(A)$ (称为事件 A 的概率)。此非负数刻画了我们对事件 A 的认识或所产生的信念程度。

公理 1.1 (概率公理)

1. (非负性) 对一切事件 A ，满足 $P(A) \geq 0$ 。
2. (归一化) $P(\Omega) = 1$ 。
3. (可加性) 若 $A \cap B = \emptyset$ ，那么 $P(A \cup B) = P(A) + P(B)$ 。
(可列可加性) 若 A_1, A_2, \dots 是互不相交的事件，那么

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

定义 1.2 (古典概型 (离散均匀概率))

设样本空间 Ω 由 n 个等可能性的试验结果组成，因此每个试验结果组成的事件 (称为基本事件) 的概率是相等的。由此得到

$$P(A) = \frac{\text{含于事件 } A \text{ 的试验结果数}}{n}$$

用 \mathbb{R}^r 表示 r 维向量空间，

$$\mathbb{R}^r = \{(x_1, x_2, \dots, x_r) \mid x_i \in (-\infty, \infty), 1 \leq i \leq r\}.$$

对于 \mathbb{R}^r 的子集 A ，用 $m(A) = \int_A dx_1 dx_2 \dots dx_r$ 表示 A 的体积。

定义 1.3 (几何概率模型 (连续均匀概率))

设样本空间 $\Omega \subset \mathbb{R}^r$ 的体积 $m(\Omega)$ 是正数，且 Ω 中的每个试验结果发生的可能性相同，则对于事件 $A \subset \Omega$ ，其发生的概率为

$$P(A) = \frac{m(A)}{m(\Omega)}$$

1.2 概率的性质

性质 概率的若干直观性质:

1. 若 $A \subset B$, 则 $P(A) \leq P(B)$.
2. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
3. $P(A \cup B) \leq P(A) + P(B)$.
4. $P(A \cup B \cup C) = P(A) + P(A^c \cap B) + P(A^c \cap B^c \cap C)$.

性质 性质 1: $P(\emptyset) = 0$.

证明 因为 $\Omega = \Omega \cup \emptyset \cup \emptyset \cup \dots$, 由概率公理 (3) 得

$$\begin{aligned} P(\Omega) &= P(\Omega \cup \emptyset \cup \emptyset \cup \dots) \\ &= P(\Omega) + P(\emptyset) + P(\emptyset) + \dots \end{aligned}$$

由概率公理 (2), 得

$$1 = 1 + P(\emptyset) + P(\emptyset) + \dots$$

即

$$0 = P(\emptyset) + P(\emptyset) + \dots$$

再由概率公理 (1), 得

$$P(\emptyset) = 0$$

性质 性质 2 (概率的有限可加性) 设事件 $A_i, i = 1, \dots, n$, 且 $A_i \cap A_j = \emptyset, i \neq j$, 则

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

证明 令 $A_{n+1} = A_{n+2} = \dots = \emptyset$, 则 $\bigcup_{i=1}^n A_i = \bigcup_{i=1}^{\infty} A_i$, 且当 $i \neq j$ 时, $A_i \cap A_j = \emptyset$, 由概率公理 (3) 和概率性质 1, 可得

$$P\left(\bigcup_{i=1}^n A_i\right) = P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i) = \sum_{i=1}^n P(A_i)$$

性质 性质 3: 如果有事件 A , 则 $P(A^c) = 1 - P(A)$

证明 因为 $A \cap A^c = \emptyset, A \cup A^c = \Omega$, 由性质 2 和概率公理 (2) 得

$$1 = P(\Omega) = P(A \cup A^c) = P(A) + P(A^c)$$

故 $P(A^c) = 1 - P(A)$

性质 性质 4: 如果有事件 A, B , 且 $A \subset B$, 则 $P(B \setminus A) = P(B) - P(A)$

证明 因为 $B = A \cup (B \setminus A)$ 且 $A \cap (B \setminus A) = \emptyset$, 由性质 2 得

$$P(B) = P(A) + P(B \setminus A)$$

即: $P(B \setminus A) = P(B) - P(A)$

推论 1.1

1. (概率的单调性) 如果有事件 A, B , 且 $A \subset B$, 则 $P(A) \leq P(B)$.
2. 对任意的事件 A , 有 $0 \leq P(A) \leq 1$.



性质 性质 5: 如果有事件 A, B , 则 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

证明 因为 $A \cup B = A \cup (B \setminus A)$, 且 $A \cap (B \setminus A) = \emptyset$, 由性质 2 和 4 得

$$\begin{aligned} P(A \cup B) &= P(A) + P(B \setminus A) \\ &= P(A) + P(B \setminus (A \cap B)) \\ &= P(A) + P(B) - P(A \cap B) \end{aligned}$$

推论 1.2 (有限次可加性, finite subadditivity, 或 Boole's inequality)

如果有事件 $A_i, i = 1, \dots, n$, 则

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n P(A_i)$$



性质 性质 6 (The inclusion-exclusion formula 容斥恒等式):

如果有事件 $A_i, i = 1, \dots, n$, 则

$$\begin{aligned} P\left(\bigcup_{i=1}^n A_i\right) &= \sum_{1 \leq i \leq n} P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j) \\ &\quad + \sum_{1 \leq i < j < k \leq n} P(A_i \cap A_j \cap A_k) - \dots \\ &\quad + (-1)^{n-1} P(A_1 \cap A_2 \cap \dots \cap A_n) \end{aligned}$$

性质 性质 7 (Bonferroni's inequality) 如果有事件 $A_i, i = 1, \dots, n$, 则

$$P\left(\bigcup_{i=1}^n A_i\right) \geq \sum_{1 \leq i \leq n} P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i \cap A_j)$$

(Kounias's inequality)

$$P\left(\bigcup_{i=1}^n A_i\right) \leq \min_k \left\{ \sum_{1 \leq i \leq n} P(A_i) - \sum_{i: i \neq k} P(A_i \cap A_k) \right\}$$

性质 性质 8 (可列次可加性, σ -subadditivity) 如果有事件 $A_i, i = 1, 2, \dots$, 则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$$

证明 令 $B_1 = A_1, B_n = A_n \setminus \bigcup_{i=1}^{n-1} A_i$, 则 $\bigcup_{i=1}^{\infty} A_i = \bigcup_{i=1}^{\infty} B_i$ 且 $B_i \cap B_j = \emptyset, i \neq j, B_n \subset A_n$. 由概率公理 (3) 和概率的单调性, 得

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = P\left(\bigcup_{i=1}^{\infty} B_i\right) = \sum_{i=1}^{\infty} P(B_i) \leq \sum_{i=1}^{\infty} P(A_i)$$

性质 性质 9: 如果有事件 $A_i, i = 1, 2, \dots$, 则

$$P\left(\bigcap_{i=1}^{\infty} A_i\right) \geq 1 - \sum_{i=1}^{\infty} P(A_i^c)$$

特别地

$$P(A_1 \cap A_2) \geq 1 - P(A_1^c) - P(A_2^c)$$

证明 由性质 3 和 8 得,

$$\begin{aligned} P\left(\bigcap_{i=1}^{\infty} A_i\right) &= 1 - P\left(\left(\bigcap_{i=1}^{\infty} A_i\right)^c\right) = 1 - P\left(\bigcup_{i=1}^{\infty} A_i^c\right) \\ &\geq 1 - \sum_{i=1}^{\infty} P(A_i^c) \end{aligned}$$

特别地, 令 $A_3 = A_4 = \cdots = \Omega$, 由性质 (1), 可得第二个结论.

1.3 随机抽样与随机分配

有放回抽样与无放回抽样

定义 1.4

- 如果每次将抽到的球在下次抽球前放回箱子中, 则试验称做**放回抽样**。这时, 由 n 个球形成的每一个样本可以表示为向量 (a_1, \dots, a_n) , 其中, $a_i (i = 1, \dots, n)$ 是第 i 次抽到的球的编号。易见, 对于放回抽样, 每个 a_i 可以是 $\{1, 2, \dots, M\}$ 中的任何一个数。
- 假设 $n \leq M$, 且凡是抽到的球都不再放回, 则试验称做**无放回抽样**。



有序抽样和无序抽样

样本空间的描述, 本质上与如下情形有关: 诸如 $(4, 1, 2, 1)$ 和 $(1, 4, 2, 1)$ 是认为是‘不同’的基本事件’, 还是‘同一基本事件’。因此, 习惯上区分两种情形: **有序抽样**和**无序抽样**。

定义 1.5

- 对**有序抽样**, 由相同元素组成的两个样本, 只要其中元素的先后顺序有所不同, 就视为‘不同’的样本。
- 对**无序抽样**, 不管元素的顺序, 只要由相同元素组成的样本, 都视为‘同一个’样本。
- 为强调具体样本属于哪一种, 对有序样本, 使用记号 (a_1, \dots, a_n) , 而无序样本则记作 $[a_1, \dots, a_n]$ 。



例 1.1

	抽样方式		基本事件
自含有 M 个球箱子中的 n 次抽样 ($M = 3, n = 2$) 相应基本空间的构造列表	放回	有序	$(i, j), i, j = 1, 2, 3$
		无序	$[1, 1][2, 2][3, 3][1, 2][1, 3][2, 3]$
	不放回	有序	$(1, 2)(1, 3)(2, 1)(2, 3)(3, 1)(3, 2)$
		无序	$[1, 2][1, 3][2, 3]$

随机抽样的样本空间

1. 有放回抽样

1. 放回有序抽样: 样本空间 Ω 具有如下构造:

$$\Omega = \{\omega : \omega = (a_1, \dots, a_n), \quad a_i \in \{1, 2, \dots, M\}\},$$

且

$$\#(\Omega) = M^n.$$

2. 放回无序抽样: 样本空间 Ω 具有如下构造:

$$\Omega = \{\omega : \omega = [a_1, \dots, a_n], \quad a_i \in \{1, 2, \dots, M\}\},$$

且

$$\#(\Omega) = \binom{M+n-1}{n}.$$

2. 无放回抽样

1. 不放回有序抽样: 样本空间 Ω 具有如下构造:

$$\Omega = \{\omega : \omega = (a_1, \dots, a_n), a_k \neq a_l, k \neq l, a_i \in \{1, 2, \dots, M\}\},$$

且

$$\#(\Omega) = M(M-1)\dots(M-n+1) = P_M^n.$$

2. 不放回无序抽样: 样本空间 Ω 具有如下构造:

$$\Omega = \{\omega : \omega = [a_1, \dots, a_n], a_k \neq a_l, k \neq l, a_i \in \{1, 2, \dots, M\}\},$$

且

$$\#(\Omega) = \binom{M}{n}.$$

1.4 概率空间

定义 1.6 (事件域或 σ -域或 σ -代数 (σ -field or σ -algebra))

设 Ω 是样本空间, \mathcal{F} 表示 Ω 的某些子集构成的集合, 如果 \mathcal{F} 满足以下三个条件:

1. $\Omega \in \mathcal{F}$;
2. 如果 $A \in \mathcal{F}$, 则 $A^c \in \mathcal{F}$;
3. 如果 $A_n \in \mathcal{F}, n = 1, 2, \dots$, 则 $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$

称 \mathcal{F} 是 Ω 上的事件域或 σ -域或 σ -代数, 称 \mathcal{F} 中的元素为事件, 称 (Ω, \mathcal{F}) 为可测空间 (measurable space).



注

1. \mathcal{F} 中每一个事件都是可以分配概率的; 圈定了全部我们关心的事件的范围;
2. Ω 的任意子集未必是事件, 只有 \mathcal{F} 中的元素才能称之为事件;
3. \mathcal{F} 对集合的各类可列交并补运算都是封闭的, 包括事件列的极限运算。
4. \mathcal{F} 中任选一个事件, 其概率是否可计算, 取决于已知条件;

对于固定的 Ω ，可以构造出多个不同的 Ω 上的事件域。

例 1.2

σ -代数的例子

1. $\mathcal{F} = \{\Omega, \emptyset\}$, 平凡的 σ -代数;
2. $\mathcal{F} = \{\Omega \text{ 的所有子集}\}$, 最大的 σ -代数;
3. $\mathcal{F} = \{\Omega, \emptyset, A, A^c\}$ 是包含 A 的最小 σ -代数, 记作 $\mathcal{F} = \sigma(\{A\})$;

\mathcal{F} 的构造

- 如果 A, B 是 Ω 的两个子集, 且 $B \neq A^c$, 那么由 $\mathcal{A} = \{A, B\}$ 所生成的 σ -域 \mathcal{F} 是:
- $\mathcal{F} = \sigma(\mathcal{A}) = \{\Omega, \emptyset, A, A^c, B, B^c, A \cap B, A \cap B^c, A^c \cap B, A^c \cap B^c, A \cup B, A^c \cup B, A \cup B^c, A^c \cup B^c, (A \cap B) \cup (A^c \cap B^c), (A \cap B^c) \cup (A^c \cap B)\}$

定义 1.7 (概率或概率测度 (probability measure))

设 (Ω, \mathcal{F}) 是可测空间, \mathbb{P} 是定义在 \mathcal{F} 上的函数, 如果 \mathbb{P} 满足下面三个条件:

1. (非负性) 对任意的 $A \in \mathcal{F}, \mathbb{P}(A) \geq 0$.
2. (完全性) $\mathbb{P}(\Omega) = 1$.
3. (可列可加性, σ -additivity) 对于 \mathcal{F} 中互不相交 (disjoint) (或互不相容) 的事件 A_1, A_2, \dots , 有

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

称 \mathbb{P} 为 \mathcal{F} 上的概率测度 (probability measure), 简称概率 (probability), 称 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间 (probability space).



注

1. 如果 Ω 是可列的, 则存在概率分配使得 Ω 的任一子集都可测, 当然此时 \mathcal{F} 可以包含 Ω 的所有子集;
2. 如果 Ω 是不可列的, 则存在 Ω 的不可测子集, 此时这些不可测子集就不能把它们当成事件了, 因为我们无法确定其概率。

例 1.3 $(\Omega, \mathcal{F}, \mathbb{P})$ 的构造: 简单例子

1. 掷一枚硬币. $\Omega = \{H, T\}, \mathcal{F} = \{\Omega, \emptyset, \{H\}, \{T\}\}, \mathbb{P}(\{H\}) = 0.6, \mathbb{P}(\{T\}) = 0.4$.
2. 掷一枚骰子. $\Omega = \{1, 2, \dots, 6\}, \mathcal{F} = 2^\Omega$ (Ω 的所有子集构成的集合, 称为幂集, power sets), $\mathbb{P}(\{i\}) = 1/6, i = 1, \dots, 6$. 对任意的 $A \in \mathcal{F}, \mathbb{P}(A) = \#(A)/6$.
3. 反复掷一枚硬币 (每次正面朝上的概率为 p), 直到正面向上.

$$\Omega = \{T^n H : n \geq 0\} \cup \{T^\infty\}$$

$$\mathbb{P}(T^n H) = (1-p)^n p, \quad \mathbb{P}(T^\infty) = \lim_{n \rightarrow \infty} (1-p)^n = 0$$

对于 $A \in \mathcal{F}$, 如果 $\mathbb{P}(A) = 1$, 称 A 以概率 1 发生或几乎处处发生, 这里的几乎处处是指对几乎每个 $\omega \in \Omega$. 几乎处处有时又称为几乎必然, 记作 a.s. (almost surely).

注 请注意区分事件域 \mathcal{F} 、可测空间 (Ω, \mathcal{F}) 与测度空间 $(\Omega, \mathcal{F}, \mathbb{P})$:

1. 事件域 \mathcal{F} 包含全部我们关心的事件; 其中每一个事件都是可以分配概率的;
2. 对于固定的 Ω , 可以构造出多个不同的 Ω 上的事件域。
3. 对同一个可测空间 (Ω, \mathcal{F}) , 可构造不同的概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$;
4. \mathcal{F} 中任选一个事件, 其概率是否可计算, 取决于已知条件;

1.5 概率的连续性

定义 1.8 (单调序列)

对给定的事件列 $\{A_i, i = 1, 2, \dots\}$,

1. 如果 $A_1 \subset A_2 \subset \dots$, 称事件列 $\{A_i, i = 1, 2, \dots\}$ 是单调递增的;
2. 如果 $A_1 \supset A_2 \supset \dots$, 称事件列 $\{A_i, i = 1, 2, \dots\}$ 是单调递减的;

单调增序列和单调减序列统称为单调序列.

对于单调增序列 $\{A_i\}$, 则

$$\lim_{n \rightarrow \infty} A_n = \bigcup_{i=1}^{\infty} A_i$$

对于单调减序列 $\{A_i\}$, 则

$$\lim_{n \rightarrow \infty} A_n = \bigcap_{i=1}^{\infty} A_i$$



定理 1.1

设 $\{A_i\}$ 和 $\{B_j\}$ 是事件列。

1. 如果 $\{A_i\}$ 是单调增序列, 则

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} A_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n)$$

2. 如果 $\{B_j\}$ 是单调减序列, 则

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} B_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(B_n)$$



定义 1.9 (事件列的上极限与下极限)

设 $\{A_i, i = 1, 2, \dots\}$ 是 Ω 中的事件列, 定义:

1. $\{A_i, i = 1, 2, \dots\}$ 的 **上极限**, 记作 $\limsup_{n \rightarrow \infty} A_n$, 定义为:

$$\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k = \{\omega \in \Omega : \omega \text{ 属于无穷多个 } A_i\}$$

2. $\{A_i, i = 1, 2, \dots\}$ 的 **下极限**, 记作 $\liminf_{n \rightarrow \infty} A_n$, 定义为:

$$\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k = \{\omega \in \Omega : \omega \text{ 属于所有的 } A_i \text{ 除了有限个之外}\}$$

3. 如果 $\liminf_{n \rightarrow \infty} A_n = \limsup_{n \rightarrow \infty} A_n$, 则称事件列 $\{A_i\}$ 的极限存在, 记作 $\lim_{n \rightarrow \infty} A_n$.



定理 1.2

任意一组事件列 $\{A_i, i = 1, 2, \dots\}$, 有

$$\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) \geq \limsup_{n \rightarrow \infty} \mathbb{P}(A_n), \quad \mathbb{P}(\liminf_{n \rightarrow \infty} A_n) \leq \liminf_{n \rightarrow \infty} \mathbb{P}(A_n)$$



证明 记 $B_n = \bigcup_{k=n}^{\infty} A_k$, 则 $\{B_n\}$ 是单调减序列, 有

$$\mathbb{P}(\limsup_{n \rightarrow \infty} A_n) = \mathbb{P}\left(\lim_{n \rightarrow \infty} B_n\right) = \lim_{n \rightarrow \infty} \mathbb{P}(B_n)$$

又由概率单调性, 有 $\mathbb{P}(B_n) \geq \mathbb{P}(A_k), \forall k \geq n$.

即 $\mathbb{P}(B_n) \geq \sup_{k \geq n} \mathbb{P}(A_k)$, 代入上式得到第一个不等式.

(注意, 此时 $\sup_{k \geq n} \mathbb{P}(A_k)$ 是数列, 不是事件列; 该数列关于 n 是单调的, 从而保证了其极限存在.)

第二个不等式的证明是类似的.

定理 1.3 (Borel-Cantelli 引理)

设 $\{A_n\}$ 是事件列。

1. 如果

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$$

则

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 0.$$

2. 如果 $\{A_n\}$ 是相互独立的, 且

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$$

则

$$\mathbb{P}\left(\limsup_{n \rightarrow \infty} A_n\right) = 1.$$



1.6 条件概率

定义 1.10 (条件概率 (conditional probability))

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B \in \mathcal{F}$, 且 $\mathbb{P}(A) > 0$, 则在事件 A 发生的条件下, 事件 B 发生的条件概率定义为:

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)}.$$

**定理 1.4**

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A \in \mathcal{F}$, 且 $\mathbb{P}(A) > 0$, 则

1. 对任意的 $B \in \mathcal{F}$, $\mathbb{P}(B|A) \geq 0$;
2. $\mathbb{P}(\Omega|A) = 1$;
3. 对互不相容的事件列 $\{B_i\}$, 有

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} B_i \middle| A\right) = \sum_{i=1}^{\infty} \mathbb{P}(B_i|A).$$



用 $\mathbb{P}_A(\cdot)$ 表示在事件 A 发生的条件下的条件概率, 即 $\mathbb{P}_A(\cdot) = \mathbb{P}(\cdot|A)$ 。则 $(\Omega, \mathcal{F}, \mathbb{P}_A)$ 也是一个概率空间。

由于 $\mathbb{P}(A|A) = 1$, 条件概率完全集中在 A 上, 这样, 我们可以将 A 以外的结果排除掉, 并将 A 看成新的样本空间 $(A, \mathcal{A} \cap \mathcal{F}, \mathbb{P}_A)$ 。

条件概率依然是一个概率测度, 所有关于概率的性质对条件概率都成立。

1.7 乘法公式

定理 1.5 (乘法公式)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A_i \in \mathcal{F}, i = 1, \dots, n$, 且 $\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_{n-1}) > 0$, 则

$$\mathbb{P}\left(\bigcap_{i=1}^n A_i\right) = \mathbb{P}(A_1) \prod_{i=2}^n \mathbb{P}(A_i|A_1 \cap A_2 \cap \dots \cap A_{i-1}).$$



例 1.4 配对问题 某人写了 n 封信, 将其装入 n 个信封, 并在每个信封上分别任意写上 n 个收信人的一个地址 (不重复), 求:

1. 没有一个信封上所写的地址正确的概率 q_0 ;
2. 恰有 r 个信封上所写的地址正确的概率 $q_r (r \leq n)$.

证明 (1) 设 $A_i =$ “第 i 个信封上所写的地址正确”, $i = 1, 2, \dots, n$, 则 $\bigcup_{i=1}^n A_i$ 表示 “ n 个信封至少有一个信封上所写的地址正确”, 故 $q_0 = 1 - \mathbb{P}(\bigcup_{i=1}^n A_i)$.

对任意的 $1 \leq i \leq n$, 有 $\mathbb{P}(A_i) = \frac{(n-1)!}{n!} = \frac{1}{n}$.

对任意的 $1 \leq i < j \leq n$, 有

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i) \mathbb{P}(A_j | A_i) = \frac{1}{n} \frac{1}{n-1} = \frac{(n-2)!}{n!}.$$

对任意的 $1 \leq i < j < k \leq n$, 有 $\mathbb{P}(A_i \cap A_j \cap A_k) = \frac{(n-3)!}{n!}$.

...

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \frac{1}{n!}.$$

从而, 根据容斥原理 (inclusion-exclusion formula):

$$\begin{aligned} \mathbb{P}\left(\bigcup_{i=1}^n A_i\right) &= \sum_i \mathbb{P}(A_i) - \sum_{i < j} \mathbb{P}(A_i \cap A_j) + \dots + (-1)^{n-1} \mathbb{P}\left(\bigcap_{i=1}^n A_i\right) \\ &= \binom{n}{1} \mathbb{P}(A_1) - \binom{n}{2} \mathbb{P}(A_1 \cap A_2) + \dots + (-1)^{n-1} \binom{n}{n} \mathbb{P}\left(\bigcap_{i=1}^n A_i\right) \\ &= \binom{n}{1} \frac{1}{n} - \binom{n}{2} \frac{(n-2)!}{n!} + \dots + (-1)^{n-1} \frac{1}{n!} \\ &= 1 - \frac{1}{2!} + \frac{1}{3!} - \dots + (-1)^{n-1} \frac{1}{n!} \end{aligned}$$

因此

$$q_0 = 1 - \mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = 1 - \left(1 - \frac{1}{2!} + \frac{1}{3!} - \dots + (-1)^{n-1} \frac{1}{n!}\right) = \sum_{k=0}^n \frac{(-1)^k}{k!}$$

进一步, 由于 q_0 跟 n 有关, 故一般记为 $q_0(n)$. 从而

$$\lim_{n \rightarrow \infty} q_0(n) = e^{-1} = 0.36787944117144233\dots,$$

即, 当 n 非常大的时候, $q_0 \approx 0.37$.

(2) 首先, 指定某 r 个信封正确, 其余 $n-r$ 个不正确的概率是:

$$\underbrace{\frac{1}{n(n-1)\cdots(n-r+1)}}_{r \text{ 个正确}} \times \underbrace{q_0(n-r)}_{n-r \text{ 个不正确}}$$

其中, 前一项是在 n 个位置中, 指定的 r 个位置都正确的概率。后一项是剩下 $n-r$ 个信封全部装错的概率。

由于我们可以从 n 个信封中任意选择 r 个, 共有 $\binom{n}{r}$ 种选择方式。故所求概率为

$$\begin{aligned} q_r(n) &= \binom{n}{r} \frac{1}{n(n-1)\cdots(n-r+1)} \sum_{k=0}^{n-r} \frac{(-1)^k}{k!} \\ &= \frac{n!}{r!(n-r)!} \cdot \frac{(n-r)!}{n!} \cdot \sum_{k=0}^{n-r} \frac{(-1)^k}{k!} = \frac{1}{r!} \sum_{k=0}^{n-r} \frac{(-1)^k}{k!} \end{aligned}$$

1.8 全概率公式

定理 1.6 (Total Probability Theorem 全概率公式)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $B, A_i \in \mathcal{F}, i = 1, \dots, n$ (n 可以是 ∞), 且 $\mathbb{P}(A_i) > 0$, $\{A_i\}$ 是 Ω 的一个分割, 则

$$\mathbb{P}(B) = \mathbb{P}(A_1)\mathbb{P}(B|A_1) + \dots + \mathbb{P}(A_n)\mathbb{P}(B|A_n)$$

或者写作

$$\mathbb{P}(B) = \sum_{i=1}^n \mathbb{P}(A_i)\mathbb{P}(B|A_i).$$



注 $\{A_i\}$ 是 Ω 的一个分割: $\Omega = \bigcup_{i=1}^n A_i$, 且 $A_i \cap A_j = \emptyset, \forall i \neq j, i, j \in \{1, \dots, n\}$.

例 1.5 设一袋中有 n 个白球与 m 个黑球, 现从中无放回连续抽取 k 个球, 求第 k 次取得黑球的概率 ($1 \leq k \leq m+n$).

证明 (归纳法) 设 A_i 为事件 “第 i 次抽到黑球”。

显然

$$\begin{aligned}\mathbb{P}(A_1) &= \frac{m}{n+m}; \\ \mathbb{P}(A_2) &= \mathbb{P}(A_1)\mathbb{P}(A_2|A_1) + \mathbb{P}(A_1^c)\mathbb{P}(A_2|A_1^c) \\ &= \frac{m}{n+m} \cdot \frac{m-1}{n+m-1} + \frac{n}{n+m} \cdot \frac{m}{n+m-1} = \frac{m}{n+m}.\end{aligned}$$

假设 “无论开始黑球、白球个数是多少, 无放回抽到第 i 次时, 抽到黑球的概率都是初始状态中黑球的比例”。

往证 “无放回抽到第 $i+1$ 次时, 抽到黑球的概率仍是初始状态中黑球的比例”, 即 $\mathbb{P}(A_{i+1}) = \frac{m}{n+m}, i+1 \leq n+m$ 。

因为

$$\begin{aligned}\mathbb{P}(A_{i+1}) &= \mathbb{P}(A_1)\mathbb{P}(A_{i+1}|A_1) + \mathbb{P}(A_1^c)\mathbb{P}(A_{i+1}|A_1^c) \\ &= \frac{m}{n+m}\mathbb{P}(A_{i+1}|A_1) + \frac{n}{n+m}\mathbb{P}(A_{i+1}|A_1^c).\end{aligned}$$

根据归纳假设, $\mathbb{P}(A_{i+1}|A_1)$ 表示在 $m-1$ 个黑球与 n 个白球的袋中第 i 次摸得黑球的概率:

$$\mathbb{P}(A_{i+1}|A_1) = \frac{m-1}{n+m-1}.$$

同理,

$$\mathbb{P}(A_{i+1}|A_1^c) = \frac{m}{n-1+m}.$$

所以

$$\mathbb{P}(A_{i+1}) = \frac{m}{n+m} \cdot \frac{m-1}{n+m-1} + \frac{n}{n+m} \cdot \frac{m}{n-1+m} = \frac{m}{n+m}.$$

故

$$\mathbb{P}(A_k) = \frac{m}{n+m}.$$

1.9 Bayes 准则

定理 1.7 (Bayes' Rule)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $B, A_i \in \mathcal{F}, i = 1, \dots, n$, 且 $\mathbb{P}(B) > 0, \mathbb{P}(A_i) > 0, \{A_i\}$ 是 Ω 的一个分割, 则

$$\mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i)\mathbb{P}(B|A_i)}{\sum_{j=1}^n \mathbb{P}(A_j)\mathbb{P}(B|A_j)}, \quad i = 1, \dots, n.$$



第2节 随机变量和概率分布

2.1 事件的独立性

“**独立性定义**”：事件 B 的发生并没有给事件 A 带来新的信息，它没有改变事件 A 发生的概率，即 $\mathbb{P}(A|B) = \mathbb{P}(A)$ 。

定义 2.1 (独立性 (independence))

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B \in \mathcal{F}$, 如果

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B),$$

则称 A 与 B 相互独立, 简称独立。

若 A 和 B 独立, 则 (i) A 和 B^c 独立 (ii) A^c 和 B 独立 (iii) A^c 和 B^c 独立。

定义 2.2 (条件独立性 (conditional independence))

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A, B, C \in \mathcal{F}$, 且 $\mathbb{P}(C) > 0$, 如果

$$\mathbb{P}(A \cap B|C) = \mathbb{P}(A|C)\mathbb{P}(B|C)$$

则称 A 与 B 在给定 C 之下条件独立。

注 条件独立性和独立性之间没有特别的联系，也即二者互不存在蕴含关系。

例 2.1 考虑抛掷两次均匀的硬币。这个试验的四种可能结果都是等可能的。令

- $H_1 = \{ \text{第一枚硬币正面向上} \}$,
- $H_2 = \{ \text{第二枚硬币正面向上} \}$,
- $D = \{ \text{两枚硬币的试验结果不同} \}$ 。

则事件 H_1 和事件 H_2 是独立的。但是

$$\mathbb{P}(H_i|D) = \frac{1}{2}, \quad \mathbb{P}(H_1 \cap H_2|D) = 0, \quad i = 1, 2.$$

这样,

$$\mathbb{P}(H_1 \cap H_2|D) \neq \mathbb{P}(H_1|D)\mathbb{P}(H_2|D),$$

即 H_1 和 H_2 并不条件独立。

定义 2.3 (一组事件的独立性)

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A_1, \dots, A_n \in \mathcal{F}$, 如果对任意非空子集 $S \subset \{1, 2, \dots, n\}$, 都有

$$\mathbb{P}\left(\bigcap_{i \in S} A_i\right) = \prod_{i \in S} \mathbb{P}(A_i),$$

则称 A_1, A_2, \dots, A_n 是相互独立的。

定义 2.4 (两两独立性 (Pairwise independence))

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, $A_1, \dots, A_n \in \mathcal{F}$, 如果

$$\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i)\mathbb{P}(A_j), \quad \forall i \neq j; i, j \in \{1, 2, \dots, n\},$$

则称 A_1, A_2, \dots, A_n 是两两独立的。

例 2.2 将一个均匀的正四面体的第一面染上红、黄、蓝三色, 将其它三面分别染上红色、黄色、蓝色。设 A, B, C 分别表示掷一次四面体红色、黄色、蓝色与桌面接触的事件, 则

$$\begin{aligned}\mathbb{P}(A) &= \mathbb{P}(B) = \mathbb{P}(C) = \frac{1}{2}, \\ \mathbb{P}(A \cap B) &= \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(B), \\ \mathbb{P}(B \cap C) &= \frac{1}{4} = \mathbb{P}(B)\mathbb{P}(C), \\ \mathbb{P}(A \cap C) &= \frac{1}{4} = \mathbb{P}(A)\mathbb{P}(C).\end{aligned}$$

但是

$$\mathbb{P}(A \cap B \cap C) = 1/4 \neq \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C).$$

即: 两两独立并不能保证相互独立!

2.2 随机变量

定义 2.5 (随机变量 (random variable, r.v., rv))

设 (Ω, \mathcal{F}) 为可测空间, 如果 Ω 上的函数 $X(\omega)$ 满足: 对 $\forall x \in \mathbb{R}$,

$$\{\omega | X(\omega) \leq x\} \in \mathcal{F},$$

则称 $X(\omega)$ 为 (Ω, \mathcal{F}) 上的随机变量, 简称随机变量。通常将随机变量 $X(\omega)$ 简记为 X 。



注 以后用 $\{X \leq x\}$ 来表示事件 $\{\omega | X(\omega) \leq x\}$ 。显然,

1.

$$\{X > x\} = \{X \leq x\}^c \in \mathcal{F}$$

2.

$$\{X < x\} = \bigcup_{n=1}^{\infty} \left\{ X \leq x - \frac{1}{n} \right\} \in \mathcal{F}$$

3.

$$\{X \geq x\} = \{X < x\}^c \in \mathcal{F}$$

随机变量严格定义下的性质

用 \mathbb{R} 表示全体实数, 用 \mathcal{C} 表示 \mathbb{R} 中左开右闭的子区间的全体, 即 $\mathcal{C} = \{(a, b]\}$ 。令 $\mathcal{B} = \sigma(\mathcal{C})$, 通常称 \mathcal{B} 为 **Borel 域**, 称 \mathcal{B} 的元素为 **Borel 集**。

当 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, 下面的定理表明, 对任何 Borel 集 A , $\{X \in A\}$ 都是事件, 于是可以计算概率 $\mathbb{P}(X \in A)$ 。

定理 2.1

设 X 是可测空间 (Ω, \mathcal{F}) 上的随机变量, 则对任意的 Borel 集 A , 有

$$\{X \in A\} \stackrel{\text{def}}{=} \{\omega | X(\omega) \in A\} \in \mathcal{F}.$$



此后, 相对于原始概率空间 $\Omega, \mathcal{F}, \mathbb{P}$, 我们将更多关注经过 X 映射后的概率空间 $\mathbb{R}, \mathcal{B}, \mathbb{P}$ 。

随机变量的函数

定理 2.2

如果 X 是可测空间 (Ω, \mathcal{F}) 上的随机变量, $g(x)$ 是可测函数, 则 $Y = g(X)$ 是 (Ω, \mathcal{F}) 上的随机变量。



连续函数、阶梯函数、单调函数以及这些函数的线性组合都是可测函数。完全类似的可以证明, 如果 X_1, X_2, \dots, X_n 都是可测空间 (Ω, \mathcal{F}) 上的随机变量, $g(x_1, x_2, \dots, x_n)$ 是 n 元可测函数, 则 $Y = g(X_1, X_2, \dots, X_n)$ 是 (Ω, \mathcal{F}) 上的随机变量。(n 维 Borel 域)

2.3 随机变量的独立性

定义 2.6 (随机变量的相互独立性)

设 X_1, \dots, X_n 是 (Ω, \mathcal{F}) 上的随机变量, 如果对任意的实数 x_1, \dots, x_n 都有

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \mathbb{P}(X_1 \leq x_1) \cdots \mathbb{P}(X_n \leq x_n),$$

称随机变量 X_1, \dots, X_n 相互独立。



定理 2.3

设 X_1, \dots, X_n 相互独立, 则对任何 Borel 集 A_1, \dots, A_n , 事件

$$\{X_1 \in A_1\}, \{X_2 \in A_2\}, \dots, \{X_n \in A_n\}$$

相互独立。



随机变量序列或函数的独立性

定义 2.7 (独立序列)

如果对任意的 n , X_1, \dots, X_n 相互独立, 则称随机变量序列 $\{X_i\}$ 相互独立, 此时称 $\{X_i\}$ 为独立序列。



定义 2.8 (独立同分布序列)

如果随机变量 X_1, X_2, \dots 是相互独立并且具有相同的分布函数, 则称 X_1, X_2, \dots 独立同分布 (independent and identically distributed, i.i.d.)。



定理 2.4

设随机变量 X_1, \dots, X_n 相互独立, $g_1(x), \dots, g_n(x)$ 是一元实可测函数, $\phi(x_1, x_2, \dots, x_k)$ 是 k 元实可测函数, 则

1. 随机变量 $g_1(X_1), \dots, g_n(X_n)$ 相互独立;
2. 随机变量 $\phi(X_1, X_2, \dots, X_k), X_{k+1}, \dots, X_n$ 相互独立。



例 2.3 若 (X_1, X_2) 与 (X_3, X_4) 独立, 则 X_1/X_2^2 与 $\frac{X_3 + X_4}{2}$ 独立。

2.4 常见离散型随机变量

定义 2.9 (离散型随机变量 (discrete random variable))

如果随机变量 X 只取有限个值 x_1, \dots, x_m 或者可列个值 x_1, x_2, \dots , 则称 X 是离散型随机变量, 简称离散随机变量。

定义 2.10 (概率分布、概率分布列)

设 X 为离散型随机变量, 称

$$\mathbb{P}(X = x_k) = p_k, \quad k \geq 1$$

为 X 的概率分布, 称 $\{p_k\}$ 是概率分布列, 简称分布列 (Probability mass function, PMF)。

当分布列 $\{p_k\}$ 的规律性不够明显时, 概率分布常写为:

X	x_1	x_2	x_3	\dots
\mathbb{P}	p_1	p_2	p_3	\dots

分布列 $\{p_k\}$ 满足以下性质:

1. $p_k \geq 0$;
2. $\sum_{k=1}^{\infty} p_k = 1$.

两点分布、二项分布

定义 2.11 (两点分布 (Bernoulli 分布))

如果 X 只取值 0 或 1, 概率分布是 $\mathbb{P}(X = 1) = p = 1 - \mathbb{P}(X = 0)$, 则称 X 服从两点分布 (**Bernoulli 分布**), 记作 $X \sim B(1, p)$ 或 $X \sim B(p)$ 。其分布列为:

X	0	1
\mathbb{P}	$1 - p$	p

设试验 S 成功的概率为 p , 将试验 S 重复 n 次, 用 X 表示成功的次数, 求 $\mathbb{P}(X = k)$ 。

定义 2.12 (二项分布 (Binomial 分布))

如果随机变量 X 的概率分布如下:

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, \dots, n,$$

则称 X 服从二项分布, 其中 $p \in (0, 1)$, 记作 $X \sim B(n, p)$ 。

如果随机变量 X_1, \dots, X_n 相互独立, 都服从两点分布 $B(1, p)$, 则 $S = X_1 + \dots + X_n \sim B(n, p)$ 。

如果随机变量 X, Y 相互独立, 且 $X \sim B(n, p), Y \sim B(m, p)$, 则 $X + Y \sim B(m + n, p)$ 。

定理

二项分布的最大可能值 k_0 存在, 即满足

$$b(k_0, n, p) = \max_{0 \leq k \leq n} b(k, n, p)$$

的整数 k_0 存在, 且

$$k_0 = \begin{cases} (n+1)p, (n+1)p - 1, & \text{如果 } (n+1)p \text{ 为整数,} \\ \lfloor (n+1)p \rfloor, & \text{如果 } (n+1)p \text{ 不是整数.} \end{cases}$$

一般称 $b(k_0, n, p)$ 为二项分布的中心项

几何分布

甲向一个目标射击, 直到击中为止. 用 X 表示射击停止时的射击次数. 如果甲每次击中的概率是 $p \in (0, 1)$, 求 $\mathbb{P}(X = k)$.

定义 2.13 (几何分布 (Geometric 分布))

如果随机变量 X 的概率分布如下:

$$\mathbb{P}(X = k) = (1-p)^{k-1}p, \quad k = 1, 2, \dots,$$

则称 X 服从参数为 p 的几何分布. 记作 $X \sim G(p)$.

定理

取正整数值的随机变量 $X \sim G(p)$ 的充要条件是 X 有无记忆性, 即对每个 $k \geq 1$,

$$\mathbb{P}(X = k+1 | X > k) = \mathbb{P}(X = 1).$$

甲向一个目标射击, 直到击中 r 次为止. 用 X 表示射击停止时的射击次数. 如果甲每次击中的概率是 $p \in (0, 1)$, 求 $\mathbb{P}(X = k)$.

定义 2.14 (Pascal 分布)

如果随机变量 X 的概率分布如下:

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} (1-p)^{k-r} p^r, \quad k = r, r+1, \dots$$

则称 X 服从帕斯卡分布.

当 $r = 1$ 时, 帕斯卡分布就是几何分布.

负二项分布

令 $Y = X - r$ 则 Y 是射击停止时, 射击失败的次数.

定义 2.15 (负二项分布)

如果随机变量 Y 的概率分布如下:

$$\mathbb{P}(Y = k) = \binom{k+r-1}{r-1} (1-p)^k p^r, \quad k = 0, 1, \dots \quad (1)$$

则称 Y 服从负二项分布, 记作 $Y \sim NB(r, p)$.

超几何分布

在包含 N 个元素的总体中, M 个是红的, $N-M$ 个是黑的. 任意选取 n 个元素组成一组. 试求所取出的这一组中, 恰有 k 个红元素的概率。

定义 2.16 (超几何分布)

如果随机变量 X 的概率分布如下:

$$\mathbb{P}(X = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, \min\{n, M\},$$

则称 X 服从超几何分布 (Hypergeometric distribution), 记作 $X \sim H(n, M, N)$ 。



Poisson 分布

定义 2.17 (Poisson 分布)

如果随机变量 X 的概率分布如下:

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots,$$

则称 X 服从参数为 λ 的 **Poisson** 分布, 记作 $X \sim \mathcal{P}(\lambda)$, 其中 λ 是正常数。



2.5 常见连续型随机变量

定义 2.18 (连续型随机变量、概率密度)

设随机变量 X , 如果存在非负函数 $f(x)$ 使得对任意的 $a < b$,

$$\mathbb{P}(a < X \leq b) = \int_a^b f(x) dx,$$

则称 X 是连续型随机变量 (continuous r.v.), 称 $f(x)$ 是 X 的概率密度函数, 简称概率密度或者密度 (probability density function, PDF)。



定理 (概率密度函数的性质)

设 $f(x)$ 是 X 的概率密度, 则

1. $\int_{-\infty}^{\infty} f(x) dx = 1$ 。
2. 对任意的 Borel 集 A , 有 $\mathbb{P}(X \in A) = \int_A f(x) dx$ 。
3. $\mathbb{P}(X = a) = 0$ 。(推论: $\mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X \leq b)$ 。)



均匀分布

定义 2.19 (均匀分布 $U(a, b)$)

对 $a < b$, 如果 X 的概率密度是

$$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b), \\ 0, & x \notin (a, b), \end{cases}$$

称 X 服从区间 (a, b) 上的均匀分布, 记作 $X \sim U(a, b)$ 。



密度函数 $f(x)$ 还可以写成示性函数的形式:

$$f(x) = \frac{1}{b-a} I_{(a,b)}(x) \text{ 或 } f(x) = \frac{1}{b-a} I_{x \in (a,b)}$$

定义 (Borel 集上的均匀分布 $U(a,b)$)

对任意的 Borel 集 A , 如果 A 的测度 $m(A) = \int_A 1 dx < \infty$, 可以类似定义 A 上的均匀分布: 如果 X 的密度是

$$f(x) = \begin{cases} \frac{1}{m(A)}, & x \in A, \\ 0, & x \notin A, \end{cases}$$

称 X 服从 Borel 集 A 上的均匀分布, 记作 $X \sim U(A)$ 。对任意的 Borel 集 B ,

$$\mathbb{P}(B) = \frac{m(A \cap B)}{m(A)}.$$



指数分布

定义 2.20 (指数分布 $\mathcal{E}(\lambda)$)

对正常数 λ , 如果 X 的概率密度是

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

称 X 服从参数为 λ 的指数分布, 记作 $X \sim \mathcal{E}(\lambda)$ 。



密度函数 $f(x)$ 还可以写成示性函数的形式:

$$f(x) = \lambda e^{-\lambda x} I_{(0,\infty)} \text{ 或 } f(x) = \lambda e^{-\lambda x}, x \geq 0.$$

当随机变量 X 使得 $\mathbb{P}(X < 0) = 0$, 则称 X 是非负随机变量

定理 2.5 (指数分布的无记忆性)

设 X 是连续型非负随机变量, 则 X 服从指数分布的充要条件是 X 有无记忆性, 即, 对任意的 $s, t \geq 0$, 有

$$\mathbb{P}(X > s+t | X > s) = \mathbb{P}(X > t). \quad (2)$$



正态分布

定义 2.21 (正态分布 $\mathcal{N}(\mu, \sigma^2)$)

如果 X 的密度是

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}, \quad (2)$$

称 X 服从参数为 (μ, σ^2) 的正态分布 (Normal distribution), 记作 $X \sim \mathcal{N}(\mu, \sigma^2)$ 。 N 是 Normal 的首字母。特别地, 当 $X \sim \mathcal{N}(0, 1)$ 时, 称 X 服从标准正态分布。标准正态分布的密度函数:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right), \quad x \in \mathbb{R}.$$



一些其他分布

定义 2.22 (Beta 分布 $Beta(\alpha, \beta)$)

设 α, β 是正常数, 如果 X 的密度是

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$

其中 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$, 则称 X 服从参数为 (α, β) 的 **Beta** 分布, 记作 $X \sim Beta(\alpha, \beta)$ 。

**定义 2.23 (Gamma 分布 $\Gamma(\alpha, \lambda)$)**

设 α, λ 是正常数, 如果 X 的密度是

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0,$$

称 X 服从参数为 (α, λ) 的 **Gamma** 分布, 记作 $X \sim \Gamma(\alpha, \lambda)$, 其中

$$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$$

称为 **Gamma** 函数。

**性质 Gamma 函数的性质**

- (a) $\Gamma(n) = (n-1)!$;
- (b) $\Gamma(\alpha+1) = \alpha\Gamma(\alpha)$;
- (c) $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$.

α 被称为**形状参数** (shape parameter); λ 被称为**尺度参数** (rate parameter)。当 $\alpha = 1$ 时, 为指数分布。

定义 2.24 (Weibull 分布)

如果 X 的密度是

$$f(x) = \lambda \alpha x^{\alpha-1} \exp(-\lambda x^\alpha), \quad x \geq 0,$$

称 X 服从参数为 (α, λ) 的 **Weibull** 分布。



- (a) 当 $\alpha = 1$ 时, Weibull 分布为指数分布;
- (b) 当 $\alpha = 2$ 时, Weibull 分布为 **Rayleigh 分布**, 其密度为:

$$f(x; \sigma) = \frac{x}{\sigma^2} \exp\left(-\frac{x^2}{2\sigma^2}\right), \quad x \geq 0.$$

定义 2.25 (卡方分布 (Chi-squared distribution))

设 $\nu > 0$, 如果 X 的密度是

$$f(x) = \frac{1}{2^{\nu/2} \Gamma(\nu/2)} x^{\nu/2-1} e^{-x/2}, \quad x \geq 0,$$

称 X 服从参数为 ν 的 χ_ν^2 分布, 记作 $X \sim \chi_\nu^2$ 。



设有独立同分布 (i.i.d) 的变量 $Z_j \sim \mathcal{N}(0, 1), j = 1, \dots, n$ 。令 $X = Z_1^2 + \dots + Z_n^2$, 则 $X \sim \chi_n^2$ 。

可以验证 $\chi_1^2 = \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$ 。于是由 Gamma 分布的性质, 有 $\chi_n^2 = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$ 。

定义 2.26 (Student's t 分布)

设 $\nu > 0$, 如果 X 的密度是

$$f(x) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}, \quad x \in \mathbb{R},$$

称 X 服从参数为 ν 的 **Student's t 分布**, 简称 **t 分布**, 记作 $X \sim t_\nu$.

设有 $Z \sim \mathcal{N}(0, 1)$, $X \sim \chi_n^2$, 且 X 与 Z 独立. 令 $T = \frac{Z}{\sqrt{X/n}}$, 则有 $T \sim t_n$.

对称性: 若 $T \sim t_\nu$, 则 $-T \sim t_\nu$.

当 ν 很大时, t_ν 分布看起来和标准正态分布很像. 当 $\nu = 1$ 时, 性质特殊, 亦称为 **Cauchy 分布**.

定义 2.27 (Cauchy 分布)

如果 X 的密度是

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R},$$

称 X 服从 **Cauchy 分布**. 亦可记作 $X \sim t_1$.

设有独立同分布 (i.i.d) 的变量 $Z_j \sim t_1, j = 1, \dots, n$. 令 $X = \frac{Z_1 + \dots + Z_n}{n}$, 则依然有 $X \sim t_1$.

定义 2.28 (F 分布 (Fisher Snedecor distribution))

设 m, n 是正整数, 如果 X 的密度是

$$f(x) = \frac{\Gamma\left(\frac{m+n}{2}\right) m^{m/2} n^{n/2} x^{\frac{m}{2}-1}}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right) (mx+n)^{\frac{m+n}{2}}}, \quad x \geq 0,$$

称 X 服从参数为 (m, n) 的 **F 分布**, 记作 $X \sim F(m, n)$.

设有独立同分布 (i.i.d) 的变量 $X_j \sim \mathcal{N}(0, 1), j = 1, \dots, m$ 和 $Y_j \sim \mathcal{N}(0, 1), j = 1, \dots, n$. 令 $F = \frac{\sum_i X_i^2/m}{\sum_j Y_j^2/n}$, 则 $F \sim F(m, n)$.

定义 2.29 (分布函数 (distribution function))

对随机变量 (random variable, r.v.) X , 称 x 的函数

$$F(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R}$$

为 X 的概率分布函数或累积分布函数 (cumulative distribution function, CDF), 简称为分布函数.

令 $H(x)$ 是 Heaviside 函数: $H(x) = I_{[0, \infty)}(x)$. 则离散型随机变量的分布函数可以表示为

$$F(x) = \sum_{k=1}^{\infty} p_k H(x - x_k). \quad (1)$$

如果分布函数 $F(x)$ 可以表示为 (1) 这种形式, 称 $F(x)$ 是**离散的**.

如果 X 是连续型随机变量, 有概率密度 $f(x)$, 则

$$F(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f(t) dt, \quad x \in \mathbb{R}$$

是连续函数, 并且在 $f(x)$ 的连续点 x 有 $f(x) = F'(x)$. 称 $F(x)$ 是 $f(x)$ 的分布函数.

定理 2.6 (分布函数 $F(x)$ 的性质)

1. $F(x)$ 单调非降;
2. $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$.
3. $F(x)$ 是右连续的.

**定理 2.7**

如果对 $\forall x \in \mathbb{R}$ 都有 $\mathbb{P}(X = x) = 0$, 则 $F(x) = \mathbb{P}(X \leq x)$ 是连续的。

**定理 2.8**

设 X 的分布函数 $F(x)$ 连续, 数集 A 中任何两点之间的距离大于某个正数 δ 。如果在 A^c 上, 导数 $F'(x)$ 存在且连续, 则

$$f(x) = \begin{cases} F'(x), & \text{当 } x \notin A, \\ 0, & \text{当 } x \in A. \end{cases}$$

是 X 的密度函数。



注 在该定理中, F 连续的条件是至关重要的。尽管 F 连续不能保证 X 是连续型随机变量, 但是 F 不连续能保证 X 不是连续型随机变量。当 F 是二项分布的随机变量的分布函数时, 除去有限个点外, $F'(x) = 0$, 所以 X 的密度不存在。

2.6 随机变量函数的分布

一般地, 有如下定理:

定理 2.9 (随机变量函数的分布)

设 X 的概率密度为 $f(x)$, $D \subset \mathbb{R}, Y = g(X), \mathbb{P}(Y \in D) = 1$, 如果

1. 对 $y \in D, \{Y = y\} = \bigcup_{i=1}^n \{X = h_i(y)\}$;
2. 每个 $h_i(y)$ 是 D 到其值域 D_i 的可逆映射, 在 D 内有连续的导数;
3. D_1, D_2, \dots, D_n 互不相交,

则 Y 的密度函数为

$$f_Y(y) = \begin{cases} \sum_{i=1}^n f(h_i(y)) |h'_i(y)|, & y \in D \\ 0, & y \in D^c \end{cases}.$$



例 2.4 设 r 是正常数, $X \sim U(0, 2\pi)$, 求 $Y = r \cos X$ 的概率密度。

解 方法一:

设 $D = (-r, r)$, 则 $\mathbb{P}(Y \in D) = 1$ 。对于 $y \in D$, 有

$$\begin{aligned}\{Y = y\} &= \{\cos X = y/r\} \\ &= \{\cos X = y/r, X \in (0, \pi)\} \cup \{\cos X = y/r, X \in (\pi, 2\pi)\} \\ &= \{X = \arccos(y/r)\} \cup \{X = 2\pi - \arccos(y/r)\}\end{aligned}$$

令 $h_1(y) = \arccos(y/r) : D \rightarrow (0, \pi)$ 和 $h_2(y) = 2\pi - \arccos(y/r) : D \rightarrow (\pi, 2\pi)$ 都是可逆的、连续可微的函数。

利用 $f_X(x) = 1/(2\pi), x \in (0, 2\pi)$, 可得 Y 的密度函数

$$\begin{aligned}f_Y(y) &= \frac{1}{2\pi} \left| \frac{d}{dy} \left[\arccos\left(\frac{y}{r}\right) \right] \right| + \frac{1}{2\pi} \left| \frac{d}{dy} \left[2\pi - \arccos\left(\frac{y}{r}\right) \right] \right| \\ &= \frac{1}{2\pi} \left| -\frac{1}{\sqrt{r^2 - y^2}} \right| + \frac{1}{2\pi} \left| \frac{1}{\sqrt{r^2 - y^2}} \right| \\ &= \frac{1}{\pi \sqrt{r^2 - y^2}}, \quad y \in (-r, r).\end{aligned}$$

方法二:

对 $y \in (-r, r)$, 先求分布函数 $F_Y(y) = \mathbb{P}(Y \leq y)$ 。

$$\begin{aligned}\mathbb{P}(Y \leq y) &= \mathbb{P}(\cos X \leq y/r) \\ &= \int_{\{x: \cos x \leq y/r\}} \frac{1}{2\pi} dx \\ &= \frac{1}{2\pi} \{2\pi - 2 \arccos(y/r)\} \quad (\text{在 } (0, 2\pi) \text{ 区间}) \\ &= 1 - \frac{1}{\pi} \arccos(y/r)\end{aligned}$$

根据 $[\arccos(x)]' = -\frac{1}{\sqrt{1-x^2}}$, 对分布函数求导可得密度函数 $f_Y(y)$:

$$\begin{aligned}f_Y(y) &= F'_Y(y) = \frac{d}{dy} \left(1 - \frac{1}{\pi} \arccos\left(\frac{y}{r}\right) \right) \\ &= -\frac{1}{\pi} \left(-\frac{1}{\sqrt{1-(y/r)^2}} \right) \cdot \frac{1}{r} \\ &= \frac{1}{\pi \sqrt{r^2 - y^2}}, \quad y \in (-r, r).\end{aligned}$$

第3节 随机向量和概率分布

定义 3.1 (n 维随机向量)

如果 X_1, \dots, X_n 都是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量, 称 $\mathbf{X} = (X_1, \dots, X_n)$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的 n 维随机向量, 简称随机向量。

定义 3.2 (联合概率分布函数)

设 $\mathbf{X} = (X_1, \dots, X_n)$ 是随机向量, 称 \mathbb{R}^n 上的 n 元函数

$$F(x_1, x_2, \dots, x_n) = \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

为 $\mathbf{X} = (X_1, \dots, X_n)$ 的联合概率分布函数, 简称分布函数或者联合分布。

联合分布函数 $F(x_1, x_2, \dots, x_n)$ 是 \mathbb{R}^n 上的右连续函数, 关于每个自变量 x_j 单调非降。

$F(\mathbf{x}) = \mathbb{P}(\mathbf{X} \leq \mathbf{x})$, 其中 $\mathbf{X} \leq \mathbf{x} \Leftrightarrow X_j \leq x_j, j = 1, \dots, n$ 。

3.1 离散型随机向量

定义 3.3 (离散型随机向量)

如果 X_1, X_2, \dots, X_n 都是离散型随机变量, 则称 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 为离散型随机向量。如果 \mathbf{X} 所有的不同取值是

$$\mathbf{x}(j_1, j_2, \dots, j_n) = (x_1(j_1), x_2(j_2), \dots, x_n(j_n)), \quad j_1, j_2, \dots, j_n \geq 1$$

则称

$$p_{j_1, j_2, \dots, j_n} = \mathbb{P}(\mathbf{X} = \mathbf{x}(j_1, j_2, \dots, j_n)), \quad j_1, j_2, \dots, j_n \geq 1$$

是 \mathbf{X} 的联合分布列。

概率分布的性质

1. $p_{j_1, j_2, \dots, j_n} \geq 0$;
2. $\sum_{j_1, j_2, \dots, j_n} p_{j_1, j_2, \dots, j_n} = 1$.

定义 3.4 (边缘分布列)

设离散型随机向量 \mathbf{X} 的联合分布列为 p_{j_1, j_2, \dots, j_n} , 则称

$$\begin{aligned} & \mathbb{P}(X_1 = x_1(j_1), X_2 = x_2(j_2), \dots, X_k = x_k(j_k)) \\ &= \sum_{j_{k+1}, j_{k+2}, \dots, j_n} p_{j_1, j_2, \dots, j_n}, \quad j_1, j_2, \dots, j_k \geq 1 \end{aligned}$$

为 \mathbf{X} 的边缘分布列。

例 3.1 设 $F(x, y)$ 是 (X, Y) 的联合分布, 则对矩形 $D = \{a < x \leq b, c < y \leq d\}$, 有

$$\begin{aligned}\mathbb{P}((X, Y) \in D) &= \mathbb{P}(a < X \leq b, c < Y \leq d) \\ &= F(b, d) - F(b, c) - F(a, d) + F(a, c)\end{aligned}$$

因此

$$F(b, d) - F(b, c) - F(a, d) + F(a, c) \geq 0, \quad a < b, c < d.$$

进一步, X, Y 分别有概率分布

$$\begin{aligned}F_X(x) &= \mathbb{P}(X \leq x, Y \leq \infty) = F(x, \infty) \\ F_Y(y) &= \mathbb{P}(X \leq \infty, Y \leq y) = F(\infty, y)\end{aligned}$$

更一般地, 我们定义

定义 3.5 (边缘分布、边际分布 (marginal distribution))

对 $1 \leq k < n, S_k = \{i_1, i_2, \dots, i_k\}$ 为指标集, 称 $\mathbf{X}_{S_k} := (X_{i_1}, X_{i_2}, \dots, X_{i_k})$ 的联合分布

$$\begin{aligned}F_k(x_{i_1}, x_{i_2}, \dots, x_{i_k}) \\ &= \mathbb{P}(X_{i_1} \leq x_{i_1}, X_{i_2} \leq x_{i_2}, \dots, X_{i_k} \leq x_{i_k}) \\ &= \mathbb{P}(X_j \leq x_j, j \in S_k, X_t \leq \infty, t \in S_k^c)\end{aligned}$$

为 $F(x_1, x_2, \dots, x_n)$ 的 \mathbf{k} -维边缘分布。



$F(x_1, x_2, \dots, x_n)$ 一共有 $(2^n - 2)$ 个边缘分布。

离散型随机变量的独立性

定义 3.6 (复习: 随机变量的相互独立性)

设 X_1, \dots, X_n 是 (Ω, \mathcal{F}) 上的随机变量, 如果对任意的实数 x_1, \dots, x_n 都有

$$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \mathbb{P}(X_1 \leq x_1) \cdots \mathbb{P}(X_n \leq x_n),$$

称随机变量 X_1, \dots, X_n 相互独立。



等价表达: 设 (X_1, X_2, \dots, X_n) 有联合分布 $F(x_1, x_2, \dots, x_n)$, X_i 有边缘分布 $F_i(x_i)$ 。则 X_1, \dots, X_n 相互独立当且仅当

$$F(x_1, x_2, \dots, x_n) = F_1(x_1)F_2(x_2) \cdots F_n(x_n).$$

定理 3.1 (离散型随机向量的相互独立性)

设离散型随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 有概率分布

$$p_{j_1, j_2, \dots, j_n} = \mathbb{P}(\mathbf{X} = \mathbf{x}(j_1, j_2, \dots, j_n)), \quad j_1, j_2, \dots, j_n \geq 1$$

则 X_1, \dots, X_n 相互独立的充分必要条件是: 对任意的 $(x_1(j_1), x_2(j_2), \dots, x_n(j_n))$, 有

$$\mathbb{P}(X_1 = x_1(j_1), \dots, X_n = x_n(j_n)) = \prod_{i=1}^n \mathbb{P}(X_i = x_i(j_i)).$$



推论 3.1

设离散型随机向量 (X, Y) 的所有不同取值是 $(x_i, y_j), i, j \geq 1$ 。则 X, Y 相互独立的充分必要条件是: 对任意的 (x_i, y_j) , 有

$$\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j).$$



3.2 连续型随机向量

定义 3.7 (连续型随机向量)

设 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 是随机向量。如果存在 \mathbb{R}^n 上的非负可积函数 $f(x_1, \dots, x_n)$ (or $f(\mathbf{x})$), 使得对 \mathbb{R}^n 的任何子立方体 $D = \{(x_1, x_2, \dots, x_n) | a_i \leq x_i \leq b_i, 1 \leq i \leq n\}$ 有

$$\mathbb{P}(\mathbf{X} \in D) = \int_D f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n := \int_D f(\mathbf{x}) d\mathbf{x}$$

就称 \mathbf{X} 是连续型随机向量, 并称 $f(x_1, x_2, \dots, x_n)$ (or $f(\mathbf{x})$) 是 \mathbf{X} 的联合概率密度函数, 简称为联合密度或概率密度。



定理 3.2

对任意 n 维 Borel 集 B 有:

$$\mathbb{P}(\mathbf{X} \in B) = \int_B f(\mathbf{x}) d\mathbf{x}$$



- 随机向量 \mathbf{X} 的联合概率密度不必唯一。
- 由于 \mathbb{R}^n 是 Borel 集, 有

$$\int_{\mathbb{R}^n} f(\mathbf{x}) d\mathbf{x} = \mathbb{P}(\mathbf{X} \in \mathbb{R}^n) = 1$$

定义 3.8 (边缘密度、边际密度)

被积函数

$$f_k(x_1, \dots, x_k) = \int_{\mathbb{R}^{n-k}} f(x_1, \dots, x_n) dx_{k+1} \dots dx_n$$

是 (X_1, \dots, X_k) 的联合密度, 被称为 \mathbf{X} 的边缘概率密度函数, 简称为边缘密度。



例 3.2 设 $f(\mathbf{x})$ 是 \mathbf{X} 的概率密度。 $(X_{j_1}, X_{j_2}, \dots, X_{j_k})$ 的边缘密度为:

$$g_k(x_{j_1}, x_{j_2}, \dots, x_{j_k}) = \int_{\mathbb{R}^{n-k}} f(x_1, \dots, x_n) dx_{j_{k+1}} \dots dx_{j_n}$$

例 3.3 设 (X, Y) 在单位圆 $D = \{(x, y) | x^2 + y^2 \leq 1\}$ 内均匀分布, 求 X, Y 的概率密度。

解 (X, Y) 的联合密度为 $f(x, y) = \frac{1}{\pi} I_D$, 其中 I_D 是单位圆 D 的示性函数。 X 只在 $[-1, 1]$ 中取值, 则

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} f(x, y) dy = \frac{1}{\pi} \int_{-\infty}^{\infty} I_{x^2+y^2 \leq 1} dy \\ &= \frac{1}{\pi} \int_{-\infty}^{\infty} I_{|y| \leq \sqrt{1-x^2}} dy = \frac{2}{\pi} \sqrt{1-x^2}, \quad |x| \leq 1. \end{aligned}$$

同理可得 Y 的密度:

$$f_Y(y) = \frac{2}{\pi} \sqrt{1-y^2}, \quad |y| \leq 1.$$

连续型随机向量的独立性

定理 3.3 (连续型随机向量的独立性)

设对每个 $i (1 \leq i \leq n)$, 随机变量 X_i 有概率密度 $f_i(x_i)$, 则 X_1, X_2, \dots, X_n 相互独立的充分必要条件是随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 有联合密度

$$f_1(x_1) f_2(x_2) \dots f_n(x_n), \quad (x_1, x_2, \dots, x_n) \in \mathbb{R}^n.$$



经典连续型随机向量

定义 3.9 (二元正态分布)

设 μ_1, μ_2 是常数, σ_1, σ_2 是正常数, $\rho \in (-1, 1)$ 中的常数。如果随机向量 (X, Y) 有概率密度

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}$$

则称 (X, Y) 服从二元正态分布, 记作 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。



对比一元正态分布:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}$$

简写形式:

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^2|\Sigma|}} \exp \left\{ -\frac{1}{2}(\mathbf{x}-\mu)'\Sigma^{-1}(\mathbf{x}-\mu) \right\}$$

其中 $\mathbf{x} = (x, y)'$, $\mu = (\mu_1, \mu_2)'$, $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$, $|\Sigma|$ 是 Σ 的行列式。

定理

设 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。则 X, Y 独立的充分必要条件是 $\rho = 0$ 。



联合分布与联合密度

设 $f(x, y)$ 是 (X, Y) 的联合密度, 则有

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv.$$

当 $f(x, y)$ 连续时, 两者有关系

$$f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}.$$

定理

设 (X, Y) 有连续的分布函数 $F(x, y)$, 定义

$$f(x, y) = \begin{cases} \frac{\partial^2 F(x, y)}{\partial x \partial y}, & \text{当该混合偏导数存在} \\ 0, & \text{其它.} \end{cases}$$

如果

$$\int_{\mathbb{R}^2} f(x, y) dx dy = 1$$

则 $f(x, y)$ 是 (X, Y) 的联合密度。



3.3 条件分布和条件密度

3.3.1 离散型条件分布

设 (X, Y) 是离散型随机向量, 有概率分布 (joint PMF)

$$p_{ij} = \mathbb{P}(X = x_i, Y = y_j) > 0, \quad i, j = 1, 2, \dots,$$

则 X, Y 分别有边缘分布 (marginal PMF)

$$p_i = \mathbb{P}(X = x_i), \quad q_j = \mathbb{P}(Y = y_j), \quad i, j = 1, 2, \dots,$$

定义 3.10 (条件概率分布)

对每个固定的 j , 称

$$\mathbb{P}(X = x_i | Y = y_j) = \frac{\mathbb{P}(X = x_i, Y = y_j)}{\mathbb{P}(Y = y_j)} = \frac{p_{ij}}{q_j}, \quad i = 1, 2, \dots,$$

为给定条件 $Y = y_j$ 下, X 的条件分布列 (conditional PMF)。



定理 3.4

X, Y 独立的充分必要条件是对任何 $i, j \geq 1$,

$$\mathbb{P}(X = x_i | Y = y_j) = \mathbb{P}(X = x_i).$$



- 等价于, $\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i)\mathbb{P}(Y = y_j), \quad i, j \geq 1$ 。

3.3.2 连续型条件分布

定义 3.11 (连续型条件分布与条件密度)

设随机向量 (X, Y) 有联合密度 $f(x, y)$, Y 有边缘密度 $f_Y(y)$ 。

若在 y (确定的 y) 处 $f_Y(y) > 0$, 则称

$$\mathbb{P}(X \leq x | Y = y) = \frac{\int_{-\infty}^x f(s, y) ds}{f_Y(y)}, \quad x \in \mathbb{R}$$

为给定条件 $Y = y$ 下, X 的条件分布函数, 简称条件分布, 记作 $F_{X|Y}(x|y)$ 。

称

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{f(x, y)}{\int_{-\infty}^{\infty} f(x, y) dx}, \quad x \in \mathbb{R}$$

为给定条件 $Y = y$ 下, X 的条件概率密度, 简称条件密度。



由条件密度定义可得:

$$f(x, y) = f_Y(y)f_{X|Y}(x|y).$$

定理 3.5 (条件密度与条件分布的关系)

对使得 $f_Y(y) > 0$ 的 y ,

1. $F_{X|Y}(x|y) = \mathbb{P}(X \leq x | Y = y) = \int_{-\infty}^x f_{X|Y}(s|y) ds, \quad x \in \mathbb{R};$
2. 如果 $F_{X|Y}(x|y)$ 关于 x 连续, 且除去至多可列个点外有连续的导数, 则

$$f_{X|Y}(x|y) = \begin{cases} \frac{\partial F_{X|Y}(x|y)}{\partial x}, & \text{当偏导数存在} \\ 0, & \text{其它} \end{cases}$$

是给定条件 $Y = y$ 下, X 的条件密度。



定理 3.6

X, Y 独立的充分必要条件是对 $y \in \{y | f_Y(y) > 0\}$,

$$f_{X|Y}(x|y) = f_X(x), \quad x \in \mathbb{R}.$$

- 等价于, $f(x, y) = f_X(x)f_Y(y)$, $x, y \in \mathbb{R}$.



例 3.4 设计计算机使用的环境指标 $Y \sim \Gamma(\alpha, \beta)$, 概率密度是

$$f_Y(y) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}, \quad y > 0.$$

已知 $Y = y$ 时, 软件的使用寿命 $X|Y = y \sim \mathcal{E}(y)$. 求 X 的分布。

解 X 的条件密度 $f_{X|Y}(x|y) = ye^{-xy}, x > 0$. 于是 (X, Y) 的联合密度为

$$f(x, y) = f_{X|Y}(x|y)f_Y(y) = ye^{-xy} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}, \quad x, y > 0.$$

最后对 $x > 0$, 有

$$\begin{aligned} f_X(x) &= \int_0^\infty f(x, y) dy = \int_0^\infty \frac{\beta^\alpha}{\Gamma(\alpha)} y^\alpha e^{-y(x+\beta)} dy \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{(x+\beta)^{\alpha+1}} \int_0^\infty t^\alpha e^{-t} dt \quad (\text{令 } t = y(x+\beta)) \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+1)}{(x+\beta)^{\alpha+1}} = \frac{\alpha\beta^\alpha}{(x+\beta)^{\alpha+1}} \quad (\text{利用 } \Gamma(\alpha+1) = \alpha\Gamma(\alpha)). \end{aligned}$$

于是 X 有概率密度

$$f_X(x) = \frac{\alpha\beta^\alpha}{(x+\beta)^{\alpha+1}}, \quad x > 0.$$

定义 (条件分布和条件密度的一般定义)

设 $\mathbf{X} = (X_1, \dots, X_n)$ 和 $\mathbf{Y} = (Y_1, \dots, Y_m)$ 是随机向量, $f(\mathbf{x}, \mathbf{y})$ 是 (\mathbf{X}, \mathbf{Y}) 的联合密度, 此时 \mathbf{Y} 有边缘密度

$$f_Y(\mathbf{y}) = \int_{\mathbb{R}^n} f(\mathbf{x}, \mathbf{y}) d\mathbf{x}.$$

若在 \mathbf{y} (确定的 \mathbf{y}) 处 $f_Y(\mathbf{y}) > 0$, 则称

$$\mathbb{P}(\mathbf{X} \leq \mathbf{x} | \mathbf{Y} = \mathbf{y}) = \frac{\int_{\mathbf{s} \leq \mathbf{x}} f(\mathbf{s}, \mathbf{y}) d\mathbf{s}}{f_Y(\mathbf{y})}$$

为给定条件 $\mathbf{Y} = \mathbf{y}$ 下, \mathbf{X} 的条件分布函数, 简称条件分布, 记作 $F_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}|\mathbf{y})$ 。

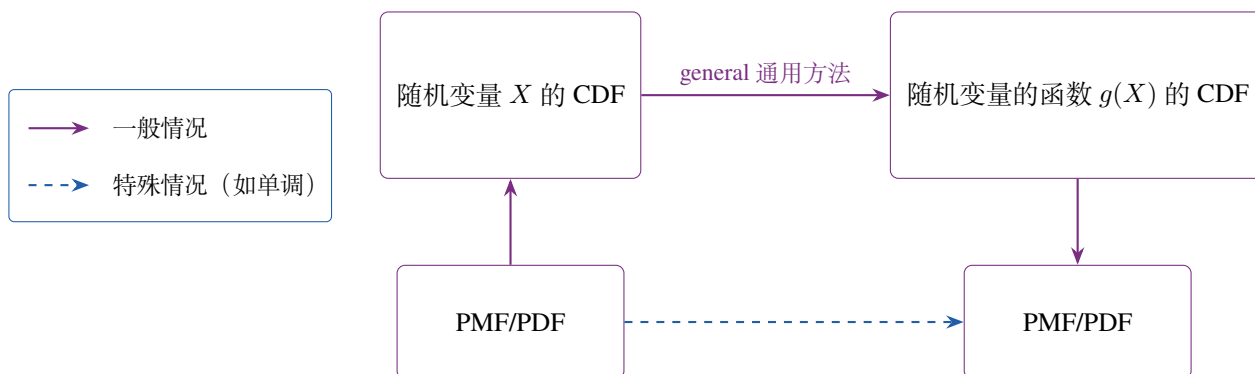
称

$$f_{\mathbf{X}|\mathbf{Y}}(\mathbf{x}|\mathbf{y}) = \frac{f(\mathbf{x}, \mathbf{y})}{f_Y(\mathbf{y})}$$

为给定条件 $\mathbf{Y} = \mathbf{y}$ 下, \mathbf{X} 的条件概率密度, 简称条件密度。



3.4 概率向量函数的分布



一般情形

直接求分布，再根据要求 PDF 或 PMF

例 3.5 设 X, Y 独立且都服从 $\mathcal{N}(0, 1)$. 求 $Z = \sqrt{X^2 + Y^2}$ 的分布。

解 (X, Y) 有联合密度

$$f(x, y) = \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right).$$

对 $z \geq 0$, 有

$$\begin{aligned} F_Z(z) &= \mathbb{P}\left(\sqrt{X^2 + Y^2} \leq z\right) \\ &= \iint_{\{\sqrt{x^2 + y^2} \leq z\}} \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right) dx dy \\ &\xrightarrow{x=r \cos \theta, y=r \sin \theta} \frac{1}{2\pi} \int_0^{2\pi} d\theta \int_0^z r e^{-r^2/2} dr \\ &= \int_0^z r e^{-r^2/2} dr. \end{aligned}$$

求导可得 Z 的密度函数

$$f_Z(z) = z e^{-z^2/2}, \quad z \geq 0.$$

此分布称为 **Rayleigh** 分布。

向坐标 $(0,0)$ 射击时, 弹落点 (X, Y) 服从二元正态分布. $R = Z = \sqrt{X^2 + Y^2}$ 为弹落点到目标的距离, 被称为脱靶量。

特殊情形

(i) $Z = X + Y$

例 3.6 设 (X, Y) 有联合分布列, 求 $Z = X + Y$ 的分布列。

解

$$P_Z(z) = \mathbb{P}(X + Y = z) = \sum_x \mathbb{P}(X = x, Y = z - x).$$

特别地, 当 X, Y 独立时, $Z = X + Y$ 有分布列

$$P_Z(z) = \sum_x \mathbb{P}(X = x) \mathbb{P}(Y = z - x) = \sum_x P_X(x) P_Y(z - x).$$

此时 Z 的分布列为 X 和 Y 的分布列的卷积。

例 3.7 设 (X, Y) 有联合密度 $f(x, y)$, 则 $Z = X + Y$ 有密度函数

$$f_Z(z) = \int_{-\infty}^{\infty} f(x, z-x) dx.$$

特别地, 当 X, Y 独立时, $Z = X + Y$ 有密度函数

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx.$$

(ii) $V = X - Y$ (类似 (i))

例 3.8 设 (X, Y) 有联合密度 $f(x, y)$, 则 $V = X - Y$ 有密度函数

$$f_V(v) = \int_{-\infty}^{\infty} f(x, x-v) dx.$$

特别地, 当 X, Y 独立时, $V = X - Y$ 有密度函数

$$f_V(v) = \int_{-\infty}^{\infty} f_X(x) f_Y(x-v) dx.$$

3.4.1 多个函数的联合密度

定理 3.7

设 (X, Y) 有联合密度 $f(x, y)$, $U = u(X, Y), V = v(X, Y)$ 是 (X, Y) 的函数, D 是平面上的区域使得 $\mathbb{P}((U, V) \in D) = 1$. 如果存在 D 上的函数 $x_i = x_i(u, v), y_i = y_i(u, v), i = 1, 2, \dots, n$, 使得

1. 对 $(u, v) \in D$, 有 $\{U = u, V = v\} = \bigcup_{i=1}^n \{X = x_i, Y = y_i\}$;
2. $\Delta_i: x_i = x_i(u, v), y_i = y_i(u, v)$ 是 D 到其值域 D_i 的可逆映射, 有连续的偏导数, 并且雅克比 (Jacobian) 行列式的绝对值 $\left| \frac{\partial(x_i, y_i)}{\partial(u, v)} \right| \neq 0, (u, v) \in D, i = 1, \dots, n$.
3. D_1, \dots, D_n 互不相交.

则 (U, V) 有联合密度

$$g(u, v) = \begin{cases} \sum_{i=1}^n f(x_i(u, v), y_i(u, v)) \left| \frac{\partial(x_i, y_i)}{\partial(u, v)} \right|, & (u, v) \in D, \\ 0, & (u, v) \in D^c \end{cases}$$



例 3.9 设 X, Y 独立, $X \sim \mathcal{N}(0, 1)$, (R, Θ) 由极坐标变换

$$\begin{cases} X = R \cos \Theta \\ Y = R \sin \Theta \end{cases}$$

决定, 求 (R, Θ) 的联合密度.

解 (X, Y) 有联合密度

$$f(x, y) = \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right)$$

定义

$$D = \{(r, \theta) | r > 0, \theta \in [0, 2\pi)\}$$

则 $\mathbb{P}((R, \Theta) \in D) = 1$

$$\Delta = \begin{cases} x = r \cos \theta \\ y = r \sin \theta \end{cases}$$

建立了 D 到 $D_1 = \{(x, y) | (x, y) \neq 0\}$ 的可逆变换. 对 $(r, \theta) \in D$, 利用

$$\{R = r, \Theta = \theta\} = \{X = x, Y = y\}, \quad \left| \frac{\partial(x, y)}{\partial(r, \theta)} \right| = r > 0,$$

得 (R, Θ) 的联合密度

$$g(r, \theta) = f(r \cos \theta, r \sin \theta) \cdot r = \frac{1}{2\pi} \cdot r \cdot \exp\left(-\frac{r^2}{2}\right), \quad (r, \theta) \in D.$$

从中可以看出 R 和 Θ 独立, 分别有概率密度

$$g_R(r) = r \exp\left(-\frac{r^2}{2}\right), \quad r \geq 0; \quad g_\Theta(\theta) = \frac{1}{2\pi} I_{[0, 2\pi)}.$$

即 R 是 Rayleigh 分布, $\Theta \sim \mathcal{U}[0, 2\pi)$.

定理 3.8

设 n 维随机向量 \mathbf{X} 和 \mathbf{Y} 有相同的分布, $g: R^n \rightarrow R^m$ 是可测的, 则 $g(\mathbf{X})$ 与 $g(\mathbf{Y})$ 有相同的分布.



例 3.10 设 U, V 独立, $U \sim \mathcal{U}(0, 1)$, 定义

$$\begin{cases} X = \sqrt{-2 \log U} \cos(2\pi V) \\ Y = \sqrt{-2 \log U} \sin(2\pi V) \end{cases}$$

则 X, Y 独立, 且服从 $\mathcal{N}(0, 1)$. **【用来产生正态随机变量】**

证明 $R = \sqrt{-2 \log U} \sim \text{Rayleigh 分布}$, $\Theta = 2\pi V \sim \mathcal{U}[0, 2\pi)$. 且 R 与 Θ 独立.

由定理 1.2 易得结论成立.

3.5 次序统计量

定义 3.12

设 X_1, X_2, \dots, X_n 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量, 对 $\omega \in \Omega$, 将 $X_1(\omega), X_2(\omega), \dots, X_n(\omega)$ 从小到大排列得到

$$X_{(1)}(\omega) \leq X_{(2)}(\omega) \leq \dots \leq X_{(n)}(\omega)$$

称 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 为 X_1, X_2, \dots, X_n 的次序统计量 (order statistics).



次序统计量的分布密度

以下设随机变量 X_1, X_2, \dots, X_n 独立同分布, 有公共的分布函数 $F(x)$ 和密度函数 $f(x)$.

性质 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 有联合密度

$$g(x_1, \dots, x_n) = \begin{cases} n! \prod_{i=1}^n f(x_i), & \text{if } x_1 < \dots < x_n \\ 0, & \text{others} \end{cases}$$

性质 $X_{(k)}$ 有密度

$$g_k(x_k) = n \binom{n-1}{k-1} [F(x_k)]^{k-1} [1 - F(x_k)]^{n-k} f(x_k)$$

性质 对于 $-\infty \leq a < x_1 < x_2 < \dots < x_k < b \leq \infty$, 有

$$\int_{a < x_1 < \dots < x_k < b} f(x_1) \cdots f(x_k) dx_1 \cdots dx_k = \frac{(F(b) - F(a))^k}{k!}$$

性质 对 $k_1 < k_2$, $(X_{(k_1)}, X_{(k_2)})$ 有联合密度

$$g(x_{k_1}, x_{k_2}) = \begin{cases} \frac{n!}{(k_1-1)!(k_2-k_1-1)!(n-k_2)!} [F(x_{k_1})]^{k_1-1} [F(x_{k_2}) - F(x_{k_1})]^{k_2-k_1-1} \\ \quad \times [1 - F(x_{k_2})]^{n-k_2} f(x_{k_1})f(x_{k_2}), & x_{k_1} < x_{k_2} \\ 0, & \text{others} \end{cases}$$

例 3.11 某教学楼原来每个教室有 4 只灯泡用于室内照明, 新装修后每个教室有 24 只灯泡用于室内照明。装修后教室管理员总认为灯泡更容易坏了, 试解释其中的原因。

解 设所有灯泡的使用寿命相互独立, 且服从 $\mathcal{E}(\lambda)$. 用 X_i 表示第 i 只灯泡的使用寿命。

装修前等待第一只灯泡烧坏的时间长度为

$$X = \min\{X_1, X_2, X_3, X_4\} = X_{(1)} \sim \mathcal{E}(4\lambda),$$

装修后等待第一只灯泡烧坏的时间长度为

$$Y = \min\{X_1, X_2, \dots, X_{24}\} = X_{(1)} \sim \mathcal{E}(24\lambda).$$

利用性质 2.2 的结论分别得到 X 和 Y 的密度函数

$$f_X(t) = 4\lambda e^{-4\lambda t}, \quad f_Y(t) = 24\lambda e^{-24\lambda t}, \quad t > 0.$$

因此 $\mathbb{P}(X > t) = e^{-4\lambda t}$, $\mathbb{P}(Y > t) = e^{-24\lambda t}$ 。

当 $\lambda = 1/6000$ (小时) 时, 有

$$\begin{aligned} \mathbb{P}(X > 400) &= e^{-4 \cdot \frac{1}{6000} \cdot 400} \approx 0.7659, & \mathbb{P}(X > 200) &= e^{-4 \cdot \frac{1}{6000} \cdot 200} \approx 0.8752, \\ \mathbb{P}(Y > 400) &= e^{-24 \cdot \frac{1}{6000} \cdot 400} \approx 0.2019, & \mathbb{P}(Y > 200) &= e^{-24 \cdot \frac{1}{6000} \cdot 200} \approx 0.4493. \end{aligned}$$

从中可以看到, Y 要比 X 随机地小得多, 因此“更容易坏”的直观感受是合理的。

常见分布补充: Beta 分布

定义 3.13 (Beta 分布 $\text{Beta}(\alpha, \beta)$)

设 $\alpha, \beta > 0$. 若随机变量 X 的概率密度为

$$f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1,$$

其中

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)},$$

则称 X 服从参数为 (α, β) 的 Beta 分布, 记作 $X \sim \text{Beta}(\alpha, \beta)$.



性质 与二项分布的共轭性

在贝叶斯统计方法中, 常将二项分布的成功概率 $p \in (0, 1)$ 的先验分布取为 $\text{Beta}(\alpha, \beta)$. 若给定 p 条件下

$$X | p \sim \text{Binomial}(n, p),$$

则观测到 X 之后, 参数的后验分布为

$$p | X \sim \text{Beta}(\alpha + X, \beta + n - X).$$

Beta 分布可看作是均匀分布 $\mathcal{U}(0, 1)$ 的次序统计量.

3.6 随机变量的 p 分位数

设 X 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上的随机变量, $F(x)$ 是其分布函数。

定义 3.14 (随机变量的 p 分位数)

对 $p \in (0, 1)$, 定义

$$F^{-1}(p) := \inf\{x \in \mathbb{R} \mid F(x) \geq p\}.$$

称 $F^{-1}(p)$ 为 F 的 (或 X 的) p -分位数, 通常记为 ξ_p ; 特别地, $\xi_{1/2}$ 为 F 或 X 的中位数。



p-分位数的性质

性质 对所有 $p \in (0, 1)$ 、 $t \in \mathbb{R}$, 有

1. $F^{-1}(p)$ 关于 p 单调非降;
2. $F^{-1}(F(x)) \leq x, \forall x \in \mathbb{R}$;
3. $F(F^{-1}(p)) \geq p$;
4. $F^{-1}(p) \leq t \iff p \leq F(t)$;
5. $F^{-1}(p)$ 关于 p 左连续;
6. 若 F 连续, 则 $F(F^{-1}(p)) = p$ 。

定理 3.9 (产生服从分布函数 $F(x)$ 的随机变量)

设 $X \sim \mathcal{U}(0, 1)$, $F(x)$ 是连续分布函数。令 $Y = F^{-1}(X)$, 则 $Y \sim F$ (即 Y 的分布函数为 F)。



例 3.12 设易生成服从均匀分布的随机变量, 如何生成服从下列分布函数的随机变量:

1. $\mathcal{E}(\lambda)$; 2. Cauchy 分布; 3. $\mathcal{N}(0, 1)$; 4. $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{x_i \leq x\}$, 其中 x_1, \dots, x_n 为给定观测值。

解 设 $U, V \sim \mathcal{U}(0, 1)$ 且相互独立。

1. 指数分布: 取

$$X = -\lambda^{-1} \log(1 - U).$$

则 $X \sim \mathcal{E}(\lambda)$ 。

2. Cauchy 分布: 令

$$Z = \frac{X}{Y}, \quad \text{其中 } X, Y \text{ 独立且 } X, Y \sim \mathcal{N}(0, 1),$$

则 Z 服从标准 Cauchy 分布。

3. 正态分布 (Box-Muller 变换): 令

$$\theta = 2\pi U, \quad R = \sqrt{-2 \log V}.$$

则

$$X = R \cos \theta, \quad Y = R \sin \theta$$

相互独立, 且 $X, Y \sim \mathcal{N}(0, 1)$ 。

4. 经验分布 F_n : 注意 F_n 为阶梯函数。设

$$x_{(1)} \leq \cdots \leq x_{(n)}$$

为 $x_1 \leq \cdots \leq x_n$ 的次序统计量, 则

$$F_n^{-1}(x) = \begin{cases} x_{(1)}, & 0 < x \leq \frac{1}{n}, \\ x_{(2)}, & \frac{1}{n} < x \leq \frac{2}{n}, \\ \vdots & \\ x_{(n)}, & \frac{n-1}{n} < x \leq 1. \end{cases}$$

因此 $F_n^{-1}(U)$ 的取值集合为 $\{x_{(1)}, \dots, x_{(n)}\}$, 并且

$$\mathbb{P}(F_n^{-1}(U) = x_{(k)}) = \mathbb{P}\left(\frac{k-1}{n} < U \leq \frac{k}{n}\right) = \frac{1}{n}, \quad k = 1, \dots, n.$$

即只需等概率地从观测值中抽样。

第4节 期望、方差、条件期望等数字特征

4.1 随机变量的数学期望

定义 4.1 (离散型随机变量的期望)

设 X 有概率分布 $\mathbb{P}(X = x_j)$, $j = 1, 2, \dots$. 如果

$$\sum_{j=1}^{\infty} |x_j| \mathbb{P}(X = x_j) < +\infty,$$

称

$$E(X) = \sum_{j=1}^{\infty} x_j \mathbb{P}(X = x_j)$$

为 X 的数学期望或均值。



例 4.1 两点分布的期望 设 $X \sim B(1, p)$, 即 $\mathbb{P}(X = 1) = p = 1 - \mathbb{P}(X = 0)$. 求 $E(X)$.

解

$$E(X) = 1 \cdot p + 0 \cdot (1 - p) = p.$$

例 4.2 设 A 是事件, I_A 为 A 的示性函数. 求 $E(I_A)$.

解 I_A 服从两点分布, 且

$$E(I_A) = 1 \cdot \mathbb{P}(A) + 0 \cdot (1 - \mathbb{P}(A)) = \mathbb{P}(A).$$

例 4.3 二项分布的期望 设 $X \sim B(n, p)$, 即 $p_j = \mathbb{P}(X = j) = \binom{n}{j} p^j (1-p)^{n-j}$, $0 \leq j \leq n$. 求 $E(X)$.

解 可将 X 表示为 n 个独立的两点分布之和: $X = \sum_{i=1}^n X_i$, 其中 $X_i \sim B(1, p)$ 相互独立. 于是

$$E(X) = \sum_{i=1}^n E(X_i) = \sum_{i=1}^n p = np.$$

例 4.4 设 $X \sim \text{Poisson}(\lambda)$, 即

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$$

求 $E(X)$.

解 由级数移位可得

$$E(X) = \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} = \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} e^{-\lambda} = \lambda.$$

例 4.5 设 $X \sim G(p)$ (几何分布), 即

$$\mathbb{P}(X = k) = p(1-p)^{k-1}, \quad k = 1, 2, \dots$$

求 $E(X)$.

解 利用等比级数求和公式 $\sum_{k=1}^{\infty} k r^{k-1} = \frac{1}{(1-r)^2}$ ($|r| < 1$), 取 $r = 1-p \in (0, 1)$, 得

$$E(X) = p \sum_{k=1}^{\infty} k (1-p)^{k-1} = p \cdot \frac{1}{(1-(1-p))^2} = \frac{1}{p}.$$

定义 4.2 (连续型随机变量的期望)

设 X 的概率密度为 $f(x)$ 。如果

$$\int_{-\infty}^{\infty} |x|f(x) dx < +\infty,$$

则定义

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx$$

为 X 的数学期望或均值。



例 4.6 设 $X \sim \mathcal{U}(a, b)$, 即

$$f(x) = \frac{1}{b-a} I_{(a,b)}(x).$$

求 $E(X)$ 。

解

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx = \int_a^b \frac{x}{b-a} dx = \frac{a+b}{2}.$$

例 4.7 设 $X \sim \mathcal{E}(\lambda)$ (指数分布), 其密度

$$f(x) = \lambda e^{-\lambda x}, \quad x > 0.$$

求 $E(X)$ 。

解 分部积分或由标准积分表可得

$$E(X) = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}.$$

例 4.8 设 $X \sim \Gamma(\alpha, \beta)$, 其密度

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0.$$

求 $E(X)$ 。

解 由代换 $t = \beta x$ 且利用 $\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$, 有

$$E(X) = \int_0^{\infty} xf(x) dx = \int_0^{\infty} \frac{\beta^\alpha}{\Gamma(\alpha)} x^\alpha e^{-\beta x} dx = \frac{1}{\beta \Gamma(\alpha)} \int_0^{\infty} t^\alpha e^{-t} dt = \frac{\Gamma(\alpha+1)}{\beta \Gamma(\alpha)} = \frac{\alpha}{\beta}.$$

例 4.9 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 密度

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

求 $E(X)$ 。

解 由对称性与换元

$$E(X) = \int_{-\infty}^{\infty} xf(x) dx = \int_{-\infty}^{\infty} \mu f(x) dx + \int_{-\infty}^{\infty} (x-\mu)f(x) dx = \mu + \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (x-\mu) \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx.$$

令 $t = x - \mu$, 则第二项为奇函数在对称区间的积分, 故为 0, 从而 $E(X) = \mu$ 。

定义 4.3 (期望的一般定义 (Stieltjes 形式))

若随机变量 X 的分布函数为 $F(x)$, 则 X 的数学期望 (若存在) 可写为

$$E(X) = \int_{\Omega} X d\mathbb{P} = \int_{\mathbb{R}} x dF(x).$$

为说明 Stieltjes 积分的离散化形式, 设 $G(x)$ 是任意单调非降的右连续函数, 且在 $(a, b]$ 上至多有可列个跳跃点 x_j ($j = 1, 2, \dots$), 并满足

$$\sum_{j: x_j \in (a, b]} g(x_j) [G(x_j) - G(x_j - 0)] < \infty.$$

则可形式地定义

$$\int_a^b g(x) dG(x) = \sum_{j: x_j \in (a, b]} g(x_j) [G(x_j) - G(x_j - 0)].$$

对任意随机变量 X , 若存在非负函数 $f_0(x)$ 使得

$$F(x) = F_1(x) + F_2(x), \quad F_1(x) = \int_{-\infty}^x f_0(s) ds,$$

且 F_2 仅在可列点 x_j 处有跳跃, 满足 $\mathbb{P}(X = x_j) = F(x_j) - F(x_j - 0)$ 。若

$$\int_{-\infty}^{\infty} |x| f_0(x) dx + \sum_{j=1}^{\infty} |x_j| \mathbb{P}(X = x_j) < \infty,$$

则 $E(X)$ 存在, 并且

$$E(X) = \int_{-\infty}^{\infty} x f_0(x) dx + \sum_{j=1}^{\infty} x_j \mathbb{P}(X = x_j) = \int_{-\infty}^{\infty} x dF_1(x) + \int_{-\infty}^{\infty} x dF_2(x) = \int_{-\infty}^{\infty} x dF(x).$$

(若期望存在), 同分布的随机变量具有相同的期望。



4.2 期望的性质

随机变(向)量函数的数学期望

定理 4.1

设 $\mathbf{X} = (X_1, \dots, X_n)$ 是随机向量, $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ 。若 \mathbf{X} 具有联合分布函数 $F(\mathbf{x})$, 实函数 $g(\mathbf{x})$ 满足

$$\int_{\mathbb{R}^n} |g(\mathbf{x})| dF(\mathbf{x}) < \infty,$$

则 $Y = g(\mathbf{X})$ 有数学期望, 且

$$E(Y) =: E(g(\mathbf{X})) = \int_{\mathbb{R}^n} g(\mathbf{x}) dF(\mathbf{x}).$$



例 4.10 设 $X \sim \mathcal{U}(0, \pi/2)$, 计算 $E(\cos X)$ 。

解 由密度 $f(x) = \frac{2}{\pi} I_{(0, \pi/2)}(x)$, 得

$$E(\cos X) = \int_0^{\pi/2} \frac{2}{\pi} \cos(x) dx = \frac{2}{\pi}.$$

例 4.11 设 $X \sim \mathcal{N}(0, 1)$, α 为常数, 计算 $E(|X|^\alpha)$ 。

解 令标准正态密度 $\varphi(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ 。当 $\alpha > -1$ 时, 偶函数对称性与换元 $x = \sqrt{2t}$ 给出

$$E(|X|^\alpha) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} |x|^\alpha e^{-x^2/2} dx = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} x^\alpha e^{-x^2/2} dx = \sqrt{\frac{2}{\pi}} \Gamma\left(\frac{\alpha+1}{2}\right).$$

特别地:

- $E(X^2) = 1$;
- $E|X| = \sqrt{\frac{2}{\pi}}$;
- 若 $\alpha \leq -1$, 则 $E|X|^\alpha = \infty$ 。

注: $\Gamma(1/2) = \sqrt{\pi}$ 。

期望的基本性质

定理 4.2

设 $E|X| < \infty$, $E|Y| < \infty$, 且 $a, b, c \in \mathbb{R}$ 。则:

1. $EC = C$;
2. $|EX| \leq E|X|$;
3. 线性性: $E(aX + bY) = aEX + bEY$;
4. 若 $X \leq Y$ 几乎处处, 则 $EX \leq EY$;
5. 若 X 与 Y 独立, 则 $E(XY) = (EX)(EY)$ 。



最佳(常数)预测

定理 4.3

设 $EX = \mu$ 且 $E(X^2) < \infty$, 则对所有 $c \in \mathbb{R}$ 有

$$E[(X - \mu)^2] \leq E[(X - c)^2].$$



由此得到等价的优化表述 (最小二乘角度):

$$EX = \arg \min_{c \in \mathbb{R}} E[(X - c)^2].$$

高阶矩

一类“特殊的随机变量函数”的期望:

定义 4.4 (Moment)

设 X 是随机变量, m 是正整数。若 $E(|X|^m) < +\infty$, 称 $E(X^m)$ 为 X 的 m 阶原点矩; 称 $E((X - EX)^m)$ 为 X 的 m 阶中心矩。当 $m > 2$ 时, 我们将原点矩和中心矩统称为高阶矩。



4.3 方差

定义 4.5 (随机变量的方差)

如果随机变量 X 的期望 $\mu = EX$ 有限, 则称

$$\text{var}(X) := E[(X - \mu)^2]$$

为 X 的方差 (Variance), 记作 $\text{var}(X)$ 或 σ_X^2 。当 $\text{var}(X) < \infty$ 时, 称 X 的方差有限。



例 4.12 两点分布 $B(1, p)$: 设 $\mathbb{P}(X = 1) = p, \mathbb{P}(X = 0) = q = 1 - p$ 。注意 $X^2 = X, EX = p$, 于是

$$\text{var}(X) = E(X^2) - (EX)^2 = p - p^2 = p(1 - p) = pq.$$

例 4.13 二项分布 $B(n, p)$: $\mathbb{P}(X = j) = \binom{n}{j} p^j (1 - p)^{n-j}, 0 \leq j \leq n$ 。将 X 写成 n 个相互独立的 $B(1, p)$ 之和可得

$$\text{var}(X) = npq, \quad q = 1 - p.$$

例 4.14 Poisson 分布 $\mathcal{P}(\lambda)$: $\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$ 。有

$$E(X^2) = E(X(X-1)) + EX = \sum_{k=0}^{\infty} k(k-1) \frac{\lambda^k}{k!} e^{-\lambda} + \lambda = \lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} e^{-\lambda} + \lambda = \lambda^2 + \lambda.$$

因此 $\text{var}(X) = E(X^2) - (EX)^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda$ 。

例 4.15 几何分布 $G(p)$ (取值 $k = 1, 2, \dots$): $\mathbb{P}(X = k) = p(1-p)^{k-1}$, 记 $q = 1 - p$ 。先算

$$E(X(X-1)) = \sum_{j=1}^{\infty} j(j-1) p q^{j-1} = p q \sum_{j=1}^{\infty} j(j-1) q^{j-2} = p q \cdot \frac{2}{(1-q)^3} = \frac{2q}{p^2}.$$

又 $EX = \frac{1}{p}$, 故

$$E(X^2) = E(X(X-1)) + EX = \frac{2q}{p^2} + \frac{1}{p}.$$

于是

$$\text{var}(X) = E(X^2) - (EX)^2 = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{q}{p^2}.$$

例 4.16 设 $X \sim \mathcal{E}(\lambda)$ (指数分布), 即 $f(x) = \lambda e^{-\lambda x}, x > 0$ 。则

$$E(X^2) = \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = \frac{1}{\lambda^2} \Gamma(3) = \frac{2}{\lambda^2}.$$

因此

$$\text{var}(X) = E(X^2) - (EX)^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2}.$$

例 4.17 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 即 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$ 。则 (由对称性与归一化)

$$\begin{aligned} \text{var}(X) &= \int_{-\infty}^{\infty} (x-\mu)^2 f(x) dx \\ &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (x-\mu)^2 \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) dx \\ &\xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{\sigma^2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t^2 e^{-t^2/2} dt = \sigma^2. \end{aligned}$$

例 4.18 设 $X \sim \Gamma(\alpha, \beta)$, 密度 $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$, $x > 0$. 有

$$\begin{aligned} E(X^2) &= \int_0^\infty x^2 f(x) dx = \int_0^\infty \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha+1} e^{-\beta x} dx \\ &\xrightarrow{t=\beta x} \frac{1}{\beta^2 \Gamma(\alpha)} \int_0^\infty t^{\alpha+1} e^{-t} dt = \frac{\Gamma(\alpha+2)}{\beta^2 \Gamma(\alpha)} = \frac{\alpha(\alpha+1)}{\beta^2}. \end{aligned}$$

又 $EX = \frac{\alpha}{\beta}$, 故

$$\text{var}(X) = E(X^2) - (EX)^2 = \frac{\alpha(\alpha+1)}{\beta^2} - \left(\frac{\alpha}{\beta}\right)^2 = \frac{\alpha}{\beta^2}.$$

4.3.1 方差的性质

定理 4.4 (方差的性质)

设 $EX = \mu$ 且 $\text{var}(X) < \infty$, 则对任意 $a, b \in \mathbb{R}$:

1. $\text{var}(aX + b) = a^2 \text{var}(X)$;
2. $\text{var}(X) = E[(X - \mu)^2] \leq E[(X - c)^2]$, $\forall c \in \mathbb{R}$;
3. $\text{var}(X) = 0 \iff X = \mu \text{ a.s.}$;
4. 若 X_1, \dots, X_n 相互独立, 则

$$\text{var}\left(\sum_{k=1}^n X_k\right) = \sum_{k=1}^n \text{var}(X_k).$$



4.3.2 标准差与标准化

定义 4.6 (标准差)

若 EX 有限且 $\text{var}(X) = E[(X - \mu)^2]$, 称

$$\sigma_X := \sqrt{\text{var}(X)}$$

为 X 的标准差 (Standard deviation)。



定义 4.7 (标准化)

设 $\text{var}(X) < \infty$. 令

$$Y := \frac{X - EX}{\sqrt{\text{var}(X)}}.$$

则 $EY = 0$, $\text{var}(Y) = 1$, 称 Y 为 X 的标准化 (standardization)。特别地, 当 $X \sim \mathcal{N}(\mu, \sigma^2)$ 时,

$$Y = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1).$$



4.4 常用的期望方差不等式

定理 4.5 (Markov 不等式)

对随机变量 X 与 $\varepsilon > 0$, 以及 $\alpha > 0$, 有

$$\mathbb{P}(|X| \geq \varepsilon) \leq \frac{E(|X|^\alpha)}{\varepsilon^\alpha}.$$



证明 由指标函数记号与 $\{|X| \geq \varepsilon\} \subseteq \{|X|^\alpha \geq \varepsilon^\alpha\}$, 得

$$\mathbb{P}(|X| \geq \varepsilon) = E I_{\{|X| \geq \varepsilon\}} \leq E \left(\frac{|X|^\alpha}{\varepsilon^\alpha} I_{\{|X|^\alpha \geq \varepsilon^\alpha\}} \right) \leq E \left(\frac{|X|^\alpha}{\varepsilon^\alpha} \right) = \frac{E(|X|^\alpha)}{\varepsilon^\alpha}.$$

推论 4.1 (Chebyshev 不等式)

若 $\text{var}(X) < \infty$, 则对任意 $\varepsilon > 0$,

$$\mathbb{P}(|X - EX| \geq \varepsilon) \leq \frac{\text{var}(X)}{\varepsilon^2}.$$

定理 4.6 (内积不等式 (Cauchy-Schwarz))

设 $EX^2 < \infty$ 且 $EY^2 < \infty$, 则

$$|E(XY)| \leq \sqrt{EX^2 EY^2}.$$

等号成立当且仅当存在不全为零的常数 a, b 使 $aX + bY = 0$ a.s.

证明 对任意 $a, b \in \mathbb{R}$, 有 $E((aX + bY)^2) \geq 0$, 即

$$a^2 EX^2 + 2ab E(XY) + b^2 EY^2 \geq 0.$$

将其视为关于 a/b 的二次式非负, 判别式不大于零, 得 $E(XY)^2 \leq EX^2 EY^2$. 若判别式为零, 存在不全为零的 a, b 使 $E((aX + bY)^2) = 0$, 于是 $aX + bY = 0$ a.s.

定理 4.7 (Jensen 不等式)

设 ψ 是 \mathbb{R} 上的凸函数, 且 $X, \psi(X)$ 都有有限期望, 则

$$\psi(EX) \leq E(\psi(X)).$$

若 ψ 严格凸, 则等号成立当且仅当 $X = EX$ a.s.

证明 凸性意味着对任意 $a, b \in \mathbb{R}$, 存在某个常数 c (可取为 ψ 的某个次梯度) 使得

$$\psi(b) - \psi(a) \geq c(b - a).$$

取 $a = EX, b = X$, 得 $\psi(X) - \psi(EX) \geq c(X - EX)$. 两侧取期望即得 $E\psi(X) - \psi(EX) \geq cE(X - EX) = 0$. 严格凸情形下等号当且仅当 $X = EX$ a.s.

条件概率复习

一些定义

1. $\mathbf{P(A | B)}$: 设事件 A, B , 且 $\mathbb{P}(B) > 0$. 定义

$$\mathbb{P}(A | B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

2. $\mathbf{P(X | A)}$: 设随机变量 X 与事件 A , 且 $\mathbb{P}(A) > 0$.

- 离散情形:

$$p_{X|A}(x) = \mathbb{P}(X = x | A) = \frac{\mathbb{P}(\{X = x\} \cap A)}{\mathbb{P}(A)}, \quad \sum_x p_{X|A}(x) = 1.$$

- 连续情形: 存在条件密度 $f_{X|A}(x)$, 使得对任意 Borel 集 B ,

$$\mathbb{P}(X \in B | A) = \int_B f_{X|A}(x) dx, \quad f_{X|A}(x) \geq 0, \quad \int_{\mathbb{R}} f_{X|A}(x) dx = 1.$$

3. $\mathbf{P(X | Y)}$: 设随机变量 (X, Y) .

- 离散 (X, Y 取可数值): 当 $\mathbb{P}(Y = y_j) > 0$ 时,

$$\mathbb{P}(X = x_i | Y = y_j) = \frac{\mathbb{P}(X = x_i, Y = y_j)}{\mathbb{P}(Y = y_j)} = \frac{p_{ij}}{q_j},$$

其中 $p_{ij} = \mathbb{P}(X = x_i, Y = y_j)$, $q_j = \sum_i p_{ij} = \mathbb{P}(Y = y_j)$ 。

- 连续 (存在联合密度 $f(x, y)$): 当 $f_Y(y) > 0$ 时,

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)}, \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx, \quad x \in \mathbb{R}.$$

进而对 Borel 集 B , $\mathbb{P}(X \in B | Y = y) = \int_B f_{X|Y}(x | y) dx$ 。

4. $\mathbf{P}(\mathbf{A} | \mathbf{X})$: 设 D 为 X 的取值域, A 为事件。若存在函数 $g: D \rightarrow [0, 1]$ 满足

$$g(x) = \mathbb{P}(A | X = x), \quad x \in D,$$

则称 $g(X)$ 为事件 A 关于随机变量 X 的条件概率; g 是定义在 D 上的实函数, 因而 $g(X)$ 也是一个随机变量

全概率公式

设 A_1, \dots, A_n 构成 Ω 的一个分割 (两两不交且并为 Ω), 且 $\mathbb{P}(A_i) > 0$ 。

1. 对事件:

$$\mathbb{P}(B) = \sum_{i=1}^n \mathbb{P}(B | A_i) \mathbb{P}(A_i).$$

2. 对随机变量 X 的条件分布:

离散:

$$p_X(x) = \sum_{i=1}^n p_{X|A_i}(x) \mathbb{P}(A_i).$$

连续:

$$f_X(x) = \sum_{i=1}^n f_{X|A_i}(x) \mathbb{P}(A_i).$$

3. 对 (X, Y) : 若 Y 取有限/可数值 y_i , 则

$$p_X(x) = \sum_i p_{X|Y}(x | y_i) \mathbb{P}(Y = y_i);$$

若 Y 连续,

$$f_X(x) = \int_{-\infty}^{\infty} f_{X|Y}(x | y) f_Y(y) dy.$$

乘法法则

1. 事件:

$$\mathbb{P}(A \cap B) = \mathbb{P}(B | A) \mathbb{P}(A) = \mathbb{P}(A | B) \mathbb{P}(B).$$

2. $\mathbf{P}(\mathbf{X} | \mathbf{A})$:

离散:

$$\mathbb{P}(\{X = x_i\} \cap A) = \mathbb{P}(X = x_i | A) \mathbb{P}(A).$$

连续: 写作密度的“加权-指示”形式

$$f_{X I_{\{X \in A\}}}(x) = f_{X|\{X \in A\}}(x) \mathbb{P}(X \in A), \quad \text{或} \quad f_X(x) I_A(x) = f_{X|\{X \in A\}}(x) \mathbb{P}(X \in A).$$

3. $\mathbf{P}(\mathbf{X} | \mathbf{Y})$:

离散:

$$\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i | Y = y_j) \mathbb{P}(Y = y_j).$$

连续:

$$f(x, y) = f_{X|Y}(x | y) f_Y(y).$$

贝叶斯准则

1. 对于事件: 设 A_1, \dots, A_n 构成 Ω 的一个分割, B 是一个事件, 且 $\mathbb{P}(B) > 0, \mathbb{P}(A_i) > 0$.

$$\mathbb{P}(A_i | B) = \frac{\mathbb{P}(A_i) \mathbb{P}(B | A_i)}{\sum_{j=1}^n \mathbb{P}(A_j) \mathbb{P}(B | A_j)}, \quad i = 1, \dots, n.$$

2. 对于随机变量 (X, Y) , 分情况讨论:

(a). X, Y 均为离散型随机变量:

$$P_{X|Y}(x | y) = \frac{P_{X,Y}(x, y)}{P_Y(y)} = \frac{P_X(x) P_{Y|X}(y | x)}{P_Y(y)},$$

其中

$$P_Y(y) = \sum_x P_X(x) P_{Y|X}(y | x).$$

(b). (X, Y) 为连续型随机向量:

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{f_X(x) f_{Y|X}(y | x)}{f_Y(y)},$$

其中

$$f_Y(y) = \int_x f_X(x) f_{Y|X}(y | x) dx.$$

(c). X 离散, Y 连续:

$$P_{X|Y}(x | y) = \frac{P_X(x) f_{Y|X}(y | x)}{f_Y(y)},$$

其中

$$f_Y(y) = \sum_x P_X(x) f_{Y|X}(y | x).$$

(d). X 连续, Y 离散:

$$f_{X|Y}(x | y) = \frac{f_X(x) P_{Y|X}(y | x)}{P_Y(y)},$$

其中

$$P_Y(y) = \int_x f_X(x) P_{Y|X}(y | x) dx.$$

4.5 条件在事件上的条件期望

定义 4.8 (离散型)

若有 $\sum_{i=1}^{\infty} |x_i| \mathbb{P}(X = x_i | A) < \infty$, 则定义给定 A 发生下, X 的期望为

$$\mathbb{E}(X | A) = \sum_{i=1}^{\infty} x_i \mathbb{P}(X = x_i | A).$$



定义 4.9 (连续型)

若有 $\int_{-\infty}^{\infty} |x| f_{X|A}(x|A) dx < \infty$, 则定义给定 A 发生下, X 的期望为

$$\mathbb{E}(X|A) = \int_{-\infty}^{\infty} x f_{X|A}(x|A) dx.$$

**定理 4.8**

设 $\mathbb{P}(A) > 0$, X 是非负随机变量, 则

$$\mathbb{E}(X|A) = \frac{\mathbb{E}(XI_A)}{\mathbb{P}(A)}.$$

**推论 4.2**

设 $\mathbb{P}(A) > 0$, $\mathbb{E}(X|A)$ 存在, 则有

$$\mathbb{E}(X|A) = \frac{\mathbb{E}(XI_A)}{\mathbb{P}(A)}.$$



例 4.19 设 $X \sim \mathcal{E}(\lambda)$, 对 $a > 0$, 证明

$$\mathbb{E}(X|X > a) = a + \frac{1}{\lambda}.$$

解 X 有密度函数 $f(x) = \lambda e^{-\lambda x}, x > 0$. 利用定理 2.1, 有

$$\mathbb{E}(X|X > a) = \frac{\mathbb{E}(XI_{\{X > a\}})}{\mathbb{P}(X > a)} = \frac{1}{e^{-\lambda a}} \int_a^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda} + a.$$

事实上, 该结果也可由指数分布的无记忆性获得:

$$\mathbb{E}(X|X > a) = a + \mathbb{E}(X - a|X > a) = a + \mathbb{E}(X) = a + \frac{1}{\lambda}.$$

因为指数分布具有无记忆性, 在条件 $X > a$ 下, $X - a$ 依然服从指数分布 $\mathcal{E}(\lambda)$. 同时 $\mathbb{E}(X) = 1/\lambda$.

例 4.20 设 X, Y 独立, 且 $X \sim \mathcal{E}(\lambda), Y \sim \mathcal{E}(\mu)$, 计算 $\mathbb{E}(X|X < Y)$.

解 由定理得

$$\begin{aligned} \mathbb{E}(X|X < Y) &= \frac{\mathbb{E}(XI_{\{X < Y\}})}{\mathbb{P}(X < Y)} = \frac{\int_0^{\infty} \int_0^{\infty} x I_{\{x < y\}} \lambda e^{-\lambda x} \mu e^{-\mu y} dy dx}{\int_0^{\infty} \int_0^{\infty} I_{\{x < y\}} \lambda e^{-\lambda x} \mu e^{-\mu y} dy dx} \\ &= \frac{\int_0^{\infty} x \lambda e^{-\lambda x} \left(\int_x^{\infty} \mu e^{-\mu y} dy \right) dx}{\int_0^{\infty} \lambda e^{-\lambda x} \left(\int_x^{\infty} \mu e^{-\mu y} dy \right) dx} = \frac{\int_0^{\infty} x \lambda e^{-\lambda x} e^{-\mu x} dx}{\int_0^{\infty} \lambda e^{-\lambda x} e^{-\mu x} dx} \\ &= \frac{\lambda \int_0^{\infty} x e^{-(\lambda+\mu)x} dx}{\lambda \int_0^{\infty} e^{-(\lambda+\mu)x} dx} = \frac{\lambda \cdot \frac{1}{(\lambda+\mu)^2}}{\lambda \cdot \frac{1}{\lambda+\mu}} = \frac{1}{\lambda+\mu}. \end{aligned}$$

定理 4.9 (全期望定理)

设 A_1, \dots, A_n 构成 Ω 的一个分割, 则

$$\mathbb{E}(X) = \sum_{i=1}^n \mathbb{P}(A_i) \mathbb{E}(X | A_i).$$



例 4.21 利用全期望定理计算几何分布 $X \sim G(p)$ 的期望。

解 令 $A_1 = \{X = 1\}, A_2 = \{X > 1\}$ 。这是一个分割。

$$\begin{aligned} \mathbb{E}(X) &= \mathbb{E}(X | A_1) \mathbb{P}(A_1) + \mathbb{E}(X | A_2) \mathbb{P}(A_2) \\ &= 1 \cdot p + \mathbb{E}(X | X > 1) \cdot (1 - p). \end{aligned}$$

而由于几何分布的无记忆性, $\mathbb{E}(X - 1 | X > 1) = \mathbb{E}(X)$, 所以

$$\mathbb{E}(X | X > 1) = \mathbb{E}(X - 1 | X > 1) + 1 = \mathbb{E}(X) + 1.$$

代入上式可得

$$\mathbb{E}(X) = p + (\mathbb{E}(X) + 1)(1 - p) = p + \mathbb{E}(X) - p\mathbb{E}(X) + 1 - p.$$

整理得 $p\mathbb{E}(X) = 1$, 故 $\mathbb{E}(X) = 1/p$ 。

4.6 条件在随机变量上的条件期望

定义 4.10 (离散型)

设 (X, Y) 为离散型随机向量。若 $\sum_{i=1}^{\infty} |x_i| \mathbb{P}(X = x_i | Y = y) < \infty$, 则定义给定 $Y = y$ 下, X 的期望为

$$\mathbb{E}(X | Y = y) = \sum_{i=1}^{\infty} x_i \mathbb{P}(X = x_i | Y = y).$$

**定义 4.11 (连续型)**

设 (X, Y) 为连续型随机向量。若 $\int_{-\infty}^{\infty} |x| f_{X|Y}(x | y) dx < \infty$, 则定义给定 $Y = y$ 下, X 的期望为

$$\mathbb{E}(X | Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x | y) dx.$$

**定义 4.12 ($\mathbb{E}(X|Y)$ 的定义)**

设 (X, Y) 是随机向量, $\mathbb{E}|X| < \infty$ 。如果

$$m(y) = \mathbb{E}(X | Y = y),$$

就称随机变量 $m(Y)$ 为给定 Y 时 X 的条件期望, 记作 $\mathbb{E}(X | Y)$ 。

**定理 4.10 (重期望法则)**

设 X, Y 是随机变量, 则

$$\mathbb{E}[\mathbb{E}(X | Y)] = \mathbb{E}(X).$$



例 4.22 密室逃脱问题 一位玩家在有三个门的大型密室逃脱游戏中迷了路, 第一个门通向一密道走 3 小时可使他到达出口。第二个门通向使他走 5 小时后又回到原地的密道, 第三个门通向使他走了 7 小时后又回到原地的密道。如果他在任何时刻都等可能地选定其中一个门。试问他到达出口平均要花多少时间?

解 设 X 表示他到达出口所需的时数, Y 表示他最初选定的门的编号, 于是

$$\mathbb{P}(Y=1) = \mathbb{P}(Y=2) = \mathbb{P}(Y=3) = 1/3.$$

由全期望公式, 所求平均时数为

$$\mathbb{E}(X) = \sum_{i=1}^3 \mathbb{E}(X | Y=i) \mathbb{P}(Y=i) = \frac{\mathbb{E}(X | Y=1) + \mathbb{E}(X | Y=2) + \mathbb{E}(X | Y=3)}{3}.$$

又因为

$$\mathbb{E}(X | Y=1) = 3,$$

$$\mathbb{E}(X | Y=2) = 5 + \mathbb{E}(X),$$

$$\mathbb{E}(X | Y=3) = 7 + \mathbb{E}(X).$$

所以

$$\mathbb{E}(X) = \frac{3 + 5 + \mathbb{E}(X) + 7 + \mathbb{E}(X)}{3}.$$

解之得 $\mathbb{E}(X) = 15$ 。

例 4.23 设计计算机使用的环境指标 $Y \sim \Gamma(\alpha, \beta)$, 其概率密度是

$$f_Y(y) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}, \quad y > 0.$$

已知 $Y=y$ 时, 计算机软件的使用寿命 $X \sim \mathcal{E}(y)$ 。计算条件期望 $\mathbb{E}(X|Y)$, $\mathbb{E}(Y|X)$ 和 $\mathbb{E}(X)$ 。

解 给定 $Y=y$ 时, $X \sim \mathcal{E}(y)$, 即条件密度为 $f_{X|Y}(x|y) = ye^{-xy}, x > 0$ 。于是

$$\mathbb{E}(X|Y=y) = \int_0^\infty xye^{-xy} dx = \frac{1}{y},$$

得 $\mathbb{E}(X|Y) = 1/Y$ 。

(X, Y) 的联合密度为

$$f(x, y) = f_{X|Y}(x|y)f_Y(y) = ye^{-xy} \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}, \quad x, y > 0.$$

X 有边缘密度函数

$$f_X(x) = \int_0^\infty f(x, y) dy = \frac{\alpha\beta^\alpha}{(x+\beta)^{\alpha+1}}, \quad x > 0.$$

于是在条件 $X=x$ 下, Y 有条件密度

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{(x+\beta)^{\alpha+1}}{\Gamma(\alpha+1)} y^\alpha e^{-(x+\beta)y},$$

这是 $\Gamma(\alpha+1, x+\beta)$ 分布的密度, 其期望为 $(\alpha+1)/(x+\beta)$ 。所以有

$$\mathbb{E}(Y|X=x) = \int_0^\infty y f_{Y|X}(y|x) dy = \frac{\alpha+1}{x+\beta}.$$

于是 $\mathbb{E}(Y|X) = \frac{\alpha+1}{X+\beta}$ 。

由于

$$\begin{aligned} \mathbb{E}(X) &= \mathbb{E}[\mathbb{E}(X|Y)] = \mathbb{E}(Y^{-1}) = \int_0^\infty y^{-1} f_Y(y) dy \\ &= \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty y^{\alpha-2} e^{-\beta y} dy \\ &= \frac{\beta^\alpha \Gamma(\alpha-1) \beta^{-(\alpha-1)}}{\Gamma(\alpha)} = \frac{\beta \Gamma(\alpha-1)}{(\alpha-1) \Gamma(\alpha-1)} = \frac{\beta}{\alpha-1}. \end{aligned}$$

此积分仅当 $\alpha-1 > 0$ 时收敛。因此

$$\mathbb{E}(X) = \begin{cases} \frac{\beta}{\alpha-1}, & \alpha > 1, \\ \infty, & \alpha \in (0, 1]. \end{cases}$$

定理 4.11 (条件期望的性质)

设 X, Y 是随机变量, $g(x), h(y)$ 是实函数, $\mathbb{E}|X| < \infty, \mathbb{E}|g(X)| < \infty$ 。又设 r.v. X_1, X_2, \dots, X_n 的期望有限, 则

1. $|\mathbb{E}(X|Y)| \leq \mathbb{E}(|X||Y|)$;
2. $[\mathbb{E}(X|Y)]^2 \leq \mathbb{E}(X^2|Y)$;
3. $\mathbb{E}[h(Y)g(X)|Y] = h(Y)\mathbb{E}[g(X)|Y]$;
4. $\mathbb{E}[\mathbb{E}(g(X)|Y)] = \mathbb{E}g(X)$.
5. 当 X, Y 独立时, $\mathbb{E}\{g(X)|Y\} = \mathbb{E}g(X)$;
6. $\mathbb{E}(c + \sum_{i=1}^n c_i X_i | Y) = c + \sum_{i=1}^n c_i \mathbb{E}(X_i | Y)$;
7. 如果 $X_1 \leq X_2$, 则 $\mathbb{E}(X_1|Y) \leq \mathbb{E}(X_2|Y)$;



例 4.24 设 X, Y 是随机变量, $h(x)$ 是实函数, 若 $\mathbb{E}(X^2) < \infty, \mathbb{E}[h^2(Y)] < \infty$, 则

$$\mathbb{E}[(X - \mathbb{E}(X|Y))h(Y)] = 0$$

证明 由 Cauchy-Schwarz 不等式得

$$\mathbb{E}(|Xh(Y)|) \leq \sqrt{\mathbb{E}(X^2)\mathbb{E}[h^2(Y)]} < \infty.$$

利用条件期望的性质, 可得

$$\begin{aligned} \mathbb{E}[(X - \mathbb{E}(X|Y))h(Y)] &= \mathbb{E}[Xh(Y)] - \mathbb{E}[\mathbb{E}(X|Y)h(Y)] \\ &= \mathbb{E}[Xh(Y)] - \mathbb{E}[\mathbb{E}(Xh(Y)|Y)] \\ &= \mathbb{E}[Xh(Y)] - \mathbb{E}[Xh(Y)] \\ &= 0. \end{aligned}$$

例 4.25 最佳预测问题 设 $\mathbb{E}(X^2) < \infty, m(Y) = \mathbb{E}(X|Y)$, 则对任何实函数 $g(y)$, 有

$$\mathbb{E}[X - m(Y)]^2 \leq \mathbb{E}[X - g(Y)]^2,$$

其中等号成立当且仅当 $g(Y) = m(Y)$ a.s.

证明 当 $\mathbb{E}g^2(Y) = \infty$, 利用不等式 $b^2 \leq 2(a - b)^2 + 2a^2$ 可得

$$\infty = \mathbb{E}g^2(Y) \leq 2\mathbb{E}[X - g(Y)]^2 + 2\mathbb{E}(X^2),$$

从而 $\mathbb{E}[X - g(Y)]^2 = \infty$, 不等式成立.

下面设 $\mathbb{E}g^2(Y) < \infty$. 显然, $[\mathbb{E}(X|Y)]^2 \leq \mathbb{E}(X^2|Y)$, 从而 $\mathbb{E}[m(Y)]^2 \leq \mathbb{E}(X^2) < \infty$. 令 $h(Y) = m(Y) - g(Y)$, 则 $\mathbb{E}[h(Y)]^2 < \infty$. 于是

$$\begin{aligned} \mathbb{E}[X - g(Y)]^2 &= \mathbb{E}[X - m(Y) + m(Y) - g(Y)]^2 \\ &= \mathbb{E}[X - m(Y)]^2 + \mathbb{E}[m(Y) - g(Y)]^2 \\ &\quad + 2\mathbb{E}[(X - m(Y))[m(Y) - g(Y)]] \\ &= \mathbb{E}[X - m(Y)]^2 + \mathbb{E}[m(Y) - g(Y)]^2 \\ &\geq \mathbb{E}[X - m(Y)]^2. \end{aligned}$$

式中等号成立当且仅当 $\mathbb{E}[m(Y) - g(Y)]^2 = 0$, 当且仅当 $g(Y) = m(Y)$ a.s.

称 $m(Y) = \mathbb{E}(X|Y)$ 是 X 的**最佳预测** (optimal forecast)。

4.7 条件方差

定义 4.13 (条件方差)

如果 $\mathbb{E}\{[X - \mathbb{E}(X|Y)]^2|Y\}$ 存在, 则称它为给定 Y 下, X 的**条件方差**, 记作 $\text{var}(X|Y)$, 即

$$\text{var}(X|Y) = \mathbb{E}\{[X - \mathbb{E}(X|Y)]^2|Y\}.$$



定理 4.12 (全方差法则)

$$\text{var}(X) = \mathbb{E}[\text{var}(X|Y)] + \text{var}(\mathbb{E}[X|Y]).$$



证明

$$\begin{aligned} \text{var}(X) &= E(X - EX)^2 \\ &= E\{(X - E(X|Y)) + (E(X|Y) - EX)\}^2 \\ &= E\{[X - E(X|Y)] + [E(X|Y) - E(E(X|Y))]\}^2 \\ &= E[(X - E(X|Y))^2] + \text{var}(E[X|Y]) \\ &= E(E\{[X - E(X|Y)]^2|Y\}) + \text{var}(E[X|Y]) \\ &= E[\text{var}(X|Y)] + \text{var}(E[X|Y]). \end{aligned}$$

例 4.26 论文数问题 设 Y 是我校明年选修概率论课程的学生人数, X_i 是第 i 位同学在学习后 5 年内写论文的篇数, X 是该段时间内这些同学写的论文的总篇数. 假设每位同学的论文数 X_i 是相互独立同分布且与选课人数 Y 也相互独立. 如果 $\mathbb{E}(X_1), \mathbb{E}(Y), \text{var}(X_1), \text{var}(Y)$ 已知, 求 X 的期望与方差.

解 显然 $X = X_1 + \cdots + X_Y$, 又因为

$$\begin{aligned} \mathbb{E}(X|Y = n) &= \mathbb{E}(X_1) + \cdots + \mathbb{E}(X_n) = n\mathbb{E}(X_1) \\ \text{var}(X|Y = n) &= \text{var}(X_1 + \cdots + X_n) = n \text{var}(X_1). \end{aligned}$$

所以

$$\mathbb{E}(X|Y) = Y\mathbb{E}(X_1), \quad \text{var}(X|Y) = Y \text{var}(X_1).$$

从而

$$\begin{aligned} \mathbb{E}(X) &= \mathbb{E}[Y\mathbb{E}(X_1)] = \mathbb{E}(Y)\mathbb{E}(X_1), \\ \text{var}(X) &= \mathbb{E}[\text{var}(X|Y)] + \text{var}(\mathbb{E}[X|Y]) \\ &= \mathbb{E}(Y) \text{var}(X_1) + [\mathbb{E}(X_1)]^2 \text{var}(Y). \end{aligned}$$

4.8 协方差

定义 4.14 (协方差 (Covariance))

设 $\mathbb{E}X$ 和 $\mathbb{E}Y$ 存在, 当 $\mathbb{E}|(X - \mathbb{E}X)(Y - \mathbb{E}Y)| < \infty$ 时, 称

$$\mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$$

为随机变量 X, Y 的协方差 (covariance), 记作 $\text{cov}(X, Y)$.



定理 4.13 (协方差性质)

1. $\text{cov}(X, X) = \text{var}(X)$;
2. $\text{cov}(X, Y) = \text{cov}(Y, X)$;
3. $\text{cov}(X, Y) = \mathbb{E}(XY) - (\mathbb{E}X)(\mathbb{E}Y)$; (常用计算公式)
4. 若 c 是某常数, 则 $\text{cov}(X, c) = 0$;
5. 双线性: $\text{cov}(cX, Y) = c \text{cov}(X, Y)$, $\text{cov}(X, Y + Z) = \text{cov}(X, Y) + \text{cov}(X, Z)$;
6. $\text{var}(X_1 + X_2) = \text{var}(X_1) + \text{var}(X_2) + 2 \text{cov}(X_1, X_2)$



4.9 相关系数

引入 X, Y 的标准化

$$\frac{X - \mathbb{E}X}{\sqrt{\text{var}(X)}}, \quad \frac{Y - \mathbb{E}Y}{\sqrt{\text{var}(Y)}}.$$

则

$$\text{cov}\left(\frac{X - \mathbb{E}X}{\sqrt{\text{var}(X)}}, \frac{Y - \mathbb{E}Y}{\sqrt{\text{var}(Y)}}\right) = \mathbb{E}\left[\left(\frac{X - \mathbb{E}X}{\sqrt{\text{var}(X)}}\right)\left(\frac{Y - \mathbb{E}Y}{\sqrt{\text{var}(Y)}}\right)\right] = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}}$$

定义 4.15 (相关系数 (Correlation coefficient))

当 $0 < \text{var}(X) \cdot \text{var}(Y) < \infty$ 时, 称

$$\frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}}$$

为 X, Y 的相关系数 (Pearson's correlation). 记作 $\text{corr}(X, Y)$.



例 4.27 设 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则 $\text{corr}(X, Y) = \rho$.

解 不失一般性, 考虑标准联合正态分布 $\mathcal{N}(0, 0, 1, 1, \rho)$. (X, Y) 有联合密度

$$f(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}[x^2 - 2\rho xy + y^2]\right\}.$$

则,

$$\begin{aligned}\text{cov}(X, Y) &= \mathbb{E}(XY) - \mathbb{E}X \cdot \mathbb{E}Y = \int_{\mathbb{R}^2} xyf(x, y)dxdy - 0 \cdot 0 = \rho. \\ \text{corr}(X, Y) &= \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}} = \frac{\rho}{1 \cdot 1} = \rho\end{aligned}$$

这是为什么经常记作符号 ρ_{XY} .

定理 4.14

设 X, Y 相互独立, 则有 X, Y 不相关, 即 $\text{cov}(X, Y) = 0$.



证明

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)] = \mathbb{E}(X - \mathbb{E}X) \cdot \mathbb{E}(Y - \mathbb{E}Y) = 0$$

例 4.28 设 (X, Y) 在单位圆 $D = \{(x, y) | x^2 + y^2 \leq 1\}$ 内均匀分布, 则 X, Y 不相关, 也不独立.

解 (X, Y) 有联合密度

$$f(x, y) = \frac{1}{\pi} I_D.$$

则

$$\begin{aligned}\mathbb{E}(X) &= \int_{R^2} x f(x, y) dx dy \\ &= \frac{1}{\pi} \int_{-1}^1 \left(\int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} x dx \right) dy = 0.\end{aligned}$$

同理 $\mathbb{E}(Y) = 0$. 于是

$$\text{cov}(X, Y) = \int_{R^2} xy f(x, y) dx dy = \frac{1}{\pi} \int_{-1}^1 y \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} x dx dy = 0.$$

相关性与独立性的关系是：若独立，则不相关，但反之不成立，如上例所示。

相关系数的几何意义

考虑 $\tilde{X} = X - \mathbb{E}X$, $\tilde{Y} = Y - \mathbb{E}Y$. 则 $\mathbb{E}\tilde{X} = 0$, $\mathbb{E}\tilde{Y} = 0$.

$$\begin{aligned}\text{corr}(X, Y) &= \text{corr}(\tilde{X} - \mathbb{E}X, \tilde{Y} - \mathbb{E}Y) \\ \text{corr}(X, Y) &= \text{corr}(\tilde{X}, \tilde{Y}) = \frac{\text{cov}(\tilde{X}, \tilde{Y})}{\sqrt{\text{var}(\tilde{X})}\sqrt{\text{var}(\tilde{Y})}} = \frac{\mathbb{E}(\tilde{X}\tilde{Y})}{\sqrt{\mathbb{E}(\tilde{X}^2)}\sqrt{\mathbb{E}(\tilde{Y}^2)}} = \frac{\langle \tilde{X}, \tilde{Y} \rangle}{|\tilde{X}| \cdot |\tilde{Y}|} = \cos(\varphi)\end{aligned}$$

$|\text{corr}(X, Y)| \leq 1$; $|\text{corr}(X, Y)| = 1$ 等价于 X, Y 共线性

统计意义总结表

	$\mathbb{E}Y$	$\mathbb{E}(Y X)$	$\text{corr}(X, Y)$
代数	$\mathbb{E}(Y) = \int_R y dF(y).$	$\mathbb{E}(Y X) = m(X),$ $m(x) = \mathbb{E}(Y X = x).$	$\text{corr}(X, Y)$ $= \frac{\mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}}$
几何	重心	投影	夹角余弦
优化	常数中的最佳预测 $\mathbb{E}Y = \underset{c \in \mathbb{R}}{\text{argmin}} \mathbb{E}(Y - c)^2.$	$g(X)$ 中的最佳预测 $\mathbb{E}(Y X) = m(X) =$ $\underset{g: \mathbb{R} \rightarrow \mathbb{R}}{\text{argmin}} \mathbb{E}[Y - g(X)]^2.$	拟合直线中的最佳预测 $\rho \sqrt{\frac{\text{var}(Y)}{\text{var}(X)}} =$ $\underset{b \in \mathbb{R}}{\text{argmin}} \mathbb{E}[(Y - \mathbb{E}Y) - b(X - \mathbb{E}X)]^2.$

4.10 随机向量的期望与协方差矩阵

设 $\mathbf{X} = (X_1, \dots, X_n)^T$ 是随机向量, 如果对每个 i , $\mu_i = \mathbb{E}X_i$ 存在, 就称 \mathbf{X} 的数学期望存在, 并且定义

$$\boldsymbol{\mu} := \mathbb{E}\mathbf{X} = (\mathbb{E}X_1, \dots, \mathbb{E}X_n)^T = (\mu_1, \dots, \mu_n)^T.$$

类似地, 对随机矩阵

$$\mathbf{Y} = \begin{pmatrix} X_{11} & X_{12} & \cdots & X_{1n} \\ X_{21} & X_{22} & \cdots & X_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ X_{m1} & X_{m2} & \cdots & X_{mn} \end{pmatrix}$$

可以定义其数学期望

$$\mathbb{E}\mathbf{Y} = \begin{pmatrix} \mathbb{E}X_{11} & \mathbb{E}X_{12} & \cdots & \mathbb{E}X_{1n} \\ \mathbb{E}X_{21} & \mathbb{E}X_{22} & \cdots & \mathbb{E}X_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}X_{m1} & \mathbb{E}X_{m2} & \cdots & \mathbb{E}X_{mn} \end{pmatrix}.$$

设 \mathbf{X}, \mathbf{Y} 如上定义, 且数学期望都存在. 容易证明, 对任何常数向量 $\mathbf{a} = (a_1, \dots, a_n)^T$, 常数矩阵 $\mathbf{A}_{k \times m}, \mathbf{B}_{n \times j}$, 有

性质

1. $\mathbb{E}(\mathbf{a}^T \mathbf{X}) = \mathbf{a}^T \mathbb{E}\mathbf{X}$;
2. $(\mathbb{E}\mathbf{Y})^T = \mathbb{E}(\mathbf{Y}^T)$;
3. $\mathbb{E}(\mathbf{A}\mathbf{Y}) = \mathbf{A}\mathbb{E}(\mathbf{Y})$;
4. $\mathbb{E}(\mathbf{Y}\mathbf{B}) = \mathbb{E}(\mathbf{Y})\mathbf{B}$;
5. $\mathbb{E}(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{Y})\mathbf{B}$;

本质上都基于期望的线性性质.

定义 4.16 (协方差矩阵 (Covariance Matrix))

如果随机向量 \mathbf{X} 的数学期望 $\boldsymbol{\mu} = \mathbb{E}\mathbf{X}$ 存在, 对每个分量 X_i 的方差有限, 则称

$$\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = (\sigma_{ij})$$

为 \mathbf{X} 的**协方差矩阵**, 其中 $\sigma_{ij} = \text{cov}(X_i, X_j)$.

协方差矩阵 $\boldsymbol{\Sigma}$ 是对称矩阵. 如果行列式 $\det(\boldsymbol{\Sigma}) = 0$, 就称 $\boldsymbol{\Sigma}$ 是退化的.

定理 4.15

设 $\boldsymbol{\Sigma}$ 是 $\mathbf{X} = (X_1, \dots, X_n)$ 的协方差矩阵, 则

1. $\boldsymbol{\Sigma}$ 是非负定矩阵;
2. $\boldsymbol{\Sigma}$ 退化的充要条件是存在不全为零的常数 a_1, \dots, a_n 使得

$$\sum_{i=1}^n a_i (X_i - \mathbb{E}X_i) = 0 \quad a.s.$$

第5节 特征函数和概率极限定理

5.1 概率母函数

定义 5.1 (probability-generating function)

设 X 是取非负整值的随机变量, 称

$$g(s) = \mathbb{E}(s^X) = \sum_{j=0}^{\infty} s^j \mathbb{P}(X = j), s \in [-1, 1],$$

为 X 的概率母函数 (probability-generating function). 约定 $0^0 = 1$.



定理 5.1 (概率母函数的性质)

设 $g(s)$ 是 X 的概率母函数, $g^{(k)}(s)$ 是 $g(s)$ 的 k -阶导数. 则

1. $\mathbb{P}(X = k) = \frac{g^{(k)}(0)}{k!}, k = 0, 1, \dots;$
2. $\mathbb{E}(X) = g^{(1)}(1);$
3. 如果 $\mathbb{E}(X) < \infty$, 则 $\text{var}(X) = g^{(2)}(1) + g^{(1)}(1) - [g^{(1)}(1)]^2;$
4. 如果 X_1, \dots, X_n 相互独立, $g_i(s) = \mathbb{E}(s^{X_i})$ 是 X_i 的概率母函数, 则 $Y = X_1 + \dots + X_n$ 的概率母函数为

$$g_Y(s) = g_1(s)g_2(s) \cdots g_n(s), s \in [-1, 1].$$



5.1.1 常见分布的概率母函数

例 5.1 二项分布 $B(n, p)$ 二项分布 $B(n, p)$ 的概率母函数是

$$g(s) = \sum_{j=0}^n s^j \binom{n}{j} p^j q^{n-j} = (q + sp)^n.$$

应用: 设 X_1, X_2, \dots, X_m 是相互独立, 且 $X_i \sim B(n_i, p)$, 则

$$Y = X_1 + X_2 + \dots + X_m \sim B(n_1 + n_2 + \dots + n_m, p).$$

例 5.2 Poisson 分布 $\mathcal{P}(\lambda)$ Poisson 分布 $\mathcal{P}(\lambda)$ 的概率母函数是

$$g(s) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k}{k!} e^{-\lambda} = e^{\lambda(s-1)}.$$

应用: 设 X_1, X_2, \dots, X_m 是相互独立, 且 $X_i \sim \mathcal{P}(\lambda_i)$, 则

$$Y = X_1 + X_2 + \dots + X_m \sim \mathcal{P}(\lambda_1 + \lambda_2 + \dots + \lambda_m).$$

例 5.3 几何分布 $G(p)$ 几何分布 $G(p)$ 的概率母函数是

$$g(s) = \sum_{k=1}^{\infty} s^k p q^{k-1} = \frac{sp}{1 - sq}.$$

应用: 设 X_1, X_2, \dots, X_m 相互独立, 且 $X_i \sim G(p)$, 则 $S_m = X_1 + X_2 + \dots + X_m$ 有概率母函数

$$g_m(s) = \left(\frac{sp}{1 - sq} \right)^m.$$

将 $g_m(s)$ Taylor 展开得到

$$\begin{aligned} g_m(s) &= (sp)^m \sum_{j=0}^{\infty} \frac{m(m+1) \cdots (m+j-1)}{j!} (sq)^j \\ &= (sp)^m \sum_{j=0}^{\infty} \binom{m+j-1}{m-1} (sq)^j \\ &= \sum_{k=m}^{\infty} \binom{k-1}{m-1} p^m q^{k-m} s^k. \end{aligned}$$

于是得到 Pascal 分布

$$\mathbb{P}(S_m = k) = \binom{k-1}{m-1} p^m q^{k-m}, k = m, m+1, \dots$$

定理 5.2 (随机和的概率母函数)

设

1. $\{X_j\}$ 是一列独立同分布的非负整值随机变量, 且 X_1 的概率母函数为

$$g_X(s) = \sum_{k=0}^{\infty} p_k s^k, p_k = \mathbb{P}(X_1 = k).$$

2. N 为取正整数值随机变量, 且其概率母函数为

$$g_N(s) = \sum_{n=1}^{\infty} s^n \mathbb{P}(N = n).$$

3. N 与 $\{X_j\}$ 相互独立.

则 $W = X_1 + X_2 + \cdots + X_N$ 的概率母函数为 $g_W(s) = g_N[g_X(s)]$.



例 5.4 设鸡蛋个数 N 服从 $\mathcal{P}(\lambda)$, λ 为正常数. 如果每颗蛋能孵出小鸡的概率为 p , 则能孵出小鸡的鸡蛋数 W 服从 $\mathcal{P}(\lambda p)$.

解 设 $X_i = 1$ or 0 , 根据第 i 个蛋有无孵出小鸡, $i = 1, 2, \dots$, 且 $W = X_1 + X_2 + \cdots + X_N$ 为能孵出小鸡的鸡蛋数.

由于 $\{X_i\}$ 独立同分布且 X_1 的概率母函数为 $g_X(s) = q + ps$ ($q = 1 - p$), 而 N 的概率母函数为 $g_N(s) = e^{\lambda(s-1)}$.

利用定理 5.2 得, W 的概率母函数为

$$g_W(s) = g_N[g_X(s)] = e^{\lambda(q+ps)-1} = e^{\lambda p(s-1)}.$$

由可逆性知, $W \sim \mathcal{P}(\lambda p)$.

5.1.2 随机向量的概率母函数

定义 5.2 (2-dimensional probability-generating function)

设 (X, Y) 是二维取非负整数值随机向量, 其分布列为 $p_{ik} = \mathbb{P}(X = i, Y = k)$, $i, k = 0, 1, 2, \dots$, 称 (s, t) 的函数

$$g(s, t) = \mathbb{E}(s^X t^Y) = \sum_{i=0}^{\infty} \sum_{k=0}^{\infty} p_{ik} s^i t^k, s, t \in [-1, 1],$$

为 (X, Y) 的概率母函数.



定理 5.3 (随机向量的概率母函数的性质)

设 $g(s, t)$ 是 (X, Y) 的概率母函数, 则

1. $|g(s, t)| \leq g(1, 1) = 1, |s| \leq 1, |t| \leq 1$;
2. $g_{aX+bY+c}(s) = s^c g(s^a, s^b)$, 其中 a, b, c 均为常数;
3. X 与 Y 独立, 等价于 $g(s, t) = g_X(s)g_Y(t), \forall s, t$;
4. $g(s, 1) = g_X(s), g(1, t) = g_Y(t)$;
- 5.

$$p_{ik} = \frac{1}{i!k!} \frac{\partial^{i+k} g(s, t)}{\partial s^i \partial t^k} \Big|_{s=t=0}, \quad i, k = 0, 1, 2, \dots;$$

6. 如果 $\mathbb{E}(X), \mathbb{E}(Y) < \infty$, 则

$$\mathbb{E}(X) = \frac{\partial g(s, t)}{\partial s} \Big|_{s=t=1}, \quad \mathbb{E}(Y) = \frac{\partial g(s, t)}{\partial t} \Big|_{s=t=1}.$$

7. 如果 $\mathbb{E}(X^2), \mathbb{E}(Y^2) < \infty$, 则

$$\begin{aligned} \mathbb{E}(X^2) &= \frac{\partial^2 g(s, t)}{\partial s^2} \Big|_{s=t=1} + \frac{\partial g(s, t)}{\partial s} \Big|_{s=t=1}, \\ \mathbb{E}(Y^2) &= \frac{\partial^2 g(s, t)}{\partial t^2} \Big|_{s=t=1} + \frac{\partial g(s, t)}{\partial t} \Big|_{s=t=1}, \\ \mathbb{E}(XY) &= \frac{\partial^2 g(s, t)}{\partial s \partial t} \Big|_{s=t=1}. \end{aligned}$$



5.2 矩母函数

定义 5.3 (moment-generating function 矩母函数)

设 X 是随机向量, 称

$$M_X(s) = \mathbb{E}(e^{sX}),$$

为 X 的矩母函数 (moment-generating function).

- 离散变量: $M_X(s) = \sum_j e^{sx_j} \mathbb{P}(X = x_j)$,
- 连续变量: $M_X(s) = \int_{-\infty}^{\infty} e^{sx} f_X(x) dx$.

仅当 $\mathbb{E}(e^{sX}) < \infty$ 时, 我们称 $M_X(s)$ 存在.

**定理 5.4 (矩母函数的性质)**

设 $M(s)$ 是 X 的矩母函数, $M^{(k)}(s)$ 是 $M(s)$ 的 k -阶导数. 则

1. $Y = aX + b$ 的矩母函数为 $M_Y(s) = e^{sb} M(sa)$;
2. $\mathbb{E}X^k = M^{(k)}(0), k = 1, 2, \dots$;
3. $M(0) = 1$; 当 X 仅取非负整数值时, $P(X = 0) = \lim_{s \rightarrow -\infty} M(s)$;
4. 可逆性: 如果存在一个正数 a , 使得对任意 $s \in [-a, a]$ 有 $M(s) < \infty$, 则 $M(s)$ 唯一地决定 X 的分布函数;
5. 如果 X_1, X_2, \dots, X_n 相互独立, $M_{X_i}(s) = \mathbb{E}(e^{sX_i})$ 是 X_i 的矩母函数, 则 $Y = X_1 + \dots + X_n$ 的矩母函数为

$$M_Y(s) = M_{X_1}(s) \cdots M_{X_n}(s)$$



5.2.1 部分常见随机变量的矩母函数

例 5.5 设离散型随机变量 X 的分布列为

X	2	3	5
\mathbb{P}	$\frac{1}{2}$	$\frac{1}{6}$	$\frac{1}{3}$

求其矩母函数 $M(s)$, 期望 $\mathbb{E}X$, 二阶矩 $\mathbb{E}X^2$.

解

$$\begin{aligned} M(s) &= \frac{1}{2}e^{2s} + \frac{1}{6}e^{3s} + \frac{1}{3}e^{5s}. \\ \mathbb{E}X &= M^{(1)}(0) = \left. \frac{1}{2}2e^{2s} + \frac{1}{6}3e^{3s} + \frac{1}{3}5e^{5s} \right|_{s=0} \\ &= \frac{1}{2} \cdot 2 + \frac{1}{6} \cdot 3 + \frac{1}{3} \cdot 5 = \frac{19}{6}. \\ \mathbb{E}X^2 &= M^{(2)}(0) = \left. \frac{1}{2}4e^{2s} + \frac{1}{6}9e^{3s} + \frac{1}{3}25e^{5s} \right|_{s=0} = \frac{71}{6}. \end{aligned}$$

例 5.6 指数分布 $\mathcal{E}(\lambda)$ 连续型随机变量 X 有概率密度函数 $f(x) = \lambda e^{-\lambda x} I_{\{x \geq 0\}}$, 求其矩母函数 $M(s)$, 期望 $\mathbb{E}X$, 二阶矩 $\mathbb{E}X^2$.

解 当 $s < \lambda$ 时, 有

$$M(s) = \lambda \int_0^{\infty} e^{sx} e^{-\lambda x} dx = \lambda \left. \frac{e^{(s-\lambda)x}}{s-\lambda} \right|_0^{\infty} = \frac{\lambda}{\lambda-s}.$$

当 $s \geq \lambda$ 时, 上积分为无穷. 当 $s < \lambda$ 时,

$$\begin{aligned} \mathbb{E}X &= M^{(1)}(0) = \left. \frac{\lambda}{(\lambda-s)^2} \right|_{s=0} = \frac{1}{\lambda}, \\ \mathbb{E}X^2 &= M^{(2)}(0) = \left. \frac{2\lambda}{(\lambda-s)^3} \right|_{s=0} = \frac{2}{\lambda^2}. \end{aligned}$$

例 5.7 混合分布 已知一银行有三位交易员, 每位交易员为顾客服务的时间皆服从指数分布. 两位快速交易员对应的参数为 $\lambda = 6$, 一位慢速交易员对应的参数为 $\lambda = 4$. 假设你来到银行等概率随机选择了一名交易员, 请求出你接受服务的时间的矩母函数.

解 设 X 为你接受服务的时间, 则 $f_X(x) = \left[\frac{2}{3}6e^{-6x} + \frac{1}{3}4e^{-4x} \right] I_{\{x \geq 0\}}$. 当 $s < 4$ 时, 有

$$M_X(s) = \int_0^{\infty} e^{sx} \left[\frac{2}{3}6e^{-6x} + \frac{1}{3}4e^{-4x} \right] dx = \frac{2}{3} \frac{6}{6-s} + \frac{1}{3} \frac{4}{4-s}.$$

反演: 若已知 X 的矩母函数形如 $p_1 \frac{\lambda_1}{\lambda_1-s} + p_2 \frac{\lambda_2}{\lambda_2-s}$, 则 X 是 X_1, X_2 的混合变量, 其中 $X_1 \sim \mathcal{E}(\lambda_1), X_2 \sim \mathcal{E}(\lambda_2)$, 且这两个变量被选中的概率分别为 p_1, p_2 相应密度函数为 $f_X(x) = p_1 f_{X_1}(x) + p_2 f_{X_2}(x)$.

例 5.8 正态分布 设连续型随机变量 $Z = X + Y$, 其中 $X \sim \mathcal{N}(\mu_1, \sigma_1^2), Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$, 且 X 和 Y 相互独立. 求 Z 的概率密度函数.

解

1. 若 $V \sim \mathcal{N}(0, 1)$, 则由定义可计算得到 $M_V(s) = e^{s^2/2}$.
2. 若 $W \sim \mathcal{N}(\mu, \sigma^2)$, 则由矩母函数性质 1 得到 $M_W(s) = e^{\mu s + (\sigma^2 s^2)/2}$.
3. 进而由性质 5 得 $M_Z(s) = M_X(s)M_Y(s) = e^{(\mu_1 + \mu_2)s + \frac{(\sigma_1^2 + \sigma_2^2)s^2}{2}}$.
4. 可见 $M_Z(s)$ 的形式符合正态分布对应的矩母函数, 由性质 4 推断 $Z \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 从而可直接得其概率密度函数.

独立的正态分布之和, 依然是正态分布!

随机数个相互独立的随机变量之和

设随机变量 X_1, X_2, \dots 独立同分布, 有共同的矩母函数 $M_X(s)$, N 为一个取正整数值的随机变量, 且独立于该随机变量列.

令 $W = X_1 + \dots + X_N$. 求 $M_W(s)$.

$$\begin{aligned}\mathbb{E}(e^{sW} | N = n) &= \mathbb{E}(e^{sX_1} \dots e^{sX_N} | N = n) \\ &= \mathbb{E}(e^{sX_1} \dots e^{sX_N}) = \mathbb{E}(e^{sX_1}) \dots \mathbb{E}(e^{sX_N}) \\ &= (M_X(s))^n.\end{aligned}$$

$$\begin{aligned}M_W(s) &= \mathbb{E}(e^{sW}) = \mathbb{E}[\mathbb{E}(e^{sW} | N = n)] = \mathbb{E}[(M_X(s))^N] \\ &= \sum_{n=1}^{\infty} (M_X(s))^n \mathbb{P}(N = n).\end{aligned}$$

对比 $M_N(s) = \mathbb{E}(e^{sN}) = \sum_{n=1}^{\infty} (e^s)^n \mathbb{P}(N = n)$.

例 5.9 小明为了买《概率论》这本书跑到一个满是书店的街道. 每家店有此书的概率皆为 p , 且与其它店相互独立. 小明逛每个店只找这本书, 找到就走, 或者这家店肯定没有他才走. 他一直逛下去直到买到此书. 假设在每个店内他花费的时间都是一个随机变量, 服从参数为 λ 的指数分布, 并且与其他任何事情都独立. 求小明逛书店的总时间的分布.

解 $X_i \sim \mathcal{E}(\lambda), N \sim G(p), W = X_1 + \dots + X_N$. 当 $s < \lambda$ 时, 有

$$M_{X_i}(s) = \frac{\lambda}{\lambda - s}.$$

而 $M_N(s) = \frac{pe^s}{1 - (1-p)e^s}$. 于是

$$M_W(s) = \frac{pM_X(s)}{1 - (1-p)M_X(s)} = \frac{p\lambda}{p\lambda - s}.$$

即 $Y \sim \mathcal{E}(p\lambda)$.

5.2.2 随机向量的矩母函数

定义 5.4 (多元矩母函数)

设 $\vec{X} = \{X_1, \dots, X_n\}'$ 是一个随机向量, 则对应的多元矩母函数可定义为

$$M_{\vec{X}}(\vec{s}) = \mathbb{E}(e^{\vec{s}'\vec{X}}) = \mathbb{E}(e^{s_1X_1 + \dots + s_nX_n}),$$

其中 $\vec{s} = (s_1, \dots, s_n)' \in \mathbb{R}^n$.



5.3 特征函数

定义 5.5 (characteristic function (C.F.) 特征函数)

对随机变量 X , 称

$$\phi(t) := \mathbb{E}(e^{itX}) = \mathbb{E} \cos(tX) + i\mathbb{E} \sin(tX), t \in \mathbb{R},$$

为 X 的特征函数 (characteristic function), 其中 $i = \sqrt{-1}$.



定理 5.5 (特征函数的性质)

设 $\phi(t) = \mathbb{E}(e^{itX})$, 则

1. $|\phi(t)| \leq \phi(0) = 1, \phi(-t) = \overline{\phi(t)}$;
2. $\phi(t)$ 在 $(-\infty, \infty)$ 上一致连续 ($|\phi(t+h) - \phi(t)| \leq \mathbb{E}|e^{ihX} - 1|$);
3. 如果 $\mathbb{E}(|X|^k) < \infty$, 则

$$\phi^{(k)}(t) = i^k \mathbb{E}(X^k e^{itX}), \phi^{(k)}(0) = i^k \mathbb{E}(X^k).$$

4. 对任意常数 a, b , 有

$$\phi_{aX+b}(t) = e^{itb} \phi_X(at).$$

5. 如果 X_k 有特征函数 $\phi_k(t)$, 且 X_1, \dots, X_n 相互独立, 则 $Y = X_1 + \dots + X_n$ 的特征函数为

$$\phi_Y(t) = \prod_{k=1}^n \phi_k(t).$$

**5.3.1 常见分布的特征函数**

例 5.10 二项分布 $B(n, p)$ 二项分布 $B(n, p)$ 的特征函数是

$$\phi(t) = \mathbb{E}(e^{itX}) = \sum_{j=0}^n e^{itj} \binom{n}{j} p^j q^{n-j} = (q + pe^{it})^n.$$

例 5.11 Poisson 分布 $\mathcal{P}(\lambda)$ Poisson 分布 $\mathcal{P}(\lambda)$ 的特征函数是

$$\phi(t) = \mathbb{E}(e^{itX}) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{\lambda(e^{it}-1)}.$$

例 5.12 几何分布 $G(p)$ 几何分布 $G(p)$ 的特征函数是

$$\phi(t) = \mathbb{E}(e^{itX}) = \sum_{k=1}^{+\infty} e^{itk} p q^{k-1} = \frac{pe^{it}}{1 - qe^{it}}.$$

例 5.13 均匀分布 $U(a, b)$ 均匀分布 $U(a, b)$ 有特征函数

$$\phi(t) = \frac{e^{itb} - e^{ita}}{it(b-a)}.$$

特别地, $U(-c, c)$ 有特征函数 $\frac{\sin(ct)}{(ct)}$.

例 5.14 指数分布 $\mathcal{E}(\lambda)$ 指数分布 $\mathcal{E}(\lambda)$ 有特征函数

$$\phi(t) = \left(1 - \frac{it}{\lambda}\right)^{-1}.$$

例 5.15 正态分布 $\mathcal{N}(\mu, \sigma^2)$ 正态分布 $\mathcal{N}(\mu, \sigma^2)$ 有特征函数

$$\phi(t) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right).$$

解 (i) 先求 $\mathcal{N}(0, 1)$ 的特征函数.

【方法 1: 形式运算】 将 i 视为常数, 形式地运算得到

$$\begin{aligned} \phi(t) &= \mathbb{E}(e^{itX}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-x^2/2} dx \\ &= e^{-t^2/2} \cdot \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{(x-it)^2}{2}} dx = e^{-t^2/2} \end{aligned}$$

【方法 2: 严格的数学推导】

$$\begin{aligned}\phi(t) &= \mathbb{E}(e^{itX}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-x^2/2} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \cos(tx) e^{-x^2/2} dx\end{aligned}$$

得

$$\begin{aligned}\phi'(t) &= -\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x \sin(tx) e^{-x^2/2} dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \sin(tx) d e^{-x^2/2} \\ &= -\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t \cos(tx) e^{-x^2/2} dx \\ &= -t\phi(t).\end{aligned}$$

即:

$$\frac{d}{dt} [\phi(t) e^{t^2/2}] = [\phi'(t) + t\phi(t)] e^{t^2/2} = 0$$

得 $\phi(t) e^{t^2/2} = C$. 因为 $C = \phi(0) = 1$ 得到

$$\phi(t) = e^{-t^2/2}.$$

(ii) 现设 $Y \sim \mathcal{N}(\mu, \sigma^2)$, 则

$$X = \frac{Y - \mu}{\sigma} \sim \mathcal{N}(0, 1), Y = \mu + \sigma X.$$

因此,

$$\mathbb{E}(e^{itY}) = \mathbb{E}(e^{it(\mu + \sigma X)}) = e^{it\mu} \mathbb{E}(e^{it\sigma X}) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right)$$

设 X_1, \dots, X_m 相互独立, $X_j \sim \mathcal{N}(\mu_j, \sigma_j^2)$, 则

$$Y = X_1 + \dots + X_m \sim \mathcal{N}\left(\sum_{j=1}^m \mu_j, \sum_{j=1}^m \sigma_j^2\right).$$

例 5.16 Cauchy 分布 Cauchy 分布, 其密度 $f(x) = \frac{1}{\pi(1+x^2)}, x \in \mathbb{R}$, 有特征函数

$$\phi(t) = e^{-|t|}.$$

例 5.17 Laplace 分布 Laplace 分布, 其密度 $f(x) = \frac{1}{2}e^{-|x|}$, 有特征函数

$$\phi(t) = \frac{1}{1+t^2}.$$

特征函数与分布函数

随机变量的特征函数和分布函数相互唯一决定

定理 5.6 (逆转公式)

设 $\phi(t)$ 是 X 的特征函数, $F(x)$ 是 X 的分布函数. 如果 $F(x)$ 在 a, b 连续, 则

$$\frac{1}{2\pi} \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-ita} - e^{-itb}}{it} \phi(t) dt = F(b) - F(a).$$



定理 5.7

如果 X 的特征函数满足 $\int_{\mathbb{R}} |\phi(t)| dt < \infty$, 则 X 有连续密度函数

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t) dt.$$

**定理 5.8**

如果 $\mathbb{E}|X|^n < \infty$, 则 X 的特征函数 $\phi(t)$ 满足

$$\phi(t) = \sum_{m=0}^n \frac{\mathbb{E}[(itX)^m]}{m!} + o(t^n).$$

特别地, 如果 $\mathbb{E}(X^2) < \infty$, 则

$$\phi(t) = 1 + it\mathbb{E}(X) - \frac{1}{2}t^2\mathbb{E}(X^2) + o(t^2).$$

**5.3.2 混合分布的特征函数****定理 5.9 (混合分布)**

设分布函数 $F_1(x), \dots, F_m(x)$ 的特征函数分别为 $\phi_1(t), \dots, \phi_m(t)$, $\lambda_i \geq 0$, 且 $\sum_{i=1}^m \lambda_i = 1$. 则 $F(x) =$

$$\sum_{i=1}^m \lambda_i F_i(x) \text{ 的特征函数为 } \phi(t) = \sum_{i=1}^m \lambda_i \phi_i(t).$$



注 $Y = \sum_{i=1}^m \lambda_i F_i$ 表示 Y 以概率 λ_i 等于 X_i , 对 $\{X_k, k = 1, \dots, m\}$ 之间的独立性无要求。此时 $Y \neq \sum_{i=1}^m \lambda_i X_i$.

5.3.3 随机向量的特征函数**定义 5.6 (随机向量的特征函数)**

设 $X = (X_1, \dots, X_n)$ 是随机向量, X 的特征函数定义为

$$\phi(t) = \mathbb{E} \left(e^{it'X} \right), t = (t_1, \dots, t_n) \in \mathbb{R}^n.$$

**定理 5.10**

设 $X = (X_1, \dots, X_n)$ 是随机向量, 则 X_1, \dots, X_n 相互独立的充要条件是

$$\phi(t) = \phi_1(t_1)\phi_2(t_2)\dots\phi_n(t_n),$$

其中 $\phi_k(t_k)$ 是 X_k 的特征函数, $k = 1, 2, \dots, n$.



例 5.18 设 X 是 Cauchy 分布, 其有密度函数 $f(x) = \frac{1}{\pi(1+x^2)}, x \in \mathbb{R}$. 令 $Y = aX, (a > 0)$. 证明 $\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t)$.

证明 首先 $\phi_X(t) = e^{-|t|}$. 故

$$\phi_Y(t) = \mathbb{E}(e^{itY}) = \mathbb{E}(e^{i(at)X}) = e^{-|at|} = e^{-a|t|}$$

和

$$\begin{aligned}\phi_{X+Y}(t) &= \mathbb{E}(e^{it(X+Y)}) = \mathbb{E}(e^{it(1+a)X}) \\ &= e^{-|(1+a)t|} = e^{-(1+a)|t|}.\end{aligned}$$

因此

$$\phi_{X+Y}(t) = e^{-(1+a)|t|} = e^{-|t|} \cdot e^{-a|t|} = \phi_X(t)\phi_Y(t).$$

此例说明: 尽管 $\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t)$, 但是推不出他们对应的随机变量是独立的.

5.4 大数定律

定理 5.11 (Weak law of large numbers, WLLN)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 且 $\text{Var}(X_1) < \infty$, 则对任意给定的 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - EX_1\right| \geq \varepsilon\right) = 0,$$

也称 $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛到 EX_1 , 记作

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{p} EX_1.$$



证明 设 $\{X_n\}$ 是独立同分布的随机序列, 且 $\text{Var}(X_1) < \infty$.

往证: 对 $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - EX_1\right| \geq \varepsilon\right) = 0$.

$$\begin{aligned}\mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - EX_1\right| \geq \varepsilon\right) &= \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)\right| \geq \varepsilon\right) \\ &\leq \frac{\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)}{\varepsilon^2} = \frac{\text{Var}(X_1)}{n\varepsilon^2} \rightarrow 0, n \rightarrow +\infty\end{aligned}$$

Recall: 切比雪夫不等式

对随机变量 X 和 $\varepsilon > 0$, 有

$$\mathbb{P}(|X - EX| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$$

定理 5.12 (辛钦大数定律)

设 $\{X_n\}$ 是 *i.i.d.*, 且 $\mathbb{E}|X_1| < \infty$, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{p} EX_1$$



定理 5.13 (WLLN 扩展 b)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 则存在实数列 $\{a_n\}$ 使得

$$\frac{1}{n} \sum_{k=1}^n X_k - a_n \xrightarrow{p} 0$$

的充分必要条件是

$$n\mathbb{P}(|X_1| \geq n) \rightarrow 0$$

此时, 可取 $a_n = \mathbb{E}(X_1 I_{\{|X_1| < n\}})$.

**定理 5.14 (Strong law of large numbers, SLLN)**

设 $\{X_n\}$ 是独立同分布的随机变量序列:

(1) 若 $\mathbb{E}|X_1| < \infty$, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} EX_1 \text{ 几乎处处收敛};$$

(2) 反之, 若

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} C \text{ 几乎处处收敛},$$

则 $\mathbb{E}|X_1| < \infty$, 且 $C = EX_1$.



注 几乎处处收敛, 以概率 1 收敛: $\mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n X_k = EX_1\right) = 1$

例 5.19 经验分布 设 $\{X_j\}$ 是概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上独立同分布的随机序列, 用 x_j 表示 X_j 的观测值, 即对某个确定的 $\omega \in \Omega$, 有

$$x_j = X_j(\omega), \quad j = 1, 2, \dots$$

则以概率 1, 观测数列 $\{x_j\}$ 可以决定 X_j 的分布函数 $F(x)$.

证明 对任何确定的 $x \in \mathcal{R}$, 定义

$$g(X_j) = \begin{cases} 1, & \text{if } X_j \leq x, \\ 0, & \text{if } X_j > x. \end{cases}$$

$j = 1, 2, \dots$ 则 $\{g(X_j)\}$ 是独立同分布的随机序列. 由 SLLN,

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{j=1}^n g(X_j) = Eg(X_1) = \mathbb{P}(X_1 \leq x) = F(x) \quad a.s.$$

即以概率 1 有 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{j=1}^n g(x_j) = F(x)$.

记 $F_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x)$ (经验分布函数).

例 5.20 Monte Carlo 蒙特卡洛 设需估计某复杂有界函数 $f(x)$ 在区间 $[a, b]$ 上的积分 $\int_a^b f(x)dx$.

解 从 A 中随机抽取 n 个点 $(X_1, Y_1), \dots, (X_n, Y_n)$. 用 I_j 表示 (X_j, Y_j) 落入 B 否. 则

$$\text{以概率 1 有 } \frac{1}{n} \sum_{j=1}^n I_j \rightarrow EI_j = \mathbb{P}(I_j = 1) = \frac{\int_a^b f(x)dx}{c(b-a)} \quad I_j = 0$$

$$\int_a^b f(x)dx \approx c(b-a) \frac{1}{n} \sum_{j=1}^n I_j.$$

5.5 收敛性的一些定义

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间, X_n 和 X 是随机变量, 其分布函数分别为 $F_n(x)$ 和 $F(x)$, 即.

$$F_n(x) = \mathbb{P}(X_n \leq x), \quad F(x) = \mathbb{P}(X \leq x).$$

定义 5.7 (数列的收敛)

设 $\{a_i\}$ 是实数列, a 为一实数, 如果对 $\forall \varepsilon > 0$, 存在正整数 N , 使得当 $n \geq N$ 时, 有

$$|a_n - a| \leq \varepsilon,$$

则称数列 $|a_n|$ 收敛于 a , 记作 $\lim_{n \rightarrow \infty} a_n = a$.



定义 5.8 (convergence in distribution)

如果在 $F(x)$ 的连续点 x , 有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

则称 X_n 依分布收敛到 X (convergence in distribution), 记作 $X_n \xrightarrow{d} X$, 或者称 F_n 弱收敛到 F (weak convergence), 记作 $F_n \rightarrow F$.



定义 5.9 (almost sure convergence)

如果

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1,$$

则称 X_n 几乎处处收敛到 X (almost sure convergence), 记作 $X_n \xrightarrow{a.s.} X$, 或 $X_n \rightarrow X$ a.s.



对 $\forall \varepsilon > 0$,

$$\begin{aligned} \left\{ \lim_{n \rightarrow \infty} X_n = X \right\} &= \left\{ \omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \\ &\rightarrow \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} \{ \omega : |X_k(\omega) - X(\omega)| < \varepsilon \} \\ &= \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} \{ |X_k - X| < \varepsilon \} = \liminf_{n \rightarrow \infty} A_n, \end{aligned}$$

with $A_n = \{ |X_n - X| < \varepsilon \}$.

注 $\lim_{n \rightarrow \infty} a_n = a \Leftrightarrow \forall \varepsilon > 0, \exists n, \text{ s.t. } \forall k \geq n, |a_k - a| \leq \varepsilon$

定义 5.10 (convergence in probability)

如果对 $\forall \varepsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0,$$

则称 X_n 依概率收敛到 X (convergence in probability), 记作 $X_n \xrightarrow{p} X$, 或 $X_n \rightarrow X$ in prob.



对 $\forall \varepsilon > 0$, denote $A_n = \{ \omega : |X_n(\omega) - X(\omega)| < \varepsilon \} = \{ |X_n - X| < \varepsilon \}$.

则

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = \lim_{n \rightarrow \infty} \mathbb{P}(A_n^c) = \lim_{n \rightarrow \infty} [1 - \mathbb{P}(A_n)] = 1 - \lim_{n \rightarrow \infty} \mathbb{P}(A_n).$$

故 $\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) = 0 \Leftrightarrow \lim_{n \rightarrow \infty} \mathbb{P}(A_n) = 1$.

定义 5.11 (L_p convergence)


对 $p > 0$, 如果

$$\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^p) = 0,$$

则称 X_n 在 L_p 下收敛到 X , 记作 $X_n \xrightarrow{L_p} X$, 或 $X_n \rightarrow X$ in L_p .



例如, $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|) = 0 \Leftrightarrow X_n \xrightarrow{L_1} X$.

5.6 各种收敛之间的关系**定理 5.15 (a.s. implies in prob.)**

如果 $X_n \xrightarrow{a.s.} X$, 则 $X_n \xrightarrow{p} X$.



证明 注意到, 对 $\forall \varepsilon > 0$,

$$\left\{ \lim_{n \rightarrow \infty} X_n = X \right\} \subset \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} \{|X_k - X| < \varepsilon\}$$

因此, 利用概率的连续性可得

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) &\leq \lim_{n \rightarrow \infty} \mathbb{P}(\bigcup_{k=n}^{\infty} |X_k - X| \geq \varepsilon) \\ &= \mathbb{P}\left(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} \{|X_k - X| \geq \varepsilon\}\right) \\ &= 1 - \mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} \{|X_k - X| < \varepsilon\}\right) = 1 - 1 = 0 \end{aligned}$$

定理 5.16 (L_p implies in prob.)

如果 $X_n \xrightarrow{L_p} X$, 则 $X_n \xrightarrow{p} X$.



证明 对 $\forall \varepsilon > 0$, 利用 Markov 不等式可得.

$$\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - X| \geq \varepsilon) \leq \lim_{n \rightarrow \infty} \frac{1}{\varepsilon^p} \mathbb{E}(|X_n - X|^p) = 0.$$

定理 5.17 (in prob. implies in dist.)

如果 $X_n \xrightarrow{p} X$, 则 $X_n \xrightarrow{d} X$.



证明 令 $F_n(x) = \mathbb{P}(X_n \leq x)$ 和 $F(x) = \mathbb{P}(X \leq x)$. 首先,

$$\begin{aligned} F_n(x) &= \mathbb{P}(X_n \leq x, |X_n - X| \leq \varepsilon) + \mathbb{P}(X_n \leq x, |X_n - X| > \varepsilon) \\ &\leq \mathbb{P}(X \leq x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) \\ &= F(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon) \end{aligned}$$

另一方面,

$$\begin{aligned} F_n(x) &= 1 - \mathbb{P}(X_n > x) \\ &= 1 - \mathbb{P}(X_n > x, |X_n - X| \leq \varepsilon) - \mathbb{P}(X_n > x, |X_n - X| > \varepsilon) \\ &\geq 1 - \mathbb{P}(X > x - (X_n - X), |X_n - X| \leq \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \\ &\geq 1 - \mathbb{P}(X > x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \\ &= F(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \end{aligned}$$

因此,

$$F(x - \varepsilon) - \mathbb{P}(|X_n - X| > \varepsilon) \leq F_n(x) \leq F(x + \varepsilon) + \mathbb{P}(|X_n - X| > \varepsilon)$$

令 $n \rightarrow \infty$,

$$F(x - \varepsilon) \leq \liminf_n F_n(x) \leq \limsup_n F_n(x) \leq F(x + \varepsilon).$$

如果 $F(x)$ 在 x 处连续, 则当 $\varepsilon \downarrow 0$, 有 $F(x - \varepsilon) \uparrow F(x)$ 和 $F(x + \varepsilon) \downarrow F(x)$. 所以

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

即, $X_n \xrightarrow{d} X$.

一些反例

例 5.21

$$X_n \xrightarrow{d} X \not\Rightarrow X_n \xrightarrow{p} X$$

解 $\{X_n\}$ 独立同分布 $\sim \mathcal{N}(0, 1)$, 则 $X_n \xrightarrow{d} X_1$. 但 $n \neq 1$ 时, $X_n - X_1 \sim \mathcal{N}(0, 2)$, 即 $\frac{X_n - X_1}{\sqrt{2}} \sim \mathcal{N}(0, 1)$, 有 $\frac{X_n - X_1}{\sqrt{2}}$ 与 X_1 同分布, 从而

$$\mathbb{P}(|X_n - X_1| > 1) = \mathbb{P}\left(\left|\frac{X_n - X_1}{\sqrt{2}}\right| > \frac{1}{\sqrt{2}}\right) = \mathbb{P}\left(|X_1| > \frac{1}{\sqrt{2}}\right) > 0$$

例 5.22

$$X_n \xrightarrow{d} C \Leftrightarrow X_n \xrightarrow{p} C, \text{ 其中 } C \text{ 为常数.}$$

例 5.23

$$X_n \xrightarrow{p} X \not\Rightarrow X_n \xrightarrow{L_p} X$$

解 取概率空间 $(\Omega, \mathcal{F}, \mathbb{P}) = ((0, 1), \mathcal{B}((0, 1)), \lambda)$, $\lambda(A) = \text{length}(A)$. 即一维几何概型. 定义

$$X_n(\omega) = \begin{cases} n, & \text{if } \omega \in (0, n^{-p}], \\ 0, & \text{if } \omega \in (n^{-p}, 1), \end{cases} \quad (1)$$

且 $X \equiv 0$. 则, 对 $\forall \varepsilon > 0$, 当 $n \rightarrow \infty$,

$$\begin{aligned} \mathbb{P}(|X_n - 0| > \varepsilon) &= \mathbb{P}(X_n > \varepsilon) = \mathbb{P}(X_n = n) \\ &= \mathbb{P}(\{\omega : \omega \in (0, n^{-p}]\}) = \mathbb{P}((0, n^{-p}]) = n^{-p} \\ &\rightarrow 0 \end{aligned}$$

但是 $\mathbb{E}(|X_n - 0|^p) = 1$.

例 5.24

$$X_n \xrightarrow{L_p} X \not\Rightarrow X_n \xrightarrow{L_q} X \quad (p < q).$$

例 5.25

$$X_n \xrightarrow{a.s.} X \not\Rightarrow X_n \xrightarrow{L_p} X$$

解 X_n 的定义见上页 (1). 对 $\forall \omega \in \Omega$, 都有 $X_n(\omega) \rightarrow 0 \equiv X$. 但是 $\mathbb{E}(|X_n - 0|^p) = 1$.

例 5.26

$$X_n \xrightarrow{L_p} X \not\Rightarrow X_n \xrightarrow{a.s.} X. \quad (\text{thus } X_n \xrightarrow{p} X \not\Rightarrow X_n \xrightarrow{a.s.} X.)$$

解 假设 $\{X_n\}$ 独立, 且 X_n 定义如下:

$$\mathbb{P}(X_n = 0) = 1 - n^{-1}, \quad \mathbb{P}(X_n = 1) = n^{-1}.$$

则 $X_n \xrightarrow{L_1} 0$. 但是 $X_n \not\xrightarrow{a.s.} 0$. 令 $A_n = \{X_n = 1\}$, 则

$$\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \frac{1}{n} = \infty.$$

由 Borel-Cantelli 引理, “ $\{A_n\}$ 有无穷多个发生” 的概率为 1.

5.7 常见的收敛性相关定理

定理 5.18 (Continuous mapping theorem)

设 $\{X, X_n\}$ 是随机元序列, g 连续, 则

1. $X_n \xrightarrow{a.s.} X \Rightarrow g(X_n) \xrightarrow{a.s.} g(X)$;
2. $X_n \xrightarrow{p} X \Rightarrow g(X_n) \xrightarrow{p} g(X)$;
3. $X_n \xrightarrow{d} X \Rightarrow g(X_n) \xrightarrow{d} g(X)$.



但是 $X_n \xrightarrow{L_p} X \not\Rightarrow g(X_n) \xrightarrow{L_p} g(X)$.

定理 5.19 (Slutsky's theorem)

假设 $X_n \xrightarrow{d} X, Y_n \xrightarrow{d} c$, 则

1. $X_n + Y_n \xrightarrow{d} X + c$;
2. $X_n Y_n \xrightarrow{d} cX$;
3. $X_n/Y_n \xrightarrow{d} X/c, (c \neq 0)$.



定理 5.20 (Delta Method)

假设 $\sqrt{n}(X_n - a) \xrightarrow{d} \mathcal{N}(0, V)$, $g: \mathbb{R} \rightarrow \mathbb{R}$ 是一个连续可导函数, 则

$$\sqrt{n}(g(X_n) - g(a)) \xrightarrow{d} \mathcal{N}(0, (g'(a))^2 \cdot V);$$



定理 5.21 (Continuity theorem, 连续性定理)

设 X_n 的特征函数为 $\phi_n(t)$. X 的特征函数为 $\phi(t)$. 则 X_n 依分布收敛到 X 的充分必要条件是,

$$\lim_{n \rightarrow \infty} \phi_n(t) = \phi(t), \quad \forall t \in \mathbb{R}$$



此定理是概率论中最常用、最重要的定理之一.

定理 5.22

设随机向量 X_n 的特征函数 $\phi_n(t)$ 收敛到在 $t=0$ 处连续的函数 $\phi(t)$, 则 $\phi(t)$ 是某个随机向量 X 的特征函数, 并且对任何常数向量 a , 有 $a^T X_n \xrightarrow{d} a^T X$.

**推论 5.1**

设随机变量 X_n 的特征函数 $\phi_n(t)$ 收敛到在 $t=0$ 处连续的函数 $\phi(t)$, 则 $\phi(t)$ 是某个随机变量 X 的特征函数, 并且有 $X_n \xrightarrow{d} X$.



判定依分布收敛, 可借助特征函数的收敛性

定理 5.23

设随机向量序列 $\{X_n, n=1, 2, \dots\}$ 和随机向量 X 的维度一致, 则 $X_n \xrightarrow{d} X$ 的充分必要条件是: 对任何常数向量 a , 有 $a^T X_n \xrightarrow{d} a^T X$.

**引理 5.1 (Cramér-Wold)**

设 X, Y 都是 p -维随机向量. 则 X, Y 同分布的充分必要条件是: 对任何常数向量 $a \in \mathbb{R}^p$, 有 $a^T X, a^T Y$ 同分布.



向量问题都可转化为一维

5.8 中心极限定理

定理 5.24 (Lindeberg-Lévy 中心极限定理)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 其期望为 μ , 方差为 $\sigma^2 < \infty$, 记 $S_n = X_1 + \dots + X_n$, 则

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} \mathcal{N}(0, 1).$$



n 充分大时提供近似分布:

$$S_n \approx \mathcal{N}(E(S_n), \text{Var}(S_n)) \approx \mathcal{N}(n\mu, n\sigma^2)$$

定理 (Lindeberg-Lévy 中心极限定理 - 样本均值形式)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 其期望为 μ , 方差为 $\sigma^2 < \infty$, 记 $M_n = (X_1 + \dots + X_n)/n$, 则

$$\frac{M_n - E(M_n)}{\sqrt{\text{Var}(M_n)}} \xrightarrow{d} \mathcal{N}(0, 1).$$



n 充分大时提供近似分布:

$$M_n \approx \mathcal{N}(E(M_n), \text{Var}(M_n)) \approx \mathcal{N}(\mu, \sigma^2/n)$$

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} = \frac{1}{\sqrt{n}} \sum_{k=1}^n \frac{(X_k - \mu)}{\sigma} = \frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$$

证明

令 $Y_k = (X_k - \mu)/\sigma$. 则 $\{Y_k\}$ 独立同分布, 其期望为 0, 方差为 1. 用 $\phi(t) = \mathbb{E}e^{itY_1}$ 表示 Y_1 的特征函数. 注意到

$$\phi'(0) = i\mathbb{E}Y_1 = 0, \quad \phi''(0) = i^2\mathbb{E}Y_1^2 = -1.$$

利用 Taylor 展开, 可得

$$\phi(t) = \phi(0) + \phi'(0)t + \frac{1}{2}\phi''(0)t^2 + o(t^2).$$

所以 $\frac{1}{\sigma\sqrt{n}} \sum_{k=1}^n (X_k - \mu)$ 的特征函数为

$$\begin{aligned}\phi_n(t) &= \mathbb{E} \exp(it(Y_1 + \cdots + Y_n)/\sqrt{n}) \\ &= [\phi(t/\sqrt{n})]^n = \left(1 - \frac{t^2}{2n} + o(t^2/n)\right)^n \\ &\rightarrow e^{-t^2/2}, \quad (n \rightarrow \infty)\end{aligned}$$

由连续性定理 (Continuity theorem) 可知, 结论成立.

例 5.27 设人群中疫苗有效的比例为 μ . 随机抽 n 个人. X_i 表示疫苗对第 i 个人是否有效. 通过样本中有效比例 $M_n = (X_1 + \cdots + X_n)/n$ 认识 μ , 需多少样本量能以 95% 概率保证误差率小于 3%?

解 求适当的 n 使 $\mathbb{P}(|M_n - \mu| < 0.03) \geq 0.95$.

$$\begin{aligned}&= \mathbb{P}\left(\left|\frac{M_n - \mu}{\sigma/\sqrt{n}}\right| < \frac{0.03}{\sigma/\sqrt{n}}\right) \quad \sigma = \sqrt{\mu(1-\mu)} \\ &\approx \mathbb{P}\left(|Z| < \frac{0.03\sqrt{n}}{\sigma}\right) \quad Z \sim \mathcal{N}(0, 1) \\ &\geq \mathbb{P}(|Z| < 0.06\sqrt{n}) = 0.95 \quad \sigma \leq \frac{1}{2}\end{aligned}$$

取 $n = \left(\frac{1.96}{0.06}\right)^2 \approx 1068$ 即可.

定理 5.25 (Lindeberg-Feller, CLT (选修))

设 $\{X_n\}$ 是独立的 r.v.s., 则: 方差序列 $\{\sigma_k^2 := \text{var}(X_k)\}$ 满足

$$B_n^2 = \sum_{k=1}^n \text{var}(X_k) \rightarrow \infty, \quad \frac{\sigma_n^2}{B_n^2} \rightarrow 0 \quad (3)$$

并且中心极限定理

$$\frac{1}{B_n} \sum_{k=1}^n (X_k - EX_k) \xrightarrow{d} \mathcal{N}(0, 1)$$

成立的充分必要条件是 Lindeberg 条件成立, 即: 对 $\forall \varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{k=1}^n \mathbb{E}\{(X_k - EX_k)^2 I_{\{|X_k - EX_k| > \varepsilon B_n\}}\} = 0.$$



条件 (3) $\Leftrightarrow \lim_{n \rightarrow \infty} \max_{1 \leq k \leq n} \frac{\sigma_k^2}{B_n^2} = 0$ (Feller 条件)

5.8.1 中心极限定理的离散修正

定理 5.26 (de Moivre-Laplace, CLT, 1716)

设 $S_n \sim B(n, p)$, n 充分大, k 和 m 是非负整数, 则

$$\mathbb{P}(k \leq S_n \leq m) \approx \Phi\left(\frac{m - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k - np}{\sqrt{np(1-p)}}\right)$$

其修正形式【近似更为精确】:

$$\mathbb{P}(k \leq S_n \leq m) \approx \Phi\left(\frac{m+0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{k-0.5 - np}{\sqrt{np(1-p)}}\right)$$

更重要的是: 修正形式可以计算单点概率 $\mathbb{P}(S_n = k)$.

该修正方法对其他离散型随机变量同样适用!

例 5.28 设 $S_n \sim B(36, 0.5)$, 求概率 $\mathbb{P}(S_n \leq 21)$.

解 其精确的概率为:

$$\mathbb{P}(S_n \leq 21) = \sum_{k=0}^{21} \binom{36}{k} 0.5^{36} = 0.8785.$$

利用中心极限定理, 若端点不经修正, 则近似概率为:

$$\mathbb{P}(S_n \leq 21) \approx \Phi\left(\frac{21 - np}{\sqrt{np(1-p)}}\right) = \Phi\left(\frac{21 - 18}{3}\right) = 0.8413.$$

修正之后的近似为:

$$\mathbb{P}(S_n \leq 21) \approx \Phi\left(\frac{21.5 - np}{\sqrt{np(1-p)}}\right) = \Phi(1.17) = 0.8789995.$$

另: $\mathbb{P}(S_n = 19) = 0.1251$, 正态近似 $\mathbb{P}(S_n = 19) \approx 0.124$

5.9 多元正态分布

定义 5.12 (Multivariate normal distribution (MVN) 定义)

当 Σ 正定时, $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$ 有联合密度函数

$$f(\vec{x}) = \frac{1}{(\sqrt{2\pi})^n \sqrt{\det(\Sigma)}} \exp\left[-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\right]$$

\vec{X} 的特征函数

$$\phi_{\vec{X}}(\vec{t}) = E \exp(i\vec{t}^T \vec{X}) = \exp\left[i\vec{t}^T \vec{\mu} - \frac{1}{2}\vec{t}^T \Sigma \vec{t}\right]$$

从中可以看出, \vec{X} 的期望和协方差矩阵唯一决定了 \vec{X} 的特征函数. 由于随机向量的特征函数与分布函数是相互唯一决定的, 所以 \vec{X} 的分布由 $\vec{\mu}$ 和 Σ 唯一决定.

定义 5.13 (multivariate normal distribution, MVN 等价定义)

设 $\vec{\mu} = (\mu_1, \mu_2, \dots, \mu_n)^T$ 是 n 维常数列向量, \mathbf{B} 是 $n \times m$ 常数矩阵, $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_m$ 是相互独立且服从标准正态分布的随机变量. 如果

$$\vec{X} = \vec{\mu} + \mathbf{B}\vec{\varepsilon}$$

其中 $\vec{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_m)^T$, 且矩阵 $\mathbf{B}\mathbf{B}^T$ 满秩, 就称 $\vec{X} = (X_1, X_2, \dots, X_n)^T$ 服从 n -维正态分布, 记作 $X \sim \mathcal{N}(\vec{\mu}, \mathbf{B}\mathbf{B}^T)$.

证明 因为 Σ 是正定的, 所以存在可逆方阵 B 使得 $\Sigma = \mathbf{B}\mathbf{B}^T$, 且 $\vec{X} = \vec{\mu} + B\vec{\varepsilon}$, 其中 $\vec{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. 易得 $\vec{\varepsilon}$ 的密度函数为

$$f_{\vec{\varepsilon}}(\vec{y}) = \frac{1}{(\sqrt{2\pi})^n} \exp\left(-\frac{1}{2}\vec{y}^T \vec{y}\right)$$

注意到

$$\{\vec{X} = \vec{x}\} = \{\vec{\varepsilon} = B^{-1}(\vec{x} - \vec{\mu})\}$$

且下面的映射是可逆的

$$\vec{y} = B^{-1}(\vec{x} - \vec{\mu})$$

其雅克比行列式为

$$\left| \frac{\partial \vec{y}}{\partial \vec{x}} \right| = |B^{-1}| = \frac{1}{\sqrt{\det(\Sigma)}}$$

故

$$\begin{aligned} f(\vec{x}) &= \frac{1}{(\sqrt{2\pi})^n} \exp \left\{ -\frac{1}{2} [B^{-1}(\vec{x} - \vec{\mu})]^T [B^{-1}(\vec{x} - \vec{\mu})] \right\} \left| \frac{\partial y}{\partial x} \right| \\ &= \frac{1}{(\sqrt{2\pi})^n \sqrt{\det(\Sigma)}} \exp \left[-\frac{1}{2} (\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu}) \right] \end{aligned}$$

$\vec{\varepsilon}$ 的特征函数

$$\begin{aligned} \phi_{\vec{\varepsilon}}(\vec{t}) &= E[\exp(i\vec{t}^T \vec{\varepsilon})] = E[\exp(it_1 \varepsilon_1 + \cdots + it_n \varepsilon_n)] = E \left[\prod_{i=1}^n \exp(it_i \varepsilon_i) \right] \\ &= \prod_{i=1}^n E[\exp(it_i \varepsilon_i)] = \prod_{j=1}^n \exp \left(\frac{-t_j^2}{2} \right) = \exp \left(-\frac{\vec{t}^T \vec{t}}{2} \right) \end{aligned}$$

其中 $\vec{t} = (t_1, t_2, \dots, t_n)^T \in \mathbb{R}^n$.

\vec{X} 的特征函数

$$\begin{aligned} \phi_{\vec{X}}(\vec{t}) &= E \exp(i\vec{t}^T \vec{X}) = E \exp[i(\vec{t}^T \vec{\mu} + \vec{t}^T \mathbf{B} \vec{\varepsilon})] \\ &= \exp(i\vec{t}^T \vec{\mu}) E \exp[i(\vec{t}^T \mathbf{B}) \vec{\varepsilon}] \\ &= \exp \left[i\vec{t}^T \vec{\mu} - \frac{1}{2} (\vec{t}^T \mathbf{B}) (\vec{t}^T \mathbf{B})^T \right] \\ &= \exp \left[i\vec{t}^T \vec{\mu} - \frac{1}{2} \vec{t}^T \mathbf{B} \mathbf{B}^T \vec{t} \right] \end{aligned}$$

定理 5.27

如果 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$, 则对任意常数矩阵 \mathbf{A} 和常数向量 \vec{b} , 只要 $\vec{b} + \mathbf{A}\vec{X}$ 有意义, $\mathbf{A}\Sigma\mathbf{A}^T$ 满秩, 则 $\vec{Y} = \vec{b} + \mathbf{A}\vec{X} \sim \mathcal{N}(\vec{b} + \mathbf{A}\vec{\mu}, \mathbf{A}\Sigma\mathbf{A}^T)$.



证明 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma) \Rightarrow$ 存在 \mathbf{B} 是 $n \times m$ 常数矩阵; $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_m$ 是相互独立且服从标准正态分布的随机变量, 使得 $\vec{X} = \vec{\mu} + \mathbf{B}\vec{\varepsilon}$, 其中 $\vec{\varepsilon} = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_m)^T$

$\vec{Y} = \vec{b} + \mathbf{A}\vec{X} = (\vec{b} + \mathbf{A}\vec{\mu}) + (\mathbf{A}\mathbf{B})\vec{\varepsilon}$, 即 \vec{Y} 服从多元正态分布. 计算其均值和协方差即可得.

定理 5.28 (重要判定法则)

$\vec{X} = (X_1, X_2, \dots, X_n)^T \sim \mathcal{N}(\vec{\mu}, \Sigma)$ 的充要条件是对任何 $\vec{a} = (a_1, a_2, \dots, a_n)^T \in \mathbb{R}^n$,

$$Y := \vec{a}^T \vec{X} \sim \mathcal{N}(\vec{a}^T \vec{\mu}, \vec{a}^T \Sigma \vec{a}).$$



证明 (\Rightarrow) Y 的特征函数

$$\phi_Y(t) = E \exp(itY) = E \exp[i(t\vec{a}^T)\vec{X}] = \exp \left[it(\vec{a}^T \vec{\mu}) - \frac{1}{2} t^2 \vec{a}^T \Sigma \vec{a} \right] \quad (1)$$

所以 $Y \sim \mathcal{N}(\vec{a}^T \vec{\mu}, \vec{a}^T \Sigma \vec{a})$.

(\Leftarrow) 在 (1) 中取 $t = 1$, 得

$$E \exp(i\vec{a}^T \vec{X}) = \phi_Y(1) = E \exp(iY) = \exp \left[i\vec{a}^T \vec{\mu} - \frac{1}{2} \vec{a}^T \Sigma \vec{a} \right].$$

故 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$.

定理 5.29 (独立性判定)

设 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$, 如果

$$\vec{X} = \begin{pmatrix} \vec{X}_1 \\ \vec{X}_2 \end{pmatrix}, \quad \vec{\mu} = \begin{pmatrix} \vec{\mu}_1 \\ \vec{\mu}_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} \end{pmatrix},$$

且 $\vec{X}_1, \vec{\mu}_1$ 和方阵 Σ_{11} 的行数相同, 则 \vec{X}_1 和 \vec{X}_2 独立, 而且

$$\vec{X}_1 \sim \mathcal{N}(\vec{\mu}_1, \Sigma_{11}), \quad \vec{X}_2 \sim \mathcal{N}(\vec{\mu}_2, \Sigma_{22})$$



证明 \vec{X} 的特征函数

$$\begin{aligned} \phi(\vec{t}) &= \phi(\vec{t}_1, \vec{t}_2) = \exp \left[i\vec{t}^T \vec{\mu} - \frac{1}{2} \vec{t}^T \Sigma \vec{t} \right] \\ &= \exp \left[i\vec{t}_1^T \vec{\mu}_1 - \frac{1}{2} \vec{t}_1^T \Sigma_{11} \vec{t}_1 + i\vec{t}_2^T \vec{\mu}_2 - \frac{1}{2} \vec{t}_2^T \Sigma_{22} \vec{t}_2 \right] \\ &= \exp \left[i\vec{t}_1^T \vec{\mu}_1 - \frac{1}{2} \vec{t}_1^T \Sigma_{11} \vec{t}_1 \right] \times \exp \left[i\vec{t}_2^T \vec{\mu}_2 - \frac{1}{2} \vec{t}_2^T \Sigma_{22} \vec{t}_2 \right] \\ &= \phi_1(\vec{t}_1) \phi_2(\vec{t}_2) \end{aligned}$$

定理 5.30 (独立性判定)

如果 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$, 则 (X_1, X_2, \dots, X_n) 相互独立的充要条件是

$$\Sigma = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2).$$

**定理 5.31 (条件分布)**

设 $\vec{X} \sim \mathcal{N}(\vec{\mu}, \Sigma)$, $\det(\Sigma) > 0$ 和分块矩阵

$$\vec{X} = \begin{pmatrix} \vec{X}_1 \\ \vec{X}_2 \end{pmatrix}, \quad \vec{\mu} = \begin{pmatrix} \vec{\mu}_1 \\ \vec{\mu}_2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

其中 $\vec{X}_1, \vec{\mu}_1$ 和方阵 Σ_{11} 的行数相同, 则在条件 $\vec{X}_1 = \vec{x}_1$ 下, \vec{X}_2 服从多元正态分布 $\mathcal{N}(\vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$.



证明 令

$$\begin{pmatrix} \vec{Y}_1 \\ \vec{Y}_2 \end{pmatrix} = \begin{pmatrix} I_{11} & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I_{22} \end{pmatrix} \begin{pmatrix} \vec{X}_1 - \vec{\mu}_1 \\ \vec{X}_2 - \vec{\mu}_2 \end{pmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12} \end{pmatrix}\right)$$

故 \vec{Y}_1 与 \vec{Y}_2 独立, 注意到 $\vec{Y}_2 = \vec{X}_2 - \vec{\mu}_2 - \Sigma_{21}\Sigma_{11}^{-1}\vec{Y}_1$,

所以

$$\vec{X}_2 = \vec{Y}_2 + \vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{X}_1 - \vec{\mu}_1)$$

从而

$$\begin{aligned} P(\vec{X}_2 \leq \vec{x}_2 \mid \vec{X}_1 = \vec{x}_1) &= P(\vec{Y}_2 + \vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1) \leq \vec{x}_2 \mid \vec{X}_1 = \vec{x}_1) \\ &= P(\vec{Y}_2 + \vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1) \leq \vec{x}_2 \mid \vec{Y}_1 = \vec{x}_1 - \vec{\mu}_1) \\ &= P(\vec{Y}_2 + \vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1) \leq \vec{x}_2) \end{aligned}$$

又 $\vec{Y}_2 \sim \mathcal{N}(\mathbf{0}, \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$, 故

$$\begin{aligned} \vec{X}_2 \mid_{\vec{X}_1 = \vec{x}_1} &\stackrel{d}{=} \vec{Y}_2 + \vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1) \\ &\sim \mathcal{N}(\vec{\mu}_2 + \Sigma_{21}\Sigma_{11}^{-1}(\vec{x}_1 - \vec{\mu}_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}). \end{aligned}$$