



2026 春 多元统计分析 课程笔记

作者：招财鱼

组织：清华大学

时间：2026 Spring

If you' re dissatisfied with the world, change yourself. -- Kusanagi Motoko

目录

第一部分 Foundations	1
第 1 节 Descriptive statistics	2
1 基本设置: 展示与建模 (Basic Setting: Display & Modeling)	2
1.1 多元数据的组织	2
1.2 多元数据的建模	2
1.3 随机抽样	2
1.4 随机样本的几何意义	3
2 马氏距离 (Mahalanobis Distance)	3
2.1 距离 (Distance)	3
2.2 距离 (无相关)	3
2.3 距离 (有相关)	3
2.4 马氏距离定义	4
2.5 二次型 (Quadratic Form)	4
2.6 距离的期望	4
2.7 谱分解 (Spectral Decomposition)	5
2.8 非负定与正定矩阵 (Nonnegative, Positive Definite Matrix)	5
2.9 逆矩阵与平方根矩阵 (Inverse and Square-root Matrix)	5
2.10 马氏距离的几何解释与推导	6
3 描述统计量 (Descriptive Statistics)	7
3.1 单变量 (Single Variable)	7
3.2 双变量 (Two Variables)	7
3.3 矩阵形式 (Matrix Form)	8
第 2 节 Multivariate normal distribution theory	9
1 多元正态分布 (Multivariate Normal Distribution)	9
1.1 定义与密度函数	9
1.2 二元正态分布 (Bivariate Normal Distribution)	9
1.3 多元正态分布的几何解释	9
1.4 多元正态分布的等价定义	10
1.5 多元正态分布的线性变换性质	10
1.6 多元正态分布的边际分布 (Marginal Distribution)	11
1.7 多元正态分布中的独立与不相关 (Independent vs Uncorrelated)	12
1.8 多元正态分布的条件分布 (Conditional Distribution)	12
第二部分 Inference	17
第 3 节 Point estimation	18
1 极大似然估计 (Maximum Likelihood Estimation)	18
1.1 建模假设与似然函数	18
1.2 正态模型下的 MLE	19

1.3 最大似然值与不变性	19
2 无偏估计量 (Unbiased Estimators)	19
2.1 线性变换的均值与方差 (Mean and Variance under Linear Transformation)	20
2.2 随机变量的线性组合 (Linear Combination of Random Variables)	20
3 充分统计量 (Sufficient Statistics)	22
3.1 正态假设下的充分统计量	22
4 点估计: 均值、方差及其分布	22
4.1 充分统计量的抽样分布	22
4.2 Wishart 分布	24
第 4 节 Hypothesis testing	26
1 单样本均值假设检验	26
1.1 假设检验的一般流程	26
1.2 一维单样本均值检验回顾	26
1.3 多元单样本均值检验与 Hotelling T^2	26
2 Hotelling T^2 的性质与置信区域	30
2.1 Hotelling T^2 的不变性	30
2.2 总体均值的置信区域	30
2.3 线性组合的个体覆盖区间	31
2.4 个别区间与同时覆盖区间	31
2.4.1 Bonferroni 同时区间	31
2.4.2 基于 T^2 的同时覆盖区间	32
3 双总体均值的推断	32
3.1 配对样本的均值检验	32
3.1.1 配对样本的记号	32
3.1.2 配对样本的置信域	33
3.2 两个独立总体的比较	33
3.2.1 假设条件	33
3.2.2 Hotelling 的 T^2 统计量	33
3.2.3 汇总协方差估计量	33
3.2.4 检验统计量	34
3.2.5 单总体 vs 双总体	34
3.2.6 双总体假设检验	34
3.3 双总体均值的置信区域	35
3.3.1 置信区域的定义	35
3.3.2 线性组合的同时覆盖区间	35
3.3.3 最大方向投影	35
4 单总体均值向量的大样本推断	36
4.1 样本均值与样本协方差的大样本行为	36
4.1.1 大数定律	36
4.1.2 中心极限定理	36
4.2 单总体均值向量的大样本推断	37
4.2.1 大样本假设检验	37
4.2.2 大样本同时置信区间	37
5 双总体均值向量的大样本推断	37

5.1 协方差不相等时的大样本推断	37
5.1.1 协方差不相等时的检验	37
5.1.2 双总体均值差的大样本置信椭圆	38
5.1.3 线性组合的同时覆盖区间	38
6 双总体协方差矩阵相等性的检验	39
6.1 检验设定与假设	39
6.2 LRT 与自由度	39
6.3 Box's M 检验 (修正的 LRT)	40
6.4 对 Box's M 检验的说明	40
7 正态性假设的评估	40
7.1 图形方法	40
7.2 Q-Q 图方法	41
7.3 多元正态性的卡方图	41

第三部分 Covariance Estimation 42

第 5 节 Primary Component Analysis (PCA) 43

1 主成分分析 (Principal Component Analysis)	43
1.1 基本思想与目标	43
1.2 总体主成分 (Population Principal Components)	43
1.2.1 矩阵最大化回顾	44
1.2.2 第二及第 i 主成分	44
1.3 如何求主成分	45
1.4 如何解释主成分	45
1.5 基于标准化变量的主成分	47
1.6 样本主成分 (Sample Principal Components)	47
1.7 基于样本相关矩阵的主成分	48
1.8 实际应用	49
2 奇异值分解与主成分分析的计算联系	49
2.1 奇异值分解回顾	49
2.2 样本协方差矩阵的矩阵表示	49
2.3 SVD 与 PCA	50
2.4 SVD 与 EVD 的比较	50
3 多维尺度分析 (Multidimensional Scaling, MDS)	51
3.1 问题背景	51
3.2 邻近矩阵与不相似矩阵	51
3.3 经典 MDS (Classical MDS)	51
3.4 经典 MDS 的推导步骤	52
4 核主成分分析 (Kernel PCA)	54
4.1 重述: 在特征空间中做 PCA	55
4.2 核技巧与 Gram 矩阵	55
4.3 常见核函数与实现	56
5 t-SNE (t-distributed Stochastic Neighbor Embedding)	56
5.1 降维视角与可视化动机	56
5.2 t-SNE 的基本思想	56

5.3 三步法描述	56
5.4 要点总结	57
第 6 节 Linear Regression Models	58
1 经典线性回归模型 (Classical Linear Regression Model)	58
1.1 记号与目标	58
1.2 建模框架	58
1.3 参数估计与预测 (Parameter Estimation & Prediction)	59
1.3.1 最小二乘估计	59
1.3.2 与相关系数的联系	60
1.3.3 多协变量情形	60
1.3.4 投影矩阵 (hat matrix) 及其性质	61
1.3.5 Gauss–Markov 模型及其性质	62
1.3.6 σ^2 的估计	62
1.3.7 Gauss–Markov 定理	63
1.3.8 正态假设	63
1.3.9 正态假设下的参数估计分布	63
1.3.10 正态假设下的预测值分布	64
1.3.11 性质比较	64
2 过拟合、正则化与模型选择	65
2.1 挑战	65
2.2 可能的解决方案	65
2.3 惩罚方法的思想	65
2.4 岭回归	65
2.5 主成分回归	66
2.6 Lasso	66
2.6.1 等价约束形式	66
2.6.2 OLS 目标函数的分解	66
2.6.3 Lasso 与岭回归的几何对比	67
第 7 节 Factor Analysis (FA)	68
1 因子分析与正交因子模型 (Factor Analysis)	68
1.1 典型例子	68
1.2 正交因子模型 (Orthogonal Factor Model)	68
2 协方差结构与例子	69
2.1 协方差矩阵的因子分解	69
3 模型性质：不可识别性与尺度不变性	70
3.1 旋转不可识别性	70
3.2 尺度不变性	70
4 参数估计：主成分法与极大似然法	71
4.1 主成分载荷估计	71
4.2 公共因子个数的选择	72
4.3 极大似然估计 (Maximum Likelihood Approach)	73
4.4 标准化版本	73
5 因子旋转与解释 (Rotation for Interpretation)	74

5.1 旋转不改变的量	74
5.2 简单结构 (Simple Structure)	75
5.3 Varimax 准则	76
6 因子得分估计 (Estimating Factor Scores)	76
6.1 普通最小二乘得分 (OLS Score)	76
6.2 加权最小二乘与 Bartlett 得分	77
6.3 回归得分 (Regression Score)	78
6.4 标准化变量下的得分	78
6.5 例子: 股票收益率	78
7 回归法的补充与比较	79
7.1 条件正态推导	79
7.2 回归得分与主成分得分	80
7.3 WLS 与回归法的代数关系	80
7.4 无偏性与均方误差比较	81
7.5 旋转对因子得分的影响	81
8 实际应用中的策略 (Strategy in Real Application)	82
第 8 节 Canonical Correlation Analysis (CCA)	83
1 典型相关分析概览 (Canonical Correlation Analysis)	83
1.1 问题背景与基本思想	83
2 总体 CCA (Population CCA)	83
2.1 标准化后的优化形式	84
2.2 高阶典型变量	84
3 Hotelling 例子与典型变量解释	85
4 典型变量的求法与性质	86
4.1 如何解释典型变量	86
4.2 典型变量的性质	87
4.3 与传统相关的关系	87
5 基于标准化变量的 CCA	88
6 样本典型相关 (Sample CCA)	88
第四部分 Classification and Discrimination	90
第 9 节 Discriminant Analysis	91
1 判别分析概述 (Overview of Discriminant Analysis)	91
1.1 判别分析的目标	91
2 两总体 Fisher 线性判别 (Fisher LDA)	91
2.1 Fisher 目标函数的矩阵形式	92
3 基于误判代价的分类准则	93
3.1 其他分类准则	95
4 正态总体下的分类规则	95
4.1 等协方差情形: LDA	95
4.2 不等协方差情形: QDA	96
5 多总体 Fisher 判别	97
5.1 Fisher LDA 的投影观点	98

5.2 直观理解：组间与组内平方和	98
5.3 Fisher 方法的多总体推广	99
5.4 用判别得分分类	100
6 分类函数评价 (Classification Evaluation)	100
6.1 表观错误率 (Apparent Error Rate, APER)	101
6.2 交叉验证 (Cross Validation)	101
6.3 其他分类评价指标	102
7 尺度变换与其他分类方法	102
7.1 其他分类方法概览	103

第五部分 Clustering 104

第 10 节 Cluster Analysis 105

1 聚类分析导论 (Introduction to Cluster Analysis)	105
1.1 什么是聚类分析	105
1.2 聚类分析的用途	105
1.3 主要聚类方法	106
2 层次聚类 (Hierarchical Clustering)	106
2.1 树状结构与 dendrogram	106
2.2 凝聚式与分裂式层次聚类	106
2.3 凝聚式聚类的基本设定	106
2.4 距离与相异度	107
2.4.1 点与点之间的距离	107
2.4.2 簇与簇之间的距离	108
2.4.3 Ward linkage 与组内平方和	109
2.5 凝聚式层次聚类的优缺点	109
2.5.1 优点	109
2.5.2 局限	109
3 划分聚类 (Partitioning Clustering)	110
3.1 基本思想	110
3.2 K -means 聚类方法	110
3.3 K -means 的优化观点	111
3.4 如何选择簇数 K	111
3.4.1 基于 SSE 的 elbow method	111
3.4.2 经验法则与交叉验证	112
3.4.3 Silhouette coefficient	112
3.4.4 Gap statistic	112
3.5 K -means 的优缺点与扩展	113
3.5.1 优点与局限	113
3.5.2 K -modes 与 K -medoids	113
4 基于模型的聚类 (Model-based Clustering)	113
4.1 Mixture modelling	113
4.2 Gaussian mixture model	114
4.3 Observed likelihood	114
4.4 Responsibilities	115

4.5 EM algorithm for GMM	115
4.6 Hard assignment 与 soft assignment 的比较	116
4.7 EM algorithm 的一般形式	116
4.8 模型选择	117
5 聚类评价与总结 (Evaluation and Summary)	117
5.1 聚类结果评价 (Evaluation)	117
5.2 总结与实践建议	118

第一部分

Foundations

第 1 节 Descriptive statistics

1 基本设置：展示与建模 (Basic Setting: Display & Modeling)

1.1 多元数据的组织

在存在噪声的多元数据中**展示 (Display)** 或**提取 (Extract)** 信号。

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

- **行 (Rows)** 对应于**样本/项目 (items)**。假设有 n 个样本从一个大总体中抽样而出 (n items sampled from a large population)。
- **列 (Columns)** 对应于**变量 (variables)**，即 $X_1, X_2, \dots, X_p$ 。

1.2 多元数据的建模

观测数据 (Observed Data)：其中小写字母 x_{jk} 表示**观测值 (observed value)**，大写字母 X_{jk} 表示**随机变量 (random variable)**。

$$\mathbf{X}_{n \times p} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \vdots \\ \mathbf{X}'_n \end{bmatrix}$$

1.3 随机抽样

定义 1.1 (随机样本)

称 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 构成来自分布 $f(\mathbf{x})$ 的**随机样本 (random sample)**，如果它们满足以下独立同分布 (*i.i.d.*) 的条件：

1. $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 表示**独立 (independent)** 的观测值；
2. $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 来自具有密度函数 $f(\mathbf{x}) = f(x_1, x_2, \dots, x_p)$ 的**共同 (common)** 联合分布。

注 通常，在单个实验单元中测量的 p 个变量是**相关的 (correlated)**。

给定随机抽样假设后，可以对多元数据集进行建模。样本 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 的**联合密度分布 (Joint density distribution)** 为：

$$f(\mathbf{x}_1)f(\mathbf{x}_2)\cdots f(\mathbf{x}_n)$$

其中 $f(\mathbf{x}_i) = f(x_{i1}, x_{i2}, \dots, x_{ip})$ 。该分布可以是参数化的 (parametric) 或非参数化的 (nonparametric)。

例 1.1 抽样的例子 每年产生的城市固体废物总重量 (Gross weight of municipal solid waste generated per year)。

表 1.1: 固体废物 (Solid Waste)

Year	1960	1970	1980	1990	1995	2000	2003
X_1 (paper)	29.2	44.3	55.2	72.7	81.7	87.7	83.1
X_2 (plastics)	0.4	2.9	6.8	17.1	18.9	24.7	26.7

1.4 随机样本的几何意义

$$\mathbf{X}_{n \times p} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} = \begin{bmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_n \end{bmatrix} \begin{matrix} \leftarrow \text{第 1 个 (多元) 观测值} \\ \leftarrow \text{第 } n \text{ 个 (多元) 观测值} \end{matrix}$$

上述数据可以视作 p 维空间中的 n 个点 (p -dimensional space, n points)。

2 马氏距离 (Mahalanobis Distance)

- 样本之间可用距离或相似性来度量。
- 如何定义两个多元数据点之间的距离？

2.1 距离 (Distance)

设

$$P = (x_1, x_2, \dots, x_p), \quad Q = (y_1, y_2, \dots, y_p),$$

欧氏距离定义为

$$d(P, Q) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_p - y_p)^2}.$$

注 欧氏距离默认各坐标对距离的贡献相同；当不同变量的单位/尺度差异较大时，这一假设通常不合理。

2.2 距离 (无相关)

若暂时假设变量间独立，可通过标准化（加权）消除单位/尺度影响：

$$x_i - y_i \rightarrow \frac{x_i - y_i}{\sqrt{s_{ii}}},$$

其中 s_{ii} 为第 i 个变量的方差估计，于是

$$d(P, Q) = \sqrt{\frac{(x_1 - y_1)^2}{s_{11}} + \frac{(x_2 - y_2)^2}{s_{22}} + \cdots + \frac{(x_p - y_p)^2}{s_{pp}}}.$$

2.3 距离 (有相关)

当变量存在相关性时，距离应包含交叉项（interaction term）：

$$d(P, Q) = \sqrt{(\mathbf{x} - \mathbf{y})' \mathbf{A} (\mathbf{x} - \mathbf{y})},$$

其中 $\mathbf{A}$ 为对称正定矩阵。展开可写为

$$\sqrt{a_{11}(x_1 - y_1)^2 + \cdots + a_{pp}(x_p - y_p)^2 + 2a_{12}(x_1 - y_1)(x_2 - y_2) + \cdots}.$$

注 交叉项刻画了非零相关性。马氏距离因此是**无量纲**、**尺度不变**并考虑变量相关结构的距离。

2.4 马氏距离定义

定义 1.2 (观测点到总体中心)

设 $\mathbf{x} = (x_1, \dots, x_p)'$, 总体均值向量为 $\boldsymbol{\mu} = (\mu_1, \dots, \mu_p)'$, 协方差矩阵为 $\boldsymbol{\Sigma}$, 则

$$d(\mathbf{x}, \boldsymbol{\mu}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}.$$



定义 1.3 (两个随机向量之间)

若 $\mathbf{x}, \mathbf{y}$ 来自同一总体且共享协方差矩阵 $\boldsymbol{\Sigma}$, 定义

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{y})}.$$



2.5 二次型 (Quadratic Form)

定义 1.4 (二次型)

在 p 个变量 $x_1, \dots, x_p$ 上,

$$Q(\mathbf{x}) = \mathbf{x}' \mathbf{A} \mathbf{x},$$

其中 $\mathbf{x} = (x_1, \dots, x_p)'$, $\mathbf{A}$ 为 $p \times p$ 对称矩阵, 则称 $Q(\mathbf{x})$ 为二次型。



总体基本记号

- 随机向量:

$$\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_p \end{pmatrix}.$$

- 总体均值向量:

$$\boldsymbol{\mu} = E\mathbf{X} = \begin{pmatrix} EX_1 \\ \vdots \\ EX_p \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_p \end{pmatrix}.$$

- 总体协方差矩阵:

$$\boldsymbol{\Sigma} = \text{cov}(\mathbf{X}) = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})'] = [\sigma_{ij}]_{p \times p},$$

其中

$$\sigma_{ij} = \text{cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)].$$

2.6 距离的期望

定理 1.1

设随机向量 $\mathbf{Z}$ 具有有限均值 $\boldsymbol{\mu}_Z$ 和有限协方差矩阵 $\boldsymbol{\Sigma}_Z$, 则

$$E[\mathbf{Z}' \mathbf{A} \mathbf{Z}] = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}_Z) + \boldsymbol{\mu}_Z' \mathbf{A} \boldsymbol{\mu}_Z.$$



证明

$$\begin{aligned}
E[\mathbf{Z}'\mathbf{A}\mathbf{Z}] &= E[\text{tr}(\mathbf{Z}'\mathbf{A}\mathbf{Z})] = E[\text{tr}(\mathbf{A}\mathbf{Z}\mathbf{Z}')] \\
&= \text{tr}(\mathbf{A}E[\mathbf{Z}\mathbf{Z}']) = \text{tr}(\mathbf{A}(\Sigma_Z + \mu_Z\mu_Z')) \\
&= \text{tr}(\mathbf{A}\Sigma_Z) + \mu_Z'\mathbf{A}\mu_Z.
\end{aligned}$$

欧氏距离的期望

定理 1.2 (期望欧氏距离)

设 p 维随机向量 $\mathbf{X}$ 具有有限均值 μ 和有限协方差矩阵 Σ , 则

$$E[\|\mathbf{X} - \mu\|_2^2] = \sum_{j=1}^p \sigma_{jj} = \text{tr}(\Sigma).$$



证明

$$\begin{aligned}
E[\|\mathbf{X} - \mu\|_2^2] &= E[(\mathbf{X} - \mu)'(\mathbf{X} - \mu)] \\
&= \text{tr}(\mathbf{I}\Sigma) + (E[\mathbf{X} - \mu])'\mathbf{I}E[\mathbf{X} - \mu] \\
&= \text{tr}(\Sigma) = \sum_{j=1}^p \sigma_{jj}.
\end{aligned}$$

附：矩阵代数回顾 (Matrix Algebra Review)

2.7 谱分解 (Spectral Decomposition)

(Res 2A.14) 设 $\mathbf{A}$ 为一个 $k \times k$ 的对称矩阵。那么 $\mathbf{A}$ 可以用它的 k 个特征值-特征向量对来表示：

$$\begin{aligned}
\mathbf{A} &= \sum_{i=1}^k \lambda_i \mathbf{e}_i \mathbf{e}_i' \\
\mathbf{A} &= \lambda_1 \mathbf{e}_1 \mathbf{e}_1' + \lambda_2 \mathbf{e}_2 \mathbf{e}_2' + \cdots + \lambda_k \mathbf{e}_k \mathbf{e}_k'
\end{aligned}$$

其等价的矩阵形式（即**谱分解**）为：

$$\begin{aligned}
\mathbf{P} &= [\mathbf{e}_1 | \mathbf{e}_2 | \cdots | \mathbf{e}_k], \quad \mathbf{\Lambda} = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_k\} \\
\mathbf{A}\mathbf{P} &= \mathbf{P}\mathbf{\Lambda} \Rightarrow \mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}'
\end{aligned}$$

其中 $\{\mathbf{e}_1, \dots, \mathbf{e}_k\}$ 构成了一组正交基 (forms an orthogonal basis)。

2.8 非负定与正定矩阵 (Nonnegative, Positive Definite Matrix)

- 设 $\mathbf{A}$ 是 $k \times k$ 对称矩阵。如果对于所有 $\mathbf{x}' = [x_1, x_2, \dots, x_k]$, 都有 $\mathbf{x}'\mathbf{A}\mathbf{x} \geq 0$, 则称矩阵 $\mathbf{A}$ 及其二次型为**非负定 (nonnegative definite)**, 或**半正定 (positive semi-definite)**。
- 如果对于所有非零向量 $\mathbf{x} \neq \mathbf{0}$, 都有 $\mathbf{x}'\mathbf{A}\mathbf{x} > 0$, 则称矩阵 $\mathbf{A}$ 及其二次型为**正定 (positive definite)**。
- 对于非负定或正定矩阵 $\mathbf{A}$, $\mathbf{x}'\mathbf{A}\mathbf{x} = \sum \lambda_i y_i^2 = \sum (\sqrt{\lambda_i} y_i)^2$, 其中 $y_i = \mathbf{x}'\mathbf{e}_i$ 。
- 矩阵 $\mathbf{A}$ 是正定矩阵**当且仅当 (if and only if)** $\mathbf{A}$ 的每个特征值都为正。
- 矩阵 $\mathbf{A}$ 是非负定矩阵**当且仅当 (if and only if)** $\mathbf{A}$ 的所有特征值均大于或等于零。

2.9 逆矩阵与平方根矩阵 (Inverse and Square-root Matrix)

设 $\mathbf{A}$ 为 $k \times k$ 矩阵, 且**所有的特征值均为正 (all eigenvalues positive)**, 其分解为 $\mathbf{A} = \sum_{i=1}^k \lambda_i \mathbf{e}_i \mathbf{e}_i'$ 。

记 $\mathbf{P} = [\mathbf{e}_1 | \mathbf{e}_2 | \cdots | \mathbf{e}_k]$, $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \lambda_2, \cdots, \lambda_k\}$, 且 $\lambda_i > 0$ 。则 $\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}'$ 。

• 逆矩阵 (Inverse matrix)

$$\mathbf{A}^{-1} = \mathbf{P}\mathbf{\Lambda}^{-1}\mathbf{P}' = \sum_{i=1}^k \frac{1}{\lambda_i} \mathbf{e}_i \mathbf{e}_i'$$

• 平方根矩阵 (Square root matrix)

$$\mathbf{A}^{1/2} = \sum_{i=1}^k \sqrt{\lambda_i} \mathbf{e}_i \mathbf{e}_i' = \mathbf{P}\mathbf{\Lambda}^{1/2}\mathbf{P}'$$

并且平方根矩阵具有以下性质：

$$(\mathbf{A}^{1/2})' = \mathbf{A}^{1/2}$$

$$\mathbf{A}^{1/2} \mathbf{A}^{1/2} = \mathbf{A}$$

$$(\mathbf{A}^{1/2})^{-1} = \sum_{i=1}^k \frac{1}{\sqrt{\lambda_i}} \mathbf{e}_i \mathbf{e}_i' = \mathbf{P}\mathbf{\Lambda}^{-1/2}\mathbf{P}'$$

2.10 马氏距离的几何解释与推导

在 p 维空间中，将中心化后的数据视为 n 个点。为便于推导，不妨设样本均值为 $\mathbf{0}$ 。若原始数据云呈椭球分布，我们希望通过线性变换将其变为近似球形 (spheroid) 分布。

设原坐标中的随机向量为 $\mathbf{X}$ ，构造模型

$$\mathbf{X} = \tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}}\mathbf{Y}, \quad \text{var}(\mathbf{Y}) = \mathbf{I}. \quad (1.1)$$

于是

$$\mathbf{\Sigma} = \text{var}(\mathbf{X}) = \tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}} \text{var}(\mathbf{Y}) \tilde{\mathbf{\Lambda}}\tilde{\mathbf{P}}' = \tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}}^2\tilde{\mathbf{P}}'. \quad (1.2)$$

由 (1.1) 可得

$$\mathbf{Y} = \tilde{\mathbf{\Lambda}}^{-1}\tilde{\mathbf{P}}'\mathbf{X}.$$

因此距离平方可写为

$$\begin{aligned} \mathbf{Y}'\mathbf{Y} &= (\mathbf{X}'\tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}}^{-1})(\tilde{\mathbf{\Lambda}}^{-1}\tilde{\mathbf{P}}'\mathbf{X}) \\ &= \mathbf{X}'(\tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}}^{-2}\tilde{\mathbf{P}}')\mathbf{X} = \mathbf{X}'(\tilde{\mathbf{P}}\tilde{\mathbf{\Lambda}}^2\tilde{\mathbf{P}}')^{-1}\mathbf{X} \\ &= \mathbf{X}'\mathbf{\Sigma}^{-1}\mathbf{X}. \end{aligned}$$

若不以原点为中心，对任意两点 $\mathbf{x}, \mathbf{y}$ ，则有

$$d_M^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})'\mathbf{\Sigma}^{-1}(\mathbf{x} - \mathbf{y}).$$

注 实际应用中总体协方差矩阵 $\mathbf{\Sigma}$ 通常未知，用样本协方差矩阵 $\mathbf{S}$ 估计。因此常用的马氏距离为

$$d_M^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})'\mathbf{S}^{-1}(\mathbf{x} - \mathbf{y}),$$

其中当 $\mathbf{y} = \bar{\mathbf{x}}$ (样本均值) 时，即得到观测点到样本中心的马氏距离。

进一步，若对称矩阵 $\mathbf{S}$ 的谱分解为

$$\mathbf{S} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}',$$

则 $\mathbf{P}$ 给出主轴方向 (旋转角度)， $\mathbf{\Lambda}$ 描述各主轴尺度。

3 描述统计量 (Descriptive Statistics)

3.1 单变量 (Single Variable)

样本均值 (Sample Mean)

样本均值刻画数据的**中心/位置 (center/location)**:

$$\bar{x}_k = \frac{1}{n} \sum_{j=1}^n x_{jk}, \quad k = 1, 2, \dots, p$$

即数据矩阵 $\mathbf{X}$ 各列的均值。

样本方差与样本标准差 (Sample Variance & Standard Deviation)

样本方差刻画数据的**分散程度 (spread/dispersion)**:

$$s_k^2 = s_{kk} = \frac{1}{n-1} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2, \quad k = 1, 2, \dots, p$$

3.2 双变量 (Two Variables)

样本协方差 (Sample Covariance)

样本协方差衡量两个变量之间的**线性关联 (linear association)**:

$$s_{ik} = \frac{1}{n-1} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k), \quad i = 1, 2, \dots, p, \quad k = 1, 2, \dots, p$$

注 协方差 s_{ik} 的大小受变量单位/尺度的影响: 若对某一变量做线性缩放, 其协方差值也会随之改变。

样本相关系数 (Sample Correlation)

为了消除单位和尺度的影响, 定义样本相关系数:

$$r_{ik} = \frac{s_{ik}}{\sqrt{s_{ii}}\sqrt{s_{kk}}} = \frac{\sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)}{\sqrt{\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2} \sqrt{\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2}}$$

例 1.2 计算样本相关系数 设数据矩阵为

$$X = \begin{bmatrix} 4 & 1 \\ 5 & 2 \\ 3 & 5 \end{bmatrix}.$$

- 样本均值:

$$\bar{x}_1 = \frac{4+5+3}{3} = 4, \quad \bar{x}_2 = \frac{1+2+5}{3} = \frac{8}{3}.$$

- 样本方差:

$$s_1^2 = \frac{(4-\bar{x}_1)^2 + (5-\bar{x}_1)^2 + (3-\bar{x}_1)^2}{2} = 1,$$

$$s_2^2 = \frac{(1-\bar{x}_2)^2 + (2-\bar{x}_2)^2 + (5-\bar{x}_2)^2}{2} = \frac{13}{3}.$$

- 样本协方差:

$$\begin{aligned} s_{12} &= \frac{(4 - \bar{x}_1)(1 - \bar{x}_2) + (5 - \bar{x}_1)(2 - \bar{x}_2) + (3 - \bar{x}_1)(5 - \bar{x}_2)}{2} \\ &= \frac{0 + (2 - \bar{x}_2) - (5 - \bar{x}_2)}{2} = -\frac{3}{2}. \end{aligned}$$

- 样本相关系数:

$$r_{12} = \frac{s_{12}}{\sqrt{s_1^2} \sqrt{s_2^2}} = \frac{-\frac{3}{2}}{\sqrt{1} \cdot \sqrt{\frac{13}{3}}} \approx -0.72.$$

注 关于样本相关系数的性质:

- r_{ik} 衡量的是**线性**关联。 $r = 0$ 意味着**无线性**关联, 但不**一定**意味着无关联 (No Association $\neq$ No Linear Association)。
- r_{ik} 是**无量纲**且**无单位**的 (scale free, unit free)。
- r_{ik} 等价于对标准化数据计算协方差。
- r_{ik} 在各变量的线性变换下不变 (HW)。

3.3 矩阵形式 (Matrix Form)

将上述统计量统一写成矩阵形式:

- 样本均值向量 (Sample means):

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}.$$

- 样本协方差矩阵 (Sample variances and covariances):

$$\mathbf{S}_n = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}.$$

- 样本相关矩阵 (Sample correlations):

$$\mathbf{R}_n = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}.$$

样本协方差矩阵 $\mathbf{S}_n$ 与样本相关矩阵 $\mathbf{R}_n$ 具有以下性质:

1. **对称性 (Symmetric)**: $\mathbf{S}'_n = \mathbf{S}_n$, $\mathbf{R}'_n = \mathbf{R}_n$ 。
2. **半正定 (Nonnegative-definite)**: 对任意 $\mathbf{a} \in \mathbb{R}^p$, $\mathbf{a}'\mathbf{S}_n\mathbf{a} \geq 0$ 。

第2节 Multivariate normal distribution theory

1 多元正态分布 (Multivariate Normal Distribution)

1.1 定义与密度函数

多元正态分布是连续型随机向量的一类重要分布，它由前两阶矩完全刻画。

单变量情形

若随机变量 $X \sim N(\mu, \sigma^2)$ ，则其密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}.$$

多变量情形

称 p 维随机向量 $\mathbf{X}$ 服从均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ 的多元正态分布 (multivariate normal distribution)，记作

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}),$$

其中 $\boldsymbol{\Sigma}$ 为对称正定矩阵。其密度函数为

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right\}.$$

- $\boldsymbol{\mu}$ 是 $\mathbf{X}$ 的均值向量；
- $\boldsymbol{\Sigma}$ 是 $\mathbf{X}$ 的方差协方差矩阵，且必须为正定矩阵。

1.2 二元正态分布 (Bivariate Normal Distribution)

当 $p = 2$ 时，记

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix},$$

以及

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} = \begin{bmatrix} \sigma_{11} & \rho_{12}\sqrt{\sigma_{11}\sigma_{22}} \\ \rho_{12}\sqrt{\sigma_{11}\sigma_{22}} & \sigma_{22} \end{bmatrix} = \begin{bmatrix} \text{var}(X_1) & \text{cov}(X_1, X_2) \\ \text{cov}(X_1, X_2) & \text{var}(X_2) \end{bmatrix}.$$

因此二元正态分布由 5 个自由参数决定：

- 2 个位置参数： μ_1, μ_2 ；
- 2 个尺度参数： σ_{11}, σ_{22} ；
- 1 个相关参数： ρ_{12} 。

注 当 $\sigma_{11} = \sigma_{22}$ 时，改变 ρ_{12} 会改变等密度曲线的倾斜方向与扁平程度。 $\rho_{12} = 0$ 时轮廓轴与坐标轴对齐； $|\rho_{12}|$ 增大时，轮廓更加狭长。

1.3 多元正态分布的几何解释

对于 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，等密度曲线（或曲面）由二次型

$$(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = c^2$$

给出。

这说明在 p 维空间中，常密度集合是以 $\boldsymbol{\mu}$ 为中心的椭球面（二维情形为椭圆）。

若 $\boldsymbol{\Sigma}$ 的特征值为

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p > 0,$$

对应特征向量为 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_p$ ，则这些椭圆的主轴方向由特征向量决定，半轴长度为

$$c\sqrt{\lambda_1}, c\sqrt{\lambda_2}, \dots, c\sqrt{\lambda_p}.$$

注 因此，协方差矩阵 $\boldsymbol{\Sigma}$ 同时决定了多元正态分布的尺度、伸缩方向与相关结构。

1.4 多元正态分布的等价定义

定理 2.1

随机向量 $\mathbf{X}$ 服从多元正态分布 $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 当且仅当对任意 $\mathbf{a} \in \mathbb{R}^p$ ，线性组合

$$\mathbf{a}'\mathbf{X}$$

都服从一维正态分布，且

$$\mathbf{a}'\mathbf{X} \sim N(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a}).$$

例 2.1 若

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N\left(\begin{bmatrix} 1 \\ -5 \end{bmatrix}, \begin{bmatrix} 4 & -2 \\ -2 & 9 \end{bmatrix}\right),$$

则对任意

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix},$$

有

$$a_1X_1 + a_2X_2 = \mathbf{a}'\mathbf{X} \sim N\left(\begin{bmatrix} a_1 & a_2 \end{bmatrix} \begin{bmatrix} 1 \\ -5 \end{bmatrix}, \begin{bmatrix} a_1 & a_2 \end{bmatrix} \begin{bmatrix} 4 & -2 \\ -2 & 9 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}\right).$$

1.5 多元正态分布的线性变换性质

定理 2.2 (多元正态分布的线性变换性质)

若 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，且矩阵 $A\boldsymbol{\Sigma}A'$ 可逆，则对任意 $q \times p$ 常数矩阵 A ($q \leq p$)，有

$$A\mathbf{X} \sim N_q(A\boldsymbol{\mu}, A\boldsymbol{\Sigma}A').$$

此外，若 $\mathbf{d}$ 为常向量，则

$$\mathbf{X} + \mathbf{d} \sim N_p(\boldsymbol{\mu} + \mathbf{d}, \boldsymbol{\Sigma}).$$

例 2.2 设

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N\left(\begin{bmatrix} 1 \\ -5 \end{bmatrix}, \begin{bmatrix} 4 & -2 \\ -2 & 9 \end{bmatrix}\right),$$

并令

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}.$$

则

$$\begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix} \sim N\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -5 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 4 & -2 \\ -2 & 9 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}\right).$$

定理 2.3 (由标准正态分布构造任意多元正态分布)

设 $Z_1, \dots, Z_p$ 独立同分布于 $N(0, 1)$, 并记

$$\mathbf{Z} = (Z_1, \dots, Z_p)'$$

若 Σ 是 $p \times p$ 对称正定矩阵, $\boldsymbol{\mu} \in \mathbb{R}^p$, 则

$$\mathbf{X} = \boldsymbol{\mu} + \Sigma^{1/2} \mathbf{Z}$$

服从多元正态分布

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma).$$

证明 由于 $\mathbf{Z}$ 的各分量独立且均服从 $N(0, 1)$, 其联合密度为

$$f_{\mathbf{Z}}(\mathbf{z}) = (2\pi)^{-p/2} \exp\left(-\frac{1}{2} \mathbf{z}' \mathbf{z}\right).$$

作变量变换

$$\mathbf{x} = \boldsymbol{\mu} + \Sigma^{1/2} \mathbf{z}, \quad \mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu}).$$

由于雅可比行列式为

$$\left| \frac{\partial \mathbf{z}}{\partial \mathbf{x}} \right| = |\Sigma^{-1/2}|,$$

可得

$$\begin{aligned} f_{\mathbf{X}}(\mathbf{x}) &= |\Sigma|^{-1/2} (2\pi)^{-p/2} \exp\left\{-\frac{1}{2} (\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu}))' (\Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu}))\right\} \\ &= \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right\}. \end{aligned}$$

因此 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$.

1.6 多元正态分布的边际分布 (Marginal Distribution)**定理 2.4**

设 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$, 并将随机向量、均值向量和协方差矩阵按同一方式分块为

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix},$$

其中 $\mathbf{X}_1$ 为 $q \times 1$, $\mathbf{X}_2$ 为 $(p-q) \times 1$ 。则边际分布

$$\mathbf{X}_1 \sim N_q(\boldsymbol{\mu}_1, \Sigma_{11}),$$

同理

$$\mathbf{X}_2 \sim N_{p-q}(\boldsymbol{\mu}_2, \Sigma_{22}).$$

例 2.3 设

$$\begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N\left(\begin{bmatrix} 2 \\ 7 \\ 3 \end{bmatrix}, \begin{bmatrix} 4 & -1 & 2 \\ -1 & 9 & -3 \\ 2 & -3 & 8 \end{bmatrix}\right).$$

由边际分布性质可得

$$X_1 \sim N(2, 4),$$

$$\begin{bmatrix} X_2 \\ X_3 \end{bmatrix} \sim N_2\left(\begin{bmatrix} 7 \\ 3 \end{bmatrix}, \begin{bmatrix} 9 & -3 \\ -3 & 8 \end{bmatrix}\right).$$

1.7 多元正态分布中的独立与不相关 (Independent vs Uncorrelated)

定理 2.5

设

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_{q_1+q_2} \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right).$$

则有以下结论:

1. 若 $\mathbf{X}_1$ 与 $\mathbf{X}_2$ 独立, 则

$$\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \mathbf{0}.$$

2. 在多元正态分布下, 反过来也成立:

$$\mathbf{X}_1 \perp \mathbf{X}_2 \iff \boldsymbol{\Sigma}_{12} = \mathbf{0}.$$

3. 若 $\mathbf{X}_1 \sim N_{q_1}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$ 、 $\mathbf{X}_2 \sim N_{q_2}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$ 且二者独立, 则

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_{q_1+q_2} \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right).$$



例 2.4 设

$$\begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N \left(\begin{bmatrix} 2 \\ 7 \\ 3 \end{bmatrix}, \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & -3 \\ 0 & -3 & 8 \end{bmatrix} \right).$$

由 $\boldsymbol{\Sigma}_{12} = \mathbf{0}$ 知

$$X_1 \perp (X_2, X_3),$$

且边际分布为

$$X_1 \sim N(2, 4), \quad \begin{bmatrix} X_2 \\ X_3 \end{bmatrix} \sim N_2 \left(\begin{bmatrix} 7 \\ 3 \end{bmatrix}, \begin{bmatrix} 9 & -3 \\ -3 & 8 \end{bmatrix} \right).$$

1.8 多元正态分布的条件分布 (Conditional Distribution)

定理 2.6

设

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim N_{q_1+q_2} \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right), \quad |\boldsymbol{\Sigma}_{22}| > 0.$$

则条件分布仍为正态分布:

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim N_{q_1}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$



证明 构造零协方差法

定义新随机向量

$$\mathbf{Y} = \mathbf{X}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\mathbf{X}_2.$$

由于 $(\mathbf{Y}', \mathbf{X}_2')$ 是 $(\mathbf{X}_1', \mathbf{X}_2')$ 的线性变换, 故仍服从联合正态分布。

计算协方差:

$$\begin{aligned} \text{Cov}(\mathbf{Y}, \mathbf{X}_2) &= \text{Cov}(\mathbf{X}_1, \mathbf{X}_2) - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\text{Cov}(\mathbf{X}_2, \mathbf{X}_2) \\ &= \boldsymbol{\Sigma}_{12} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{22} = \mathbf{0}. \end{aligned}$$

由“联合正态下不相关即独立”，得到 $\mathbf{Y} \perp \mathbf{X}_2$ 。

又有

$$\mathbf{X}_1 = \mathbf{Y} + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\mathbf{X}_2,$$

因此在条件 $\mathbf{X}_2 = \mathbf{x}_2$ 下，

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 = \mathbf{Y} + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\mathbf{x}_2.$$

只需给出 $\mathbf{Y}$ 的均值和协方差：

$$E(\mathbf{Y}) = \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\mu}_2,$$

$$\begin{aligned}\text{Var}(\mathbf{Y}) &= \text{Var}(\mathbf{X}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\mathbf{X}_2) \\ &= \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}.\end{aligned}$$

所以

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{q_1}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$

证明 分块矩阵求逆法

记

$$S = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$$

为 Schur 补。联合密度可写为

$$f(\mathbf{x}_1, \mathbf{x}_2) \propto \exp\left\{-\frac{1}{2}\begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}' \boldsymbol{\Sigma}^{-1} \begin{bmatrix} \mathbf{x}_1 - \boldsymbol{\mu}_1 \\ \mathbf{x}_2 - \boldsymbol{\mu}_2 \end{bmatrix}\right\}.$$

利用分块逆公式

$$\boldsymbol{\Sigma}^{-1} = \begin{bmatrix} S^{-1} & -S^{-1}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1} \\ -\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}S^{-1} & * \end{bmatrix},$$

其中右下角分块记为 $*$ (其具体形式对条件分布推导不关键)。将其代入并按 $\mathbf{x}_1$ 完全平方，得

$$f(\mathbf{x}_1 \mid \mathbf{x}_2) \propto \exp\left\{-\frac{1}{2}(\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2))' S^{-1}(\mathbf{x}_1 - \boldsymbol{\mu}_1 - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2))\right\}.$$

识别为 q_1 维正态核，因此

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{q_1}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), S),$$

即

$$\text{Var}(\mathbf{X}_1 \mid \mathbf{X}_2) = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}.$$

注 在上述条件分布中，条件均值依赖于给定值 $\mathbf{x}_2$ ，而条件协方差 $\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$ 与 $\mathbf{x}_2$ 无关。

例 2.5 设

$$\begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim N\left(\begin{bmatrix} 2 \\ 7 \\ 3 \end{bmatrix}, \begin{bmatrix} 4 & -1 & 2 \\ -1 & 9 & -3 \\ 2 & -3 & 8 \end{bmatrix}\right).$$

求 $X_1 \mid (X_2 = 1, X_3 = 0)$ 的条件分布。

记

$$\boldsymbol{\mu}_1 = 2, \quad \boldsymbol{\mu}_2 = \begin{bmatrix} 7 \\ 3 \end{bmatrix}, \quad \boldsymbol{\Sigma}_{11} = 4,$$

$$\boldsymbol{\Sigma}_{12} = \begin{bmatrix} -1 & 2 \end{bmatrix}, \quad \boldsymbol{\Sigma}_{22} = \begin{bmatrix} 9 & -3 \\ -3 & 8 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

由

$$\Sigma_{22}^{-1} = \frac{1}{63} \begin{bmatrix} 8 & 3 \\ 3 & 9 \end{bmatrix}$$

可得

$$\begin{aligned} \mu_{1|23} &= 2 + \begin{bmatrix} -1 & 2 \end{bmatrix} \frac{1}{63} \begin{bmatrix} 8 & 3 \\ 3 & 9 \end{bmatrix} \left(\begin{bmatrix} 1 \\ 0 \end{bmatrix} - \begin{bmatrix} 7 \\ 3 \end{bmatrix} \right) = \frac{31}{21}, \\ \sigma_{1|23}^2 &= 4 - \begin{bmatrix} -1 & 2 \end{bmatrix} \frac{1}{63} \begin{bmatrix} 8 & 3 \\ 3 & 9 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \frac{220}{63}. \end{aligned}$$

因此

$$X_1 \mid (X_2 = 1, X_3 = 0) \sim N\left(\frac{31}{21}, \frac{220}{63}\right).$$

定理 2.7 (由条件正态反推联合正态)

设

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim N_{q_1}(A\mathbf{x}_2, \Sigma_{11}),$$

其中 A 为 $q_1 \times q_2$ 常矩阵, 且

$$\mathbf{X}_2 \sim N_{q_2}(\boldsymbol{\mu}_2, \Sigma_{22}).$$

则

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}$$

服从联合多元正态分布, 并且边际分布

$$\mathbf{X}_1 \sim N_{q_1}(A\boldsymbol{\mu}_2, \Sigma_{11} + A\Sigma_{22}A').$$

证明 由条件分布假设, 可写

$$\mathbf{X}_1 = A\mathbf{X}_2 + \boldsymbol{\varepsilon},$$

其中

$$\boldsymbol{\varepsilon} \sim N_{q_1}(\mathbf{0}, \Sigma_{11}), \quad \boldsymbol{\varepsilon} \perp\!\!\!\perp \mathbf{X}_2.$$

因而

$$\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} = \begin{bmatrix} A \\ I \end{bmatrix} \mathbf{X}_2 + \begin{bmatrix} \boldsymbol{\varepsilon} \\ \mathbf{0} \end{bmatrix}$$

是独立正态向量的线性组合, 所以联合为多元正态。

进一步

$$E(\mathbf{X}_1) = AE(\mathbf{X}_2) = A\boldsymbol{\mu}_2,$$

$$\text{Var}(\mathbf{X}_1) = A\Sigma_{22}A' + \Sigma_{11},$$

即得结论。

定理 2.8 (卡方分布性质)

设 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 则:

1. 二次型

$$(\mathbf{X} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_p^2.$$

2. 若 $\chi_p^2(\alpha)$ 表示 χ_p^2 的上 $100\alpha\%$ 分位数 (即 $P(\chi_p^2 > \chi_p^2(\alpha)) = \alpha$), 则

$$P((\mathbf{X} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha)) = 1 - \alpha.$$



证明 令

$$\mathbf{Z} = \boldsymbol{\Sigma}^{-1/2} (\mathbf{X} - \boldsymbol{\mu}),$$

则 $\mathbf{Z} \sim N_p(\mathbf{0}, I_p)$ 。于是

$$(\mathbf{X} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) = \mathbf{Z}' \mathbf{Z} = \sum_{j=1}^p Z_j^2 \sim \chi_p^2.$$

第二条由分位数定义直接得到。

定理 2.9 (独立同协方差正态向量的线性组合)

设 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 相互独立, 且

$$\mathbf{X}_j \sim N_p(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}), \quad j = 1, \dots, n.$$

记常数向量

$$\mathbf{c} = (c_1, \dots, c_n)', \quad \mathbf{b} = (b_1, \dots, b_n)'.$$

定义

$$\mathbf{V}_1 = \sum_{j=1}^n c_j \mathbf{X}_j, \quad \mathbf{V}_2 = \sum_{j=1}^n b_j \mathbf{X}_j.$$

则:

1.

$$\mathbf{V}_1 \sim N_p \left(\sum_{j=1}^n c_j \boldsymbol{\mu}_j, \left(\sum_{j=1}^n c_j^2 \right) \boldsymbol{\Sigma} \right).$$

2. $\mathbf{V}_1$ 与 $\mathbf{V}_2$ 联合服从 $2p$ 维正态, 且

$$\text{Cov}(\mathbf{V}_1, \mathbf{V}_2) = \left(\sum_{j=1}^n b_j c_j \right) \boldsymbol{\Sigma} = (\mathbf{b}' \mathbf{c}) \boldsymbol{\Sigma}.$$

3. 若 $\mathbf{b}' \mathbf{c} = 0$, 则

$$\mathbf{V}_1 \perp \mathbf{V}_2.$$



证明 由独立性与线性变换性质, $\mathbf{V}_1, \mathbf{V}_2$ 为独立正态向量的线性组合, 故联合正态。计算可得

$$E(\mathbf{V}_1) = \sum_{j=1}^n c_j \boldsymbol{\mu}_j, \quad \text{Var}(\mathbf{V}_1) = \sum_{j=1}^n c_j^2 \boldsymbol{\Sigma}.$$

同理

$$\text{Cov}(\mathbf{V}_1, \mathbf{V}_2) = \sum_{j=1}^n \sum_{k=1}^n c_j b_k \text{Cov}(\mathbf{X}_j, \mathbf{X}_k) = \sum_{j=1}^n c_j b_j \boldsymbol{\Sigma} = (\mathbf{b}' \mathbf{c}) \boldsymbol{\Sigma}.$$

当 $\mathbf{b}' \mathbf{c} = 0$ 时, 协方差为零; 联合正态下零协方差等价于独立, 结论成立。

条件期望与最佳预测

命题 2.1 (正交性原理)

设 X, Y 为随机变量, $h(\cdot)$ 为可测函数, 且

$$E(X^2) < \infty, \quad E[h^2(Y)] < \infty.$$

则

$$E[(X - E(X | Y))h(Y)] = 0.$$

命题 2.2 (最佳预测)

设 $m(Y) = E(X | Y)$, 则对任意平方可积函数 $g(Y)$, 有

$$E[(X - m(Y))^2] \leq E[(X - g(Y))^2],$$

且等号成立当且仅当 $g(Y) = m(Y)$ (几乎处处)。

注 在联合正态分布下, 条件期望 $E(X_1 | X_2)$ 对 X_2 为线性函数, 因此 “最佳预测 = 最佳线性预测”。

第二部分

Inference

第3节 Point estimation

1 极大似然估计 (Maximum Likelihood Estimation)

1.1 建模假设与似然函数

设 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 是来自多元正态总体 $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的随机样本，即

1. $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 相互独立；
2. 对每个 $i = 1, \dots, n$, $\mathbf{X}_i \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。

于是联合密度（亦即似然函数）可写为

$$\begin{aligned} L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \prod_{j=1}^n \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_j - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\} \\ &= \frac{1}{(2\pi)^{np/2} |\boldsymbol{\Sigma}|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\}. \end{aligned}$$

对数似然为

$$\ell(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}).$$

矩阵求导约定 (Vector and Matrix Calculus)

以下采用 **denominator-layout** 记号。

注 对于 $\mathbf{y} = A\mathbf{x}$,

$$\left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)_{\text{num}} = A, \quad \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)_{\text{den}} = A'.$$

后续统一使用 denominator-layout。

例 3.1 设 $\mathbf{y} = (y_1, y_2, y_3)'$, $\mathbf{x} = (x_1, x_2)'$ 。在 denominator-layout 下,

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_2}{\partial x_1} & \frac{\partial y_3}{\partial x_1} \\ \frac{\partial y_1}{\partial x_2} & \frac{\partial y_2}{\partial x_2} & \frac{\partial y_3}{\partial x_2} \end{bmatrix},$$

即分母变量作行、分子分量作列。

向量与矩阵求导常用公式

设 $\mathbf{x}$ 为向量, A 为常矩阵, 则

$$\begin{aligned} \frac{\partial}{\partial \mathbf{x}} (A\mathbf{x}) &= A', & \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}'A) &= A, \\ \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}'\mathbf{x}) &= 2\mathbf{x}, & \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}'A\mathbf{x}) &= A\mathbf{x} + A'\mathbf{x}. \end{aligned}$$

设 A 为 $p \times p$ 对称正定矩阵, B 为 $p \times p$ 常矩阵, 则

$$\begin{aligned} \frac{\partial |A|}{\partial A} &= |A|A^{-1}, & \frac{\partial \text{tr}(AB)}{\partial A} &= B', \\ \frac{\partial \text{tr}(A^{-1}B)}{\partial A} &= -A^{-1}B'A^{-1}, & \frac{\partial \text{tr}(B'A^{-1}B)}{\partial A} &= -A^{-1}(BB')A^{-1}. \end{aligned}$$

1.2 正态模型下的 MLE

定理 3.1

设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 为来自 $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的随机样本, 则

$$\hat{\boldsymbol{\mu}}_{\text{MLE}} = \bar{\mathbf{X}}, \quad \hat{\boldsymbol{\Sigma}}_{\text{MLE}} = \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})'$$

相应观测值

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}, \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})'$$

称为 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$ 的极大似然估计。



注 与无偏估计相比, MLE 的协方差矩阵分母是 n 而不是 $n-1$ 。

1.3 最大似然值与不变性

将 $\hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}}$ 代回似然函数, 得到

$$L(\hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}}) = \frac{1}{(2\pi)^{np/2}} \exp\left(-\frac{np}{2}\right) \frac{1}{|\hat{\boldsymbol{\Sigma}}|^{n/2}} \propto (\text{generalized sample variance})^{-n/2}.$$

命题 3.1 (MLE 不变性)

若 $\hat{\theta}$ 是参数 θ 的 MLE, 且 $h(\cdot)$ 为函数, 则 $h(\hat{\theta})$ 是 $h(\theta)$ 的 MLE。



例如:

$$\widehat{\boldsymbol{\mu}'\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}} = \hat{\boldsymbol{\mu}}'\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\mu}},$$

$$\widehat{\sqrt{\sigma_{ii}}} = \sqrt{\hat{\sigma}_{ii}}, \quad \hat{\sigma}_{ii} = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)^2.$$

2 无偏估计量 (Unbiased Estimators)

定理 3.2

设 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 为来自均值向量为 $\boldsymbol{\mu}$ 、协方差矩阵为 $\boldsymbol{\Sigma}$ 的联合分布的随机样本。记

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})'].$$

定义

$$S = \frac{n}{n-1} S_n = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})'$$

则有

1. $E(\bar{\mathbf{X}}) = \boldsymbol{\mu}$;
2. $\text{Var}(\bar{\mathbf{X}}) = \frac{1}{n} \boldsymbol{\Sigma}$;
3. $E(S_n) = \frac{n-1}{n} \boldsymbol{\Sigma}$, 即 $E(S) = \boldsymbol{\Sigma}$ 。



注 $\hat{\mu} = \bar{\mathbf{X}}$ 和 $S = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})'$ 分别是 μ 和 Σ 的无偏估计量 (unbiased estimators)。

例 3.2 总体与样本的对比 设 $p = 2$, 总体随机向量 $\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$, 总体参数为

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}.$$

取 $n = 3$ 个样本:

$$\mathbf{X}_1 = \begin{bmatrix} 4 \\ 1 \end{bmatrix}, \quad \mathbf{X}_2 = \begin{bmatrix} 5 \\ 2 \end{bmatrix}, \quad \mathbf{X}_3 = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

则样本均值向量和样本协方差矩阵分别为

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix} = \begin{bmatrix} 4 \\ \frac{8}{3} \end{bmatrix}, \quad S = \begin{bmatrix} s_1^2 & s_{12} \\ s_{12} & s_2^2 \end{bmatrix} = \begin{bmatrix} 1 & -\frac{3}{2} \\ -\frac{3}{2} & \frac{26}{6} \end{bmatrix}.$$

2.1 线性变换的均值与方差 (Mean and Variance under Linear Transformation)

命题 3.2 (线性变换)

设 p 维随机向量 $\mathbf{X}$ 具有均值 μ 和协方差矩阵 $\text{Var}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)']$ 。对于 $q \times p$ 常数矩阵 A , 有

$$\begin{aligned} E(A\mathbf{X}) &= A\mu, \\ \text{Var}(A\mathbf{X}) &= A \text{Var}(\mathbf{X}) A'. \end{aligned}$$



证明

$$\begin{aligned} \text{Var}(A\mathbf{X}) &= E[(A\mathbf{X} - E(A\mathbf{X}))(A\mathbf{X} - E(A\mathbf{X}))'] \\ &= E[(A\mathbf{X} - A\mu)(A\mathbf{X} - A\mu)'] \\ &= E[A(\mathbf{X} - \mu)(\mathbf{X} - \mu)'A'] \\ &= A E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)'] A' \\ &= A \text{Var}(\mathbf{X}) A'. \end{aligned}$$

2.2 随机变量的线性组合 (Linear Combination of Random Variables)

单个线性组合

考虑线性组合

$$\mathbf{b}'\mathbf{X} = b_1X_1 + \cdots + b_pX_p, \quad \mathbf{c}'\mathbf{X} = c_1X_1 + \cdots + c_pX_p.$$

定理 3.3

线性组合 $\mathbf{b}'\mathbf{X}$ 和 $\mathbf{c}'\mathbf{X}$ 具有以下统计量:

总体层面:

$$\begin{aligned} E(\mathbf{c}'\mathbf{X}) &= \mathbf{c}'\mu, \\ \text{Var}(\mathbf{c}'\mathbf{X}) &= \mathbf{c}'\Sigma\mathbf{c}. \end{aligned}$$

样本层面:

$$\begin{aligned} \text{样本均值:} \quad & \mathbf{b}'\bar{\mathbf{x}}, \quad \mathbf{c}'\bar{\mathbf{x}}, \\ \text{样本方差:} \quad & \mathbf{b}'S\mathbf{b}, \quad \mathbf{c}'S\mathbf{c}. \end{aligned}$$



例 3.3 线性组合的均值与方差 设 $p = 2$, $\mathbf{c}' = [c_1 \ c_2]$, 则

总体:

$$\mathbf{c}'\mathbf{X} = [c_1 \ c_2] \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \quad \mathbf{c}'\boldsymbol{\mu} = [c_1 \ c_2] \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \mathbf{c}'\boldsymbol{\Sigma}\mathbf{c} = [c_1 \ c_2] \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}.$$

样本:

$$\mathbf{c}'\bar{\mathbf{x}} = [c_1 \ c_2] \begin{bmatrix} 4 \\ \frac{8}{3} \end{bmatrix}, \quad \mathbf{c}'\mathbf{S}\mathbf{c} = [c_1 \ c_2] \begin{bmatrix} 1 & -\frac{3}{2} \\ -\frac{3}{2} & \frac{26}{6} \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}.$$

线性组合的协方差

命题 3.3

$$\begin{aligned} \text{cov}(\mathbf{b}'\mathbf{X}, \mathbf{c}'\mathbf{X}) &= E[(\mathbf{b}'\mathbf{X} - E(\mathbf{b}'\mathbf{X}))(\mathbf{c}'\mathbf{X} - E(\mathbf{c}'\mathbf{X}))] \\ &= E[(\mathbf{b}'\mathbf{X} - \mathbf{b}'\boldsymbol{\mu})(\mathbf{c}'\mathbf{X} - \mathbf{c}'\boldsymbol{\mu})] \\ &= E[\mathbf{b}'(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})'\mathbf{c}] \\ &= \mathbf{b}' E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})'] \mathbf{c} \\ &= \mathbf{b}' \text{Var}(\mathbf{X}) \mathbf{c}. \end{aligned}$$

更一般地, 对于矩阵 B, C , 有 $\text{cov}(B\mathbf{X}, C\mathbf{X}) = B \text{Var}(\mathbf{X}) C'$ 。

多个线性组合

考虑 q 个线性组合

$$\begin{bmatrix} a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p \\ a_{21}X_1 + a_{22}X_2 + \cdots + a_{2p}X_p \\ \vdots \\ a_{q1}X_1 + a_{q2}X_2 + \cdots + a_{qp}X_p \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{q1} & a_{q2} & \cdots & a_{qp} \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = \mathbf{A}\mathbf{X}.$$

定理 3.4

设 $\mathbf{Z} = \mathbf{A}\mathbf{X}$ 为 q 个线性组合, 则

总体层面:

$$\boldsymbol{\mu}_{\mathbf{Z}} = E(\mathbf{Z}) = E(\mathbf{A}\mathbf{X}) = \mathbf{A}\boldsymbol{\mu}_{\mathbf{X}},$$

$$\boldsymbol{\Sigma}_{\mathbf{Z}} = \text{Cov}(\mathbf{Z}) = \text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A}\boldsymbol{\Sigma}_{\mathbf{X}}\mathbf{A}'.$$

样本层面: $\mathbf{A}\mathbf{X}$ 的样本均值向量为 $\mathbf{A}\bar{\mathbf{x}}$, 样本协方差矩阵为 $\mathbf{A}\mathbf{S}\mathbf{A}'$ 。

3 充分统计量 (Sufficient Statistics)

3.1 正态假设下的充分统计量

对于对数似然中的二次型项，有如下重写（便于识别与参数有关的信息汇总形式）：

$$\begin{aligned}\sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) &= \text{tr} \left(\sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right) \\ &= \text{tr} \left(\sum_{j=1}^n \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) (\mathbf{x}_j - \boldsymbol{\mu})' \right) \\ &= \text{tr} \left(\boldsymbol{\Sigma}^{-1} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu}) (\mathbf{x}_j - \boldsymbol{\mu})' \right) \\ &= \text{tr} \left(\boldsymbol{\Sigma}^{-1} \left[\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})' + n(\bar{\mathbf{x}} - \boldsymbol{\mu}) (\bar{\mathbf{x}} - \boldsymbol{\mu})' \right] \right).\end{aligned}$$

定理 3.5

设 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ 是来自多元正态总体 $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的随机样本，则样本均值向量 $\bar{\mathbf{X}}$ 与样本离差矩阵

$$\mathbf{S} = \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}}) (\mathbf{X}_j - \bar{\mathbf{X}})'$$

是关于参数 $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的充分统计量。等价地，按前文定义的样本协方差矩阵

$$\frac{1}{n-1} \mathbf{S}$$

也是充分统计量。



注 对正态总体而言，关于模型参数 $\boldsymbol{\mu}$ 与 $\boldsymbol{\Sigma}$ 的全部样本信息都包含在 $\bar{\mathbf{X}}$ 与 $\mathbf{S}$ 中。

4 点估计：均值、方差及其分布

4.1 充分统计量的抽样分布

回顾随机样本结论：设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 是来自总体的随机样本，则

$$E(\bar{\mathbf{X}}) = \boldsymbol{\mu},$$

$$\text{Var}(\bar{\mathbf{X}}) = \frac{1}{n} \boldsymbol{\Sigma},$$

$$E(S) = \boldsymbol{\Sigma},$$

其中

$$S = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}) (\mathbf{X}_i - \bar{\mathbf{X}})'.$$

定理 3.6

设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 为来自多元正态总体 $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 的容量为 n 的随机样本，则：

1. $\bar{\mathbf{X}} \sim N_p(\boldsymbol{\mu}, \frac{1}{n} \boldsymbol{\Sigma})$;
2. $(n-1)S \sim W_p(n-1, \boldsymbol{\Sigma})$;
3. $\bar{\mathbf{X}}$ 与 S 相互独立。



一维特例：卡方分布的递推证明

当 $p = 1$ 时，设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$ ，记

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

我们证明

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

先使用递推分解恒等式

$$\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{i=1}^{n-1} (X_i - \bar{X}_{n-1})^2 + \frac{n-1}{n} (X_n - \bar{X}_{n-1})^2.$$

令

$$Z_k = \sqrt{\frac{k-1}{k}} \cdot \frac{X_k - \bar{X}_{k-1}}{\sigma}, \quad k = 2, \dots, n,$$

下面说明 $Z_k \sim N(0, 1)$ 。由于

$$X_k \sim N(\mu, \sigma^2), \quad \bar{X}_{k-1} \sim N\left(\mu, \frac{\sigma^2}{k-1}\right),$$

且 X_k 与 $\bar{X}_{k-1}$ 独立（因为 X_k 与前 $k-1$ 个样本独立），故

$$X_k - \bar{X}_{k-1} \sim N\left(0, \sigma^2 + \frac{\sigma^2}{k-1}\right) = N\left(0, \sigma^2 \frac{k}{k-1}\right).$$

再乘以系数 $\sqrt{\frac{k-1}{k}} \frac{1}{\sigma}$ ，得到

$$E(Z_k) = 0, \quad \text{Var}(Z_k) = \frac{k-1}{k} \cdot \frac{1}{\sigma^2} \cdot \sigma^2 \frac{k}{k-1} = 1.$$

因此 $Z_k \sim N(0, 1)$ 。

进一步地， Z_k 与 $\{X_1, \dots, X_{k-1}\}$ 独立（因为 X_k 与前 $k-1$ 个样本独立，且正态族下零协方差蕴含独立），故 Z_k 与 $\sum_{i=1}^{k-1} (X_i - \bar{X}_{k-1})^2$ 独立。

对每个 $k = 2, \dots, n$ ，定义

$$A_k = \frac{1}{\sigma^2} \sum_{i=1}^k (X_i - \bar{X}_k)^2.$$

将分解恒等式同除以 σ^2 ，可写为

$$A_k = A_{k-1} + Z_k^2.$$

从 $k = 2$ 递推到 $k = n$ ，得到

$$A_n = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \sum_{j=2}^n Z_j^2,$$

其中 $Z_2, \dots, Z_n$ 相互独立且同分布为 $N(0, 1)$ ，因此

$$\sum_{j=2}^n Z_j^2 \sim \chi_{n-1}^2.$$

于是

$$\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \sim \chi_{n-1}^2.$$

这也说明：一维时 $W_1(n-1, \sigma^2)$ 恰对应于 $\sigma^2 \chi_{n-1}^2$ 。

证明 记

$$\mathbf{Y}_i = \mathbf{X}_i - \boldsymbol{\mu}, \quad i = 1, \dots, n,$$

则 $\mathbf{Y}_1, \dots, \mathbf{Y}_n \stackrel{i.i.d.}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma})$ 。

首先证明第 1 点。由正态分布在线性变换下封闭可得

$$\bar{\mathbf{X}} = \boldsymbol{\mu} + \frac{1}{n} \sum_{i=1}^n \mathbf{Y}_i \sim N_p\left(\boldsymbol{\mu}, \frac{1}{n} \boldsymbol{\Sigma}\right).$$

接着证明第 2 点与第 3 点。构造一个 $n \times n$ 正交矩阵

$$\mathbf{Q} = \begin{bmatrix} \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \frac{1}{\sqrt{n}} & \cdots & \frac{1}{\sqrt{n}} \\ \frac{1}{\sqrt{2 \cdot 1}} & \frac{-1}{\sqrt{2 \cdot 1}} & 0 & \cdots & 0 \\ \frac{1}{\sqrt{3 \cdot 2}} & \frac{1}{\sqrt{3 \cdot 2}} & \frac{-2}{\sqrt{3 \cdot 2}} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \frac{1}{\sqrt{n(n-1)}} & \cdots & \frac{-(n-1)}{\sqrt{n(n-1)}} \end{bmatrix},$$

其第一行为 $\mathbf{q}'_1 = \frac{1}{\sqrt{n}}(1, \dots, 1)$ 。令

$$\mathbf{Z} = [\mathbf{Z}_1, \dots, \mathbf{Z}_n] = [\mathbf{Y}_1, \dots, \mathbf{Y}_n] \mathbf{Q}'.$$

因为 $\mathbf{Q}$ 为正交矩阵，且 $(\mathbf{Y}_1, \dots, \mathbf{Y}_n)$ 为联合正态，故

$$\mathbf{Z}_1, \dots, \mathbf{Z}_n \text{ 相互独立, 且 } \mathbf{Z}_j \sim N_p(\mathbf{0}, \boldsymbol{\Sigma}).$$

由第一行定义可得

$$\mathbf{Z}_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{Y}_i = \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}).$$

同时，样本离差矩阵可写成

$$\sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})' = \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j'.$$

因而

$$(n-1)S = \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j' \sim W_p(n-1, \boldsymbol{\Sigma}),$$

这就证明了第 2 点。

最后，由上式可见 $\bar{\mathbf{X}}$ 只由 $\mathbf{Z}_1$ 决定，而 S 只由 $\mathbf{Z}_2, \dots, \mathbf{Z}_n$ 决定；又由于这些向量相互独立，故 $\bar{\mathbf{X}}$ 与 S 相互独立，第 3 点得证。

4.2 Wishart 分布

定义 3.1

记 $\mathbf{Z}_1, \dots, \mathbf{Z}_m \stackrel{i.i.d.}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma})$ ，则随机矩阵

$$\sum_{j=1}^m \mathbf{Z}_j \mathbf{Z}_j'$$

的分布称为自由度为 m 的 Wishart 分布，记作 $W_p(m, \boldsymbol{\Sigma})$ （也常写作 $W_m(\cdot | \boldsymbol{\Sigma})$ ）。



注 Wishart 分布可以看作标量情形 χ^2 分布在多元场景下的对应物。若 $z_1, \dots, z_m \stackrel{i.i.d.}{\sim} N(0, \sigma^2)$ ，则

$$\sum_{i=1}^m z_i^2 \sim \sigma^2 \chi_m^2.$$

注 历史上该分布由 John Wishart 于 1928 年提出；在多元假设检验与贝叶斯统计中应用广泛。

Wishart 分布的基本性质

在正态性假设下有：

1. **可加性：**若 $\mathbf{A}_1 \sim W_p(m_1, \mathbf{\Sigma})$, $\mathbf{A}_2 \sim W_p(m_2, \mathbf{\Sigma})$ 且二者独立，则

$$\mathbf{A}_1 + \mathbf{A}_2 \sim W_p(m_1 + m_2, \mathbf{\Sigma}).$$

2. **合同变换封闭性：**若 $\mathbf{A} \sim W_p(m, \mathbf{\Sigma})$ ，则对任意常矩阵 $\mathbf{C}$ ，有


$$\mathbf{CAC}' \sim W_p(m, \mathbf{C}\mathbf{\Sigma}\mathbf{C}').$$

第 4 节 Hypothesis testing

1 单样本均值假设检验

1.1 假设检验的一般流程

对任意假设检验问题，常用流程可图示为：



其中， Ω_α 只由 H_0 、 T 与显著性水平 α 决定，因此可在观察样本前预先给出。

1.2 一维单样本均值检验回顾

设 $x_1, \dots, x_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$ ，考虑

$$H_0: \mu = \mu_0 \quad \text{v.s.} \quad H_1: \mu \neq \mu_0.$$

在 H_0 下，

$$\bar{X} \sim N\left(\mu_0, \frac{\sigma^2}{n}\right), \quad \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim N(0, 1),$$

且

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

由于 $\bar{X}$ 与 S^2 独立，可得

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}.$$

因此双侧检验的拒绝域可写为

$$|T| > t_{n-1}(1 - \alpha/2).$$

另外，平方形式满足

$$T^2 \sim F_{1, n-1},$$

即

$$\left(\frac{\bar{X} - \mu_0}{S/\sqrt{n}}\right)^2 \sim F_{1, n-1}.$$

1.3 多元单样本均值检验与 Hotelling T^2

设 $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{i.i.d.}{\sim} N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ ，考虑点假设

$$H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0 \quad \text{v.s.} \quad H_1: \boldsymbol{\mu} \neq \boldsymbol{\mu}_0.$$

定义

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)' S^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0),$$

其中

$$S = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})'$$

在 H_0 下, 结论为

$$\frac{n-p}{p} \cdot \frac{T^2}{n-1} \sim F_{p, n-p}, \quad (n > p).$$

等价地,

$$T^2 \sim \frac{p(n-1)}{n-p} F_{p, n-p}.$$

因此, 在显著性水平 α 下, 拒绝域可写为

$$T^2 > \frac{p(n-1)}{n-p} F_{p, n-p}(1-\alpha).$$

注

1. 当 $p = 1$ 时, 上式退化为一维的 Student t 检验 (等价地 T^2 退化为 $F_{1, n-1}$ 统计量)。
2. Hotelling T^2 检验可视为 Student t 检验在多元情形下的自然推广。

推导细节

一维时有

$$t^2 = \frac{(\sqrt{n}(\bar{X} - \mu_0))^2}{S^2} \sim F_{1, n-1}.$$

写成 Z 记号, 则在 H_0 下可取

$$Z_1 = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim N(0, 1),$$

并且存在相互独立的 $Z_2, \dots, Z_n \stackrel{i.i.d.}{\sim} N(0, 1)$ 使得

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{j=2}^n Z_j^2.$$

于是

$$t^2 = \frac{Z_1^2}{\frac{1}{n-1} \sum_{j=2}^n Z_j^2} = \frac{\chi_1^2/1}{\chi_{n-1}^2/(n-1)} \sim F_{1, n-1}.$$

多维情形对应地将标量平方替换为二次型:

$$\frac{T^2}{n-1} = \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)' \left(\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})' \right)^{-1} \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0).$$

1. 白化变换

在 H_0 下, 记

$$\mathbf{Y} = \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0), \quad \mathbf{A} = \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})'$$

则

$$\mathbf{Y} \sim N_p(\mathbf{0}, \boldsymbol{\Sigma}), \quad \mathbf{A} \sim W_p(n-1, \boldsymbol{\Sigma}),$$

且 $\mathbf{Y}$ 与 $\mathbf{A}$ 独立。令

$$\mathbf{Z}_1 = \boldsymbol{\Sigma}^{-1/2} \mathbf{Y}, \quad \mathbf{W} = \boldsymbol{\Sigma}^{-1/2} \mathbf{A} \boldsymbol{\Sigma}^{-1/2},$$

则

$$\mathbf{Z}_1 \sim N_p(\mathbf{0}, I_p), \quad \mathbf{W} \sim W_p(n-1, I_p),$$

且二者独立，并且

$$\frac{T^2}{n-1} = \mathbf{Z}_1' \mathbf{W}^{-1} \mathbf{Z}_1.$$

2. Wishart 表示

由 Wishart 的表示定理，可写

$$\mathbf{W} = \sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j', \quad \mathbf{Z}_2, \dots, \mathbf{Z}_n \stackrel{i.i.d.}{\sim} N_p(\mathbf{0}, I_p),$$

且与 $\mathbf{Z}_1$ 独立，因此

$$\frac{T^2}{n-1} = \mathbf{Z}_1' \left(\sum_{j=2}^n \mathbf{Z}_j \mathbf{Z}_j' \right)^{-1} \mathbf{Z}_1.$$

3. 拆成“长度 × 方向”

令

$$\mathbf{u} = \frac{\mathbf{Z}_1}{\|\mathbf{Z}_1\|},$$

则 $\mathbf{u}$ 为单位向量，且

$$\mathbf{Z}_1 = \|\mathbf{Z}_1\| \mathbf{u}.$$

所以

$$\frac{T^2}{n-1} = \mathbf{Z}_1' \mathbf{W}^{-1} \mathbf{Z}_1 = \|\mathbf{Z}_1\|^2 \mathbf{u}' \mathbf{W}^{-1} \mathbf{u} = \frac{\mathbf{Z}_1' \mathbf{Z}_1}{(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1}}.$$

4. 识别分子与分母的分布

由于

$$\mathbf{Z}_1 \sim N_p(\mathbf{0}, I_p),$$

故

$$\mathbf{Z}_1' \mathbf{Z}_1 \sim \chi_p^2.$$

另一方面， $\mathbf{W} \sim W_p(n-1, I_p)$ ，故对于任意固定单位向量 $\mathbf{u}$ ，由 Wishart 分布的旋转不变性可知，

$$(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1}$$

的分布与取 $\mathbf{u} = \mathbf{e}_1$ 时相同。于是只需考虑

$$(\mathbf{e}_1' \mathbf{W}^{-1} \mathbf{e}_1)^{-1}.$$

将 $\mathbf{W}$ 分块写为

$$\mathbf{W} = \begin{pmatrix} w_{11} & \mathbf{w}_{12}' \\ \mathbf{w}_{12} & \mathbf{W}_{22} \end{pmatrix},$$

则由分块矩阵求逆公式，

$$(\mathbf{e}_1' \mathbf{W}^{-1} \mathbf{e}_1)^{-1} = w_{11} - \mathbf{w}_{12}' \mathbf{W}_{22}^{-1} \mathbf{w}_{12},$$

即为 Schur 补。对于中心 Wishart 分布，该 Schur 补满足

$$w_{11} - \mathbf{w}_{12}' \mathbf{W}_{22}^{-1} \mathbf{w}_{12} \sim \chi_{n-p}^2.$$

因而

$$(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1} \sim \chi_{n-p}^2.$$

若

- $\mathbf{x} \sim N_p(\mathbf{0}, \Sigma)$,
- $\mathbf{A} \sim W_p(m, \Sigma)$,
- 且 $\mathbf{x}$ 与 $\mathbf{A}$ 独立,

则有

$$\frac{m-p+1}{mp} \mathbf{x}^\top \mathbf{A}^{-1} \mathbf{x} \sim F_{p, m-p+1}.$$

将 $m = n - 1$ 代入, 立即得到

$$\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.$$

所以第二个自由度就是

$$m - p + 1 = (n - 1) - p + 1 = n - p,$$

这就是为什么会出现

$$n - p = (n - 1) - (p - 1).$$

$n - 1$ 是 $\mathbf{W}$ 作为 Wishart 矩阵本身的自由度, 而在固定方向 $\mathbf{u}$ 后, 还要扣去其正交补空间的 $p - 1$ 个方向, 因而剩余自由度为

$$(n - 1) - (p - 1) = n - p.$$

这也正是多元情形中分母自由度由一维的 $n - 1$ 变成 $n - p$ 的原因。

5. 独立性与 F 分布

注意到

$$\mathbf{Z}_1' \mathbf{Z}_1 = \|\mathbf{Z}_1\|^2$$

只依赖于 $\mathbf{Z}_1$ 的长度, 而

$$(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1}$$

只依赖于 $\mathbf{Z}_1$ 的方向 $\mathbf{u}$ 及 $\mathbf{W}$ 。由于标准正态向量的长度与方向独立, 且 $\mathbf{Z}_1$ 与 $\mathbf{W}$ 独立, 因此这两部分相互独立。

于是

$$\mathbf{Z}_1' \mathbf{Z}_1 \sim \chi_p^2, \quad (\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1} \sim \chi_{n-p}^2,$$

且二者独立, 从而

$$\frac{\mathbf{Z}_1' \mathbf{Z}_1 / p}{(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1} / (n - p)} \sim F_{p, n-p}.$$

又因为

$$\frac{T^2}{n - 1} = \frac{\mathbf{Z}_1' \mathbf{Z}_1}{(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1}},$$

所以

$$\frac{1}{n - 1} T^2 = \frac{\mathbf{Z}_1' \mathbf{Z}_1 / p}{(\mathbf{u}' \mathbf{W}^{-1} \mathbf{u})^{-1} / (n - p)} \cdot \frac{p}{n - p}.$$

即

$$\boxed{\frac{n-p}{p(n-1)} T^2 \sim F_{p, n-p}.}$$

当 $p = 1$ 时, 上式退化为

$$T^2 \sim F_{1, n-1}.$$

而一维时 $T^2 = t^2$, 故

$$t^2 \sim F_{1, n-1},$$

与单样本 t 检验完全一致。

2 Hotelling T^2 的性质与置信区域

2.1 Hotelling T^2 的不变性

后续记号约定：向量用大写（或粗体）字母表示，标量用小写字母表示。

命题 4.1 (对测量单位变化的不变性)

设可逆矩阵 $C \in \mathbb{R}^{p \times p}$ 、向量 $d \in \mathbb{R}^p$ ，并作仿射变换

$$\mathbf{Y} = C\mathbf{X} + d.$$

记

$$\bar{\mathbf{y}} = C\bar{\mathbf{x}} + d, \quad S_{\mathbf{y}} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{y}_j - \bar{\mathbf{y}})(\mathbf{y}_j - \bar{\mathbf{y}})' = CSC',$$

以及

$$\boldsymbol{\mu}_{\mathbf{y}} = C\boldsymbol{\mu} + d, \quad \boldsymbol{\mu}_{\mathbf{y},0} = C\boldsymbol{\mu}_0 + d.$$

则基于 $\mathbf{Y}$ 的 Hotelling 统计量

$$T_{\mathbf{Y}}^2 = n(\bar{\mathbf{y}} - \boldsymbol{\mu}_{\mathbf{y},0})' S_{\mathbf{y}}^{-1} (\bar{\mathbf{y}} - \boldsymbol{\mu}_{\mathbf{y},0})$$

满足

$$T_{\mathbf{Y}}^2 = T_{\mathbf{X}}^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' S^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0).$$

证明 由 $\bar{\mathbf{y}} - \boldsymbol{\mu}_{\mathbf{y},0} = C(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$ 与 $S_{\mathbf{y}} = CSC'$ ，可得

$$\begin{aligned} T_{\mathbf{Y}}^2 &= n(C(\bar{\mathbf{x}} - \boldsymbol{\mu}_0))' (CSC')^{-1} (C(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)) \\ &= n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' C' (C')^{-1} S^{-1} C^{-1} C (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) \\ &= n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' S^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) = T_{\mathbf{X}}^2. \end{aligned}$$

2.2 总体均值的置信区域

一维回顾

设 $z_1, \dots, z_n \stackrel{i.i.d.}{\sim} N(\psi, \sigma_{\psi}^2)$ ，记

$$\hat{\psi} = \bar{z}, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2.$$

则

$$\left(\frac{\bar{z} - \psi}{s/\sqrt{n}} \right)^2 \sim F_{1,n-1},$$

从而置信区间可写为

$$I(z) = \left\{ \psi : n \frac{(\bar{z} - \psi)^2}{s^2} \leq c^2 \right\}, \quad c^2 = t_{n-1}^2 \left(\frac{\alpha}{2} \right) = F_{1,n-1}(\alpha).$$

等价形式为

$$I(z) = \bar{z} \pm t_{n-1} \left(\frac{\alpha}{2} \right) \frac{s}{\sqrt{n}}.$$

多维情形

设 $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{i.i.d.}{\sim} N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 记

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}}, \quad S = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})'$$

由

$$\frac{n-p}{p} \cdot \frac{1}{n-1} n(\bar{\mathbf{X}} - \boldsymbol{\mu})' S^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim F_{p, n-p}$$

可得 $100(1-\alpha)\%$ 的总体均值置信区域:

$$R(x) = \{\boldsymbol{\mu} : n(\bar{\mathbf{X}} - \boldsymbol{\mu})' S^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq c^2\},$$

其中

$$c^2 = T^2(\alpha) = \frac{p(n-1)}{n-p} F_{p, n-p}(\alpha).$$

2.3 线性组合的个体覆盖区间

考虑任意固定向量 $a \in \mathbb{R}^p$, 定义标量

$$z_i = a' \mathbf{X}_i \sim N(a' \boldsymbol{\mu}, a' \boldsymbol{\Sigma} a).$$

记

$$\psi = a' \boldsymbol{\mu}, \quad s_z^2 = a' S a = \frac{1}{n-1} \sum_{i=1}^n (z_i - \bar{z})^2, \quad \hat{\psi} = \bar{z} = a' \bar{\mathbf{X}}.$$

则

$$\frac{\hat{\psi} - \psi}{s_z / \sqrt{n}} \sim t_{n-1}.$$

因此, $100(1-\beta)\%$ 的个体覆盖区间为

$$I_\psi(z) = \hat{\psi} \pm t_{n-1} \left(\frac{\beta}{2} \right) \frac{s_z}{\sqrt{n}} = a' \bar{\mathbf{X}} \pm t_{n-1} \left(\frac{\beta}{2} \right) \sqrt{\frac{a' S a}{n}}.$$

2.4 个别区间与同时覆盖区间

设 $\psi_k = a'_k \boldsymbol{\mu}$ ($k = 1, \dots, m$).

1. 个别覆盖 (individual coverage):

$$P(I_{\psi_k}(z) \text{ 覆盖 } \psi_k) = 1 - \beta.$$

2. 同时覆盖 (simultaneous coverage): 关注

$$P(I_{\psi_k}(z) \text{ 对所有 } k = 1, \dots, m \text{ 同时覆盖 } \psi_k).$$

2.4.1 Bonferroni 同时区间

令事件

$$C_k = \{I_{\psi_k}(z) \text{ 覆盖 } \psi_k\}, \quad k = 1, \dots, m.$$

若每个区间都按同一误差水平 β 构造, 则由 Bonferroni 不等式

$$P(\text{至少一个 } C_k \text{ 不成立}) \leq \sum_{k=1}^m P(C_k^c) = \sum_{k=1}^m \beta = m\beta.$$

因此

$$P(\text{所有 } C_k \text{ 同时成立}) \geq 1 - m\beta.$$

令 $m\beta = \alpha$ ，即可保证同时覆盖概率至少为 $1 - \alpha$ 。由此得到 Bonferroni 区间

$$I_{\psi_k}(z) = \hat{\psi}_k \pm t_{n-1} \left(\frac{\alpha}{2m} \right) \widehat{se}(\hat{\psi}_k), \quad \hat{\psi}_k = a'_k \bar{\mathbf{X}}, \quad \widehat{se}(\hat{\psi}_k) = \sqrt{\frac{a'_k S a_k}{n}}.$$

2.4.2 基于 T^2 的同时覆盖区间

我们希望寻找常数 c ，使得对所有 $a \neq 0$ 同时有

$$I_a(x) = a' \bar{\mathbf{X}} \pm c \sqrt{\frac{a' S a}{n}}$$

覆盖 $a' \boldsymbol{\mu}$ 。这等价于要求

$$\max_{a \neq 0} \frac{n(a'(\bar{\mathbf{X}} - \boldsymbol{\mu}))^2}{a' S a} \leq c^2.$$

根据矩阵最大化引理 ($B \succ 0$ ，向量 d 给定)：

$$\max_{x \neq 0} \frac{(x' d)^2}{x' B x} = d' B^{-1} d,$$

将其应用于 $d = \bar{\mathbf{X}} - \boldsymbol{\mu}$ 、 $B = S$ ，得到

$$\max_{a \neq 0} \frac{n(a'(\bar{\mathbf{X}} - \boldsymbol{\mu}))^2}{a' S a} = n(\bar{\mathbf{X}} - \boldsymbol{\mu})' S^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}) = T_\mu^2.$$

又由前述置信区域结果，

$$P(T_\mu^2 \leq c^2) = 1 - \alpha$$

当且仅当

$$c^2 = T^2(\alpha) = \frac{p(n-1)}{n-p} F_{p, n-p}(\alpha).$$

因此得到 T^2 同时区间

$$I_a(x) = a' \bar{\mathbf{X}} \pm c \sqrt{\frac{a' S a}{n}}, \quad c^2 = \frac{p(n-1)}{n-p} F_{p, n-p}(\alpha),$$

并满足

$$P(I_a(x) \text{ 对所有 } a \neq 0 \text{ 同时覆盖 } a' \boldsymbol{\mu}) = 1 - \alpha.$$

3 双总体均值的推断

3.1 配对样本的均值检验

3.1.1 配对样本的记号

设定：对同一组 n 个实验单元，分别在处理 1 和处理 2 下观测 p 维响应向量：

$$\mathbf{X}_{1j} \sim N_p(\boldsymbol{\mu}_1, \Sigma_1), \quad \mathbf{X}_{2j} \sim N_p(\boldsymbol{\mu}_2, \Sigma_2), \quad j = 1, \dots, n.$$

差值向量：

$$\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}, \quad j = 1, \dots, n.$$

假设 $\mathbf{D}_1, \dots, \mathbf{D}_n$ 独立同分布于 $N_p(\boldsymbol{\delta}, \Sigma_d)$ ，其中：

$$\boldsymbol{\delta} = E(\mathbf{D}_j) = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = (\delta_1, \delta_2, \dots, \delta_p)',$$

$$\Sigma_d = \text{Cov}(\mathbf{D}_j).$$

样本统计量:

$$\bar{D} = \frac{1}{n} \sum_{j=1}^n D_j,$$

$$S_d = \frac{1}{n-1} \sum_{j=1}^n (D_j - \bar{D})(D_j - \bar{D})'.$$

检验假设:

$$H_0: \delta = \delta_0 \quad (\text{等价于 } H_0: \mu_1 - \mu_2 = \delta_0)$$

3.1.2 配对样本的置信域

定理 4.1

设差值 $D_1, \dots, D_n$ 是来自 $N_p(\delta, \Sigma_d)$ 总体的随机样本。则

$$T^2 = n(\bar{D} - \delta)' S_d^{-1} (\bar{D} - \delta)$$

且

$$T^2 \sim \frac{(n-1)p}{n-p} F_{p, n-p}.$$

该分布与真实参数 δ 和 Σ_d 无关。



3.2 两个独立总体的比较

3.2.1 假设条件

来自两个总体的样本满足:

$$\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1} \sim N(\mu_1, \Sigma_1) \quad \text{独立同分布}$$

$$\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2} \sim N(\mu_2, \Sigma_2) \quad \text{独立同分布}$$

两总体相互独立。当 n_1 和 n_2 较小时, 假设协方差矩阵相等:

$$\Sigma_1 = \Sigma_2 = \Sigma$$

3.2.2 Hotelling 的 T^2 统计量

考虑点原假设:

$$H_0: \mu_1 - \mu_2 = \delta_0 \quad \text{vs} \quad H_1: \mu_1 - \mu_2 \neq \delta_0$$

样本均值: $\bar{x}_1 - \bar{x}_2$

我们有:

$$E(\bar{x}_1 - \bar{x}_2) = \mu_1 - \mu_2$$

$$\text{Var}(\bar{x}_1 - \bar{x}_2) = \text{Var}(\bar{x}_1) + \text{Var}(\bar{x}_2) = \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma$$

3.2.3 汇总协方差估计量

启发式地, S_1 和 S_2 都是 Σ 的无偏估计量, 且自由度分别为

$$n_1 - 1, \quad n_2 - 1.$$

将信息合并得到 Σ 的估计量:

$$S_{\text{pooled}} = \frac{\sum_{j=1}^{n_1} (\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)(\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)' + \sum_{j=1}^{n_2} (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)(\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)'}{n_1 + n_2 - 2} \quad (4.1)$$

可改写为：

$$S_{\text{pooled}} = \frac{n_1 - 1}{n_1 + n_2 - 2} S_1 + \frac{n_2 - 1}{n_1 + n_2 - 2} S_2 \sim \frac{W_p(n_1 + n_2 - 2, \Sigma)}{n_1 + n_2 - 2} \quad (4.2)$$

其中

$$(n_1 - 1)S_1 \sim W_p(n_1 - 1, \Sigma),$$

$$(n_2 - 1)S_2 \sim W_p(n_2 - 1, \Sigma).$$

3.2.4 检验统计量

$$T^2 = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1/2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)' S_{\text{pooled}}^{-1} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1/2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)$$

可表示为：

$$T^2 = (\text{多元正态})' \left[\frac{W_p(n_1 + n_2 - 2, \Sigma)}{n_1 + n_2 - 2} \right]^{-1} (\text{多元正态})$$

在 H_0 下：

$$T^2 = N_p(0, \Sigma)' \left[\frac{W_p(n_1 + n_2 - 2, \Sigma)}{n_1 + n_2 - 2} \right]^{-1} N_p(0, \Sigma)$$

3.2.5 单总体 vs 双总体

单总体情形

- 点估计：

$$\sqrt{n}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \sim N_p(0, \Sigma), \quad (n - 1)S \sim \text{Wishart}_p(n - 1, \Sigma).$$

- 检验：

$$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' (S)^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) \sim \frac{p(n - 1)}{(n - 1) - (p - 1)} F_{p, (n - 1) - (p - 1)}.$$

双总体情形

- 点估计：

$$\left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1/2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)) \sim N_p(0, \Sigma),$$

$$(n_1 + n_2 - 2)S_{\text{pooled}} \sim \text{Wishart}_p(n_1 + n_2 - 2, \Sigma).$$

- 检验：

$$T^2 = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1/2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)' S_{\text{pooled}}^{-1} \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1/2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0).$$

3.2.6 双总体假设检验

在 H_0 下：

$$\frac{(n_1 + n_2 - p - 1)}{p(n_1 + n_2 - 2)} T^2 \sim F_{p, n_1 + n_2 - p - 1}$$

拒绝域为：

$$T^2 > T^2(\alpha) = \frac{p}{(n_1 + n_2 - p - 1)} (n_1 + n_2 - 2) F_{p, n_1 + n_2 - p - 1}(\alpha) \quad (4.3)$$

其中 $F_{p, n_1 + n_2 - p - 1}(\alpha)$ 是显著性水平 α 下的临界值。

3.3 双总体均值的置信区域

3.3.1 置信区域的定义

等价地，总体均值差 $\mu_1 - \mu_2$ 的 $100(1 - \alpha)\%$ 的置信区域可以表示为

$$R(\bar{\mathbf{x}}) = \left\{ \boldsymbol{\mu} : (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2))' \left(\left(\frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} \right)^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)) \leq T^2(\alpha) \right\}$$

其中

$$T^2(\alpha) = \frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1}(\alpha).$$

3.3.2 线性组合的同时覆盖区间

考虑线性组合 $a'(\mu_1 - \mu_2)$ ，其中 $a \in \mathbb{R}^p$ 为任意向量。

定理 4.2 (双总体同时覆盖区间)

令

$$c^2 = \frac{p}{n_1 + n_2 - p - 1} (n_1 + n_2 - 2) F_{p, n_1 + n_2 - p - 1}(\alpha).$$

则以概率 $1 - \alpha$ ，对所有的 a ，区间

$$I_a = a'(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \pm c \sqrt{a' \left(\frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} a}$$

将同时覆盖所有的 $a'(\mu_1 - \mu_2)$ 。特别地，第 i 个分量的差 $\mu_{1i} - \mu_{2i}$ 将被

$$(\bar{x}_{1i} - \bar{x}_{2i}) \pm c \sqrt{\left(\frac{1}{n_1} + \frac{1}{n_2} \right) s_{ii, \text{pooled}}}$$

覆盖，其中 $s_{ii, \text{pooled}}$ 是 S_{pooled} 的第 (i, i) 元素。



3.3.3 最大方向投影

我们希望找到向量 a 使得

$$\arg \max_a \left| \frac{a'(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)}{\sqrt{a' \left(\frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}} a}} \right|.$$

若记 $\mathbf{V} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right) S_{\text{pooled}}$ ，则等价于

$$\arg \max_a \left| \frac{a'(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)}{\sqrt{a' \mathbf{V} a}} \right|.$$

矩阵最大化引理：

命题 4.2 (Maximization Lemma)

设 $\mathbf{B}$ 是正定矩阵， $\mathbf{d}$ 是给定向量。对任意非零向量 $\mathbf{x}$ ，有

$$\max_{\mathbf{x} \neq 0} \frac{(\mathbf{x}' \mathbf{d})^2}{\mathbf{x}' \mathbf{B} \mathbf{x}} = \mathbf{d}' \mathbf{B}^{-1} \mathbf{d},$$

且当 $\mathbf{x} = c \mathbf{B}^{-1} \mathbf{d}$ (c 为任意常数) 时达到最大值。



应用与解:

将引理应用于 $\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2$ 、 $\mathbf{B} = \mathbf{V}$ ，可得

$$a^* \propto \mathbf{V}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = S_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

因此，最优投影方向正是样本协方差矩阵逆作用在两样本均值差上的结果。

4 单总体均值向量的大样本推断

4.1 样本均值与样本协方差的大样本行为

一个关键点是：以下大样本结论不要求总体正态性，只需适当矩条件成立。

4.1.1 大数定律

定理 4.3 (大数定律)

设 $Y_1, Y_2, \dots, Y_n$ 是来自某总体的独立观测，且

$$E(Y_i) = \mu, \quad \bar{Y} = \frac{Y_1 + Y_2 + \dots + Y_n}{n}.$$

则

$$\bar{Y} \xrightarrow{P} \mu.$$

对多元情形，设 $X_1, \dots, X_n \in \mathbb{R}^p$ 独立同分布，

$$E(X_i) = \mu, \quad \text{Cov}(X_i) = \Sigma,$$

则有

$$\bar{X} \xrightarrow{P} \mu, \quad S \xrightarrow{P} \Sigma.$$

其中

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})'.$$

并且可写成

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \mu)(X_i - \mu)' - \frac{n}{n-1} (\bar{X} - \mu)(\bar{X} - \mu)'.$$

第二项在概率意义下趋于 0，因此 S 收敛到 Σ 。

4.1.2 中心极限定理

定理 4.4

设 $X_1, X_2, \dots, X_n$ 是来自任意总体的独立观测，满足

$$E(X_i) = \mu, \quad \text{Cov}(X_i) = \Sigma < \infty.$$

当样本量足够大时，有近似关系

$$\sqrt{n}(\bar{X} - \mu) \approx N_p(0, \Sigma),$$

以及

$$n(\bar{X} - \mu)' S^{-1} (\bar{X} - \mu) \approx \chi_p^2.$$

这里通常要求 n 相对 p 足够大。

4.2 单总体均值向量的大样本推断

4.2.1 大样本假设检验

定理 4.5

设 $X_1, \dots, X_n$ 来自均值向量为 μ 、协方差矩阵正定的总体。考虑

$$H_0: \mu = \mu_0 \quad \text{vs} \quad H_1: \mu \neq \mu_0.$$

当 $n-p$ 足够大时, 显著性水平近似为 α 的拒绝域可写为

$$n(\bar{x} - \mu_0)' S^{-1} (\bar{x} - \mu_0) > \chi_p^2(\alpha),$$

其中 $\chi_p^2(\alpha)$ 表示 χ^2 分布 (自由度 p) 的上 100α 分位点。



4.2.2 大样本同时置信区间

定理 4.6

在上述条件下, 当 $n-p$ 足够大时, 对任意向量 $a \in \mathbb{R}^p$, 区间

$$a' \bar{x} \pm \sqrt{\chi_p^2(\alpha)} \sqrt{\frac{a' S a}{n}}$$

以近似概率 $1 - \alpha$ 同时覆盖 $a' \mu$ 。



并且当大样本近似适用时, 常有

$$\frac{(n-1)p}{n-p} F_{p, n-p}(\alpha) \approx \chi_p^2(\alpha),$$

因此与正态总体下的 Hotelling 型结果在数值上趋于一致。

5 双总体均值向量的大样本推断

5.1 协方差不相等时的大样本推断

5.1.1 协方差不相等时的检验

设定: 设两组样本

$$\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1} \quad \text{和} \quad \mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2}$$

分别来自两个总体, 组内独立同分布且两组相互独立, 并满足

$$E(\mathbf{X}_1) = \boldsymbol{\mu}_1, \quad \text{Var}(\mathbf{X}_1) = \Sigma_1, \quad E(\mathbf{X}_2) = \boldsymbol{\mu}_2, \quad \text{Var}(\mathbf{X}_2) = \Sigma_2.$$

允许 $\Sigma_1 \neq \Sigma_2$ 。记样本均值与样本协方差:

$$\bar{\mathbf{X}}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \mathbf{X}_{ij}, \quad S_i = \frac{1}{n_i - 1} \sum_{j=1}^{n_i} (\mathbf{X}_{ij} - \bar{\mathbf{X}}_i)(\mathbf{X}_{ij} - \bar{\mathbf{X}}_i)', \quad i = 1, 2.$$

命题 4.3 (均值差的大样本性质)

当 n_1, n_2 相对 p 足够大时:

1. 期望: $E(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$
2. 方差: $\text{Var}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{1}{n_1} \Sigma_1 + \frac{1}{n_2} \Sigma_2$

3. 渐近正态性 (中心极限定理):

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \xrightarrow{d} N_p\left(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2, \frac{1}{n_1}\boldsymbol{\Sigma}_1 + \frac{1}{n_2}\boldsymbol{\Sigma}_2\right)$$

4. 方差估计的一致性 (大数定律):

$$\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2 \xrightarrow{P} \frac{1}{n_1}\boldsymbol{\Sigma}_1 + \frac{1}{n_2}\boldsymbol{\Sigma}_2$$

定理 4.7 (双总体均值差的大样本检验)

在上述设定下, 对假设

$$H_0: \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}_0,$$

统计量

$$Q = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)' \left(\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2 \right)^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)$$

近似服从 χ_p^2 分布。近似显著性水平 α 的拒绝域为

$$Q > \chi_p^2(\alpha).$$

5.1.2 双总体均值差的大样本置信椭圆

定理 4.8 (双总体均值差的大样本置信椭圆)

当 $n_1 - p$ 与 $n_2 - p$ 都足够大时, $\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$ 的近似 $100(1 - \alpha)\%$ 置信区域为

$$\left\{ \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 : (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2))' \left(\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2 \right)^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)) \leq \chi_p^2(\alpha) \right\}.$$

5.1.3 线性组合的同时覆盖区间

定理 4.9 (双总体线性组合的大样本同时覆盖区间)

令

$$c^2 = \chi_p^2(\alpha).$$

则以近似概率 $1 - \alpha$, 对任意 $\mathbf{a} \in \mathbb{R}^p$, 区间

$$\mathbf{a}'(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \pm c \sqrt{\mathbf{a}' \left(\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2 \right) \mathbf{a}}$$

同时覆盖 $\mathbf{a}'(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ 。

Hotelling's T^2 统计量的适用性

注 对双总体情形, 经典 Hotelling 的 T^2 推断通常依赖以下条件:

1. **方差齐性**: 两总体具有共同协方差矩阵, $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}$;
2. **独立性**: 两组样本独立抽取 (注意这不意味着变量分量彼此独立);
3. **正态性**: 两总体服从多元正态分布。

当正态性与方差齐性较可信且样本量中等时, 优先采用基于 S_{pooled} 的 T^2 与精确 F 分布临界值。若样本量较大且可能存在 $\boldsymbol{\Sigma}_1 \neq \boldsymbol{\Sigma}_2$, 则可采用上面基于 $\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2$ 的大样本 χ^2 近似方法。

命题 4.4 (等样本量特例)

当 $n_1 = n_2 = n$ 时,

$$\frac{1}{n_1}S_1 + \frac{1}{n_2}S_2 = \frac{1}{n}(S_1 + S_2) = \frac{(n-1)S_1 + (n-1)S_2}{n+n-2} \left(\frac{1}{n} + \frac{1}{n} \right) = S_{\text{pooled}} \left(\frac{1}{n} + \frac{1}{n} \right).$$

即大样本形式与 pooled-covariance 形式在该特例下可直接对应。



6 双总体协方差矩阵相等性的检验

6.1 检验设定与假设

定理 4.10 (双总体协方差齐性检验的模型设定)

设

$$\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1} \sim N_p(\boldsymbol{\mu}_1, \Sigma_1),$$

$$\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2} \sim N_p(\boldsymbol{\mu}_2, \Sigma_2),$$

且两组样本彼此独立、组内独立同分布。考虑假设

$$H_0 : \Sigma_1 = \Sigma_2 \quad \text{vs} \quad H_1 : \Sigma_1 \neq \Sigma_2.$$



6.2 LRT 与自由度

命题 4.5 (似然比检验的自由度)

记

$$\Lambda = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)}.$$

在嵌套模型下, 渐近有

$$-2 \ln \Lambda \xrightarrow{d} \chi^2_{\nu - \nu_0},$$

其中 $\nu = \dim(\Theta)$, $\nu_0 = \dim(\Theta_0)$ 。

对双总体协方差齐性检验: 备择模型下参数为 Σ_1, Σ_2 , 其维数为

$$\nu = 2 \times \frac{p(p+1)}{2} = p(p+1),$$

原假设下参数为公共协方差矩阵 Σ , 其维数为

$$\nu_0 = \frac{p(p+1)}{2}.$$

因而自由度差为

$$\nu - \nu_0 = \frac{p(p+1)}{2}.$$



6.3 Box's M 检验 (修正的 LRT)

定理 4.11 (双总体 Box's M 检验)

记样本协方差矩阵为 S_1, S_2 , 并令

$$S_{\text{pooled}} = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}.$$

定义似然比统计量

$$\Lambda = \prod_{i=1}^2 \left(\frac{|S_i|}{|S_{\text{pooled}}|} \right)^{(n_i - 1)/2}.$$

等价地,

$$-2 \ln \Lambda = (n_1 + n_2 - 2) \ln |S_{\text{pooled}}| - (n_1 - 1) \ln |S_1| - (n_2 - 1) \ln |S_2|.$$

当样本量充分大时, 在 H_0 下有近似

$$(1 - u)(-2 \ln \Lambda) \xrightarrow{d} \chi_{\nu}^2,$$

其中

$$\nu = \frac{p(p+1)}{2},$$

$$u = \left[\sum_{i=1}^2 \frac{1}{n_i - 1} - \frac{1}{n_1 + n_2 - 2} \right] \frac{2p^2 + 3p - 1}{6(p+1)}.$$

注 给定显著性水平 α , 当

$$(1 - u)(-2 \ln \Lambda) > \chi_{\nu}^2(\alpha)$$

时拒绝 H_0 , 认为两总体协方差矩阵存在显著差异。

6.4 对 Box's M 检验的说明

注

1. Box's M 检验对正态性偏离非常敏感。
2. 小样本下检验功效较低, 不显著结果并不必然意味着协方差矩阵相等。
3. 大样本下该检验可能过于敏感, 建议结合效应大小与实际背景解读, 必要时采用更严格的显著性水平 (如 $\alpha = 0.001$)。

7 正态性假设的评估

7.1 图形方法

对单变量数据, 常用图形方法包括:

1. 直方图 (Histogram);
2. Q-Q 图 (normal Q-Q plot)。

定理 4.12 (多元正态分布的可检验性质)

若 $\mathbf{X} \sim N_p(\mu, \Sigma)$, 则有:

1. 每个边际分量 X_i 服从一维正态分布;
2. 任意线性组合 $a'\mathbf{X}$ 服从一维正态分布;
3. 二次型

$$(\mathbf{X} - \mu)' \Sigma^{-1} (\mathbf{X} - \mu)$$

服从自由度为 p 的卡方分布。



注 在实践中, 可对边际变量或主要方向投影 (如 PCA 主成分得分) 作直方图和 Q-Q 图; 也可基于马氏距离构造卡方图评估多元正态性。

7.2 Q-Q 图方法

命题 4.6 (一维正态 Q-Q 图构造步骤)

设 $x_{(1)}, \dots, x_{(n)}$ 为样本次序统计量, 定义

$$p_{(j)} = \frac{j - \frac{1}{2}}{n}, \quad q_{(j)} = \Phi^{-1}(p_{(j)}), \quad j = 1, \dots, n.$$

构造步骤如下:

1. 将观测值从小到大排序, 得到 $x_{(1)}, \dots, x_{(n)}$;
2. 计算标准正态分位数 $q_{(1)}, \dots, q_{(n)}$;
3. 绘制点对 $(q_{(j)}, x_{(j)})$, 并检查是否近似线性。

可用相关系数

$$r_Q = \frac{\sum_{j=1}^n (x_{(j)} - \bar{x})(q_{(j)} - \bar{q})}{\sqrt{\sum_{j=1}^n (x_{(j)} - \bar{x})^2} \sqrt{\sum_{j=1}^n (q_{(j)} - \bar{q})^2}}$$

作为“线性程度”的辅助度量。



7.3 多元正态性的卡方图

命题 4.7 (卡方图步骤)

设

$$d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})' S^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, \dots, n.$$

构造多元正态卡方图可按以下步骤进行:

1. 将 d_j^2 从小到大排序, 记为 $d_{(1)}^2, \dots, d_{(n)}^2$, 并计算 $p_{(j)} = \frac{j - \frac{1}{2}}{n}$;
2. 计算卡方分位数

$$q_{(j)} = \chi_p^2(1 - p_{(j)}), \quad j = 1, \dots, n;$$

3. 绘制点对 $(q_{(j)}, d_{(j)}^2)$, 并与直线 $y = x$ 比较其线性程度。



第三部分

Covariance Estimation

第5节 Primary Component Analysis (PCA)

1 主成分分析 (Principal Component Analysis)

1.1 基本思想与目标

定义 5.1 (主成分分析)

设随机向量

$$\mathbf{X} = (X_1, X_2, \dots, X_p)'$$

对 $j = 1, \dots, p$, 考虑线性组合 (候选主成分)

$$Y_j = \mathbf{a}_j' \mathbf{X} = a_{j1}X_1 + \dots + a_{jp}X_p.$$



主成分分析 (PCA) 关注如何用少数几个这样的线性组合解释原始变量的方差-协方差结构。

PCA 的总体目标通常包括:

- 数据降维 (data reduction);
- 结构解释 (interpretation)。

几何与代数视角

几何上, PCA 可看作对原坐标系进行旋转; 代数上, PCA 是原变量的线性变换。

令

$$\mathbf{A} = (a_1, a_2, \dots, a_p),$$

则可写为

$$\mathbf{Y} = \mathbf{A}' \mathbf{X}.$$

若 $\mathbf{A}$ 为正交矩阵 ($\mathbf{A}'\mathbf{A} = \mathbf{I}_p$), 该变换对应旋转坐标系。

在样本矩阵层面, 若

$$\mathbf{X} = [x_{ij}]_{n \times p},$$

则旋转后的得分矩阵可写为

$$\mathbf{Y} = [y_{ij}]_{n \times p} = \mathbf{X} \mathbf{A}.$$

1.2 总体主成分 (Population Principal Components)

设

$$\text{Cov}(\mathbf{X}) = \Sigma,$$

其特征值满足

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0.$$

定义 5.2 (第一主成分)

第一主成分定义为

$$Y_1 = a_1' \mathbf{X},$$

其中系数向量 a_1 由优化问题确定:

$$\max_{a_1} a_1' \Sigma a_1, \quad a_1' a_1 = 1.$$

等价写法为 Rayleigh 商优化:

$$\max_{a \neq 0} \frac{a' \Sigma a}{a' a}.$$



该约束来自尺度不唯一性:

$$\text{Var}(c a' \mathbf{X}) = c^2 a' \Sigma a.$$

若不限制 a 的长度, 可通过放大 c 使方差任意增大。

1.2.1 矩阵最大化回顾**命题 5.1 (单位球面上二次型的极值)**

设 Σ 为正定矩阵, 特征值与单位特征向量分别为

$$(\lambda_1, e_1), \dots, (\lambda_p, e_p), \quad \lambda_1 \geq \dots \geq \lambda_p > 0.$$

则

$$\max_{a \neq 0} \frac{a' \Sigma a}{a' a} = \lambda_1.$$

最大值在 $a = e_1$ 处达到。

$$\min_{a \neq 0} \frac{a' \Sigma a}{a' a} = \lambda_p.$$

最小值在 $a = e_p$ 处达到。

进一步, 若约束 $a \perp e_1, \dots, e_k$, 则

$$\max_{a \perp e_1, \dots, e_k} \frac{a' \Sigma a}{a' a} = \lambda_{k+1},$$

并在 $a = e_{k+1}$ 处达到。

**1.2.2 第二及第 i 主成分****定义 5.3 (第二主成分)**

第二主成分定义为

$$Y_2 = a_2' \mathbf{X},$$

其中 a_2 由下述优化问题确定:

$$\max_{a_2} a_2' \Sigma a_2,$$

并满足约束

$$a_2' a_2 = 1, \quad \text{Cov}(Y_1, Y_2) = a_1' \Sigma a_2 = 0.$$



定义 5.4 (第 i 主成分)

对 $i \geq 2$, 第 i 主成分定义为

$$Y_i = a_i' \mathbf{X} = a_{i1}X_1 + \cdots + a_{ip}X_p,$$

其中 a_i 由下述优化问题确定:

$$\max_{a_i} a_i' \Sigma a_i,$$

并满足约束

$$a_i' a_i = 1, \quad \text{Cov}(Y_i, Y_k) = a_i' \Sigma a_k = 0, \quad k < i.$$

**1.3 如何求主成分****定理 5.1**

设 Σ 为随机向量 $\mathbf{X}' = [X_1, \dots, X_p]$ 的协方差矩阵,

$$(\lambda_i, e_i), \quad i = 1, \dots, p$$

是 Σ 的特征值-特征向量对, 且

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$

则第 i 个主成分 (得分) 为

$$Y_i = e_i' \mathbf{X} = e_{i1}X_1 + \cdots + e_{ip}X_p, \quad i = 1, 2, \dots, p.$$

并且有性质

$$\text{Var}(Y_i) = e_i' \Sigma e_i = \lambda_i, \quad i = 1, 2, \dots, p,$$

$$\text{Cov}(Y_i, Y_k) = e_i' \Sigma e_k = 0, \quad i \neq k.$$



若某些特征值相等, 则相应系数向量 (从而主成分) 并不唯一。

1.4 如何解释主成分**定理 5.2 (主成分贡献率)**

设 Σ 为随机向量 $\mathbf{X}' = [X_1, X_2, \dots, X_p]$ 的协方差矩阵,

$$(\lambda_i, e_i), \quad i = 1, \dots, p$$

是 Σ 的特征值-特征向量对, 且

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$

令主成分为

$$Y_1 = e_1' \mathbf{X}, Y_2 = e_2' \mathbf{X}, \dots, Y_p = e_p' \mathbf{X}.$$

则

$$\sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp} = \sum_{i=1}^p \text{Var}(X_i) = \lambda_1 + \lambda_2 + \cdots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i).$$

因而第 k 个主成分对总体总方差的贡献率为

$$\frac{\lambda_k}{\lambda_1 + \lambda_2 + \cdots + \lambda_p}.$$



例 5.1 总体主成分 给定

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix},$$

其特征值-特征向量可取为

$$\lambda_1 = 5.83, \quad e'_1 = [0.383, -0.924, 0],$$

$$\lambda_2 = 2.00, \quad e'_2 = [0, 0, 1],$$

$$\lambda_3 = 0.17, \quad e'_3 = [0.924, 0.383, 0].$$

因而可写出谱分解

$$\Sigma = P\Lambda P', \quad P = [e_1, e_2, e_3], \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \lambda_3).$$

因而主成分为

$$Y_1 = e'_1 \mathbf{X} = 0.383X_1 - 0.924X_2,$$

$$Y_2 = e'_2 \mathbf{X} = X_3,$$

$$Y_3 = e'_3 \mathbf{X} = 0.924X_1 + 0.383X_2.$$

定理 5.3

若 $Y_1 = e'_1 \mathbf{X}, Y_2 = e'_2 \mathbf{X}, \dots, Y_p = e'_p \mathbf{X}$ 是由协方差矩阵 Σ 得到的主成分, 则

$$\rho_{Y_i, X_k} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}, \quad i, k = 1, 2, \dots, p,$$

即第 i 个主成分与第 k 个原变量的相关系数。并且对任意固定的 k 有

$$\sum_{i=1}^p \rho_{Y_i, X_k}^2 = 1.$$



例 5.2 相关系数与系数向量 在上例中,

$$\rho_{Y_1, X_1} = \frac{e_{11} \sqrt{\lambda_1}}{\sqrt{\sigma_{11}}} = \frac{0.383 \sqrt{5.83}}{\sqrt{1}} \approx 0.925,$$

$$\rho_{Y_1, X_2} = \frac{e_{12} \sqrt{\lambda_1}}{\sqrt{\sigma_{22}}} = \frac{-0.924 \sqrt{5.83}}{\sqrt{5}} \approx -0.998.$$

另外

$$\rho_{Y_2, X_3} = \frac{e_{23} \sqrt{\lambda_2}}{\sqrt{\sigma_{33}}} = \frac{1 \cdot \sqrt{2}}{\sqrt{2}} = 1.$$

1.5 基于标准化变量的主成分

定义 5.5 (标准化变量)

对 $k = 1, 2, \dots, p$, 定义

$$Z_k = \frac{X_k - \mu_k}{\sqrt{\sigma_{kk}}}.$$

记

$$V = \text{diag}(\sigma_{11}, \sigma_{22}, \dots, \sigma_{pp}),$$

则

$$\mathbf{Z} = V^{-1/2}(\mathbf{X} - \boldsymbol{\mu}), \quad \text{Cov}(\mathbf{Z}) = V^{-1/2}\Sigma V^{-1/2} = \rho,$$

其中 ρ 为总体相关矩阵。



定理 5.4 (标准化变量的主成分)

设 $\mathbf{Z}' = [Z_1, Z_2, \dots, Z_p]$, 且

$$\text{Cov}(\mathbf{Z}) = \rho.$$

若 $(\lambda_i, e_i), i = 1, \dots, p$ 是 ρ 的特征值-特征向量对, 则标准化变量的第 i 个主成分为

$$Y_i = e_i' \mathbf{Z}, \quad i = 1, 2, \dots, p.$$

且

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p,$$

以及

$$\rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i}, \quad i, k = 1, 2, \dots, p.$$



注 由 Σ 与由 ρ 得到的主成分一般并不相同。当前者量纲差异较大时, 标准化后的主成分通常更有可比性。

1.6 样本主成分 (Sample Principal Components)

设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 是来自某 p 维总体的独立样本, 记样本均值向量为

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j,$$

样本协方差矩阵为

$$S = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})'$$

记数据矩阵为

$$X = [x_{jk}]_{n \times p}.$$

注 样本主成分分析的目标与总体情形一致: 寻找一组互不相关的线性组合, 使其尽可能解释样本总变异。

命题 5.2 (求样本主成分的替换原则)

在总体主成分公式中, 将总体分布替换为经验分布; 将 Σ 替换为 S ; 将相关矩阵 ρ 替换为样本相关矩阵 R , 即可得到样本主成分分析的对应结论。



定理 5.5 (样本主成分定义与性质)

设 $(\hat{\lambda}_i, \hat{e}_i)$, $i = 1, \dots, p$ 是样本协方差矩阵 S 的特征值-特征向量对, 且

$$\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0.$$

定义第 i 个样本主成分得分为

$$\hat{y}_i = \hat{e}_i' \mathbf{x} = \hat{e}_{i1}x_1 + \hat{e}_{i2}x_2 + \dots + \hat{e}_{ip}x_p, \quad i = 1, 2, \dots, p.$$

则有

$$s^2(\hat{y}_i) = \hat{\lambda}_i, \quad i = 1, 2, \dots, p,$$

$$s(\hat{y}_i, \hat{y}_k) = 0, \quad i \neq k,$$

$$\sum_{i=1}^p s^2(\hat{y}_i) = \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \hat{\lambda}_2 + \dots + \hat{\lambda}_p.$$

此外, 第 i 个样本主成分与第 k 个原变量的样本相关系数为

$$\rho_{\hat{y}_i, x_k} = \frac{\hat{e}_{ik} \sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}, \quad i, k = 1, 2, \dots, p.$$

**1.7 基于样本相关矩阵的主成分****定义 5.6 (标准化样本变量)**

令

$$z_k = \frac{x_k - \bar{x}_k}{\sqrt{s_{kk}}}, \quad k = 1, 2, \dots, p,$$

记 $\mathbf{z}' = [z_1, z_2, \dots, z_p]$, 其样本相关矩阵为 R .

**定理 5.6 (相关矩阵 PCA)**

设 $(\tilde{\lambda}_i, \tilde{e}_i)$, $i = 1, \dots, p$ 是 R 的特征值-特征向量对, 则第 i 个标准化样本主成分可写为

$$\hat{y}_i^{(R)} = \tilde{e}_i' \mathbf{z} = \tilde{e}_{i1}z_1 + \dots + \tilde{e}_{ip}z_p.$$

并有

$$s^2(\hat{y}_i^{(R)}) = \tilde{\lambda}_i, \quad s(\hat{y}_i^{(R)}, \hat{y}_k^{(R)}) = 0 \quad (i \neq k),$$

以及

$$\sum_{i=1}^p s^2(\hat{y}_i^{(R)}) = \text{tr}(R) = p.$$

**命题 5.3 (几何解释)**

在二维情形中, 等高线

$$(\mathbf{x} - \bar{\mathbf{x}})' S^{-1} (\mathbf{x} - \bar{\mathbf{x}}) = c^2$$

为椭圆 (或圆)。当 $\hat{\lambda}_1 > \hat{\lambda}_2$ 时, 主成分方向唯一; 当 $\hat{\lambda}_1 = \hat{\lambda}_2$ 时, 方向不唯一。



1.8 实际应用

定理 5.7 (如何选择保留的主成分个数)

常用准则包括:

- 碎石图 (scree/elbow): 在特征值序列拐点处截断;
- 累计贡献率: 选择最小的 m 使

$$\frac{\sum_{i=1}^m \hat{\lambda}_i}{\sum_{i=1}^p \hat{\lambda}_i} \geq \eta,$$

其中 η 常取 $0.80 \sim 0.95$;

- **Kaiser** 准则 (基于相关矩阵 R): 保留特征值大于 1 的主成分。



注 在实际分析中, 可绘制前若干主成分得分图与后若干主成分得分图: 前者常用于检查正态性或主要结构, 后者有助于识别可疑观测 (潜在离群点)。

2 奇异值分解与主成分分析的计算联系

2.1 奇异值分解回顾

定理 5.8 (奇异值分解)

设 $A \in \mathbb{R}^{m \times k}$, 则存在 $m \times m$ 正交矩阵 U 与 $k \times k$ 正交矩阵 V , 使得

$$A = U\Lambda V',$$

其中 $\Lambda \in \mathbb{R}^{m \times k}$ 为“对角形”矩阵, 其对角元满足

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, \min(m, k),$$

其余元素为 0。



定义 (奇异值)

上述分解中的正数 λ_i 称为矩阵 A 的奇异值。



命题 5.4 (与特征分解的关系)

若 $A = U\Lambda V'$, 则

$$AA' = U\Lambda\Lambda'U', \quad A'A = V\Lambda'\Lambda V'.$$

因而 AA' 与 $A'A$ 的非零特征值均为 λ_i^2 。



2.2 样本协方差矩阵的矩阵表示

设样本矩阵

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

命题 5.5 (中心化与协方差)

记

$$H = I_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n',$$

则中心化矩阵可写为

$$\tilde{X} = X - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n' X = HX.$$

样本协方差矩阵满足

$$(n-1)S = \tilde{X}'\tilde{X} = (HX)'(HX).$$

此外, H 为对称幂等矩阵, 即 $H' = H$ 且 $H^2 = H$ 。

注 矩阵 $(HX)(HX)'$ 描述的是“观测单位之间”的内积相似性, 而 $(HX)'(HX)$ 描述的是“变量之间”的协方差结构。

2.3 SVD 与 PCA**定理 5.9 (利用 SVD 计算主成分)**

对中心化矩阵作奇异值分解:

$$\tilde{X} = U\Lambda V'.$$

则

$$S = \frac{1}{n-1} \tilde{X}'\tilde{X} = V \left(\frac{\Lambda'\Lambda}{n-1} \right) V'.$$

因而:

- S 的特征向量即 V 的列向量;
- S 的特征值为 $\Lambda'\Lambda/(n-1)$ 的对角元;
- 全部样本主成分得分矩阵为

$$\hat{Y} = \tilde{X}V = U\Lambda.$$

注 设第 j 个载荷向量为 $\hat{e}_j$, 则第 i 个样本在第 j 主成分上的得分可写为

$$\hat{y}_{ij} = \hat{e}_j'(\mathbf{x}_i - \bar{\mathbf{x}}).$$

注 (S 与 $\tilde{X}'\tilde{X}$ 的谱分解差异) 二者特征向量相同, 仅特征值相差比例因子 $1/(n-1)$ 。

2.4 SVD 与 EVD 的比较**命题 5.6 (计算取舍)**

在 PCA 计算中:

- 当 $n \gg p$ 时, 基于 $p \times p$ 协方差矩阵的特征分解通常更快;
- 当 $n \ll p$ 时, 直接对中心化数据做 SVD (或转向核技巧) 通常更合适;
- 就数值稳定性而言, SVD 往往更可靠。

3 多维尺度分析 (Multidimensional Scaling, MDS)

3.1 问题背景

定义 5.7 (MDS 目标)

多维尺度分析的目标是：给定一个邻近 (proximity) 矩阵，用一个低维几何表示 (坐标图) 尽可能保留对象间的邻近关系。



注 与 PCA 常见的“已知数据矩阵 X ”不同，MDS 中常常直接观测到的是邻近矩阵

$$D = [d_{ij}],$$

而原始坐标矩阵 X 可能未知。

3.2 邻近矩阵与不相似矩阵

定义 5.8 (邻近矩阵)

称矩阵 $D = (d_{ij})_{n \times n}$ 为邻近矩阵，若满足

$$D = D', \quad d_{ij} \geq 0, \quad d_{ii} = 0 \quad (i, j = 1, 2, \dots, n).$$



注 邻近矩阵可来自：

- 直接主观评定 (如两两相似/不相似评分)；
- 由原始特征数据间的相关、协方差或距离间接构造。

例 5.3 可乐不相似度示例 下面给出 10 种可乐 (一个受试者) 的两两不相似度评分 (0 表示“完全相同”，100 表示“非常不同”) 作为示例：

$$D = \begin{bmatrix} 0 & 16 & 81 & 56 & 87 & 60 & 84 & 50 & 99 & 16 \\ 16 & 0 & 47 & 32 & 68 & 35 & 94 & 87 & 25 & 92 \\ 81 & 47 & 0 & 71 & 44 & 21 & 98 & 79 & 53 & 90 \\ 56 & 32 & 71 & 0 & 71 & 98 & 57 & 73 & 98 & 83 \\ 87 & 68 & 44 & 71 & 0 & 34 & 99 & 19 & 52 & 79 \\ 60 & 35 & 21 & 98 & 34 & 0 & 99 & 92 & 17 & 44 \\ 84 & 94 & 98 & 57 & 99 & 99 & 0 & 45 & 99 & 24 \\ 50 & 87 & 79 & 73 & 19 & 92 & 45 & 0 & 84 & 18 \\ 99 & 25 & 53 & 98 & 52 & 17 & 99 & 84 & 0 & 98 \\ 16 & 92 & 90 & 83 & 79 & 44 & 24 & 18 & 98 & 0 \end{bmatrix}.$$

该矩阵满足 $D = D'$ 且 $d_{ii} = 0$ ，可直接用于经典 MDS 的双中心化计算。

3.3 经典 MDS (Classical MDS)

定义 5.9 (欧氏距离矩阵)

称 $D = (d_{ij})_{n \times n}$ 为欧氏距离矩阵，若存在点

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$$

使得

$$d_{ij}^2 = (\mathbf{x}_i - \mathbf{x}_j)'(\mathbf{x}_i - \mathbf{x}_j), \quad \forall i, j.$$



命题 5.7 (解的非唯一性)

若 Z 与 X 满足

$$\mathbf{z}_i = P\mathbf{x}_i + \mathbf{a},$$

其中 P 为正交矩阵、 $\mathbf{a}$ 为常向量, 则 Z 与 X 诱导的两两欧氏距离完全相同。因而给定距离矩阵 D 时, 坐标解只在平移、旋转 (及反射) 意义下唯一。

定理 5.10 (双中心化)

设 $D^{(2)} = [d_{ij}^2]$, 定义

$$B = -\frac{1}{2}HD^{(2)}H, \quad H = I_n - \frac{1}{n}\mathbf{1}_n\mathbf{1}_n'.$$

若 D 是由某坐标矩阵 X 的欧氏距离得到的, 则

$$B = (HX)(HX)'.$$

对 B 做谱分解并截断非负特征值, 即可得到经典 MDS 的低维坐标表示。

3.4 经典 MDS 的推导步骤**命题 5.8 (平移与正交变换下的不变性)**

设第 i 个单位变换为

$$\mathbf{y}_i = P\mathbf{x}_i + \mathbf{a},$$

其中 P 为正交矩阵、 $\mathbf{a}$ 为常向量。记矩阵形式

$$Y = XP + \mathbf{1}_n\mathbf{a}',$$

则有

$$HY = HXP + H\mathbf{1}_n\mathbf{a}' = HXP,$$

进而

$$(HY)(HY)' = (HXP)(HXP)' = (HX)(HX)'.$$

注 因此, $B = (HX)(HX)'$ 也不随平移、旋转或反射变化。

命题 5.9 (已知量、未知量与连接关系)

在经典 MDS 中, 通常已知邻近矩阵 $D = (d_{ij})$, 未知坐标矩阵 X 。定义

$$B = (HX)(HX)' = (b_{ij}), \quad b_{ij} = (\mathbf{x}_i - \bar{\mathbf{x}})'(\mathbf{x}_j - \bar{\mathbf{x}}).$$

若记

$$\tilde{x}_{ik} = x_{ik} - \bar{x}_k,$$

则

$$b_{ij} = \sum_{k=1}^p \tilde{x}_{ik}\tilde{x}_{jk},$$

且

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}.$$

为便于计算与实现, 经典 MDS 可按以下两步进行:

(1) Step 1: $D \rightarrow B$

由连接关系

$$d_{ij}^2 = b_{ii} + b_{jj} - 2b_{ij}$$

出发。记

$$\tilde{x}_{ik} = x_{ik} - \bar{x}_k, \quad b_{ij} = \sum_{k=1}^p \tilde{x}_{ik} \tilde{x}_{jk}, \quad \sum_{i=1}^n \tilde{x}_{ik} = 0.$$

则可得行列和约束

$$\sum_{j=1}^n b_{ij} = 0, \quad \sum_{i=1}^n b_{ij} = 0.$$

令

$$T = \sum_{i=1}^n b_{ii} = \text{tr}(B),$$

对固定 j 求和:

$$\sum_{i=1}^n d_{ij}^2 = \sum_{i=1}^n b_{ii} + nb_{jj} - 2 \sum_{i=1}^n b_{ij} = T + nb_{jj}.$$

对固定 i 求和:

$$\sum_{j=1}^n d_{ij}^2 = T + nb_{ii}.$$

再对双下标求和:

$$\sum_{i=1}^n \sum_{j=1}^n d_{ij}^2 = 2nT.$$

记

$$d_{i\cdot}^2 = \frac{1}{n} \sum_{j=1}^n d_{ij}^2, \quad d_{\cdot j}^2 = \frac{1}{n} \sum_{i=1}^n d_{ij}^2, \quad d_{\cdot\cdot}^2 = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_{ij}^2,$$

则

$$b_{ii} = d_{i\cdot}^2 - \frac{1}{2}d_{\cdot\cdot}^2, \quad b_{jj} = d_{\cdot j}^2 - \frac{1}{2}d_{\cdot\cdot}^2.$$

代回

$$b_{ij} = \frac{1}{2}(b_{ii} + b_{jj} - d_{ij}^2),$$

得到双中心化公式

$$b_{ij} = -\frac{1}{2} \left(d_{ij}^2 - d_{i\cdot}^2 - d_{\cdot j}^2 + d_{\cdot\cdot}^2 \right).$$

矩阵形式写为

$$A = (a_{ij}), \quad a_{ij} = -\frac{1}{2}d_{ij}^2, \quad B = HAH.$$

(2) Step 2: $B \rightarrow Z$

对对称矩阵 B 做谱分解

$$B = \tilde{P}\tilde{\Lambda}\tilde{P}'.$$

设正特征值为

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0,$$

对应特征向量矩阵与对角阵记为

$$\tilde{P}_r = [\tilde{e}_1, \dots, \tilde{e}_r], \quad \tilde{\Lambda}_r = \text{diag}(\lambda_1, \dots, \lambda_r).$$

定义

$$Z = \tilde{P}_r \tilde{\Lambda}_r^{1/2},$$

则

$$ZZ' = \tilde{P}_r \tilde{\Lambda}_r \tilde{P}_r' = B,$$

因而给出一组完整主坐标解。

若只保留前 $k < r$ 个主方向，则取

$$Z_k = \tilde{P}_k \tilde{\Lambda}_k^{1/2},$$

作为低维近似。维数 k 的选择可参考 PCA（碎石图、累计解释比例）。

注（与 PCA 的关系） 经典 MDS 在文献中也常被称为主坐标分析（principal coordinates analysis, PCoA），其“选取维数 k ”的思路与 PCA（如碎石图、累计解释量）高度相似。

定理 5.11 (欧氏距离矩阵判别定理)

设 $D = (d_{ij})_{n \times n}$ 为邻近矩阵，定义

$$A = (a_{ij}), \quad a_{ij} = -\frac{1}{2}d_{ij}^2, \quad B = HAH.$$

则

$$D \text{ 是欧氏距离矩阵} \iff B \succeq 0.$$

证明 “ $\Rightarrow$ ”：若 D 来自某坐标矩阵 X 的欧氏距离，则由双中心化结论可得

$$B = (HX)(HX)',$$

故 B 为半正定矩阵。

“ $\Leftarrow$ ”：若 $B \succeq 0$ ，设其秩为 r ，对正特征值部分作分解

$$B = \tilde{P}_r \tilde{\Lambda}_r \tilde{P}_r'.$$

令

$$\tilde{X} = \tilde{P}_r \tilde{\Lambda}_r^{1/2},$$

则 $B = \tilde{X} \tilde{X}'$ ，故

$$(\tilde{x}_i - \tilde{x}_j)'(\tilde{x}_i - \tilde{x}_j) = b_{ii} + b_{jj} - 2b_{ij}.$$

又由 $B = HAH$ 的元素展开

$$b_{ij} = a_{ij} - \bar{a}_{i\cdot} - \bar{a}_{\cdot j} + \bar{a}_{\cdot\cdot},$$

结合 $a_{ij} = -\frac{1}{2}d_{ij}^2$ 、 $d_{ii} = 0$ 、 $D = D'$ ，可推出

$$b_{ii} + b_{jj} - 2b_{ij} = d_{ij}^2.$$

因而 D 可由坐标矩阵 $\tilde{X}$ 的欧氏距离重构，即 D 为欧氏距离矩阵。

4 核主成分分析 (Kernel PCA)

动机

注（从线性 PCA 到非线性 PCA） 经典 PCA 本质上是线性投影，常用于分类前的降维预处理：保留最重要的方差信息并压缩特征维度。但当数据在原空间中**线性不可分**、而在某个非线性变换后可分时，线性 PCA 的表达能力就会受限。

因此，一个自然思路是先做**非线性映射**，再在新特征空间中执行 PCA，这就是 Kernel PCA 的基本出发点。

4.1 重述：在特征空间中做 PCA

设样本 $x_1, \dots, x_n \in \mathbb{R}^{p_0}$ ，引入特征映射

$$\phi: \mathbb{R}^{p_0} \rightarrow \mathbb{R}^p, \quad x \mapsto \tilde{x} = \phi(x),$$

并记

$$\tilde{X} = \begin{bmatrix} \phi(x_1)' \\ \vdots \\ \phi(x_n)' \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

命题 5.10 (特征空间协方差矩阵)

在特征空间中，样本协方差矩阵可写为

$$\tilde{S}_n = \frac{1}{n} (H\tilde{X})'(H\tilde{X}).$$

若不失一般性地假设 $\tilde{X}$ 已中心化（即列均值为 0），则

$$\tilde{S}_n = \frac{1}{n} \tilde{X}'\tilde{X}.$$

注（高维瓶颈） 在许多场景中，映射后维度满足 $p \gg n$ ，直接对 $p \times p$ 矩阵 $\tilde{S}_n$ 做特征分解往往代价过高，甚至不可行。

4.2 核技巧与 Gram 矩阵

定义 5.10 (核函数与核矩阵)

定义核函数

$$K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle,$$

并构造核矩阵（Gram 矩阵）

$$K = [K(x_i, x_j)]_{n \times n}.$$

注（与 PCA/MDS 的联系） 记

$$B = \tilde{X}\tilde{X}'.$$

这与前文 PCA 与 MDS 中出现的内积矩阵形式一致。因而可转而对 $n \times n$ 的矩阵 B （或中心化后的 $K_c = HKH$ ）做谱分解，避免直接处理 $p \times p$ 的协方差矩阵。

命题 5.11

Kernel PCA 的关键在于：算法仅依赖样本两两内积 $\langle \phi(x_i), \phi(x_j) \rangle$ ，即核函数值 $K(x_i, x_j)$ 。因此通常不必显式构造 ϕ ，即使 ϕ 对应无限维特征空间也可计算。

定义 5.11 (正定核)

若对任意 n 、任意样本点 $x_1, \dots, x_n$ 与任意实数 $c_1, \dots, c_n$ ，都有

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0,$$

则称 K 为（半）正定核。等价地，核矩阵 $[K(x_i, x_j)]_{n \times n}$ 为半正定矩阵。

4.3 常见核函数与实现

定义 (常见核函数)

对 $x, y \in \mathbb{R}^{p_0}$, 常见选择包括:

- 多项式核

$$K(x, y) = (a x' y + c)^d, \quad d \in \mathbb{N}, c \geq 0.$$

- 高斯核 (RBF 核)

$$K(x, y) = \exp\left(-\frac{\|x - y\|^2}{2\sigma^2}\right).$$

- Sigmoid 核

$$K(x, y) = \tanh(ax' y + r).$$



注 (软件实现) 在 R 中可使用 `kernlab::kpca()` 实现 Kernel PCA。

5 t-SNE (t-distributed Stochastic Neighbor Embedding)

5.1 降维视角与可视化动机

降维大体可以分为两类思路:

- **Projection**: 用全局线性或非线性投影把高维点映到低维;
- **Manifold Learning**: 假设数据近似位于低维流形, 目标是恢复其局部几何结构。

注 (为什么需要 t-SNE) 在可视化任务中 (例如手写数字图像), PCA 等线性方法有时无法在二维平面上清晰分离簇结构。t-SNE 的目标是: 在低维空间中尽量保持高维空间中的“邻近关系”, 让可视化结果更符合局部聚类形态。

5.2 t-SNE 的基本思想

定义 5.12 (高维与低维的相似度匹配)

设高维样本为 $x_1, \dots, x_n$, 低维嵌入为 $y_1, \dots, y_n$ 。t-SNE 构造两个概率分布:

- 高维相似度分布 $P = (p_{ij})$;
- 低维相似度分布 $Q = (q_{ij})$ 。

然后通过优化使 Q 尽可能接近 P 。



注 直观上, t-SNE 先将低维点随机初始化, 再通过迭代更新坐标, 使“在高维中相近的点”在低维中也尽量靠近。

5.3 三步法描述

Step 1: 在原空间中计算相似度 (高维分布)

对给定点 x_i , 用高斯核刻画其与其他点的未归一化相似度:

$$\tilde{p}_{j|i} = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right), \quad j \neq i,$$

并令 $\tilde{p}_{i|i} = 0$ 。归一化得到条件概率

$$p_{j|i} = \frac{\exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|x_i - x_k\|^2}{2\sigma_i^2}\right)}.$$

其中 σ_i 由困惑度 (perplexity) 控制。随后做对称化:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}, \quad p_{ii} = 0.$$

Step 2: 在低维空间中计算相似度 (低维分布)

在低维空间中, t-SNE 使用自由度为 1 的 t 分布 (Cauchy 核):

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}, \quad q_{ii} = 0.$$

Step 3: 最小化分布差异并更新坐标

通过最小化 KL 散度

$$C = KL(P \parallel Q) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}},$$

使用梯度下降迭代更新 $y_1, \dots, y_n$, 使低维相似度矩阵 Q 逐步逼近高维相似度矩阵 P 。

5.4 要点总结

t-SNE 的关键特征:

- 将欧氏距离转换为概率意义上的“邻近相似度”;
- 高维使用高斯分布定义局部条件概率;
- 低维使用 t 分布缓解拥挤问题 (crowding problem);
- 以 $KL(P \parallel Q)$ 为目标函数进行优化;
- 更强调局部邻域结构的保持, 适合可视化解释。

第 6 节 Linear Regression Models

1 经典线性回归模型 (Classical Linear Regression Model)

1.1 记号与目标

统计学与机器学习中，大量问题具有如下数据结构：

观测单位	响应变量	协变量/特征/预测变量			
i	Y	X_1	X_2	$\cdots$	X_p
1	y_1	x_{11}	x_{12}	$\cdots$	x_{1p}
2	y_2	x_{21}	x_{22}	$\cdots$	x_{2p}
$\vdots$	$\vdots$	$\vdots$	$\vdots$		$\vdots$
n	y_n	x_{n1}	x_{n2}	$\cdots$	x_{np}

基于该数据，常见问题有两类：

- 描述 X 与 Y 之间的关联或相关关系，例如身高与体重的关联、教育年限与收入的关联；
- 利用旧数据，对新协变量 X^* 预测响应变量 Y^* 。

1.2 建模框架

定义 6.1 (基本概念与假设)

称 Y 为响应变量 (outcome/response)， $X_1, \dots, X_p$ 为协变量 (covariates/predictors)，向量记为 $X = (X_1, \dots, X_p)'$ 。

假设观测到 n 个独立同分布的 (X, Y) 样本，维数 p 已知， X_i 视为给定 (非随机)。

响应变量的标准分解为：

$$Y = \underbrace{E(Y \mid X = x)}_{= g(x)} + \varepsilon,$$

其中 $g(x)$ 为条件均值函数， ε 为随机误差项。线性模型进一步假设

$$g(x) = a + bx_1,$$

即 $(Y \mid X_1 = x_1) = a + bx_1 + \varepsilon$ 。

线性模型的优点：

- 线性模型简单但非平凡，是统计学习的自然起点，兼具可解释性与数学深度；
- 基于代数与几何可推导封闭公式，提供深刻的理论洞察；
- 通过引入协变量的多项式或其他非线性变换，可有效处理非线性关系；
- 对许多非线性数据生成过程是良好近似，预测性能不亚于更复杂的非线性模型。

注 统计学中，“线性”指**参数线性**，而非协变量线性。例如 $Y = a + b \log(X_1) + \varepsilon$ 仍为线性模型，参数 a, b 线性。而 $Y = \beta_0 + \beta_1^2 X_1 + \varepsilon$ 则非线性模型，参数 β_1 非线性。

典型例子

例 6.1 连续协变量——收入预测 已知某人年龄 x ，预测其明年收入 y (一元情形)。

数据 (x_i, y_i) , $i = 1, \dots, n$, 模型为

$$y_i = a + bx_i + \varepsilon_i, \quad i = 1, \dots, n.$$

矩阵形式 $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$:

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}, \quad \beta = \begin{bmatrix} a \\ b \end{bmatrix}.$$

例 6.2 二值协变量——职业培训效果 若某人参加了职业培训 ($x = 1$) 或未参加 ($x = 0$), 预测其明年收入。

模型同为 $y_i = a + bx_i + \varepsilon_i$ 。在 $E\varepsilon_i = 0$ 下:

- 未培训组 ($x = 0$): $\mu_1 = a$
- 已培训组 ($x = 1$): $\mu_2 = a + b$
- 检验 $H_0: \mu_1 = \mu_2 \Leftrightarrow$ 检验 $H_0: b = 0$

此时设计矩阵 $\mathbf{X}$ 的每行仅含 0/1 取值:

$$\mathbf{X} = \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}.$$

例 6.3 多项式协变量——二次趋势 若收入对年龄呈二次趋势, 模型扩展为

$$y_i = a + bx_i + cx_i^2 + \varepsilon_i, \quad i = 1, \dots, n.$$

矩阵形式 $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$:

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}, \quad \beta = \begin{bmatrix} a \\ b \\ c \end{bmatrix}.$$

$\mathbf{X}$ 可包含协变量的任意非线性变换, 模型仍属线性模型 (参数线性)。

1.3 参数估计与预测 (Parameter Estimation & Prediction)

1.3.1 最小二乘估计

对线性模型 $y_i = a + bx_i + \varepsilon_i$, 以**最小二乘** (Ordinary Least Squares, OLS) 准则求解。

定义 6.2 (普通最小二乘估计量)

一元线性回归的 OLS 估计量定义为

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{a, b} n^{-1} \sum_{i=1}^n (y_i - a - bx_i)^2.$$



命题 6.1 (OLS 解的显式公式)

令目标函数关于 a, b 的偏导数为零, 得正规方程:

$$\begin{aligned} -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta} x_i) &= 0 \implies \bar{y} = \hat{\alpha} + \hat{\beta} \bar{x}, \\ -\frac{2}{n} \sum_{i=1}^n x_i (y_i - \hat{\alpha} - \hat{\beta} x_i) &= 0 \implies \overline{xy} = \hat{\alpha} \bar{x} + \hat{\beta} \overline{x^2}. \end{aligned}$$

两式联立消去 $\hat{\alpha}$, 得

$$\overline{xy} - \bar{x}\bar{y} = \hat{\beta}(\overline{x^2} - \bar{x}^2), \quad \text{即} \quad \hat{\sigma}_{xy} = \hat{\beta} \hat{\sigma}_x^2.$$

因此 OLS 解为

$$\hat{\beta} = \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x^2}, \quad \hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}.$$

1.3.2 与相关系数的联系

将拟合值改写可揭示 OLS 与样本相关系数的关系:

$$\hat{y}_i - \bar{y} = \frac{\hat{\sigma}_{xy}}{\hat{\sigma}_x^2} (x_i - \bar{x}) = \frac{\hat{\rho}_{xy} \hat{\sigma}_x \hat{\sigma}_y}{\hat{\sigma}_x^2} (x_i - \bar{x}),$$

化简得

$$\frac{\hat{y}_i - \bar{y}}{\hat{\sigma}_y} = \hat{\rho}_{xy} \frac{x_i - \bar{x}}{\hat{\sigma}_x}.$$

即标准化拟合值与标准化协变量之比恰等于样本相关系数。

注 这与概率论中的最佳线性预测完全对应: 在总体中, $\rho \frac{\sqrt{\text{Var}(Y)}}{\sqrt{\text{Var}(X)}}$ 正是

$$\arg \min_{b \in \mathbb{R}} \mathbb{E}[(Y - \mathbb{E}Y) - b(X - \mathbb{E}X)]^2$$

的最优解。因此, 回归反映的是**相关关系**, 而非因果关系。

1.3.3 多协变量情形

为统一记号, 约定将截距纳入设计矩阵——令第一个协变量恒为 1, 协变量总数 (含截距列) 仍记为 p , 数据重整为

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix} = \begin{pmatrix} x_1^\top \\ x_2^\top \\ \vdots \\ x_n^\top \end{pmatrix} = (X_1, \dots, X_p).$$

多协变量的 OLS 目标函数推广为

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top \beta)^2 = \arg \min_{\beta} \|Y - X\beta\|^2.$$

命题 6.2 (多元 OLS 正规方程与解)

令目标函数对 β 的梯度为零, 得正规方程

$$\sum_{i=1}^n x_i(y_i - x_i^\top \hat{\beta}) = 0, \quad \text{即} \quad X^\top(Y - X\hat{\beta}) = 0.$$

若 $X^\top X = \sum_{i=1}^n x_i x_i^\top$ 非退化, 则 OLS 解唯一:

$$\hat{\beta} = \left(\sum_{i=1}^n x_i x_i^\top \right)^{-1} \left(\sum_{i=1}^n x_i y_i \right) = (X^\top X)^{-1} X^\top Y.$$

OLS 的几何意义

记 X 的列空间为

$$\mathcal{C}(X) = \{b_1 X_1 + \cdots + b_p X_p : b_1, \dots, b_p \in \mathbb{R}\},$$

则 OLS 的几何本质是在列空间中寻找距 Y 最近的向量:

$$X\hat{\beta} = \arg \min_{v \in \mathcal{C}(X)} \|Y - v\|^2.$$

命题 6.3 (正交投影)

$X\hat{\beta}$ 是 Y 在列空间 $\mathcal{C}(X)$ 上的正交投影, 残差向量 $\hat{\varepsilon} = Y - X\hat{\beta}$ 与 $\mathcal{C}(X)$ 中每一向量正交, 即

$$X^\top \hat{\varepsilon} = X^\top(Y - X\hat{\beta}) = 0.$$

注 以 $n = 3$ 、两协变量 X_1, X_2 为例, $\mathcal{C}(X)$ 是 $\mathbb{R}^3$ 中的一个平面, $X\hat{\beta}$ 是 Y 在该平面上的垂足, $\hat{\varepsilon}$ 是从垂足指向 Y 的线段。此几何图像揭示了 OLS 的核心性质: 残差与所有协变量正交。

1.3.4 投影矩阵 (hat matrix) 及其性质**定义 6.3 (投影矩阵 H)**

定义

$$H = X(X^\top X)^{-1}X^\top,$$

则拟合值向量可写为 $\hat{Y} = X\hat{\beta} = HY$, 称 H 为 hat matrix (投影矩阵)。

命题 6.4 (投影矩阵性质)

矩阵 H 满足 $H^2 = H$ 且 $H^\top = H$, 即 H 为对称幂等矩阵。

命题 6.5 (性质 I: 拟合值与残差正交)

$\hat{Y} \perp \hat{\varepsilon}$, 其中 $\hat{\varepsilon} = Y - \hat{Y}$ 。进一步, 每个拟合值是观测值的线性组合:

$$\hat{y}_i = \sum_{j=1}^n h_{ij} y_j,$$

其中 h_{ij} 为矩阵 H 的 (i, j) 元素。

1.3.5 Gauss–Markov 模型及其性质

定义 6.4 (Gauss–Markov 模型)

考虑线性模型 $Y = X\beta + \varepsilon$, 其中设计矩阵 X 固定且列向量线性无关, 随机误差项 ε 满足

$$E(\varepsilon) = 0, \quad \text{cov}(\varepsilon) = \sigma^2 I_n.$$

等价地, $y_i = x_i^\top \beta + \varepsilon_i$, $i = 1, \dots, n$, 其中 $E\varepsilon_i = 0$, $\text{Var}(\varepsilon_i) = \sigma^2$, $\text{cov}(\varepsilon_i, \varepsilon_j) = 0$ ($i \neq j$). 未知参数为 (β, σ^2) .

定理 6.1 ($\hat{\beta}$ 的矩)

在 Gauss–Markov 模型下, OLS 估计量 $\hat{\beta} = (X^\top X)^{-1} X^\top Y$ 满足

$$E(\hat{\beta}) = \beta, \quad \text{cov}(\hat{\beta}) = \sigma^2 (X^\top X)^{-1}.$$



证明 对期望, 利用 $E(Y) = X\beta$:

$$E(\hat{\beta}) = (X^\top X)^{-1} X^\top E(Y) = (X^\top X)^{-1} X^\top X\beta = \beta.$$

对协方差矩阵, 利用 $\text{cov}(Y) = \sigma^2 I_n$:

$$\begin{aligned} \text{cov}(\hat{\beta}) &= (X^\top X)^{-1} X^\top \text{cov}(Y) X (X^\top X)^{-1} \\ &= \sigma^2 (X^\top X)^{-1} X^\top X (X^\top X)^{-1} = \sigma^2 (X^\top X)^{-1}. \end{aligned}$$

定理 6.2 ($\hat{Y}$ 与 $\hat{\varepsilon}$ 的矩)

在 Gauss–Markov 模型下, 记 $\hat{Y} = X\hat{\beta}$, $\hat{\varepsilon} = Y - \hat{Y}$, 则

$$E \begin{pmatrix} \hat{Y} \\ \hat{\varepsilon} \end{pmatrix} = \begin{pmatrix} X\beta \\ 0 \end{pmatrix}, \quad \text{cov} \begin{pmatrix} \hat{Y} \\ \hat{\varepsilon} \end{pmatrix} = \sigma^2 \begin{pmatrix} H & 0 \\ 0 & I_n - H \end{pmatrix}.$$



证明 注意到关键分解

$$\begin{pmatrix} \hat{Y} \\ \hat{\varepsilon} \end{pmatrix} = \begin{pmatrix} HY \\ (I_n - H)Y \end{pmatrix} = \begin{pmatrix} H \\ I_n - H \end{pmatrix} Y.$$

利用 $HX = X$ 、 $(I_n - H)X = 0$ 及 $\text{cov}(Y) = \sigma^2 I_n$, 逐块计算即得。

1.3.6 σ^2 的估计

记残差平方和 (Residual Sum of Squares, RSS) 为

$$\text{RSS} = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \|Y - X\hat{\beta}\|^2.$$

由于 $E\hat{\varepsilon}_i = 0$, $\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii})$, 故

$$E(\text{RSS}) = \sum_{i=1}^n \sigma^2(1 - h_{ii}) = \sigma^2(n - \text{tr} H) = \sigma^2(n - p).$$

命题 6.6 (σ^2 的无偏估计)

定义

$$\hat{\sigma}^2 = \frac{\text{RSS}}{n - p},$$

则 $E(\hat{\sigma}^2) = \sigma^2$, 即 $\hat{\sigma}^2$ 是 σ^2 的无偏估计量。



1.3.7 Gauss–Markov 定理

定理 6.3 (Gauss–Markov 定理 (BLUE))

在 Gauss–Markov 模型下, OLS 估计量 $\hat{\beta}$ 是 β 的最优线性无偏估计量 (Best Linear Unbiased Estimator, BLUE), 即对任意满足下述条件的估计量 $\tilde{\beta}$:

(C1) $\tilde{\beta} = AY$, $A \in \mathbb{R}^{p \times n}$ 不依赖于 Y ;

(C2) $E(\tilde{\beta}) = \beta$ 对任意 β 成立,

均有

$$\text{cov}(\tilde{\beta}) \succeq \text{cov}(\hat{\beta}).$$

此处 $\succeq$ 的含义为: 对任意 $c \in \mathbb{R}^p$, $\text{Var}(c^\top \tilde{\beta}) \geq \text{Var}(c^\top \hat{\beta})$ 。



1.3.8 正态假设

定义 6.5 (正态线性模型)

假设计矩阵 X 固定且列线性无关, 误差项服从正态分布:

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I_n),$$

等价地,

$$y_i = x_i^\top \beta + \varepsilon_i, \quad \varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n.$$



注 正态线性模型蕴含 Gauss–Markov 模型的全部假设, 是后者的加强形式。

1.3.9 正态假设下的参数估计分布

在正态线性模型下, 参数估计量具有以下联合分布。

定理 6.4 (参数估计量与残差的联合分布)

在正态线性模型下, 记 $\hat{\beta} = (X^\top X)^{-1} X^\top Y$, $\hat{\varepsilon} = Y - X\hat{\beta}$, 则

$$\begin{pmatrix} \hat{\beta} \\ \hat{\varepsilon} \end{pmatrix} \sim N \left\{ \begin{pmatrix} \beta \\ 0 \end{pmatrix}, \sigma^2 \begin{pmatrix} (X^\top X)^{-1} & 0 \\ 0 & I_n - H \end{pmatrix} \right\}.$$

其中 $\hat{\sigma}^2/\sigma^2 \sim \chi_{n-p}^2/(n-p)$, 且

$$\hat{\beta} \perp\!\!\!\perp \hat{\varepsilon}, \quad \hat{\beta} \perp\!\!\!\perp \hat{\sigma}^2.$$



证明 由于 $\begin{pmatrix} \hat{\beta} \\ \hat{\varepsilon} \end{pmatrix} = \begin{pmatrix} (X^\top X)^{-1} X^\top \\ I_n - H \end{pmatrix} Y$ 是 Y 的线性变换, 在正态假设 $Y \sim N(X\beta, \sigma^2 I_n)$ 下, 联合分布仍为正态。计算均值与协方差: $E\hat{\beta} = \beta, E\hat{\varepsilon} = 0$; 协方差矩阵分块对角, 非对角块 $\text{cov}(\hat{\beta}, \hat{\varepsilon}) = (X^\top X)^{-1} X^\top \cdot \sigma^2 I_n \cdot (I_n - H)^\top = 0$, 故 $\hat{\beta}$ 与 $\hat{\varepsilon}$ 不相关, 在联合正态下即独立。

对 $\hat{\sigma}^2$: 因 $(I_n - H)$ 的秩为 $n - p$, 故 $(1/\sigma^2)\hat{\varepsilon}^\top \hat{\varepsilon} = (1/\sigma^2)\|(I_n - H)Y\|^2$ 服从 χ_{n-p}^2 分布, 从而 $\hat{\sigma}^2/\sigma^2 \sim \chi_{n-p}^2/(n-p)$ 。

1.3.10 正态假设下的预测值分布

定理 6.5 (预测值与残差的联合分布)

在正态线性模型下, 记 $\hat{Y} = X\hat{\beta} = HY$, 则

$$\begin{pmatrix} \hat{Y} \\ \hat{\varepsilon} \end{pmatrix} \sim N \left\{ \begin{pmatrix} X\beta \\ 0 \end{pmatrix}, \sigma^2 \begin{pmatrix} H & 0 \\ 0 & I_n - H \end{pmatrix} \right\},$$

即 $\hat{Y} = X\hat{\beta}$, 因此

$$\hat{Y} \perp \hat{\varepsilon}.$$



1.3.11 性质比较

下表汇总三种假设强度下 $\hat{Y}$ 与 $\hat{\varepsilon}$ 之间关系的递进:

假设条件	核心性质
无假设	$\hat{Y} \perp \hat{\varepsilon}$ (OLS 几何性质)
Gauss-Markov 模型: $y_i = x_i^\top \beta + \varepsilon_i$, $E\varepsilon_i = 0$, $\text{cov}(\hat{Y}, \hat{\varepsilon}) = 0$ $\text{Var}(\varepsilon_i) = \sigma^2$, $\text{cov}(\varepsilon_i, \varepsilon_j) = 0$, $i \neq j$	
正态线性模型: $y_i = x_i^\top \beta + \varepsilon_i$, $\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, $\hat{Y}$ 与 $\hat{\varepsilon}$ 独立 (概率性质) $i = 1, \dots, n$	

注 正态性假设条件较强, 但上述统计推断程序对多种模型偏差具有较好的稳健性。

正态假设下的统计推断

定理 6.6 (单个线性组合的分布)

在正态线性模型下, 对任意固定向量 $c \in \mathbb{R}^p$, 有

$$c^\top \hat{\beta} \sim N\{c^\top \beta, \sigma^2 c^\top (X^\top X)^{-1} c\}.$$

因此, 检验统计量

$$T_c = \frac{c^\top \hat{\beta} - c^\top \beta}{\sqrt{\hat{\sigma}^2 c^\top (X^\top X)^{-1} c}} \sim t_{n-p}.$$



对 l 个线性约束, 引入约束矩阵 $C \in \mathbb{R}^{l \times p}$ (行满秩):

$$C\beta = \begin{pmatrix} c_1^\top \beta \\ \vdots \\ c_l^\top \beta \end{pmatrix}.$$

例 6.4 取

$$C = \begin{pmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix}_{(p-1) \times p}, \quad C\beta = \begin{pmatrix} \beta_2 \\ \vdots \\ \beta_p \end{pmatrix},$$

则 $C\beta = 0$ 等价于所有非截距参数均为零。

定理 6.7 (F 检验)

在正态线性模型下，对 $l \times p$ 行满秩矩阵 C ，有

$$C\hat{\beta} - C\beta \sim N\{0, \sigma^2 C(X^\top X)^{-1} C^\top\}.$$

因此，检验统计量

$$F_C = \frac{(C\hat{\beta} - C\beta)^\top \{C(X^\top X)^{-1} C^\top\}^{-1} (C\hat{\beta} - C\beta)}{l\hat{\sigma}^2} \sim F_{l, n-p}.$$



2 过拟合、正则化与模型选择

2.1 挑战

- 在线性模型中引入无关协变量会导致估计量精度下降。当协变量总数远小于样本量时，此问题尚不严重。
- 在许多现代应用中，协变量数目可能远大于样本量。例如，现代 DNA 测序技术可以产生数百万维度的协变量，远超通常的样本量。
- 在这些应用场景中，前述理论不再适用，可能面临过拟合问题，或需要变量选择以获得更稳定、有意义的结果。

2.2 可能的解决方案

- 新的指标，例如方差膨胀因子 (Variance Inflation Factor, VIF)。
- 模型选择准则：
 - RSS、 R^2 、调整 R^2 ；
 - 信息准则：AIC、BIC 等；
 - 交叉验证 (Cross-Validation, CV)。
- 变量选择：前向选择 / 后向删除等。
- 岭回归 (Ridge Regression)
- 主成分回归 (Principal Component Regression)
- Lasso

2.3 惩罚方法的思想

当 X 的各列高度相关时，OLS 出现问题。特别地，当 $p > n$ 时， $X^\top X$ 不可逆，OLS 估计量不唯一。为此，研究者提出以下带惩罚项的目标函数：

$$Q(\beta) = \frac{1}{2n} \|Y - X\beta\|_2^2 + \sum_{j=1}^p p_\lambda(|\beta_j|),$$

其中 $p_\lambda(\cdot)$ 称为**惩罚函数**， λ 称为**调节参数** (tuning parameter)。

2.4 岭回归

OLS 的优化目标为

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - x_i^\top \beta)^2 = \arg \min_{\beta} \|Y - X\beta\|^2,$$

解为 $\hat{\beta} = (X^\top X)^{-1} X^\top Y$ 。

定义 6.6 (岭回归)

岭回归在 OLS 目标函数基础上加入 ℓ_2 惩罚项：

$$\hat{\beta}^{\text{Ridge}}(\lambda) = \arg \min_{\beta} \{ \|Y - X\beta\|^2 + \lambda \|\beta\|^2 \}.$$

其闭式解为

$$\hat{\beta}^{\text{Ridge}}(\lambda) = (X^\top X + \lambda I_p)^{-1} X^\top Y.$$



注 加入正则项 λI_p 后, $X^\top X + \lambda I_p$ 对任意 $\lambda > 0$ 均可逆, 从而解决了 $p > n$ 时 OLS 不唯一的问题。岭回归对预测性能较好, 但系数普遍非零, 解释性较差。

2.5 主成分回归

- 对设计矩阵 X 做主成分分析 (PCA), 提取主成分。
- 选取部分主成分作为新协变量进行回归, 替代原始协变量。
- 注意: 方差最大的前几个主成分未必是对 Y 最有信息量的; 应选取与 Y 相关性更强的主成分, 而非仅按方差大小排序。

2.6 Lasso

岭回归对预测表现良好, 但难以解释众多非零但数值很小的系数。

定义 6.7 (Lasso)

Tibshirani (1996) 提出 Lasso (最小绝对值收缩与选择算子, Least Absolute Shrinkage and Selection Operator), 同时实现参数估计与变量选择:

$$\hat{\beta}^{\text{Lasso}}(\lambda) = \arg \min_{\beta} \left\{ \|Y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

Lasso 无闭式解。



注 ℓ_1 惩罚 (绝对值和) 的几何性质导致许多系数恰好收缩为零, 从而自动完成变量选择; 而 ℓ_2 惩罚 (平方和) 仅使系数趋近于零但不为零。

Lasso 与岭回归的几何理解

2.6.1 等价约束形式

Lasso 的惩罚形式与约束形式等价:

$$\hat{\beta}^{\text{Lasso}}(\lambda) = \arg \min_{\beta} \left\{ \|Y - X\beta\|^2 + \lambda \sum_{j=1}^p |\beta_j| \right\} \iff \arg \min_{\beta} \|Y - X\beta\|^2, \quad \text{s.t.} \sum_{j=1}^p |\beta_j| \leq t,$$

其中 t 与 λ 一一对应。类似地, 岭回归等价于约束 $\|\beta\|^2 \leq t$ 。

2.6.2 OLS 目标函数的分解

对任意 β , OLS 目标函数有如下分解:

$$\begin{aligned} \|Y - X\beta\|^2 &= (Y - X\beta)^\top (Y - X\beta) \\ &= (Y - X\hat{\beta})^\top (Y - X\hat{\beta}) + (\beta - \hat{\beta})^\top X^\top X (\beta - \hat{\beta}). \end{aligned}$$

第一项为残差平方和（与 β 无关），第二项为以 $\hat{\beta}$ 为中心的二次型，因此等高线为椭圆（轴方向由 $X^\top X$ 决定），中心即 OLS 估计量 $\hat{\beta}$ 。

2.6.3 Lasso 与岭回归的几何对比

求解带约束的 OLS 问题时，最优解为 OLS 等高线椭圆与可行域边界的切点。

- **Lasso**: 可行域 $\sum_j |\beta_j| \leq t$ 为菱形（ ℓ_1 球），其顶角恰好在坐标轴上。椭圆通常先切到顶角，使某些分量恰好为零，产生**稀疏解**（变量选择）。
- **岭回归**: 可行域 $\|\beta\|^2 \leq t$ 为圆形（ ℓ_2 球），无顶角。椭圆与圆的切点通常不在坐标轴上，故各分量均非零，**不产生稀疏解**。

注 在 $p = 2$ 时，Lasso 可行域等高线方程为 $|b_1| + |b_2| \leq t$ （菱形），OLS 等高线为 $(b - \hat{\beta})^\top X^\top X (b - \hat{\beta}) = C$ （椭圆）。二者相切处若在坐标轴顶点，则 $\hat{\beta}_2^{\text{Lasso}} = 0$ ，实现变量选择；而岭回归可行域为圆，切点满足 $\hat{\beta}_1^{\text{Ridge}} \neq 0, \hat{\beta}_2^{\text{Ridge}} \neq 0$ 。

第 7 节 Factor Analysis (FA)

1 因子分析与正交因子模型 (Factor Analysis)

因子分析 (Factor Analysis, FA) 旨在用少数不可观测的公共因子解释高维观测变量的协方差结构。设

$$\mathbf{X} = (X_1, \dots, X_p)^\top, \quad \mathbf{E}(\mathbf{X}) = \boldsymbol{\mu}, \quad \text{Cov}(\mathbf{X}) = \Sigma.$$

其中

$$\Sigma = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix}.$$

FA 的核心目标包括:

- **降维 (Reduction)**: 用 $m \ll p$ 个公共因子描述主要协方差结构;
- **解释 (Interpretation)**: 将变量间相关性解释为共同潜在因素的作用。

1.1 典型例子

例如两个成绩变量可写成

$$X_1 = 50 + 0.8F_1 + 0.2F_2 + \varepsilon_1,$$

$$X_2 = 60 + 0.1F_1 + 0.9F_2 + \varepsilon_2,$$

其中 F_1 可理解为理科能力因子, F_2 可理解为文科能力因子, $\varepsilon_1, \varepsilon_2$ 为各变量的特殊因子。矩阵形式为

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} - \begin{pmatrix} 50 \\ 60 \end{pmatrix} = \begin{pmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{pmatrix} \begin{pmatrix} F_1 \\ F_2 \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \end{pmatrix}.$$

1.2 正交因子模型 (Orthogonal Factor Model)

定义 7.1 (正交因子模型)

设 $\mathbf{F} = (F_1, \dots, F_m)^\top$ 为公共因子, $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_p)^\top$ 为特殊因子, $L = (\ell_{ij})_{p \times m}$ 为载荷矩阵 (loading matrix)。正交因子模型定义为

$$\mathbf{X} - \boldsymbol{\mu} = L\mathbf{F} + \boldsymbol{\varepsilon}.$$

分量形式为

$$X_i - \mu_i = \ell_{i1}F_1 + \cdots + \ell_{im}F_m + \varepsilon_i, \quad i = 1, \dots, p.$$

模型假设为

$$\mathbf{E}(\mathbf{F}) = \mathbf{0}, \quad \text{Cov}(\mathbf{F}) = \mathbf{E}(\mathbf{F}\mathbf{F}^\top) = I_m,$$

$$\mathbf{E}(\boldsymbol{\varepsilon}) = \mathbf{0}, \quad \text{Cov}(\boldsymbol{\varepsilon}) = \mathbf{E}(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\top) = \Psi,$$

其中

$$\Psi = \text{diag}(\psi_1, \dots, \psi_p), \quad \psi_i \geq 0.$$

此外假设公共因子与特殊因子不相关:

$$\text{Cov}(\boldsymbol{\varepsilon}, \mathbf{F}) = \mathbf{E}(\boldsymbol{\varepsilon}\mathbf{F}^\top) = \mathbf{0}_{p \times m}.$$

2 协方差结构与例子

命题 7.1 (因子模型的协方差分解)

在正交因子模型下,

$$\Sigma = LL^{\top} + \Psi.$$

证明 由 $\mathbf{X} - \boldsymbol{\mu} = L\mathbf{F} + \boldsymbol{\varepsilon}$,

$$\begin{aligned}\Sigma &= E[(L\mathbf{F} + \boldsymbol{\varepsilon})(L\mathbf{F} + \boldsymbol{\varepsilon})^{\top}] \\ &= LE(\mathbf{F}\mathbf{F}^{\top})L^{\top} + LE(\mathbf{F}\boldsymbol{\varepsilon}^{\top}) + E(\boldsymbol{\varepsilon}\mathbf{F}^{\top})L^{\top} + E(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^{\top}) \\ &= LL^{\top} + \Psi.\end{aligned}$$

命题 7.2 (共同度与特殊方差)

记 L 的第 i 行为 $\ell_i^{\top} = (\ell_{i1}, \dots, \ell_{im})$ 。则

$$\sigma_{ii} = \ell_{i1}^2 + \dots + \ell_{im}^2 + \psi_i = h_i^2 + \psi_i,$$

其中

$$h_i^2 = \ell_{i1}^2 + \dots + \ell_{im}^2$$

称为第 i 个变量的共同度 (communality), ψ_i 称为特殊方差 (specific variance)。当 $i \neq k$ 时,

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = \ell_i^{\top} \ell_k = \ell_{i1}\ell_{k1} + \dots + \ell_{im}\ell_{km}.$$

进一步, 观测变量与公共因子的协方差为

$$\text{Cov}(\mathbf{X}, \mathbf{F}) = E[(\mathbf{X} - \boldsymbol{\mu})\mathbf{F}^{\top}] = L.$$

因此载荷 ℓ_{ij} 可解释为第 i 个观测变量与第 j 个公共因子的协方差。

2.1 协方差矩阵的因子分解

例 7.1 教材例 9.1 给定

$$\Sigma = \begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix}.$$

取

$$L = \begin{bmatrix} 4 & 1 \\ 7 & 2 \\ -1 & 6 \\ 1 & 8 \end{bmatrix}, \quad \Psi = \text{diag}(2, 4, 1, 3).$$

则 $\Sigma = LL^{\top} + \Psi$ 。

解 直接计算得

$$LL^{\top} = \begin{bmatrix} 17 & 30 & 2 & 12 \\ 30 & 53 & 5 & 23 \\ 2 & 5 & 37 & 47 \\ 12 & 23 & 47 & 65 \end{bmatrix}.$$

因而

$$LL^T + \Psi = \begin{bmatrix} 19 & 30 & 2 & 12 \\ 30 & 57 & 5 & 23 \\ 2 & 5 & 38 & 47 \\ 12 & 23 & 47 & 68 \end{bmatrix} = \Sigma.$$

例如第一个变量满足

$$\sigma_{11} = 19 = 4^2 + 1^2 + 2, \quad h_1^2 = 17, \quad \psi_1 = 2.$$

注 (Heywood case) 若将上例中 σ_{11} 改为 15, 且 L 不变, 则

$$15 = 4^2 + 1^2 + \psi_1 \Rightarrow \psi_1 = -2.$$

这在代数上可写出形式分解, 但统计上不可接受。出现负特殊方差或不合法相关结构的现象称为 Heywood case。

因此, 并非所有协方差矩阵都能在 $m \ll p$ 且 Ψ 非负对角的条件下写成 $LL^T + \Psi$ 。

3 模型性质：不可识别性与尺度不变性

3.1 旋转不可识别性

令 T 为任意 $m \times m$ 正交矩阵。由于 $TT^T = I_m$,

$$\begin{aligned} \mathbf{X} - \boldsymbol{\mu} &= L\mathbf{F} + \boldsymbol{\varepsilon} \\ &= L(TT^T)\mathbf{F} + \boldsymbol{\varepsilon} \\ &= (LT)(T^T\mathbf{F}) + \boldsymbol{\varepsilon}. \end{aligned}$$

记

$$L^* = LT, \quad \mathbf{F}^* = T^T\mathbf{F},$$

则 $\mathbf{X} - \boldsymbol{\mu} = L^*\mathbf{F}^* + \boldsymbol{\varepsilon}$, 且

$$\text{Cov}(\mathbf{F}^*) = T^TT = I_m.$$

因此 L 并不唯一。实际中常利用旋转使载荷矩阵更易解释, 或辅助极大似然估计的优化。

3.2 尺度不变性

令 $C = \text{diag}(c_1, \dots, c_p)$ 为非奇异对角矩阵, 并定义 $\mathbf{Y} = C\mathbf{X}$ 。若

$$\mathbf{X} = \boldsymbol{\mu} + L\mathbf{F} + \boldsymbol{\varepsilon},$$

则

$$\mathbf{Y} = C\boldsymbol{\mu} + CL\mathbf{F} + C\boldsymbol{\varepsilon} = \boldsymbol{\mu}_C + L_C\mathbf{F} + \boldsymbol{\varepsilon}_C.$$

同时

$$\text{Var}(\boldsymbol{\varepsilon}_C) = C\Psi C^T$$

仍为对角矩阵。因此因子模型的结构不受变量逐坐标重缩放影响。实际分析中常先标准化变量, 再对相关矩阵进行因子分析。

4 参数估计：主成分法与极大似然法

实际数据中，设 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 是来自 p 维总体的独立样本。通常未知 $\boldsymbol{\mu}$ 与 Σ ，但可由样本协方差矩阵 S 或样本相关矩阵 R 出发估计载荷矩阵与特殊方差：

$$S \approx \hat{L}\hat{L}^\top + \hat{\Psi}.$$

这里 $\hat{L}$ 的列空间决定公共因子的主要解释方向；但由于旋转不可识别，潜在因子的具体含义仍需结合载荷结构与后续旋转来解释。

4.1 主成分载荷估计

设 S 的谱分解为

$$S = \sum_{j=1}^p \hat{\lambda}_j \hat{e}_j \hat{e}_j^\top, \quad \hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p \geq 0.$$

若取全部 p 个特征值，则

$$S = L_0 L_0^\top, \quad L_0 = [\sqrt{\hat{\lambda}_1} \hat{e}_1, \dots, \sqrt{\hat{\lambda}_p} \hat{e}_p],$$

这并没有达到降维目的，因为公共因子个数等于变量个数。

因此在主成分法中，取前 m 个较大的特征值，定义

$$\hat{L} = [\sqrt{\hat{\lambda}_1} \hat{e}_1, \sqrt{\hat{\lambda}_2} \hat{e}_2, \dots, \sqrt{\hat{\lambda}_m} \hat{e}_m]_{p \times m}.$$

特殊方差常取为残差矩阵对角元：

$$\hat{\Psi} = \text{diag}(S - \hat{L}\hat{L}^\top).$$

注意 $S - \hat{L}\hat{L}^\top$ 本身一般不是对角矩阵；只取其对角元作为特殊方差，是为了保持正交因子模型的结构。

例 7.2 教材例 9.1：主成分法 对前述协方差矩阵 Σ ，若取 $m = 2$ ，主成分法可得到近似载荷

$$\hat{L} \approx \begin{bmatrix} -2.5 & 3.3 \\ -4.8 & 5.8 \\ -5.1 & -3.3 \\ -7.8 & -2.4 \end{bmatrix}.$$

此时

$$\hat{L}\hat{L}^\top \approx \begin{bmatrix} 17 & 31 & 2 & 12 \\ 31 & 56 & 5 & 23 \\ 2 & 5 & 37 & 48 \\ 12 & 23 & 48 & 67 \end{bmatrix}, \quad \hat{\Psi} = \text{diag}(2, 1, 1, 1).$$

因而 $\Sigma \approx \hat{L}\hat{L}^\top + \hat{\Psi}$ 。

4.2 公共因子个数的选择

命题 7.3 (因子个数的参数计数限制)

p 维协方差矩阵包含

$$\frac{p(p+1)}{2}$$

个自由参数。正交 m 因子模型中，载荷矩阵 L 有 pm 个参数，特殊方差矩阵 Ψ 有 p 个参数；同时由于正交旋转不可识别，需要扣除

$$\frac{m(m-1)}{2}$$

个旋转自由度。因此模型的有效参数个数为

$$pm + p - \frac{m(m-1)}{2}.$$

为了避免模型参数数超过无约束协方差矩阵，至少需要

$$pm + p - \frac{m(m-1)}{2} \leq \frac{p(p+1)}{2},$$

等价地，

$$(p-m)^2 \geq p+m.$$

注 这是选择公共因子个数的必要参数计数条件，而不是充分条件；即使满足该不等式，仍可能出现 Heywood case 或解释性不足的问题。

选择 m 还可视为矩阵近似问题。若

$$E_m = S - (\hat{L}\hat{L}^\top + \hat{\Psi}),$$

则忽略的特征值越小，近似误差越小。可证明残差平方和满足类似界：

$$\sum_{i,k} (E_m)_{ik}^2 \leq \hat{\lambda}_{m+1}^2 + \cdots + \hat{\lambda}_p^2.$$

因此，当后 $p-m$ 个特征值较小时，取前 m 个公共因子通常已经能解释主要协方差结构。

从总方差角度，

$$\text{tr}(S) = s_{11} + \cdots + s_{pp}.$$

第 j 个公共因子对总方差的贡献近似为

$$\sum_{i=1}^p \hat{\ell}_{ij}^2 = \hat{\lambda}_j,$$

故前 m 个公共因子解释的方差比例为

$$\frac{\hat{\lambda}_1 + \cdots + \hat{\lambda}_m}{\text{tr}(S)}.$$

实际中可结合累计解释比例、碎石图 (scree plot) 以及残差矩阵大小来选择 m 。

4.3 极大似然估计 (Maximum Likelihood Approach)

主成分法只利用谱分解给出矩阵近似；若进一步假定正态性，则可从似然函数出发估计 L 与 Ψ 。

定义 7.2 (正态因子模型)

在正交因子模型

$$\mathbf{X} - \boldsymbol{\mu} = \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}$$

中，假设

$$\mathbf{F} \sim N_m(0, \mathbf{I}_m), \quad \boldsymbol{\varepsilon} \sim N_p(0, \Psi), \quad \mathbf{F} \perp \boldsymbol{\varepsilon},$$

其中 Ψ 为对角正定矩阵。则

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma), \quad \Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

设 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 为样本，记

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{j=1}^n \mathbf{x}_j, \quad \mathbf{S} = \frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})^\top.$$

忽略与参数无关的常数，正态模型的 profile log-likelihood 可写为

$$\ell_p(L, \Psi) = -\frac{n}{2} \{ \log |\mathbf{L}\mathbf{L}^\top + \Psi| + \text{tr} [\mathbf{S}(\mathbf{L}\mathbf{L}^\top + \Psi)^{-1}] \}.$$

因此极大似然法求解

$$\max_{L, \Psi} \ell_p(L, \Psi), \quad \Psi \text{ 对角正定}, \quad \Sigma = \mathbf{L}\mathbf{L}^\top + \Psi.$$

由于 L 对正交旋转不唯一，通常加入计算上方便的唯一性约束

$$\mathbf{L}^\top \Psi^{-1} \mathbf{L} = \Delta, \quad \Delta \text{ 为对角矩阵}.$$

该约束并不改变协方差结构，只是在等价的旋转载荷中选取一个代表。

命题 7.4 (MLE 下的共同度与贡献率)

设 $\hat{L} = (\hat{\ell}_{ij})$ 与 $\hat{\Psi}$ 为满足 $\hat{L}^\top \hat{\Psi}^{-1} \hat{L}$ 为对角矩阵的极大似然估计，则第 i 个变量的共同度估计为

$$\hat{h}_i^2 = \hat{\ell}_{i1}^2 + \hat{\ell}_{i2}^2 + \dots + \hat{\ell}_{im}^2, \quad i = 1, \dots, p.$$

第 j 个公共因子解释的总样本方差比例为

$$\frac{\hat{\ell}_{1j}^2 + \hat{\ell}_{2j}^2 + \dots + \hat{\ell}_{pj}^2}{s_{11} + s_{22} + \dots + s_{pp}}.$$

注 主成分法强调低秩矩阵近似，极大似然法强调正态模型下的拟合。后者需要数值优化与唯一性约束，但也允许用似然比检验、信息准则或残差结构辅助选择公共因子个数 m 。

4.4 标准化版本

若变量量纲差异较大，可先将变量标准化。令

$$\mathbf{V} = \text{diag}(\Sigma), \quad \mathbf{Z} = \mathbf{V}^{-1/2}(\mathbf{X} - \boldsymbol{\mu}).$$

由

$$\mathbf{X} - \boldsymbol{\mu} = \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}$$

两边左乘 $\mathbf{V}^{-1/2}$ ，得到

$$\mathbf{Z} = \mathbf{L}_Z \mathbf{F} + \boldsymbol{\varepsilon}_Z, \quad \mathbf{L}_Z = \mathbf{V}^{-1/2} \mathbf{L}, \quad \Psi_Z = \mathbf{V}^{-1/2} \Psi \mathbf{V}^{-1/2}.$$

因此标准化不改变因子模型的形式；实际估计时常用

$$\hat{V} = \text{diag}(S), \quad \hat{L}_Z = \hat{V}^{-1/2} \hat{L}, \quad \hat{\Psi}_Z = \hat{V}^{-1/2} \hat{\Psi} \hat{V}^{-1/2},$$

等价于在样本相关矩阵

$$R = \hat{V}^{-1/2} S \hat{V}^{-1/2}$$

上进行因子分析。

注 (本节小结) 正交因子模型的核心是

$$\Sigma = LL^\top + \Psi,$$

其中 L 描述公共因子载荷, Ψ 描述特殊方差。主成分法给出快速的谱近似; 极大似然法在正态假设下估计 L, Ψ , 并通过 $L^\top \Psi^{-1} L = \Delta$ 处理旋转不可识别性。两类方法都需结合解释性、残差大小和方差贡献率选择公共因子个数 m 。

5 因子旋转与解释 (Rotation for Interpretation)

若 T 为 $m \times m$ 正交矩阵, 则

$$L^* = LT, \quad F^* = T^\top F$$

给出同一个正交因子模型。这说明载荷矩阵 L 本身并不唯一; 真正由模型决定的是

$$LL^\top \quad \text{以及} \quad \Psi.$$

旋转 (rotation) 的目的不是改变拟合的协方差结构, 而是在等价的载荷矩阵中选出一个更容易解释的代表。

5.1 旋转不改变的量

命题 7.5 (正交旋转下的不变量)

设 $T^\top T = TT^\top = I_m$, 令 $L^* = LT$ 。则

$$L^*(L^*)^\top = LL^\top.$$

因而正交旋转不改变拟合协方差矩阵

$$\hat{\Sigma} = \hat{L}\hat{L}^\top + \hat{\Psi},$$

也不改变残差矩阵、特殊方差和共同度。

证明 直接计算

$$L^*(L^*)^\top = (LT)(LT)^\top = LTT^\top L^\top = LL^\top.$$

对第 i 个变量, 旋转前后的共同度分别为

$$h_i^2 = \ell_i^\top \ell_i, \quad (h_i^*)^2 = \ell_i^\top T T^\top \ell_i = h_i^2.$$

因此若 $\psi_i = \sigma_{ii} - h_i^2$, 则 ψ_i 也不变。

注 (FA 与 PCA 中“唯一性”的差别) 在 PCA 中, 主成分方向通常由协方差矩阵的特征向量决定; 当特征值互异且按大小排序后, 除符号外方向基本唯一。在 FA 中, 协方差结构只要求

$$\Sigma = LL^\top + \Psi,$$

对任意正交 T , LT 给出的 $LL^\top$ 相同。因此 FA 的公共因子方向具有旋转不可识别性, 旋转后的因子含义需要根据载荷模式重新解释。

5.2 简单结构 (Simple Structure)

因子旋转希望得到所谓**简单结构**：每个变量最好只在少数、理想情况下一个因子上有较大载荷，而在其余因子上载荷较小。这样每个公共因子可以由一组高载荷变量命名。

定义 7.3 (简单结构)

对载荷矩阵 $L = (\ell_{ij})_{p \times m}$ ，若每一行只有少数较大的 $|\ell_{ij}|$ ，且每一列也有若干变量显著加载，则称该载荷矩阵具有较好的简单结构。



注 旋转的影响集中在载荷元素 ℓ_{ij} 本身：变量-因子的对应关系会改变，因子解释也会改变；但拟合的相关矩阵、残差矩阵、共同度和特殊方差不随正交旋转改变。

例 7.3 消费者偏好数据：旋转前的载荷 五个变量的初始二因子载荷可写为

$$\hat{L} = \begin{bmatrix} 0.56 & 0.82 \\ 0.78 & -0.53 \\ 0.65 & 0.75 \\ 0.94 & -0.10 \\ 0.80 & -0.54 \end{bmatrix}.$$

对应共同度与特殊方差为

$$\hat{h}^2 = (0.98, 0.88, 0.98, 0.89, 0.93)^\top, \quad \hat{\psi} = (0.02, 0.12, 0.02, 0.11, 0.07)^\top.$$

解 旋转前，多个变量在两个因子上都有较大载荷，例如 Taste 的两项载荷为 (0.56, 0.82)，Flavor 的两项载荷为 (0.65, 0.75)。这使得两个因子的解释混合在一起。

经过合适正交旋转后，可得到近似载荷

$$\hat{L}^* = \begin{bmatrix} 0.02 & 0.99 \\ 0.94 & -0.01 \\ 0.13 & 0.98 \\ 0.84 & 0.43 \\ 0.97 & -0.02 \end{bmatrix}.$$

此时 Taste 和 Flavor 主要加载在 F_2^* 上，Good buy for money 与 Provides lots of energy 主要加载在 F_1^* 上。因而可将

$$F_1^* \text{ 解释为 “实用/性价比因子”，} \quad F_2^* \text{ 解释为 “口味偏好因子”。}$$

共同度仍为

$$(0.02)^2 + (0.99)^2 \approx 0.98, \quad (0.94)^2 + (-0.01)^2 \approx 0.88,$$

与旋转前一致。

变量	$\hat{\ell}_{i1}$	$\hat{\ell}_{i2}$	$\hat{\ell}_{i1}^*$	$\hat{\ell}_{i2}^*$	$\hat{h}_i^2$
Taste	0.56	0.82	0.02	0.99	0.98
Good buy for money	0.78	-0.53	0.94	-0.01	0.88
Flavor	0.65	0.75	0.13	0.98	0.98
Suitable for snack	0.94	-0.10	0.84	0.43	0.89
Provides lots of energy	0.80	-0.54	0.97	-0.02	0.93
累计解释比例	0.571	0.932	0.507	0.932	

注意单个因子的解释比例会随旋转改变；例如第一因子的累计解释位置从 0.571 变为 0.507。但两个因子共同解释的总比例仍为 0.932。这正是正交旋转只重新分配公共因子坐标轴，而不改变公共因子空间的体现。

5.3 Varimax 准则

Varimax 是常用的正交旋转准则。它的基本思想是：重要性取决于载荷大小而不是符号，故应考察平方载荷；同时为了避免共同度大的变量主导准则，先对每个变量按共同度标准化。

定义 7.4 (标准化平方载荷)

对旋转载荷 $\hat{L}^* = (\hat{\ell}_{ij}^*)$ ，定义

$$\tilde{\ell}_{ij}^* = \frac{\hat{\ell}_{ij}^*}{\hat{h}_i}, \quad (\tilde{\ell}_{ij}^*)^2 = \frac{(\hat{\ell}_{ij}^*)^2}{\hat{h}_i^2}.$$

这里 $\hat{h}_i^2 = \sum_{j=1}^m (\hat{\ell}_{ij}^*)^2$ 为第 i 个变量的共同度。



定义 7.5 (Varimax criterion)

Varimax 在所有正交矩阵 T 中选择使

$$V(T) = \frac{1}{p} \sum_{j=1}^m \left\{ \sum_{i=1}^p (\tilde{\ell}_{ij}^*)^4 - \frac{1}{p} \left[\sum_{i=1}^p (\tilde{\ell}_{ij}^*)^2 \right]^2 \right\}$$

最大的旋转，其中 $\hat{L}^* = \hat{L}T$ 。



注 (Varimax 的解释) 对固定因子 j ，Varimax 实际上最大化该因子上标准化平方载荷

$$(\tilde{\ell}_{1j}^*)^2, \dots, (\tilde{\ell}_{pj}^*)^2$$

的离散程度。换言之，它希望某些变量在该因子上载荷很大，另一些变量载荷接近 0。这会把平方载荷尽可能“spread out”，从而形成更清楚的变量分组和更容易命名的公共因子。

6 因子得分估计 (Estimating Factor Scores)

因子分析中公共因子 $\mathbf{F}$ 是潜变量，模型估计通常只给出 $\hat{\mathbf{L}}$ 与 $\hat{\Psi}$ 。实际应用中常希望为每一个样本点 $\mathbf{x}$ 给出一个因子得分 (factor score)

$$\hat{\mathbf{f}} = (\hat{f}_1, \dots, \hat{f}_m)',$$

用于诊断、样本排序、聚类/判别等后续分析，或作为综合指标。

注 若只观察到单个 x ，方程

$$\mathbf{x} - \boldsymbol{\mu} = \mathbf{L}\mathbf{f} + \boldsymbol{\varepsilon}$$

同时含有 m 个公共因子和 p 个特殊因子，未知量过多，不能直接精确求解。因此因子得分估计通常把 $\mathbf{L}, \Psi, \boldsymbol{\mu}$ 视为已知或用 $\hat{\mathbf{L}}, \hat{\Psi}, \hat{\boldsymbol{\mu}}$ 代入，再用启发式准则估计 $\mathbf{f}$ 。

6.1 普通最小二乘得分 (OLS Score)

把单个样本 $\mathbf{x}$ 看作一次回归问题：

$$\mathbf{x} - \boldsymbol{\mu} = \mathbf{L}\mathbf{f} + \boldsymbol{\varepsilon}, \quad \mathbf{L} : p \times m, \quad \mathbf{f} : m \times 1.$$

若忽略特殊方差的差异，可令残差平方和最小：

$$Q_{\text{OLS}}(\mathbf{f}) = \boldsymbol{\varepsilon}'\boldsymbol{\varepsilon} = (\mathbf{x} - \boldsymbol{\mu} - \mathbf{L}\mathbf{f})'(\mathbf{x} - \boldsymbol{\mu} - \mathbf{L}\mathbf{f}).$$

命题 7.6 (OLS 因子得分)

若 $L'L$ 非奇异, 则 OLS 因子得分为

$$\hat{f}^{OLS} = (L'L)^{-1}L'(x - \mu).$$

实际计算中常代入 $\hat{L}$ 与 $\hat{\mu} = \bar{x}$ 。

证明 对 $Q_{OLS}(f)$ 求导,

$$\frac{\partial Q_{OLS}}{\partial f} = -2L'(x - \mu - Lf).$$

令导数为 0, 得正规方程

$$L'Lf = L'(x - \mu),$$

因而得到结论。

6.2 加权最小二乘与 Bartlett 得分

若特殊因子方差不相同, 直接最小化 $\varepsilon'\varepsilon$ 会把高噪声变量和低噪声变量同等对待。更自然的准则是按特殊方差加权:

$$Q_{WLS}(f) = \varepsilon'\Psi^{-1}\varepsilon = (x - \mu - Lf)'\Psi^{-1}(x - \mu - Lf).$$

命题 7.7 (Bartlett score)

若 $L'\Psi^{-1}L$ 非奇异, 则 WLS/Bartlett 因子得分为

$$\hat{f}^{WLS} = (L'\Psi^{-1}L)^{-1}L'\Psi^{-1}(x - \mu).$$

实际中取

$$L = \hat{L}, \quad \Psi = \hat{\Psi}, \quad \hat{\mu} = \bar{x}.$$

证明 对 $Q_{WLS}(f)$ 求导并令其为 0, 得到

$$L'\Psi^{-1}Lf = L'\Psi^{-1}(x - \mu),$$

于是得到 Bartlett 得分公式。

注 (OLS 与 Bartlett 的选择) OLS 不使用 Ψ , 形式简单, 常与主成分法得到的载荷配合使用; Bartlett 得分使用 Ψ^{-1} , 会降低特殊方差较大的变量权重, 常与极大似然估计 $\hat{L}, \hat{\Psi}$ 配合使用。

与主成分得分的关系

若 $\hat{L}$ 来自主成分法, 常取

$$\hat{L} = [\sqrt{\hat{\lambda}_1}\hat{e}_1, \sqrt{\hat{\lambda}_2}\hat{e}_2, \dots, \sqrt{\hat{\lambda}_m}\hat{e}_m].$$

此时

$$\hat{L}'\hat{L} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_m).$$

OLS 因子得分的第 j 个分量为

$$\hat{f}_j^{OLS} = \frac{1}{\sqrt{\hat{\lambda}_j}}\hat{e}_j'(x - \bar{x}) = \frac{1}{\sqrt{\hat{\lambda}_j}}\hat{y}_j,$$

其中

$$\hat{y}_j = \hat{e}_j'(x - \bar{x})$$

为第 j 个样本主成分得分。因此 PC 方法下的 OLS 因子得分就是主成分得分按 $\sqrt{\hat{\lambda}_j}$ 标准化后的版本。

6.3 回归得分 (Regression Score)

若进一步采用正态因子模型

$$\mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m), \quad \boldsymbol{\varepsilon} \sim N_p(\mathbf{0}, \Psi),$$

则

$$\text{Cov}(\mathbf{F}, \mathbf{X}) = \mathbf{L}', \quad \text{Cov}(\mathbf{X}) = \mathbf{L}\mathbf{L}' + \Psi = \Sigma.$$

此时可用条件均值作为因子得分:

$$\hat{\mathbf{f}} = E(\mathbf{F} | \mathbf{x}) = \mathbf{L}'\Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \mathbf{L}'(\mathbf{L}\mathbf{L}' + \Psi)^{-1}(\mathbf{x} - \boldsymbol{\mu}).$$

利用 Woodbury 恒等式也可写作

$$\hat{\mathbf{f}} = (\mathbf{I}_m + \mathbf{L}'\Psi^{-1}\mathbf{L})^{-1}\mathbf{L}'\Psi^{-1}(\mathbf{x} - \boldsymbol{\mu}).$$

注 Bartlett 得分来自加权残差最小化; 回归得分来自正态模型下的条件期望。两者一般不同: 前者更强调重构 $\mathbf{x} - \boldsymbol{\mu}$, 后者具有向 0 收缩的性质。

6.4 标准化变量下的得分

若因子分析基于相关矩阵而非协方差矩阵, 应先标准化变量。令

$$\mathbf{V} = \text{diag}(\Sigma), \quad \mathbf{z} = \mathbf{V}^{-1/2}(\mathbf{x} - \boldsymbol{\mu}).$$

标准化模型为

$$\mathbf{z} = \mathbf{L}_Z \mathbf{f} + \boldsymbol{\varepsilon}_Z, \quad \mathbf{L}_Z = \mathbf{V}^{-1/2}\mathbf{L}, \quad \Psi_Z = \mathbf{V}^{-1/2}\Psi\mathbf{V}^{-1/2}.$$

于是 Bartlett 得分应写作

$$\hat{\mathbf{f}}_Z^{WLS} = (\mathbf{L}_Z' \Psi_Z^{-1} \mathbf{L}_Z)^{-1} \mathbf{L}_Z' \Psi_Z^{-1} \mathbf{z}.$$

注 (相关矩阵估计时的尺度) 如果 $\hat{\mathbf{L}}$ 与 $\hat{\Psi}$ 是从相关矩阵估计得到的, 则对应的是标准化变量模型, 计算因子得分时应使用

$$\hat{\mathbf{z}} = \hat{\mathbf{V}}^{-1/2}(\mathbf{x} - \bar{\mathbf{x}}),$$

而不是直接使用原始尺度的 $\mathbf{x} - \bar{\mathbf{x}}$ 。若 $\mathbf{L}_Z, \Psi_Z, \mathbf{z}$ 与 $\mathbf{L}, \Psi, \mathbf{x} - \boldsymbol{\mu}$ 完全一致地相互转换, 则 Bartlett 公式给出的得分相同。

6.5 例子: 股票收益率

例 7.4 股票价格因子得分 对五只股票收益率变量

(JP, CitiBank, Fargo, Shell, Mobil)

做二因子正态因子分析, 并采用 Varimax 旋转。第一期观测可记为

$$\mathbf{x}'_1 = (0.0130338, -0.0078431, -0.0031889, -0.0447693, 0.0052151).$$

MLE 估计给出的特殊方差近似为

$$\hat{\Psi} = (0.417, 0.275, 0.542, 0.005, 0.530)',$$

旋转后载荷近似为

$$\hat{\mathbf{L}} = \begin{bmatrix} 0.763 & 0 \\ 0.819 & 0.232 \\ 0.668 & 0.108 \\ 0.113 & 0.991 \\ 0.108 & 0.677 \end{bmatrix}.$$

解 对第一期观测, 使用 Bartlett/WLS 公式

$$\hat{\mathbf{f}}_1^{WLS} = (\hat{\mathbf{L}}' \hat{\Psi}^{-1} \hat{\mathbf{L}})^{-1} \hat{\mathbf{L}}' \hat{\Psi}^{-1} (\mathbf{x}_1 - \bar{\mathbf{x}})$$

可得到

$$\hat{\mathbf{f}}_1^{WLS} \approx \begin{bmatrix} 0.2508994 \\ -1.8536707 \end{bmatrix}.$$

第一因子主要由 JP、CitiBank、Fargo 加载, 可理解为银行股因子; 第二因子主要由 Shell、Mobil 加载, 可理解为能源股因子。因此该期观测在能源股因子上的得分显著为负, 而银行股因子得分略为正。

7 回归法的补充与比较

7.1 条件正态推导

回归法的出发点是多元正态分布的条件分布公式。在正态因子模型下,

$$\mathbf{X} - \boldsymbol{\mu} = \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}, \quad \mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}_m), \quad \boldsymbol{\varepsilon} \sim N_p(\mathbf{0}, \boldsymbol{\Psi}),$$

且 $\mathbf{F}$ 与 $\boldsymbol{\varepsilon}$ 独立。于是

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}).$$

为了求 $\mathbf{F} | \mathbf{X}$, 把 $\mathbf{X} - \boldsymbol{\mu}$ 与 $\mathbf{F}$ 联合写成

$$\begin{pmatrix} \mathbf{X} - \boldsymbol{\mu} \\ \mathbf{F} \end{pmatrix} = \begin{pmatrix} \mathbf{L} \\ \mathbf{I}_m \end{pmatrix} \mathbf{F} + \begin{pmatrix} \boldsymbol{\varepsilon} \\ \mathbf{0} \end{pmatrix}.$$

命题 7.8 (联合分布与条件分布)

记

$$\boldsymbol{\Sigma} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}.$$

则

$$\begin{pmatrix} \mathbf{X} - \boldsymbol{\mu} \\ \mathbf{F} \end{pmatrix} \sim N_{p+m} \left(\mathbf{0}, \begin{bmatrix} \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi} & \mathbf{L} \\ \mathbf{L}' & \mathbf{I}_m \end{bmatrix} \right).$$

因而给定 $\mathbf{X} = \mathbf{x}$ 时,

$$\mathbf{F} | \mathbf{x} \sim N_m (\mathbf{L}' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}), \mathbf{I}_m - \mathbf{L}' \boldsymbol{\Sigma}^{-1} \mathbf{L}).$$

证明 由模型假设,

$$\text{Cov}(\mathbf{X}) = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}, \quad \text{Cov}(\mathbf{X}, \mathbf{F}) = \mathbf{L}, \quad \text{Cov}(\mathbf{F}) = \mathbf{I}_m.$$

因此联合协方差矩阵为上式。对一般联合正态向量

$$\begin{pmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \end{pmatrix} \sim N \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right),$$

条件分布均值与协方差为

$$\mathbf{Y}_2 | \mathbf{Y}_1 = \mathbf{y}_1 \sim N (\boldsymbol{\mu}_2 + \boldsymbol{\Sigma}_{21} \boldsymbol{\Sigma}_{11}^{-1} (\mathbf{y}_1 - \boldsymbol{\mu}_1), \boldsymbol{\Sigma}_{22} - \boldsymbol{\Sigma}_{21} \boldsymbol{\Sigma}_{11}^{-1} \boldsymbol{\Sigma}_{12}).$$

令 $\mathbf{Y}_1 = \mathbf{X}$, $\mathbf{Y}_2 = \mathbf{F}$, 则 $\boldsymbol{\Sigma}_{21} = \mathbf{L}'$, $\boldsymbol{\Sigma}_{11} = \boldsymbol{\Sigma}$, $\boldsymbol{\mu}_2 = \mathbf{0}$, 故得到结论。

因此回归法因子得分就是条件均值:

$$\hat{\mathbf{f}}^R = \mathbf{L}' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \mathbf{L}' (\mathbf{L}\mathbf{L}' + \boldsymbol{\Psi})^{-1} (\mathbf{x} - \boldsymbol{\mu}).$$

实际估计时用

$$\hat{\mathbf{f}}^R = \hat{\mathbf{L}}' \hat{\boldsymbol{\Sigma}}^{-1} (\mathbf{x} - \bar{\mathbf{x}}) = \hat{\mathbf{L}}' (\hat{\mathbf{L}} \hat{\mathbf{L}}' + \hat{\boldsymbol{\Psi}})^{-1} (\mathbf{x} - \bar{\mathbf{x}}).$$

注 (近似版本) 若担心因子个数 m 选错导致 $\widehat{L}\widehat{L}' + \widehat{\Psi}$ 不稳定, 实务中也常用样本协方差矩阵 S 替代 $\widehat{\Sigma}$:

$$\hat{f}_S^R = \widehat{L}' S^{-1} (x - \bar{x}).$$

若使用标准化变量并基于样本相关矩阵 R 估计, 则课件中的相应形式为

$$\hat{f}_Z^R = \widehat{L}_Z' R^{-1} z.$$

7.2 回归得分与主成分得分

设样本协方差矩阵谱分解为

$$S = P\Lambda P', \quad P_m = [e_1, \dots, e_m], \quad \Lambda_m = \text{diag}(\lambda_1, \dots, \lambda_m).$$

若采用主成分载荷

$$L = P_m \Lambda_m^{1/2},$$

并用 S 近似 Σ , 则

$$\begin{aligned} \hat{f}_S^R &= L' S^{-1} (x - \bar{x}) \\ &= (P_m \Lambda_m^{1/2})' (P \Lambda^{-1} P') (x - \bar{x}) \\ &= \Lambda_m^{-1/2} P_m' (x - \bar{x}). \end{aligned}$$

这里 $P_m' (x - \bar{x})$ 正是前 m 个主成分得分。因此该近似回归得分与前面得到的 PC-OLS 因子得分一致。

7.3 WLS 与回归法的代数关系

记

$$A = L' \Psi^{-1} L.$$

由 Woodbury 恒等式可得

$$L' (L L' + \Psi)^{-1} = (I_m + L' \Psi^{-1} L)^{-1} L' \Psi^{-1}.$$

因此

$$\hat{f}^R = (I_m + A)^{-1} L' \Psi^{-1} (x - \mu), \quad \hat{f}^{WLS} = A^{-1} L' \Psi^{-1} (x - \mu).$$

命题 7.9 (两种得分的转换关系)

若 $A = L' \Psi^{-1} L$ 非奇异, 则

$$\boxed{\hat{f}^R = (I_m + A)^{-1} A \hat{f}^{WLS}}, \quad \boxed{\hat{f}^{WLS} = (I_m + A^{-1}) \hat{f}^R}.$$

证明 由 WLS 公式,

$$L' \Psi^{-1} (x - \mu) = A \hat{f}^{WLS}.$$

代入回归得分公式即得第一式; 第一式两边左乘 $A^{-1} (I_m + A) = I_m + A^{-1}$ 得第二式。

注 回归得分可看作 WLS 得分经过矩阵 $(I_m + A)^{-1} A$ 的收缩版本。当 A 很大, 即公共因子信号相对特殊方差较强时, 两者接近; 当特殊方差较大时, 回归得分更明显向 0 收缩。

7.4 无偏性与均方误差比较

命题 7.10 (条件无偏性)

在给定真实因子 $\mathbf{F}$ 的条件下, WLS 得分是无偏的:

$$E(\hat{\mathbf{f}}^{WLS} | \mathbf{F}) = \mathbf{F}.$$

回归得分一般有偏:

$$E(\hat{\mathbf{f}}^R | \mathbf{F}) = (\mathbf{I}_m + \mathbf{A}^{-1})^{-1} \mathbf{F}.$$

证明 由 $\mathbf{x} - \boldsymbol{\mu} = \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}$ 且 $E(\boldsymbol{\varepsilon} | \mathbf{F}) = \mathbf{0}$,

$$E(\hat{\mathbf{f}}^{WLS} | \mathbf{F}) = \mathbf{A}^{-1} \mathbf{L}' \Psi^{-1} \mathbf{L} \mathbf{F} = \mathbf{F}.$$

对回归得分,

$$E(\hat{\mathbf{f}}^R | \mathbf{F}) = \mathbf{L}'(\mathbf{L}\mathbf{L}' + \Psi)^{-1} \mathbf{L} \mathbf{F} = (\mathbf{I}_m + \mathbf{A}^{-1})^{-1} \mathbf{F}.$$

命题 7.11 (平均预测误差)

若同时对 $\mathbf{F}$ 与 $\boldsymbol{\varepsilon}$ 取期望, 则

$$E[(\hat{\mathbf{f}}^{WLS} - \mathbf{F})(\hat{\mathbf{f}}^{WLS} - \mathbf{F})'] = \mathbf{A}^{-1},$$

而

$$E[(\hat{\mathbf{f}}^R - \mathbf{F})(\hat{\mathbf{f}}^R - \mathbf{F})'] = (\mathbf{I}_m + \mathbf{A})^{-1}.$$

因而回归法的平均均方误差较小, 但它牺牲了条件无偏性。

证明 WLS 有

$$\hat{\mathbf{f}}^{WLS} = \mathbf{F} + \mathbf{A}^{-1} \mathbf{L}' \Psi^{-1} \boldsymbol{\varepsilon},$$

故

$$\text{Var}(\hat{\mathbf{f}}^{WLS} - \mathbf{F}) = \mathbf{A}^{-1} \mathbf{L}' \Psi^{-1} \Psi \Psi^{-1} \mathbf{L} \mathbf{A}^{-1} = \mathbf{A}^{-1}.$$

回归法可写为

$$\hat{\mathbf{f}}^R = (\mathbf{I}_m + \mathbf{A})^{-1} \mathbf{A} \mathbf{F} + (\mathbf{I}_m + \mathbf{A})^{-1} \mathbf{L}' \Psi^{-1} \boldsymbol{\varepsilon}.$$

因此

$$\hat{\mathbf{f}}^R - \mathbf{F} = -(\mathbf{I}_m + \mathbf{A})^{-1} \mathbf{F} + (\mathbf{I}_m + \mathbf{A})^{-1} \mathbf{L}' \Psi^{-1} \boldsymbol{\varepsilon}.$$

由于 $\text{Var}(\mathbf{F}) = \mathbf{I}_m$ 且 $\text{Var}(\mathbf{L}' \Psi^{-1} \boldsymbol{\varepsilon}) = \mathbf{A}$,

$$\text{Var}(\hat{\mathbf{f}}^R - \mathbf{F}) = (\mathbf{I}_m + \mathbf{A})^{-1} (\mathbf{I}_m + \mathbf{A}) (\mathbf{I}_m + \mathbf{A})^{-1} = (\mathbf{I}_m + \mathbf{A})^{-1}.$$

注 两种方法的取舍可概括为:

- WLS/Bartlett: 条件无偏, 但平均误差较大;
- Regression: 存在收缩偏差, 但平均 MSE 较小。

7.5 旋转对因子得分的影响

理论上若

$$\mathbf{L}^* = \mathbf{L}\mathbf{T}, \quad \mathbf{f}^* = \mathbf{T}' \mathbf{f}, \quad \mathbf{T}' \mathbf{T} = \mathbf{I}_m,$$

则新坐标下的因子得分也应相应旋转。

命题 7.12 (正交旋转下得分的协变性)

对回归得分与 WLS 得分, 若使用旋转载荷 $L^* = LT$ 且 Ψ 不变, 则

$$\hat{f}^{R,*} = T' \hat{f}^R, \quad \hat{f}^{WLS,*} = T' \hat{f}^{WLS}.$$

证明 回归法中

$$L^*(L^*)' + \Psi = LL' + \Psi,$$

因而

$$\hat{f}^{R,*} = (L^*)' \Sigma^{-1} (x - \mu) = T' L' \Sigma^{-1} (x - \mu) = T' \hat{f}^R.$$

WLS 中

$$(L^*)' \Psi^{-1} L^* = T' AT,$$

所以

$$\hat{f}^{WLS,*} = (T' AT)^{-1} T' L' \Psi^{-1} (x - \mu) = T' A^{-1} L' \Psi^{-1} (x - \mu) = T' \hat{f}^{WLS}.$$

注 因子旋转会改变各个因子得分坐标的数值, 但只是坐标轴旋转意义下的改变; 若估计与得分公式保持一致, 几何信息不会丢失。软件输出中若旋转载荷和未旋转载荷混用, 得分可能出现表面不一致。

8 实际应用中的策略 (Strategy in Real Application)

因子分析的目标不是机械地分解协方差矩阵, 而是得到可解释、可复现的低维结构。实际使用时应同时关注两个原则:

1. **解释性 (interpretation)**: 因子应能对应清楚的变量组或实际概念;
2. **一致性 (consistency)**: 不同估计方法、不同因子个数、不同样本切分下的结论应大体稳定。

命题 7.13 (因子分析的实际流程)

对给定数据, 因子分析通常按如下步骤进行:

1. 数据收集与预处理: 检查缺失值、异常值、变量尺度, 并决定使用协方差矩阵还是相关矩阵;
2. 选择候选公共因子个数 m , 可结合特征值、累计解释比例、残差矩阵和实际解释需求;
3. 对固定 m , 分别尝试主成分法 (PC factor analysis) 和极大似然法 (MLE factor analysis);
4. 对初始载荷进行旋转, 得到更容易解释的载荷模式;
5. 比较不同方案的共同度、特殊方差、残差相关矩阵与因子含义, 检查解释是否一致;
6. 若需要后续分析, 再根据最终模型计算因子得分或因子尺度。

注 (稳定性检查) 当样本量较大时, 可以将数据随机分成两部分, 分别进行因子分析。若两部分得到的因子个数、载荷模式和旋转后解释基本一致, 则说明该因子结构较稳定。对不同候选 m , 也应重复比较 PC 与 MLE 的结果; 最终选择不只看数值拟合, 还要看能否给出简洁且有意义的解释。

第 8 节 Canonical Correlation Analysis (CCA)

1 典型相关分析概览 (Canonical Correlation Analysis)

内容提要

- 基本思想：在两组变量中分别寻找线性组合，使二者相关系数尽可能大
- 总体 CCA：由分块协方差矩阵 $\Sigma_{11}, \Sigma_{12}, \Sigma_{21}, \Sigma_{22}$ 推导典型相关和典型变量
- 求解方法：将目标化为标准化交叉协方差矩阵的奇异值分解或特征值问题
- 解释与性质：典型变量的相关、方差归一化、正交性及与原变量的相关
- 样本 CCA：用样本协方差矩阵 S 或样本相关矩阵 R 替代总体矩阵
- 实际问题：标准化变量、Hotelling 例子以及典型相关结果的解释

1.1 问题背景与基本思想

典型相关分析 (canonical correlation analysis, CCA) 研究的是两组变量之间的关联结构。与 PCA 只在一组变量内部寻找主要方向不同，CCA 同时考虑两组变量

$$\mathbf{X}^{(1)} = (X_1^{(1)}, \dots, X_p^{(1)})', \quad \mathbf{X}^{(2)} = (X_1^{(2)}, \dots, X_q^{(2)})'$$

之间的协方差结构，希望用少数几个线性组合概括两组变量之间的主要关系。

注 (为什么需要 CCA) 若我们有两组不同类型的测量变量，例如：

- 图像特征与文本特征，用于多媒体检索；
- 运动能力指标与健康指标；
- 销售表现指标与智力/创造力测验指标；

则感兴趣的不是单个变量之间的逐一相关，而是两组变量整体之间最强、最稳定的关联方向。CCA 的核心思想是：分别在两组变量中寻找线性组合，使这两个线性组合的相关系数最大。

定义 8.1 (CCA 的总体目标)

设两组随机向量的联合协方差矩阵分块为

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix},$$

其中 $\Sigma_{11} = \text{Cov}(\mathbf{X}^{(1)})$, $\Sigma_{22} = \text{Cov}(\mathbf{X}^{(2)})$, $\Sigma_{12} = \text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$ 。CCA 试图寻找系数向量 $\mathbf{a}$ 与 $\mathbf{b}$ ，使得

$$U = \mathbf{a}'\mathbf{X}^{(1)}, \quad V = \mathbf{b}'\mathbf{X}^{(2)}$$

的相关系数尽可能大。



2 总体 CCA (Population CCA)

给定 $\mathbf{a} \neq \mathbf{0}$ 与 $\mathbf{b} \neq \mathbf{0}$ ，有

$$\text{Var}(U) = \mathbf{a}'\Sigma_{11}\mathbf{a}, \quad \text{Var}(V) = \mathbf{b}'\Sigma_{22}\mathbf{b}, \quad \text{Cov}(U, V) = \mathbf{a}'\Sigma_{12}\mathbf{b}.$$

因此

$$\text{corr}(U, V) = \frac{\mathbf{a}'\Sigma_{12}\mathbf{b}}{\sqrt{\mathbf{a}'\Sigma_{11}\mathbf{a}}\sqrt{\mathbf{b}'\Sigma_{22}\mathbf{b}}}.$$

命题 8.1 (第一对典型变量)

第一对典型变量 (first canonical variate pair) 定义为

$$U_1 = \mathbf{a}'_1 \mathbf{X}^{(1)}, \quad V_1 = \mathbf{b}'_1 \mathbf{X}^{(2)},$$

其中 $(\mathbf{a}_1, \mathbf{b}_1)$ 解如下优化问题:

$$\max_{\mathbf{a}, \mathbf{b} \neq \mathbf{0}} \frac{\mathbf{a}' \Sigma_{12} \mathbf{b}}{\sqrt{\mathbf{a}' \Sigma_{11} \mathbf{a}} \sqrt{\mathbf{b}' \Sigma_{22} \mathbf{b}}}.$$

对应的最大相关系数

$$\rho_1^* = \text{corr}(U_1, V_1)$$

称为第一典型相关系数 (first canonical correlation)。

注 (尺度不唯一性) 若将 $\mathbf{a}$ 替换为 $c\mathbf{a}$, 相关系数不变。因此 CCA 的系数向量只在尺度意义下确定。通常加入标准化约束

$$\mathbf{a}' \Sigma_{11} \mathbf{a} = 1, \quad \mathbf{b}' \Sigma_{22} \mathbf{b} = 1.$$

在该约束下, 最大化相关系数等价于最大化协方差

$$\mathbf{a}' \Sigma_{12} \mathbf{b}.$$

2.1 标准化后的优化形式

为把目标写成标准的单位向量优化问题, 令

$$\tilde{\mathbf{a}} = \Sigma_{11}^{-1/2} \mathbf{a}, \quad \tilde{\mathbf{b}} = \Sigma_{22}^{-1/2} \mathbf{b}.$$

则

$$\mathbf{a} = \Sigma_{11}^{-1/2} \tilde{\mathbf{a}}, \quad \mathbf{b} = \Sigma_{22}^{-1/2} \tilde{\mathbf{b}},$$

并且

$$\frac{\mathbf{a}' \Sigma_{12} \mathbf{b}}{\sqrt{\mathbf{a}' \Sigma_{11} \mathbf{a}} \sqrt{\mathbf{b}' \Sigma_{22} \mathbf{b}}} = \frac{\tilde{\mathbf{a}}' \Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1/2} \tilde{\mathbf{b}}}{\sqrt{\tilde{\mathbf{a}}' \tilde{\mathbf{a}}} \sqrt{\tilde{\mathbf{b}}' \tilde{\mathbf{b}}}}.$$

因此第一典型相关系数也可写作

$$\rho_1^* = \max_{\|\tilde{\mathbf{a}}\|=\|\tilde{\mathbf{b}}\|=1} \underbrace{\tilde{\mathbf{a}}' \Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1/2} \tilde{\mathbf{b}}}_C.$$

注 上式说明 CCA 本质上是在标准化后的交叉协方差矩阵

$$C = \Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1/2}$$

上寻找最强的双线性方向。这与 PCA 中在协方差矩阵上寻找最大方差方向是平行的。

2.2 高阶典型变量

第一对典型变量只刻画最强的一条关联方向。为了得到后续方向, 需要要求新的典型变量与前面已经得到的典型变量在各自变量组内不相关。

定义 8.2 (第 i 对典型变量)

第 i 对典型变量定义为

$$U_i = \mathbf{a}_i' \mathbf{X}^{(1)}, \quad V_i = \mathbf{b}_i' \mathbf{X}^{(2)}.$$

它在满足

$$\text{Var}(U_i) = \mathbf{a}_i' \Sigma_{11} \mathbf{a}_i = 1, \quad \text{Var}(V_i) = \mathbf{b}_i' \Sigma_{22} \mathbf{b}_i = 1$$

以及

$$\text{Cov}(U_i, U_k) = 0, \quad \text{Cov}(V_i, V_k) = 0, \quad k < i$$

的约束下, 使

$$\text{corr}(U_i, V_i) = \mathbf{a}_i' \Sigma_{12} \mathbf{b}_i$$

尽可能大。



注 因为每一对典型变量都消除了与前面典型变量的组内相关, 高阶典型变量可以看作在剩余关联结构中继续提取的信息。最多可得到 $\min(p, q)$ 对非零典型相关系数。

3 Hotelling 例子与典型变量解释

例 8.1 Hotelling 例子: 阅读能力与算术能力 Hotelling 的例子中有两组变量:

$$\mathbf{X}^{(1)} = \begin{bmatrix} X_1^{(1)} \\ X_2^{(1)} \end{bmatrix} = \begin{bmatrix} \text{reading speed} \\ \text{reading power} \end{bmatrix}, \quad \mathbf{X}^{(2)} = \begin{bmatrix} X_1^{(2)} \\ X_2^{(2)} \end{bmatrix} = \begin{bmatrix} \text{arithmetic speed} \\ \text{arithmetic power} \end{bmatrix}.$$

其协方差矩阵可写成分块形式

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} = \begin{bmatrix} 100 & 60 & 30 & 7.2 \\ 60 & 100 & -6 & 8.4 \\ 30 & -6 & 144 & 57.6 \\ 7.2 & 8.4 & 57.6 & 144 \end{bmatrix}.$$

对应的相关矩阵为

$$\rho = \begin{bmatrix} 1 & 0.6 & 0.25 & 0.06 \\ 0.6 & 1 & -0.05 & 0.07 \\ 0.25 & -0.05 & 1 & 0.4 \\ 0.06 & 0.07 & 0.4 & 1 \end{bmatrix}.$$

第一对典型变量形如

$$U_1 = a_{11}X_1^{(1)} + a_{12}X_2^{(1)}, \quad V_1 = b_{11}X_1^{(2)} + b_{12}X_2^{(2)},$$

目标是选择 $\mathbf{a}_1 = (a_{11}, a_{12})'$ 与 $\mathbf{b}_1 = (b_{11}, b_{12})'$, 使 $\text{corr}(U_1, V_1)$ 最大。

解 由 CCA 的谱分解计算可得

$$(\rho_1^*)^2 \approx 0.146, \quad (\rho_2^*)^2 \approx 0.005.$$

因而 $\rho_1^* \approx 0.38$, 第二个典型相关已经很弱。第一对典型变量可近似写为

$$U_1 = -0.12X_1^{(1)} + 0.10X_2^{(1)}, \quad V_1 = -0.09X_1^{(2)} + 0.03X_2^{(2)}.$$

解释时不要只比较典型变量的系数大小, 因为系数会受尺度和组内相关影响。例如

$$\text{corr}(V_1, X_1^{(2)}) \approx -0.923, \quad \text{corr}(V_1, X_2^{(2)}) \approx -0.017.$$

因此第一组典型关联在第二组变量中主要对应算术速度, 而不是简单由 -0.09 与 0.03 的系数大小判断。

4 典型变量的求法与性质

下面给出总体 CCA 的显式求法。为简化记号, 假设 $p \leq q$, 且 Σ_{11} 与 Σ_{22} 非退化。令

$$C = \Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1/2}.$$

设 C 的奇异值分解为

$$C = P_1 \Lambda P_2', \quad \Lambda = \text{diag}(\rho_1^*, \dots, \rho_p^*), \quad \rho_1^* \geq \dots \geq \rho_p^* \geq 0,$$

其中 $P_1 = (\mathbf{e}_1, \dots, \mathbf{e}_p)$, $P_2 = (\mathbf{f}_1, \dots, \mathbf{f}_q)$ 。

命题 8.2 (总体典型变量的谱分解求法)

第 k 对典型变量可取为

$$U_k = \mathbf{e}_k' \Sigma_{11}^{-1/2} \mathbf{X}^{(1)}, \quad V_k = \mathbf{f}_k' \Sigma_{22}^{-1/2} \mathbf{X}^{(2)}, \quad k = 1, \dots, p.$$

对应典型相关系数为 ρ_k^* 。等价地,

$$(\rho_k^*)^2$$

是矩阵

$$\Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1/2}$$

的特征值, 特征向量为 $\mathbf{e}_k$ 。右奇异向量可由

$$\mathbf{f}_k = \frac{1}{\rho_k^*} \Sigma_{22}^{-1/2} \Sigma_{21} \Sigma_{11}^{-1/2} \mathbf{e}_k$$

得到。

证明 由标准化变换

$$\tilde{\mathbf{a}} = \Sigma_{11}^{1/2} \mathbf{a}, \quad \tilde{\mathbf{b}} = \Sigma_{22}^{1/2} \mathbf{b}$$

可将目标化为

$$\max_{\|\tilde{\mathbf{a}}\|=\|\tilde{\mathbf{b}}\|=1} \tilde{\mathbf{a}}' C \tilde{\mathbf{b}}.$$

写 $C = P_1 \Lambda P_2'$, 令

$$\mathbf{c} = P_1' \tilde{\mathbf{a}}, \quad \mathbf{d} = P_2' \tilde{\mathbf{b}}.$$

则 $\|\mathbf{c}\| = \|\mathbf{d}\| = 1$, 且

$$\tilde{\mathbf{a}}' C \tilde{\mathbf{b}} = \mathbf{c}' \Lambda \mathbf{d} = \sum_{i=1}^p \rho_i^* c_i d_i \leq \rho_1^* \sum_{i=1}^p |c_i| |d_i| \leq \rho_1^*.$$

等号在 $\tilde{\mathbf{a}} = \mathbf{e}_1$, $\tilde{\mathbf{b}} = \mathbf{f}_1$ 时达到。后续典型变量在与前面方向正交的子空间中重复同样的 SVD 论证即可。

注 这个结果说明 CCA 与 PCA 的求解方式非常相似: PCA 对一个协方差矩阵做特征分解; CCA 对标准化交叉协方差矩阵 $C = \Sigma_{11}^{-1/2} \Sigma_{12} \Sigma_{22}^{-1/2}$ 做奇异值分解。

4.1 如何解释典型变量

设

$$U_i = \mathbf{a}_i' \mathbf{X}^{(1)} = a_{i1} X_1^{(1)} + \dots + a_{ip} X_p^{(1)}.$$

系数 a_{ik} 描述第 k 个变量在第 i 个典型变量中的线性组合权重; 类似地, b_{ik} 描述 $\mathbf{X}^{(2)}$ 中变量对 V_i 的贡献。但由于系数依赖尺度, 实际解释时更常看典型变量与原始变量之间的相关系数。

令

$$A = \begin{bmatrix} \mathbf{a}'_1 \\ \vdots \\ \mathbf{a}'_p \end{bmatrix}, \quad B = \begin{bmatrix} \mathbf{b}'_1 \\ \vdots \\ \mathbf{b}'_p \end{bmatrix}, \quad \mathbf{U} = A\mathbf{X}^{(1)}, \quad \mathbf{V} = B\mathbf{X}^{(2)}.$$

记

$$V_{11} = \text{diag}(\Sigma_{11}), \quad V_{22} = \text{diag}(\Sigma_{22}),$$

则典型变量与原变量的相关矩阵可写为

$$\begin{aligned} \text{corr}(\mathbf{U}, \mathbf{X}^{(1)}) &= A\Sigma_{11}^{-1/2}, & \text{corr}(\mathbf{U}, \mathbf{X}^{(2)}) &= A\Sigma_{12}V_{22}^{-1/2}, \\ \text{corr}(\mathbf{V}, \mathbf{X}^{(2)}) &= B\Sigma_{22}^{-1/2}, & \text{corr}(\mathbf{V}, \mathbf{X}^{(1)}) &= B\Sigma_{21}V_{11}^{-1/2}. \end{aligned}$$

注 这些相关系数常称为 canonical loadings 或 structure correlations。它们是解释典型变量含义的重要工具：若某个原变量与 U_i 或 V_i 的相关绝对值很大，则该原变量对该典型变量的实际解释更重要。

4.2 典型变量的性质

命题 8.3 (典型变量的协方差结构)

按上述标准化方式取典型变量，则

$$\text{Var}(U_k) = \text{Var}(V_k) = 1, \quad k = 1, \dots, p,$$

且

$$\text{Cov}(U_k, U_l) = 0, \quad \text{Cov}(V_k, V_l) = 0, \quad \text{Cov}(U_k, V_l) = 0, \quad k \neq l.$$

用矩阵形式表示为

$$\begin{aligned} \text{Cov}(\mathbf{U}, \mathbf{U}) &= A\Sigma_{11}A' = I_p, & \text{Cov}(\mathbf{V}, \mathbf{V}) &= B\Sigma_{22}B' = I_p, \\ \text{Cov}(\mathbf{U}, \mathbf{V}) &= A\Sigma_{12}B' = \text{diag}(\rho_1^*, \dots, \rho_p^*). \end{aligned}$$

注 与 PCA 不同，CCA 中的系数向量 $\mathbf{a}_i$ 一般不在欧氏内积下正交；正交性是在 Σ_{11} 加权内积下成立的，即 $\mathbf{a}'_k \Sigma_{11} \mathbf{a}_l = 0$, $k \neq l$ 。

4.3 与传统相关的关系

第一典型相关系数可以看作普通相关系数的多元推广。

- 当 $p = q = 1$ 时，

$$\rho_1^* = |\text{corr}(X_1^{(1)}, X_1^{(2)})|.$$

- 当一边只有一个变量时，例如 $p = 1$ ，则

$$\rho_1^* = \max_{\mathbf{b}} \text{corr}(X_1^{(1)}, \mathbf{b}'\mathbf{X}^{(2)}),$$

即多重相关系数 (multiple correlation coefficient)。

- 对第 k 对典型变量，

$$\max_{\mathbf{b}} \text{corr}(U_k, \mathbf{b}'\mathbf{X}^{(2)}) = \text{corr}(U_k, V_k) = \rho_k^*,$$

$$\max_{\mathbf{a}} \text{corr}(\mathbf{a}'\mathbf{X}^{(1)}, V_k) = \text{corr}(U_k, V_k) = \rho_k^*.$$

注 因为 $\text{Var}(U_k) = \text{Var}(V_k) = 1$, $(\rho_k^*)^2$ 可理解为 U_k 与 V_k 之间的共享方差比例：它既是 U_k 可由 $\mathbf{X}^{(2)}$ 中最佳线性组合解释的比例，也是 V_k 可由 $\mathbf{X}^{(1)}$ 中最佳线性组合解释的比例。

5 基于标准化变量的 CCA

若某些变量的量纲或尺度差异很大，直接在协方差矩阵 Σ 上比较系数并不方便。一种常用做法是先对两组变量分别标准化。记

$$V_{11} = \text{diag}(\Sigma_{11}), \quad V_{22} = \text{diag}(\Sigma_{22}), \quad V = \begin{bmatrix} V_{11} & 0 \\ 0 & V_{22} \end{bmatrix}.$$

令

$$\mathbf{Z}^{(j)} = V_{jj}^{-1/2}(\mathbf{X}^{(j)} - \boldsymbol{\mu}^{(j)}), \quad j = 1, 2.$$

等价地，对第 j 组的第 k 个变量，

$$Z_k^{(j)} = \frac{X_k^{(j)} - \mu_k^{(j)}}{\sqrt{\sigma_{kk}^{(j)}}}.$$

于是标准化后的相关矩阵为

$$\rho = V^{-1/2} \Sigma V^{-1/2} = \begin{bmatrix} \rho_{11} & \rho_{12} \\ \rho_{21} & \rho_{22} \end{bmatrix}.$$

命题 8.4 (相关矩阵上的 CCA)

在标准化变量上作 CCA，即令

$$U = \mathbf{a}' \mathbf{Z}^{(1)}, \quad V = \mathbf{b}' \mathbf{Z}^{(2)}.$$

若 $p \leq q$ ，则第 k 对典型变量可取为

$$U_k = \mathbf{e}_k' \rho_{11}^{-1/2} \mathbf{Z}^{(1)}, \quad V_k = \mathbf{f}_k' \rho_{22}^{-1/2} \mathbf{Z}^{(2)}, \quad k = 1, \dots, p.$$

其中 $(\rho_k^*)^2$ 是

$$\rho_{11}^{-1/2} \rho_{12} \rho_{22}^{-1} \rho_{21} \rho_{11}^{-1/2}$$

的特征值，对应特征向量为 $\mathbf{e}_k$ ，并且

$$\mathbf{f}_k = \frac{1}{\rho_k^*} \rho_{22}^{-1/2} \rho_{21} \rho_{11}^{-1/2} \mathbf{e}_k.$$

注 (标准化不改变典型相关) 标准化只改变变量的坐标表示，不改变两组变量张成的线性空间。更一般地，若

$$\mathbf{Z}^{(j)} = C_j \mathbf{X}^{(j)} + \boldsymbol{\eta}_j, \quad C_j \text{ 可逆},$$

则在 $\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)}$ 上的目标函数可通过 $\mathbf{a} = C_1' \mathbf{a}_z$ 、 $\mathbf{b} = C_2' \mathbf{b}_z$ 写回原变量：

$$\max_{\mathbf{a}_z, \mathbf{b}_z \neq 0} \frac{\mathbf{a}_z' \tilde{\Sigma}_{12} \mathbf{b}_z}{\sqrt{\mathbf{a}_z' \tilde{\Sigma}_{11} \mathbf{a}_z} \sqrt{\mathbf{b}_z' \tilde{\Sigma}_{22} \mathbf{b}_z}} = \max_{\mathbf{a}, \mathbf{b} \neq 0} \frac{\mathbf{a}' \Sigma_{12} \mathbf{b}}{\sqrt{\mathbf{a}' \Sigma_{11} \mathbf{a}} \sqrt{\mathbf{b}' \Sigma_{22} \mathbf{b}}}.$$

因此典型相关系数不变；系数向量会随坐标变换而改变，但中心化后的典型变量本身对应同一组线性信息。Hotelling 例子中，无论从 Σ 还是从相关矩阵 ρ 出发，均得到

$$(\rho_1^*)^2 \approx 0.146, \quad (\rho_2^*)^2 \approx 0.005.$$

6 样本典型相关 (Sample CCA)

设 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 是来自同一 $(p+q)$ 维总体的独立观测，其均值向量为 $\boldsymbol{\mu}$ ，协方差矩阵为 Σ 。将观测按两组变量分块：

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} & \mathbf{X}^{(2)} \end{bmatrix}, \quad \mathbf{X}^{(1)} \in \mathbb{R}^{n \times p}, \quad \mathbf{X}^{(2)} \in \mathbb{R}^{n \times q}.$$

记样本均值为 $\bar{\mathbf{x}}$, 样本协方差矩阵和样本相关矩阵分别为

$$S = \begin{bmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{bmatrix}, \quad R = \begin{bmatrix} R_{11} & R_{12} \\ R_{21} & R_{22} \end{bmatrix}.$$

样本 CCA 的做法就是把总体分布替换为经验分布, 把 Σ 替换为 S ; 若使用标准化变量, 则把总体相关矩阵 ρ 替换为样本相关矩阵 R .

命题 8.5 (样本典型变量)

对单个观测, 以下 $\mathbf{x}^{(j)}$ 默认表示中心化后的第 j 组向量。若 $p \leq q$, 则第 k 对样本典型变量可取为

$$\hat{U}_k = \hat{\mathbf{e}}_k' S_{11}^{-1/2} \mathbf{x}^{(1)}, \quad \hat{V}_k = \hat{\mathbf{f}}_k' S_{22}^{-1/2} \mathbf{x}^{(2)}.$$

其中 $(\hat{\rho}_k^*)^2$ 是

$$S_{11}^{-1/2} S_{12} S_{22}^{-1} S_{21} S_{11}^{-1/2}$$

的特征值, 对应特征向量为 $\hat{\mathbf{e}}_k$, 并且

$$\hat{\mathbf{f}}_k = \frac{1}{\hat{\rho}_k^*} S_{22}^{-1/2} S_{21} S_{11}^{-1/2} \hat{\mathbf{e}}_k.$$

由此得到样本典型相关

$$\widehat{\text{corr}}(\hat{U}_k, \hat{V}_k) = \hat{\rho}_k^*, \quad k = 1, \dots, p.$$

命题 8.6 (样本典型变量的性质)

令

$$\hat{A} = \begin{bmatrix} \hat{\mathbf{a}}_1' \\ \vdots \\ \hat{\mathbf{a}}_p' \end{bmatrix}, \quad \hat{B} = \begin{bmatrix} \hat{\mathbf{b}}_1' \\ \vdots \\ \hat{\mathbf{b}}_p' \end{bmatrix}, \quad \hat{\mathbf{U}} = \hat{A} \mathbf{x}^{(1)}, \quad \hat{\mathbf{V}} = \hat{B} \mathbf{x}^{(2)}.$$

则在样本方差和样本协方差意义下,

$$\widehat{\text{Var}}(\hat{U}_k) = \widehat{\text{Var}}(\hat{V}_k) = 1,$$

且

$$\widehat{\text{Cov}}(\hat{U}_k, \hat{U}_l) = 0, \quad \widehat{\text{Cov}}(\hat{V}_k, \hat{V}_l) = 0, \quad \widehat{\text{Cov}}(\hat{U}_k, \hat{V}_l) = 0, \quad k \neq l.$$

矩阵形式为

$$\begin{aligned} \widehat{\text{Cov}}(\hat{\mathbf{U}}, \hat{\mathbf{V}}) &= \hat{A} S_{12} \hat{B}' = \text{diag}(\hat{\rho}_1^*, \dots, \hat{\rho}_p^*), \\ \widehat{\text{Cov}}(\hat{\mathbf{U}}, \hat{\mathbf{U}}) &= \hat{A} S_{11} \hat{A}' = I_p, \quad \widehat{\text{Cov}}(\hat{\mathbf{V}}, \hat{\mathbf{V}}) = \hat{B} S_{22} \hat{B}' = I_p. \end{aligned}$$

第四部分

Classification and Discrimination

第9节 Discriminant Analysis

1 判别分析概述 (Overview of Discriminant Analysis)

内容提要

- 基本思想：用已知类别样本建立分类规则，将新观测分到预先给定的类别中
- 多总体分类： $g > 2$ 时的应用为主，理论不作重点要求
- 两总体分类：Fisher 线性判别分析；基于似然的分类器；两个多元正态总体的分类
- 分类规则评价：误判概率、期望误判代价与分类函数的检验

例 9.1 Iris 数据 Iris 数据中，每朵花记录四个连续型测量：

sepal length, sepal width, petal length, petal width,

同时记录其类别：

setosa, versicolor, virginica.

Fisher 最初提出的线性判别思想，正是为了用这些测量变量对三类 iris 进行分类。

1.1 判别分析的目标

判别分析关注的是**分离** (separation) 和**分类** (classification)。给定一批对象的观测测量 $\mathbf{x}$ 以及已知类别 g ，目标是由已有数据学习一个规则，并将一个类别未知的新对象分到预先给定的某一类中。该问题也常称为 pattern recognition 或 classification。

定义 9.1 (判别数据结构)

设有 n 个训练样本，每个样本有 p 个测量变量及一个类别标签。记

$$D = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} & g_1 \\ x_{21} & x_{22} & \cdots & x_{2p} & g_2 \\ \vdots & \vdots & & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} & g_n \end{bmatrix}, \quad D \in \mathbb{R}^{n \times (p+1)}.$$

对新观测

$$\tilde{D} = \begin{bmatrix} x_{01} & x_{02} & \cdots & x_{0p} & ? \end{bmatrix},$$

判别分析的任务是根据前 p 个测量变量预测最后的类别标签。

注 (为什么需要分类) 分类问题通常来自未来表现或真实类别无法直接获得的情形：

- 完全信息不可得，或者获得代价很高；
- 有些“完美”检测会破坏对象本身；
- 需要用已有测量对未来结果或未知类别作预测。

与线性回归不同，分类问题的响应变量是类别标签，而不是连续数值。

2 两总体 Fisher 线性判别 (Fisher LDA)

先考虑两个总体 π_1, π_2 的分类问题。Fisher 的思想是：把 p 维观测向量 $\mathbf{x}$ 投影到一维

$$y = \mathbf{a}'\mathbf{x},$$

并选择投影方向 $\mathbf{a}$, 使来自 π_1 和 π_2 的一维投影尽可能分离。

注 (Fisher 方法的假设) Fisher 方法只要求两个总体具有相同协方差矩阵:

$$\Sigma_1 = \Sigma_2.$$

这里不需要正态性假设。正态性将在后面的似然分类器中出现。

设来自两个总体的样本分别为

$$\mathbf{x}_{1j}, \quad j = 1, \dots, n_1, \quad \mathbf{x}_{2j}, \quad j = 1, \dots, n_2,$$

样本均值为

$$\bar{\mathbf{x}}_1 = \frac{1}{n_1} \sum_{j=1}^{n_1} \mathbf{x}_{1j}, \quad \bar{\mathbf{x}}_2 = \frac{1}{n_2} \sum_{j=1}^{n_2} \mathbf{x}_{2j}.$$

投影后的样本均值为

$$\bar{y}_1 = \mathbf{a}' \bar{\mathbf{x}}_1, \quad \bar{y}_2 = \mathbf{a}' \bar{\mathbf{x}}_2.$$

记均值差为

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2.$$

定义 9.2 (Fisher separation)

Fisher 用如下比例度量一维投影后的分离程度:

$$\text{sep}(\mathbf{a}) = \frac{(\bar{y}_1 - \bar{y}_2)^2}{s_y^2},$$

其中 s_y^2 是两组投影数据的 pooled variance:

$$s_y^2 = \frac{\sum_{j=1}^{n_1} (y_{1j} - \bar{y}_1)^2 + \sum_{j=1}^{n_2} (y_{2j} - \bar{y}_2)^2}{n_1 + n_2 - 2}.$$

因而 Fisher 的目标是

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{(\bar{y}_1 - \bar{y}_2)^2}{s_y^2}.$$



2.1 Fisher 目标函数的矩阵形式

由 $y_{ij} = \mathbf{a}' \mathbf{x}_{ij}$, 有

$$\bar{y}_1 - \bar{y}_2 = \mathbf{a}' (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = \mathbf{a}' \mathbf{d}.$$

同时,

$$\begin{aligned} s_y^2 &= \frac{\sum_{j=1}^{n_1} (\mathbf{a}' (\mathbf{x}_{1j} - \bar{\mathbf{x}}_1))^2 + \sum_{j=1}^{n_2} (\mathbf{a}' (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2))^2}{n_1 + n_2 - 2} \\ &= \mathbf{a}' \left\{ \frac{\sum_{j=1}^{n_1} (\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)(\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)' + \sum_{j=1}^{n_2} (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)(\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)'}{n_1 + n_2 - 2} \right\} \mathbf{a} \\ &= \mathbf{a}' S_{\text{pooled}} \mathbf{a}. \end{aligned}$$

其中

$$S_{\text{pooled}} = \frac{\sum_{j=1}^{n_1} (\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)(\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)' + \sum_{j=1}^{n_2} (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)(\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)'}{n_1 + n_2 - 2}$$

是两个总体公共协方差矩阵的 pooled estimate。于是 Fisher 目标函数化为

$$\max_{\mathbf{a} \neq \mathbf{0}} \frac{(\bar{y}_1 - \bar{y}_2)^2}{s_y^2} = \max_{\mathbf{a} \neq \mathbf{0}} \frac{(\mathbf{a}' \mathbf{d})^2}{\mathbf{a}' S_{\text{pooled}} \mathbf{a}}.$$

命题 9.1 (Fisher 线性判别方向)

若 S_{pooled} 非退化, 则使

$$\frac{(\mathbf{a}'\mathbf{d})^2}{\mathbf{a}'S_{\text{pooled}}\mathbf{a}}$$

最大的方向可取为

$$\hat{\mathbf{a}} = S_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$

因而 Fisher 线性判别变量为

$$\hat{y} = \hat{\mathbf{a}}'\mathbf{x} = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)'S_{\text{pooled}}^{-1}\mathbf{x}.$$

最大分离比例为

$$D^2 = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)'S_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2).$$



证明 令 $S = S_{\text{pooled}}$ 。由 Cauchy-Schwarz 不等式,

$$(\mathbf{a}'\mathbf{d})^2 = \left\{ (S^{1/2}\mathbf{a})'(S^{-1/2}\mathbf{d}) \right\}^2 \leq (\mathbf{a}'S\mathbf{a})(\mathbf{d}'S^{-1}\mathbf{d}).$$

因此

$$\frac{(\mathbf{a}'\mathbf{d})^2}{\mathbf{a}'S\mathbf{a}} \leq \mathbf{d}'S^{-1}\mathbf{d}.$$

当 $\mathbf{a} \propto S^{-1}\mathbf{d}$ 时等号成立, 故 Fisher 判别方向为 $\hat{\mathbf{a}} = S_{\text{pooled}}^{-1}\mathbf{d}$, 最大值即为 D^2 。

注 Fisher LDA 的核心不是直接在原始 p 维空间中分类, 而是先找到最能区分两类的线性方向, 再在一维分数 $\hat{y} = \hat{\mathbf{a}}'\mathbf{x}$ 上进行分类。后续还需要给出阈值或分类规则, 才能把一个新观测分配到 π_1 或 π_2 。

3 基于误判代价的分类准则

从另一个角度看, 分类规则不仅应使误判概率小, 还应考虑:

- 不同误判的代价可能不同;
- 两个总体在总体中出现的先验概率可能不同。

例如 Iris 数据有三类花, 每类约 50 个样本; 若不同类别的重要性或误判代价不同, 则“好的分类规则”不一定只等价于最少误判数。下面先讨论两个总体的情形。

定义 9.3 (分类区域、先验概率与误判代价)

设总体 π_1, π_2 下 $p \times 1$ 随机向量 $\mathbf{X}$ 的密度函数分别为

$$f_1(\mathbf{x}), \quad f_2(\mathbf{x}).$$

令 Ω 为样本空间。分类规则可以用区域 R_1, R_2 表示:

$$R_1 = \{\mathbf{x} : \text{classify as } \pi_1\}, \quad R_2 = \Omega - R_1 = \{\mathbf{x} : \text{classify as } \pi_2\}.$$

两个区域互斥且完备。记先验概率为

$$p_1 = P(G = 1), \quad p_2 = P(G = 2), \quad p_1 + p_2 = 1,$$

其中 $G = i$ 表示真实总体为 π_i 。

误判代价记为 $c(i | j)$, 表示真实总体为 π_j 而被判为 π_i 的代价。通常正确分类代价取为 0:

	classify as π_1	classify as π_2
true π_1	0	$c(2 1)$
true π_2	$c(1 2)$	0



定义 9.4 (期望误判代价 (expected cost of misclassification))

对给定分类区域 R_1 ，期望误判代价定义为

$$ECM(R_1) = c(2 | 1)P(\mathbf{X} \in R_2, G = 1) + c(1 | 2)P(\mathbf{X} \in R_1, G = 2).$$

由于

$$P(2 | 1) = P(\mathbf{X} \in R_2 | G = 1) = \int_{R_2} f_1(\mathbf{x}) d\mathbf{x},$$

$$P(1 | 2) = P(\mathbf{X} \in R_1 | G = 2) = \int_{R_1} f_2(\mathbf{x}) d\mathbf{x},$$

可写为

$$ECM(R_1) = c(2 | 1)p_1 \int_{R_2} f_1(\mathbf{x}) d\mathbf{x} + c(1 | 2)p_2 \int_{R_1} f_2(\mathbf{x}) d\mathbf{x}.$$

目标是

$$\min_{R_1} ECM(R_1).$$

**命题 9.2 (最小 ECM 分类区域)**

使 $ECM(R_1)$ 最小的分类区域由似然比给出：

$$R_1 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{c(1 | 2) p_2}{c(2 | 1) p_1},$$

$$R_2 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < \frac{c(1 | 2) p_2}{c(2 | 1) p_1}.$$

即

$$\text{density ratio} \geq \text{cost ratio} \times \text{prior ratio}$$

时判为 π_1 ，否则判为 π_2 。



证明 对一个给定观测值 $\mathbf{x}$ ，若把它放入 R_1 ，则只会在真实总体为 π_2 时产生误判代价，局部贡献为

$$c(1 | 2)p_2 f_2(\mathbf{x}).$$

若把它放入 R_2 ，则只会在真实总体为 π_1 时产生误判代价，局部贡献为

$$c(2 | 1)p_1 f_1(\mathbf{x}).$$

因而当

$$c(1 | 2)p_2 f_2(\mathbf{x}) \leq c(2 | 1)p_1 f_1(\mathbf{x})$$

时应将 $\mathbf{x}$ 放入 R_1 。整理即得

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{c(1 | 2) p_2}{c(2 | 1) p_1}.$$

注 (若干特殊情形)

1. 若先验概率相等，即 $p_2/p_1 = 1$ ，则

$$R_1 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{c(1 | 2)}{c(2 | 1)}, \quad R_2 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < \frac{c(1 | 2)}{c(2 | 1)}.$$

2. 若误判代价相等，即 $c(1 | 2) = c(2 | 1)$ ，则

$$R_1 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{p_2}{p_1}, \quad R_2 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < \frac{p_2}{p_1}.$$

3. 若先验概率和误判代价均相等，或更一般地 $\frac{p_2}{p_1} = \frac{c(2 | 1)}{c(1 | 2)}$ ，则阈值为 1：

$$R_1 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq 1, \quad R_2 : \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} < 1.$$

3.1 其他分类准则

定义 9.5 (总误判概率 (total probability of misclassification))

若忽略误判代价，只关心总体误判概率，则定义

$$\begin{aligned} TPM &= P(\text{misclassifying an observation}) \\ &= P(\mathbf{X} \in R_1, G = 2) + P(\mathbf{X} \in R_2, G = 1) \\ &= P(1 | 2)p_2 + P(2 | 1)p_1 \\ &= p_2 \int_{R_1} f_2(\mathbf{x}) d\mathbf{x} + p_1 \int_{R_2} f_1(\mathbf{x}) d\mathbf{x}. \end{aligned}$$

当 $c(1 | 2) = c(2 | 1)$ 时，

$$\arg \min_{R_1} TPM(R_1) = \arg \min_{R_1} ECM(R_1).$$



命题 9.3 (后验概率规则与 Bayes classifier)

给定新观测 $\mathbf{x}_0$ ，由 Bayes 公式，

$$\begin{aligned} P(G = 1 | \mathbf{X} = \mathbf{x}_0) &= \frac{p_1 f_1(\mathbf{x}_0)}{p_1 f_1(\mathbf{x}_0) + p_2 f_2(\mathbf{x}_0)}, \\ P(G = 2 | \mathbf{X} = \mathbf{x}_0) &= \frac{p_2 f_2(\mathbf{x}_0)}{p_1 f_1(\mathbf{x}_0) + p_2 f_2(\mathbf{x}_0)}. \end{aligned}$$

因而 Bayes classifier 在

$$P(G = 1 | \mathbf{X} = \mathbf{x}_0) > P(G = 2 | \mathbf{X} = \mathbf{x}_0)$$

时将 $\mathbf{x}_0$ 判为 π_1 ，否则判为 π_2 。



注 后验概率规则等价于

$$p_1 f_1(\mathbf{x}_0) > p_2 f_2(\mathbf{x}_0) \iff \frac{f_1(\mathbf{x}_0)}{f_2(\mathbf{x}_0)} > \frac{p_2}{p_1}.$$

因此它正是误判代价相等时的最小 ECM 规则。

4 正态总体下的分类规则

前面的最小 ECM 规则只依赖密度比

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})}.$$

若进一步假设两个总体服从多元正态分布，

$$\pi_1 : N_p(\boldsymbol{\mu}_1, \Sigma_1), \quad \pi_2 : N_p(\boldsymbol{\mu}_2, \Sigma_2),$$

则可以把密度比化为显式的判别函数。几何上，两个总体越“远”、组内变异越小，分类越容易。下面分别讨论

$$\Sigma_1 = \Sigma_2 \quad \text{与} \quad \Sigma_1 \neq \Sigma_2$$

两种情形。

4.1 等协方差情形：LDA

先考虑

$$\mathbf{X} | \pi_i \sim N_p(\boldsymbol{\mu}_i, \Sigma), \quad i = 1, 2.$$

此时

$$f_i(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) \right\}.$$

命题 9.4 (等协方差正态总体的最小 ECM 规则)

若 $\Sigma_1 = \Sigma_2 = \Sigma$, 则使 ECM 最小的区域由下列线性不等式给出:

$$\begin{aligned} R_1: & (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} \mathbf{x} - \frac{1}{2} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2) \geq \ln \left[\frac{c(1|2) p_2}{c(2|1) p_1} \right], \\ R_2: & (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} \mathbf{x} - \frac{1}{2} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2) < \ln \left[\frac{c(1|2) p_2}{c(2|1) p_1} \right]. \end{aligned}$$

证明 由最小 ECM 规则,

$$R_1: \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \geq \frac{c(1|2) p_2}{c(2|1) p_1}.$$

对两边取对数, 并代入等协方差正态密度:

$$\begin{aligned} \log \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} &= -\frac{1}{2} [(\mathbf{x} - \boldsymbol{\mu}_1)' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) - (\mathbf{x} - \boldsymbol{\mu}_2)' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_2)] \\ &= (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} \mathbf{x} - \frac{1}{2} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \Sigma^{-1} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2). \end{aligned}$$

代回即可得到结论。

实际应用中 $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \Sigma$ 通常未知, 可用样本均值和合并协方差矩阵代替:

$$S_{\text{pooled}} = \frac{\sum_{j=1}^{n_1} (\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)(\mathbf{x}_{1j} - \bar{\mathbf{x}}_1)' + \sum_{j=1}^{n_2} (\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)(\mathbf{x}_{2j} - \bar{\mathbf{x}}_2)'}{n_1 + n_2 - 2}.$$

于是得到估计的最小 ECM 规则:

$$\begin{aligned} R_1: & (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} \mathbf{x} - \frac{1}{2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} (\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2) \geq \ln \left[\frac{c(1|2) p_2}{c(2|1) p_1} \right], \\ R_2: & (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} \mathbf{x} - \frac{1}{2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} (\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2) < \ln \left[\frac{c(1|2) p_2}{c(2|1) p_1} \right]. \end{aligned}$$

注 (与 Fisher 线性判别的关系) 若

$$\frac{c(1|2) p_2}{c(2|1) p_1} = 1,$$

则阈值为 0。令

$$\hat{\mathbf{a}} = S_{\text{pooled}}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2), \quad \hat{y} = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} \mathbf{x} = \hat{\mathbf{a}}' \mathbf{x},$$

且

$$\bar{y}_i = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_{\text{pooled}}^{-1} \bar{\mathbf{x}}_i = \hat{\mathbf{a}}' \bar{\mathbf{x}}_i, \quad i = 1, 2.$$

分类规则可写成

$$R_1: \hat{y} \geq \frac{1}{2} (\bar{y}_1 + \bar{y}_2), \quad R_2: \hat{y} < \frac{1}{2} (\bar{y}_1 + \bar{y}_2).$$

因此等协方差正态模型下的最小 ECM 规则是线性的, 也就是线性判别分析 (linear discriminant analysis, LDA)。

4.2 不等协方差情形: QDA

若

$$\mathbf{X} | \pi_i \sim N_p(\boldsymbol{\mu}_i, \Sigma_i), \quad \Sigma_1 \neq \Sigma_2,$$

则密度比中的二次项不会相互抵消, 分类边界一般为二次曲面。

命题 9.5 (不等协方差正态总体的最小 ECM 规则)

若 $\Sigma_1 \neq \Sigma_2$, 则使 ECM 最小的区域可写为

$$\begin{aligned} R_1: & -\frac{1}{2}\mathbf{x}'(\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x} + (\boldsymbol{\mu}_1'\Sigma_1^{-1} - \boldsymbol{\mu}_2'\Sigma_2^{-1})\mathbf{x} - k \\ & \geq \ln \left[\frac{c(1|2)p_2}{c(2|1)p_1} \right], \\ R_2: & -\frac{1}{2}\mathbf{x}'(\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x} + (\boldsymbol{\mu}_1'\Sigma_1^{-1} - \boldsymbol{\mu}_2'\Sigma_2^{-1})\mathbf{x} - k \\ & < \ln \left[\frac{c(1|2)p_2}{c(2|1)p_1} \right], \end{aligned}$$

其中

$$k = \frac{1}{2} \ln \frac{|\Sigma_1|}{|\Sigma_2|} + \frac{1}{2} (\boldsymbol{\mu}_1'\Sigma_1^{-1}\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2'\Sigma_2^{-1}\boldsymbol{\mu}_2).$$



注 该规则对应二次判别分析 (quadratic discriminant analysis, QDA)。与 LDA 相比, QDA 允许不同类别具有不同协方差结构, 因此分类边界更灵活, 但需要估计更多参数。

5 多总体 Fisher 判别

当总体数为 $g > 2$ 时, 仍可从 ECM 的角度建立分类规则。设

$$\pi_1, \dots, \pi_g$$

为 g 个总体, 先验概率为 $p_1, \dots, p_g$, 其中

$$\sum_{i=1}^g p_i = 1.$$

记 $f_i(\mathbf{x})$ 为总体 π_i 下的密度函数, R_k 为把观测分到第 k 类的区域。

定义 9.6 (多总体误判概率与 ECM)

对 $i \neq k$, 定义

$$P(k|i) = P(\mathbf{X} \in R_k | G = i) = \int_{R_k} f_i(\mathbf{x}) d\mathbf{x}.$$

若真实总体为 π_i , 其条件期望误判代价为

$$ECM(i) = \sum_{\substack{k=1 \\ k \neq i}}^g c(k|i)P(k|i).$$

因而总体期望误判代价为

$$ECM = \sum_{i=1}^g p_i ECM(i) = \sum_{i=1}^g p_i \sum_{\substack{k=1 \\ k \neq i}}^g c(k|i)P(k|i).$$

**命题 9.6 (多总体最小 ECM 分类规则)**

为使 ECM 最小, 对给定观测 $\mathbf{x}$, 将其分到第 k 类当且仅当

$$\sum_{\substack{i=1 \\ i \neq k}}^g p_i f_i(\mathbf{x}) c(k|i)$$

在 $k = 1, \dots, g$ 中取最小值。



注（等误判代价情形） 若所有误判代价相等，则上式等价于选择使

$$p_k f_k(\mathbf{x})$$

最大的类别。也就是说，

$$R_k: p_k f_k(\mathbf{x}) > p_i f_i(\mathbf{x}), \quad \forall i \neq k.$$

注（后验概率规则） 由 Bayes 公式，

$$P(G = k | \mathbf{X} = \mathbf{x}_0) = \frac{p_k f_k(\mathbf{x}_0)}{\sum_{\ell=1}^g p_\ell f_\ell(\mathbf{x}_0)}.$$

因此在等误判代价下，选择最大后验概率的类别，与最小 ECM 规则等价。

5.1 Fisher LDA 的投影观点

Fisher LDA 可以理解为：把高维观测 $\mathbf{x} \in \mathbb{R}^p$ 投影到低维判别得分空间，使得不同类别在投影后尽可能分开。

注（Fisher LDA 的三个问题） 从投影视角看，Fisher LDA 需要回答三个问题：

1. **保留多少维？** 对 g 个总体，最多有

$$s \leq \min(g-1, p)$$

个非零判别方向；实际应用中常根据判别效果保留前若干个方向。

2. **投影方向是什么？** 方向由组间变异与组内变异的比值最大化确定。

3. **如何分类新样本？** 将新样本投影到判别得分空间，再依据距离或前面得到的最小 ECM 规则分类。

以 iris 数据为例， $p = 4$ ， $g = 3$ ，因此 Fisher LDA 至多给出

$$s = \min(g-1, p) = 2$$

个判别得分。二维图中的 LD_1, LD_2 正是这两个线性判别得分。

5.2 直观理解：组间与组内平方和

先看一维投影。令

$$y_{ij} = \mathbf{a}' \mathbf{x}_{ij}, \quad i = 1, \dots, g, \quad j = 1, \dots, n_i,$$

其中 $\mathbf{a}$ 是投影方向。记第 i 组样本均值为 $\bar{y}_i$ ，总体样本均值为 $\bar{y}$ 。

命题 9.7（一维判别得分的平方和分解）

对投影得分 y_{ij} ，有

$$\sum_{i=1}^g \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2 = \sum_{i=1}^g n_i (\bar{y}_i - \bar{y})^2 + \sum_{i=1}^g \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2.$$

即

$$SS_{\text{cor}} = SS_{\text{tr}} + SS_{\text{res}},$$

其中 SS_{tr} 是组间平方和， SS_{res} 是组内平方和。

注（好的投影方向） 判别分析希望投影后：

组间差异大， 组内差异小。

因此 Fisher 的核心思想是最大化

$$\frac{\text{between sample sum of squares}}{\text{within sample sum of squares}}.$$

如果某个方向上两类或多类的投影点混在一起，则该方向不适合作为判别方向；反之，投影后不同组均值分离明显且组内波动较小，则判别效果较好。

5.3 Fisher 方法的多总体推广

考虑 g 个总体，并假设它们具有相同协方差矩阵：

$$\Sigma_1 = \Sigma_2 = \cdots = \Sigma_g = \Sigma.$$

对任意线性组合

$$Y = \mathbf{a}'\mathbf{X},$$

在总体 π_i 下有

$$E(Y | \pi_i) = \mathbf{a}'\boldsymbol{\mu}_i, \quad \text{Var}(Y | \pi_i) = \mathbf{a}'\Sigma\mathbf{a}.$$

样本中记

$$\hat{\mu}_{iY} = \mathbf{a}'\bar{\mathbf{x}}_i, \quad \hat{\mu}_Y = \mathbf{a}'\bar{\mathbf{x}}.$$

定义组间散布矩阵与组内散布矩阵为

$$B = \sum_{i=1}^g n_i (\bar{\mathbf{x}}_i - \bar{\mathbf{x}})(\bar{\mathbf{x}}_i - \bar{\mathbf{x}})',$$

$$W = \sum_{i=1}^g \sum_{j=1}^{n_i} (\mathbf{x}_{ij} - \bar{\mathbf{x}}_i)(\mathbf{x}_{ij} - \bar{\mathbf{x}}_i)' = \sum_{i=1}^g (n_i - 1)S_i.$$

投影后相应的组间、组内平方和为

$$B_Y = \mathbf{a}'B\mathbf{a}, \quad W_Y = \mathbf{a}'W\mathbf{a}.$$

定义 9.7 (Fisher 判别准则)

Fisher 多总体判别方向由如下 Rayleigh 商确定：

$$J(\mathbf{a}) = \frac{\mathbf{a}'B\mathbf{a}}{\mathbf{a}'W\mathbf{a}}.$$

直观上，分子度量组均值之间的分离程度，分母度量组内离散程度。



命题 9.8 (Fisher 多总体判别方向)

设 $\hat{\lambda}_1, \dots, \hat{\lambda}_s > 0$ 是 $W^{-1}B$ 的非零特征值，其中

$$s \leq \min(g-1, p),$$

对应特征向量为 $\hat{\mathbf{e}}_1, \dots, \hat{\mathbf{e}}_s$ 。若将它们规范化为

$$\hat{\mathbf{e}}_i' S_{\text{pooled}} \hat{\mathbf{e}}_k = \begin{cases} 1, & i = k \leq s, \\ 0, & i \neq k, \end{cases}$$

其中

$$S_{\text{pooled}} = \frac{W}{n_1 + \cdots + n_g - g}$$

是公共协方差矩阵 Σ 的估计，则第 k 个样本判别方向为

$$\hat{\mathbf{a}}_k = \hat{\mathbf{e}}_k, \quad k = 1, \dots, s.$$

相应的第 k 个样本判别得分为

$$Y_k = \hat{\mathbf{a}}_k' \mathbf{x}.$$



证明 最大化 Fisher 准则

$$\frac{\mathbf{a}'B\mathbf{a}}{\mathbf{a}'W\mathbf{a}}$$

等价于求广义特征值问题

$$B\mathbf{a} = \lambda W\mathbf{a}.$$

当 W 非奇异时, 可写为

$$W^{-1}B\mathbf{a} = \lambda\mathbf{a}.$$

因此最大特征值对应的特征向量给出第一判别方向, 其余非零特征值对应后续判别方向。

注 (与二总体 Fisher LDA 的关系) 当 $g = 2$ 时, 最多只有一个非零判别方向, 此时多总体 Fisher LDA 退化为二总体情形; 其方向与

$$S_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$$

相同, 只差一个非零比例常数。

5.4 用判别得分分类

将所有保留的判别方向写成矩阵

$$\hat{A} = [\hat{\mathbf{a}}_1, \dots, \hat{\mathbf{a}}_s],$$

则样本 $\mathbf{x}$ 的判别得分向量为

$$\mathbf{y} = \hat{A}'\mathbf{x} = (Y_1, \dots, Y_s)'.$$

第 i 组在判别得分空间中的样本均值为

$$\hat{\boldsymbol{\mu}}_{iY} = \hat{A}'\bar{\mathbf{x}}_i = \begin{pmatrix} \hat{\mathbf{a}}_1'\bar{\mathbf{x}}_i \\ \vdots \\ \hat{\mathbf{a}}_s'\bar{\mathbf{x}}_i \end{pmatrix}.$$

定义 9.8 (判别得分空间中的最近均值分类)

对新观测 $\mathbf{x}_0$, 先计算

$$\mathbf{y}_0 = \hat{A}'\mathbf{x}_0.$$

然后将其分到距离最近的组:

$$\hat{G}(\mathbf{x}_0) = \arg \min_{1 \leq i \leq g} (\mathbf{y}_0 - \hat{\boldsymbol{\mu}}_{iY})'(\mathbf{y}_0 - \hat{\boldsymbol{\mu}}_{iY}).$$

等价地,

$$\hat{G}(\mathbf{x}_0) = \arg \min_{1 \leq i \leq g} \sum_{k=1}^s (y_{0k} - \hat{\mu}_{iY_k})^2.$$



注 (维数、方向与分类规则) Fisher LDA 的三个问题可以对应为:

- **维数:** 保留 $s \leq \min(g-1, p)$ 个非零判别方向;
- **方向:** 由 $W^{-1}B$ 的特征向量给出;
- **分类:** 在判别得分空间中使用最近均值规则, 或结合先验概率与误判代价使用前述 ECM/Bayes 规则。

6 分类函数评价 (Classification Evaluation)

前面的问题是如何构造分类规则; 接下来的问题是: 已经得到一个分类函数以后, 如何判断它“做得好不好”? 评价分类函数的目标主要有两个:

- 给出分类错误率的理论下界或可比较指标;
- 比较不同分类过程在同一数据结构下的表现。

定义 9.9 (总体误判概率与样本错误率)

若总体分布 $f_1(\mathbf{x}), f_2(\mathbf{x})$ 已知, 则可以从总体角度定义

$$TPM = p_1 P(2 | 1) + p_2 P(1 | 2),$$

这是一种 population-based 的总误判概率。实际数据分析中总体分布往往未知, 因而还需要用样本比例估计分类函数的错误率。



注 评价分类函数时应区分三类量:

1. **总误判概率**: 基于真实总体分布, 通常不可直接观测;
2. **实际错误率 (actual error rate, AER)**: 给定分类规则在新样本上的真实错误率;
3. **表观错误率 (apparent error rate, APER)**: 用训练样本本身回代得到的错误比例。

其中 APER 最容易计算, 但也最容易过于乐观。

6.1 表观错误率 (Apparent Error Rate, APER)

定义 9.10 (混淆矩阵与 APER)

设训练样本来自两个总体 π_1, π_2 。对已经拟合好的分类函数, 将训练样本重新分类, 记

$$n_{1C} = \#\{\pi_1 \text{ 中被正确判为 } \pi_1 \text{ 的样本}\},$$

$$n_{2C} = \#\{\pi_2 \text{ 中被正确判为 } \pi_2 \text{ 的样本}\},$$

并令

$$n_{1M} = n_1 - n_{1C}, \quad n_{2M} = n_2 - n_{2C}.$$

相应的混淆矩阵为

		Predicted membership		Total
		π_1	π_2	
Actual membership	π_1	n_{1C}	$n_{1M} = n_1 - n_{1C}$	n_1
	π_2	$n_{2M} = n_2 - n_{2C}$	n_{2C}	n_2

表观错误率定义为

$$APER = \frac{n_{1M} + n_{2M}}{n_1 + n_2}.$$



注 (APER 的局限) APER 的优点是直观、易计算; 缺点是通常低估 AER。原因是分类函数已经使用训练样本拟合过一次, 再用同一批样本评价, 相当于把数据用了两次。这种过拟合 (overfitting) 问题并不限于 LDA, 而是一般监督学习方法中的常见问题。

6.2 交叉验证 (Cross Validation)

定义 9.11 (留出法与交叉验证)

交叉验证的思想是避免在同一观测上同时完成训练和评价。将一部分样本暂时留出, 用剩余样本拟合分类规则, 再在留出的样本上计算错误率; 若循环留出不同样本, 就可以得到较少偏的分类误差估计。

**定义 9.12 (LOOCV 与 K-fold CV)**

1. **LOOCV** (leave-one-out cross validation, 留一交叉验证): 对每个样本点 $\mathbf{x}_i$, 用去掉第 i 个样本后的

数据拟合分类器 $\hat{g}^{(-i)}$ ，再预测 $\mathbf{x}_i$ 的类别。其错误率估计为

$$\widehat{Err}_{\text{LOOCV}} = \frac{1}{n} \sum_{i=1}^n I\{\hat{g}^{(-i)}(\mathbf{x}_i) \neq g_i\}.$$

2. **K-fold cross validation**: 将样本分成 K 份。对每一份 V_k ，用其余 $K-1$ 份训练分类器 $\hat{g}^{(-k)}$ ，在 V_k 上评价：

$$\widehat{Err}_{K\text{-fold}} = \frac{1}{n} \sum_{k=1}^K \sum_{i \in V_k} I\{\hat{g}^{(-k)}(\mathbf{x}_i) \neq g_i\}.$$



注 交叉验证比 APER 计算量更大，但更接近“在新样本上分类”的目标；它不依赖已知总体分布，因此比基于 $f_i(\mathbf{x})$ 的总体误判概率更一般。

6.3 其他分类评价指标

对二分类问题，常把正类记为 Positive，负类记为 Negative。混淆矩阵写为

	Predicted Positive	Predicted Negative
Actual Positive	TP	FN
Actual Negative	FP	TN

其中 TP, TN, FP, FN 分别表示 true positive, true negative, false positive 和 false negative。

定义 9.13 (常用二分类指标)

$$\begin{aligned} \text{Accuracy} &= \frac{TP + TN}{TP + TN + FP + FN}, \\ \text{Precision} &= \frac{TP}{TP + FP}, \quad \text{Recall} = \text{Sensitivity} = \frac{TP}{TP + FN}, \\ \text{Specificity} &= \frac{TN}{TN + FP}. \end{aligned}$$



注 (ROC, AUC 与 Precision-Recall 曲线) 当分类器输出连续得分或后验概率时，改变分类阈值会得到一系列

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN}.$$

以 FPR 为横轴、TPR 为纵轴得到 ROC 曲线；曲线下面积称为 AUC。Precision-Recall 曲线则以 recall 为横轴、precision 为纵轴。这些曲线评价规则主要为二分类设计；多分类问题通常需要 one-vs-rest 或其他扩展。

7 尺度变换与其他分类方法

若各变量量纲或尺度差异很大，一个自然问题是是否需要标准化。对普通 Fisher LDA，只要使用同一批变量并对训练样本和新样本施加同一个非奇异线性变换，分类结果具有不变性。

命题 9.9 (Fisher LDA 对非奇异线性变换的不变性)

设

$$\mathbf{z} = C\mathbf{x},$$

其中 C 是非奇异矩阵。记变换后的均值差和 pooled covariance 为

$$\mathbf{d}_z = C\mathbf{d}, \quad S_{z, \text{pooled}} = CS_{\text{pooled}}C'.$$

则 Fisher 最大分离比满足

$$\mathbf{d}_z' S_{z, \text{pooled}}^{-1} \mathbf{d}_z = \mathbf{d}' S_{\text{pooled}}^{-1} \mathbf{d},$$

且线性判别得分只差一个等价重参数化，因此由 LDA 得到的分类区域不变。



证明 由 C 非奇异，

$$S_{z,\text{pooled}}^{-1} = (C')^{-1} S_{\text{pooled}}^{-1} C^{-1}.$$

因而

$$\mathbf{d}'_z S_{z,\text{pooled}}^{-1} \mathbf{d}_z = \mathbf{d}' C' (C')^{-1} S_{\text{pooled}}^{-1} C^{-1} C \mathbf{d} = \mathbf{d}' S_{\text{pooled}}^{-1} \mathbf{d}.$$

Fisher 判别方向在 z -坐标下为

$$S_{z,\text{pooled}}^{-1} \mathbf{d}_z = (C')^{-1} S_{\text{pooled}}^{-1} \mathbf{d},$$

与原坐标中的判别函数表示同一超平面。

注 标准化可以看作一种非奇异对角线性变换。对完整的非正则 LDA，若所有步骤都在变换后的坐标中一致完成，分类结论不应因单位改变而改变。但一旦引入变量选择、正则化、核方法或其他非线性步骤，尺度可能重新影响模型表现，此时标准化通常需要作为建模决策单独考虑。

7.1 其他分类方法概览

定义 9.14 (正则化 LDA)

当 S_{pooled} 不满秩或病态时，可用

$$S_\lambda = S_{\text{pooled}} + \lambda I_p, \quad \lambda > 0,$$

替代 S_{pooled} 。在两总体等先验、等误判代价情形下，规则变为

$$R_1: (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_\lambda^{-1} \mathbf{x} \geq \frac{1}{2} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)' S_\lambda^{-1} (\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2).$$



注 (常见扩展) 除 LDA/QDA 外，分类问题中还常见如下方法：

- **Kernel Fisher discriminant**: 当线性判别边界不合适时，通过核技巧在高维特征空间中构造 Fisher 判别方向；
- **Mixture discriminant analysis**: 用混合分布刻画每一类内部的多峰结构；
- **Logistic/probit regression**: 不要求类别条件正态性，

$$\log \frac{p}{1-p} = X\beta, \quad \Phi^{-1}(p) = X\beta;$$

- **SVM, KNN 与决策树**: 分别从最大间隔、邻近样本投票和递归划分的角度构造分类规则。

注 (决策树的划分准则) 决策树分类通常包括 grow a tree 与 prune the tree 两个阶段。常用分裂准则包括：

- **entropy**: 最小化熵等价于在节点上追求更大的分类纯度；
- **Gini index**: 最小化 Gini 指数，可解释为降低期望误分类率。

第五部分

Clustering

第 10 节 Cluster Analysis

1 聚类分析导论 (Introduction to Cluster Analysis)

内容提要

- ❑ 聚类分析 (cluster analysis) 属于无监督学习：样本没有预先给定的类别标签。
- ❑ 核心目标：同一簇内对象尽量相似，不同簇之间对象尽量不相似。
- ❑ 主要方法包括层次聚类 (hierarchical clustering)、划分聚类 (partitioning clustering) 与基于模型的聚类 (model-based clustering)。
- ❑ 聚类既可作为理解数据结构的独立工具，也可作为后续建模前的数据压缩或预处理步骤。

1.1 什么是聚类分析

定义 10.1 (簇 (Cluster))

一个簇是若干数据对象组成的集合。理想情况下，同一簇内对象彼此相似或相关，不同簇之间对象则明显不相似或不相关。

定义 10.2 (聚类分析 (Cluster analysis))

给定观测对象

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p,$$

聚类分析是在没有预先给定类别标签的情况下，根据数据中观测到的特征，将 n 个对象划分为若干组

$$\mathcal{C}_1, \dots, \mathcal{C}_K, \quad \bigcup_{k=1}^K \mathcal{C}_k = \{1, \dots, n\}, \quad \mathcal{C}_k \cap \mathcal{C}_\ell = \emptyset \ (k \neq \ell),$$

使得组内相似性较高、组间相似性较低。

注 (无监督学习) 与判别分析不同，聚类分析没有训练样本标签。判别分析是 learning by examples，聚类分析更接近 learning by observations。因此聚类结果通常不是“真类别”的直接估计，而是对数据结构的一种探索性总结。

1.2 聚类分析的用途

聚类分析常见用途包括：

- **Understanding:** 作为独立工具理解数据分布，例如将相似文档、基因或蛋白质分组；
- **Summarization:** 作为预处理步骤，压缩大规模数据集，提取代表性结构；
- **Segmentation:** 在市场、图像、文本或社区网络中发现自然分群。

注 聚类分析的输出依赖于“相似”的定义。不同距离、不同标准化方式、不同聚类算法，可能在同一数据集上给出不同但各自有解释力的分组。

1.3 主要聚类方法

定义 10.3 (三类聚类思路)

常见聚类方法可以粗略分为三类：

1. 层次方法 (hierarchical approach)：按某种准则构造数据对象的层次分解，典型方法包括 DIANA, AGNES, BIRCH, CHAMELEON 等。
2. 划分方法 (partitioning approach)：直接构造若干候选划分，并用目标函数或评价准则选择较优划分，典型方法包括 K -means, K -medoids, CLARANS 等。
3. 基于模型的方法 (model-based approach)：假定每个簇由某个概率模型生成，再估计最能解释数据的模型参数与簇归属，典型方法包括 EM, SOM, COBWEB 等。



注 本节先讨论层次聚类。划分聚类与模型聚类的核心问题分别是目标函数优化和概率模型估计，后续可作为 K -means 与混合模型的专题展开。

2 层次聚类 (Hierarchical Clustering)

2.1 树状结构与 dendrogram

定义 10.4 (层次聚类)

层次聚类产生一组嵌套的簇，并把它们组织成树状结构。该结构可以用树状图 (dendrogram) 表示：树状图记录样本簇逐步合并或逐步分裂的顺序，以及每一步对应的距离高度。



注 (如何从树状图得到聚类) 给定树状图后，若需要得到 K 个簇，可以在某个高度水平切割树；切割线以下的连通分支即为最终簇。高度越低，分组越细；高度越高，分组越粗。

2.2 凝聚式与分裂式层次聚类

定义 10.5 (凝聚式聚类与分裂式聚类)

层次聚类有两种主要方向：

1. 凝聚式 (agglomerative)：初始时每个样本点都是一个簇。每一步合并最接近的两个簇，直到只剩一个簇，或者剩下预先指定的 K 个簇。
2. 分裂式 (divisive)：初始时所有样本属于同一个大簇。每一步分裂一个簇，直到每个样本各自成簇，或者得到预先指定的 K 个簇。



注 实际应用中更常见的是凝聚式层次聚类，因为它只需要反复维护簇间距离；分裂式方法通常需要在每一步决定如何把一个簇拆开，计算和建模成本更高。

2.3 凝聚式聚类的基本设定

为了度量“接近” (closeness)，凝聚式聚类通常从一个距离矩阵或相异度矩阵开始：

$$D = (d_{ij})_{n \times n}, \quad d_{ij} = d(\mathbf{x}_i, \mathbf{x}_j), \quad d_{ii} = 0, \quad d_{ij} = d_{ji}.$$

执行算法时需要指定两类距离：

- 点与点之间的距离：Euclidean, correlation, Jaccard, Hamming, cosine distance 等；
- 簇与簇之间的距离：single linkage, complete linkage, average linkage, centroid linkage 等。

定义 10.6 (凝聚式层次聚类算法)

给定点间距离 $d(\mathbf{x}_i, \mathbf{x}_j)$ 与簇间距离 $D(A, B)$, 凝聚式层次聚类可写为:

1. 初始化:

$$\mathcal{C}^{(0)} = \{\{1\}, \{2\}, \dots, \{n\}\}.$$

2. 在第 t 步, 从当前簇集合中选择

$$(A_t, B_t) = \arg \min_{A \neq B} D(A, B).$$

3. 合并 A_t 与 B_t , 得到新簇 $A_t \cup B_t$, 并更新簇间距离。

4. 重复上述过程, 直到只剩一个簇或达到指定簇数 K 。



例 10.1 六个二维点的 centroid linkage 设有六个二维观测点:

i	1	2	3	4	5	6
$\mathbf{x}_i$	(0, 0)	(1, 2)	(2, 1)	(4, 1)	(5, 3)	(5.2, 0)

点间距离取 Euclidean distance, 簇间距离取 centroid distance:

$$D_{\text{cen}}(A, B) = \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|.$$

解 初始时每个点都是一个簇。按 centroid distance 的最近合并顺序为:

step	merge	new centroid
1	$\{2\}, \{3\}$	(1.50, 1.50)
2	$\{4\}, \{6\}$	(4.60, 0.50)
3	$\{1\}, \{2, 3\}$	(1.00, 1.00)
4	$\{5\}, \{4, 6\}$	(4.73, 1.33)
5	$\{1, 2, 3\}, \{4, 5, 6\}$	(2.87, 1.17)

因此若在最后一次合并前切割树状图, 可得到两个簇

$$\{1, 2, 3\} \quad \text{and} \quad \{4, 5, 6\}.$$

树状图中的高度就是每次合并时的簇间距离; 在某个高度水平切割, 即可得到对应的簇数。

2.4 距离与相异度

2.4.1 点与点之间的距离

定义 10.7 (欧氏距离)

对连续型变量, 最常用的距离是 Euclidean distance:

$$d_E(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2 = \sqrt{\sum_{\ell=1}^p (x_{i\ell} - x_{j\ell})^2}.$$

**定义 10.8 (余弦相似度与余弦距离)**

对文本、词频向量或高维稀疏数据, 常用余弦相似度 (cosine similarity):

$$\text{cosine}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}'\mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \in [-1, 1].$$

相应的余弦距离可取为

$$d_{\text{cos}}(\mathbf{a}, \mathbf{b}) = 1 - \text{cosine}(\mathbf{a}, \mathbf{b}) \in [0, 2].$$



注 (距离选择) 距离不是纯技术细节, 而是聚类问题中的建模假设:

- Euclidean distance 强调原始坐标中的绝对差异；
- correlation distance 更关注变量变化形状是否一致；
- Jaccard distance 适合二元集合或稀疏集合数据；
- Hamming distance 常用于等长离散编码或类别序列；
- cosine distance 常用于文本和高维稀疏向量。

2.4.2 簇与簇之间的距离

设 A, B 是两个簇，点间距离为 $d(i, j) = d(\mathbf{x}_i, \mathbf{x}_j)$ 。簇间距离 $D(A, B)$ 可由 A 与 B 中所有点对的距离定义。

定义 10.9 (常见 linkage)

常见簇间距离包括：

1. Single linkage / MIN

$$D_{\min}(A, B) = \min_{i \in A, j \in B} d(i, j).$$

2. Complete linkage / MAX

$$D_{\max}(A, B) = \max_{i \in A, j \in B} d(i, j).$$

3. Group average linkage

$$D_{\text{avg}}(A, B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} d(i, j).$$

4. Centroid linkage

$$D_{\text{cen}}(A, B) = \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|, \quad \bar{\mathbf{x}}_A = \frac{1}{|A|} \sum_{i \in A} \mathbf{x}_i.$$

5. Ward's linkage

$$D_{\text{Ward}}(A, B) = SSE(A \cup B) - SSE(A) - SSE(B),$$

其中

$$SSE(A) = \sum_{i \in A} \|\mathbf{x}_i - \bar{\mathbf{x}}_A\|^2.$$



注 (linkage 的影响) 不同 linkage 对“簇与簇接近”的理解不同，因此会给出不同树状图：

- **single linkage** 只看两个簇中最近的点对，能较自然地处理不规则形状，但对噪声和离群点敏感，容易产生 chaining effect；
- **complete linkage** 只看最远点对，比 single linkage 更不易被单个近邻点牵引，常得到较紧凑、近似球形的簇，但可能打散较大的非球形簇；
- **average linkage** 取所有跨簇点对距离的平均，在 single 与 complete 之间折中；
- **centroid linkage** 用簇中心代表整个簇，计算直观但可能丢失簇内部形状信息；
- **Ward's linkage** 最小化合并造成的 within-cluster SSE 增量，可看作 K -means 的层次版本，常用于初始化 K -means。

2.4.3 Ward linkage 与组内平方和

定义 10.10 (组内平方误差和)

对一个簇 C ，记其中心为

$$\bar{\mathbf{x}}_C = \frac{1}{|C|} \sum_{i \in C} \mathbf{x}_i.$$

组内平方误差和 (within-cluster sum of squared error, SSE) 定义为

$$SSE(C) = \sum_{i \in C} \|\mathbf{x}_i - \bar{\mathbf{x}}_C\|^2.$$

对一个含 K 个簇的划分 $\mathcal{C}_1, \dots, \mathcal{C}_K$ ，总 SSE 为

$$SSE = \sum_{k=1}^K \sum_{i \in \mathcal{C}_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_{\mathcal{C}_k}\|^2.$$



命题 10.1 (Ward 合并准则)

Ward's linkage 在每一步选择使总 SSE 增量最小的两个簇：

$$(A_t, B_t) = \arg \min_{A \neq B} \{SSE(A \cup B) - SSE(A) - SSE(B)\}.$$

等价地，若距离取平方欧氏距离，则该增量可写为

$$\Delta(A, B) = \frac{|A| |B|}{|A| + |B|} \|\bar{\mathbf{x}}_A - \bar{\mathbf{x}}_B\|^2.$$



注 Ward 方法偏好合并后仍然紧凑的簇，因此通常产生较均衡、近似球形的聚类。它与 average linkage 在使用 squared distance 时有相似直觉，但 Ward 的准则明确来自 SSE 增量，因而更接近方差分析或 K -means 的思想。

2.5 凝聚式层次聚类的优缺点

2.5.1 优点

注 (凝聚式层次聚类的 strengths) 凝聚式层次聚类的主要优点包括：

- 不必事先固定簇数。树状图构造完成后，可以在不同高度切割得到任意指定的 K 个簇；
- 树状图直观展示对象之间的嵌套关系，适合解释样本的多层次结构；
- 在生物分类、文本分组、样本排序等场景中，层次结构本身往往比单一划分更有信息。

2.5.2 局限

注 (凝聚式层次聚类的 limitations) 凝聚式层次聚类也有明显限制：

- **计算问题**：需要维护 proximity matrix，空间复杂度通常为 $O(n^2)$ 。许多实现中每一步还要搜索或更新距离矩阵，时间复杂度可达 $O(n^3)$ 。
- **贪心不可回退**：一旦某一步合并了两个簇，该决定后续不能撤销；若早期合并错误，后续树状结构会继承该错误。
- **缺少全局目标函数**：除 Ward 等特殊准则外，普通 linkage 方法通常不是在直接最小化一个全局目标函数。
- **统计敏感性**：不同 linkage 可能分别受到噪声、离群点、簇大小差异、非凸形状或 large-cluster breaking 的影响。

3 划分聚类 (Partitioning Clustering)

3.1 基本思想

定义 10.11 (划分聚类)

划分聚类直接把数据对象分成互不重叠的若干子集:

$$\mathcal{C}_1, \dots, \mathcal{C}_K, \quad \mathcal{C}_k \cap \mathcal{C}_\ell = \emptyset \ (k \neq \ell), \quad \bigcup_{k=1}^K \mathcal{C}_k = \{1, \dots, n\}.$$

每个样本点恰好属于一个簇。与层次聚类不同, 划分聚类通常直接给出一个固定 K 下的最终划分, 而不是一棵完整树状图。



注 划分聚类的代表方法包括 K -means, K -medoids 和 CLARANS。其中 K -means 最常用; 它用簇中心刻画每个簇, 并通过最小化组内平方误差和来确定划分。

3.2 K -means 聚类方法

定义 10.12 (K -means 目标函数)

给定簇数 K , K -means 希望找到划分

$$\mathcal{C}_1, \dots, \mathcal{C}_K$$

以及中心

$$\mathbf{m}_1, \dots, \mathbf{m}_K$$

使组内平方误差和最小:

$$W_K = \sum_{k=1}^K \sum_{i \in \mathcal{C}_k} \|\mathbf{x}_i - \mathbf{m}_k\|^2.$$

当划分固定时, 使 W_K 最小的中心为该簇样本均值:

$$\mathbf{m}_k = \bar{\mathbf{x}}_{\mathcal{C}_k} = \frac{1}{|\mathcal{C}_k|} \sum_{i \in \mathcal{C}_k} \mathbf{x}_i.$$



定义 10.13 (K -means 算法)

K -means 的基本迭代过程为:

1. 选择 K 个初始中心

$$\mathbf{m}_1^{(0)}, \dots, \mathbf{m}_K^{(0)}.$$

2. 在第 t 次迭代中, 将每个样本分配到最近中心:

$$c_i^{(t)} = \arg \min_{1 \leq k \leq K} \|\mathbf{x}_i - \mathbf{m}_k^{(t)}\|^2.$$

3. 对每个簇更新中心:

$$\mathbf{m}_k^{(t+1)} = \frac{1}{|\mathcal{C}_k^{(t)}|} \sum_{i \in \mathcal{C}_k^{(t)}} \mathbf{x}_i, \quad \mathcal{C}_k^{(t)} = \{i : c_i^{(t)} = k\}.$$

4. 重复分配与更新, 直到簇归属或目标函数几乎不再改变。



注 (K -means 的设定) 使用 K -means 前需要指定:

- 簇数 K ;
- 点与点之间的距离, 通常是 Euclidean distance;

- 初始中心的选择。

初始中心可以随机选取，也可以先抽样并用层次聚类或 leader algorithm 产生较分散的初始点。

注 (初始值的影响) K -means 是局部优化算法，初始中心不同可能导致不同局部最优。因此实际应用中常用多次随机初始化，选择 W_K 最小或外部评价指标最好的结果。若初始中心落在不合适的位置，算法可能把本应同属一簇的样本拆开，或把不同簇错误合并。

3.3 K -means 的优化观点

也可以把 K -means 写成关于簇标签和簇中心的联合优化问题。设数据为

$$\mathbf{x}_1, \dots, \mathbf{x}_n,$$

簇中心为

$$\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K,$$

并记 $c_i \in \{1, \dots, K\}$ 为样本 i 的簇标签。目标函数为总 SSE:

$$J(\mathbf{c}, \boldsymbol{\mu}) = \sum_{i=1}^n \|\mathbf{x}_i - \boldsymbol{\mu}_{c_i}\|^2.$$

K -means 的目标是

$$\min_{\mathbf{c}, \boldsymbol{\mu}} J(\mathbf{c}, \boldsymbol{\mu}).$$

命题 10.2 (交替最小化解释)

K -means 迭代可以看作对 $J(\mathbf{c}, \boldsymbol{\mu})$ 的交替最小化:

1. 固定中心 $\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K$ ，最优标签为

$$c_i = \arg \min_{1 \leq j \leq K} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2.$$

2. 固定簇标签 $\mathbf{c}$ ，第 j 类的最优中心为

$$\boldsymbol{\mu}_j = \arg \min_{\boldsymbol{\mu}} \sum_{i: c_i = j} \|\mathbf{x}_i - \boldsymbol{\mu}\|^2 = \frac{1}{|\{i : c_i = j\}|} \sum_{i: c_i = j} \mathbf{x}_i.$$

注 (收敛性) 每一步分配或更新都会使 J 不增，因此 K -means 会在有限个划分中收敛到一个局部最优。但由于目标函数非凸，全局最优没有保证。

3.4 如何选择簇数 K

3.4.1 基于 SSE 的 elbow method

当 K 增大时，组内平方误差和

$$W_K = \sum_{k=1}^K \sum_{i \in C_k} \|\mathbf{x}_i - \mathbf{m}_k\|^2$$

必然不增。若 K 太小，许多样本到中心的距离较长；若 K 太大，继续增加簇数带来的平均距离改善很小。

定义 10.14 (Elbow method)

对一系列候选 K 运行聚类算法并记录 W_K 。若曲线 $K \mapsto W_K$ 在这一点之前下降很快、之后下降变慢，则把该转折点作为簇数选择：

$$K_{\text{elbow}} = \text{turning point of the } W_K \text{ curve.}$$

注 Elbow method 的优点是直观；缺点是转折点有时不明显，并且只反映组内紧凑性，不直接衡量簇间分离程度。

3.4.2 经验法则与交叉验证

注 (经验法则) 一个粗略经验是

$$K \approx \sqrt{\frac{n}{2}},$$

其中 n 是样本量。例如 $n = 200$ 时得到 $K \approx 10$ 。该规则只能作为初始参考，不能替代数据驱动的评价。

定义 10.15 (聚类中的交叉验证思想)

可将数据分成 m 份。对每个候选 K ：

1. 用其中 $m - 1$ 份训练聚类模型；
2. 用剩余一份评价聚类质量；
3. 对 m 次留出结果取平均；
4. 比较不同 K 的整体质量指标，选择最适合数据的簇数。

这里的质量指标可以是预测型损失、稳定性指标，或由具体应用定义的外部评价指标。



3.4.3 Silhouette coefficient

定义 10.16 (Silhouette coefficient)

给定一个聚类结果，记样本 i 所属簇为 $C(i)$ 。定义

$$a(i) = \frac{1}{|C(i)| - 1} \sum_{\substack{j \in C(i) \\ j \neq i}} d(i, j)$$

为样本 i 到本簇内其他样本的平均相异度。对任一其他簇 $C \neq C(i)$ ，计算样本 i 到该簇的平均相异度，并取最小值：

$$b(i) = \min_{C \neq C(i)} \frac{1}{|C|} \sum_{j \in C} d(i, j).$$

样本 i 的 silhouette coefficient 定义为

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad -1 \leq s(i) \leq 1.$$

平均 silhouette 为

$$\bar{s}(K) = \frac{1}{n} \sum_{i=1}^n s(i).$$



注 若 $s(i)$ 接近 1，表示样本 i 更接近本簇而远离其他簇；若接近 0，表示它处在两个簇的边界附近；若为负，则说明它可能被分错簇。实际选择 K 时，可比较不同 K 的平均 silhouette，并选择 $\bar{s}(K)$ 较大的方案。

3.4.4 Gap statistic

定义 10.17 (Gap statistic)

Gap statistic 比较真实数据的组内离散度与一个无聚类结构参考分布下的组内离散度。记 W_K 为 K 簇时的组内离散度，令

$$\text{Gap}(K) = \mathbb{E}^*\{\log W_K^*\} - \log W_K,$$

其中 $*$ 表示从参考分布中模拟得到的数据。若某个 K 使得真实数据的 $\log W_K$ 相对参考分布下降最明显，则说明该 K 具有较强聚类结构。



注 Gap statistic 由 Tibshirani, Walther and Hastie (2001) 提出。R 中可通过 `cluster::clusGap` 计算。它比 elbow method 更正式，但需要选择参考分布并进行模拟。

3.5 K -means 的优缺点与扩展

3.5.1 优点与局限

注 (K -means 的 strengths) K -means 的主要优点是计算效率高。若样本量为 n ，簇数为 K ，迭代次数为 t ，每次迭代需要把每个样本分配到最近中心，并重新计算中心，典型计算复杂度为

$$O(tKn).$$

在许多应用中 $K, t \ll n$ ，因此 K -means 比层次聚类更适合较大规模数据。

注 (K -means 的 limitations) K -means 的限制主要来自均值中心和平方欧氏距离：

- 对离群点敏感，因为均值会被极端观测拉动；
- 偏好大小相近、密度相近、近似凸且近似球形的簇；
- 当簇大小不同、密度不同或形状非凸时，可能产生明显错误划分；
- 需要事先给定 K ，且结果依赖初始中心。

3.5.2 K -modes 与 K -medoids

定义 10.18 (K -modes)

K -modes 将 K -means 中的均值中心替换为众数 (mode)。它适合类别型变量：每个簇的代表值由各变量最常见的类别组成，而不是由数值均值给出。

定义 10.19 (K -medoids)

K -medoids 用 medoid 代替 centroid。给定一个簇 C ，其 medoid 是簇内某个真实观测点：

$$\mathbf{x}_{i^*}, \quad i^* = \arg \min_{i \in C} \sum_{j \in C} d(i, j).$$

也就是说，medoid 是到本簇其他成员总距离最小的样本点。

注 与 centroid 不同，medoid 必须是实际观测，因此对离群点更稳健，也适合只定义了相异度而不适合求均值的数据。常见实现包括：

- PAM (Partitioning Around Medoids)：直接围绕 medoids 优化；
- CLARA：在抽样子集上运行 PAM，以处理大数据；
- CLARANS：使用随机化重抽样或随机搜索改进 medoid 选择。

在 R 中，`cluster::pam` 实现了 PAM，通常使用普通距离而不是平方距离。

4 基于模型的聚类 (Model-based Clustering)

4.1 Mixture modelling

层次聚类和 K -means 等方法大多是启发式算法，通常不直接给出一个形式化概率模型。基于模型的聚类把每个簇看作一个概率分布中的一个 component，因此可以在聚类同时进行参数估计和概率推断。

定义 10.20 (Mixture model)

设样本 $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$ 来自 K 个潜在成分的混合分布。每个成分有密度函数 $f_l(\mathbf{x}; \theta_l)$ ，并有混合权重

$$\pi_l \geq 0, \quad \sum_{l=1}^K \pi_l = 1.$$

混合模型的边际密度为

$$f(\mathbf{x}; \Theta) = \sum_{l=1}^K \pi_l f_l(\mathbf{x}; \theta_l), \quad \Theta = (\pi_1, \dots, \pi_K, \theta_1, \dots, \theta_K).$$

在聚类语境下，第 l 个 component 对应第 l 个簇。



注 (Soft clustering) 与 K -means 的 hard assignment 不同，混合模型自然给出 soft clustering：一个样本不必被完全分配到某一簇，而是用后验概率

$$P(Y_i = l \mid \mathbf{X}_i = \mathbf{x}_i)$$

描述它属于第 l 簇的程度。

4.2 Gaussian mixture model

虽然原则上每个 component 可以采用任意概率模型，聚类中最常见的是多元正态混合模型。

定义 10.21 (Gaussian mixture model, GMM)

设 $Y_i \in \{1, \dots, K\}$ 表示样本 i 的潜在簇标签，并假设

$$P(Y_i = l) = \pi_l, \quad \mathbf{X}_i \mid Y_i = l \sim N_p(\boldsymbol{\mu}_l, \Sigma_l), \quad l = 1, \dots, K.$$

则 $\mathbf{X}_i$ 的边际密度为

$$f(\mathbf{x}_i; \pi, \boldsymbol{\mu}, \Sigma) = \sum_{l=1}^K \pi_l \phi_p(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l),$$

其中

$$\phi_p(\mathbf{x}; \boldsymbol{\mu}, \Sigma) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}.$$



注 (与判别分析的关系) 若簇标签 Y_i 已知，则这与 LDA/QDA 中的生成式模型相同：先按先验概率 π_l 产生类别，再从对应的正态分布中产生 $\mathbf{X}_i$ 。聚类问题的困难在于标签 Y_i 不可观测，只有数据矩阵

$$\mathbf{X}_{n \times p}$$

可观测。因此目标是估计

$$\pi_l, \quad \boldsymbol{\mu}_l, \quad \Sigma_l, \quad l = 1, \dots, K.$$

4.3 Observed likelihood

由于标签 Y_i 不可观测，观测数据似然为

$$L(\Theta) = \prod_{i=1}^n \left\{ \sum_{l=1}^K \pi_l \phi_p(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l) \right\}.$$

对应对数似然为

$$\ell(\Theta) = \sum_{i=1}^n \log \left\{ \sum_{l=1}^K \pi_l \phi_p(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l) \right\}.$$

注 直接最大化 $\ell(\Theta)$ 比较困难，核心原因是 $\log$ 内部含有对潜在类别的求和。若标签 Y_i 已知，问题会退化为分组后的正态参数估计，均值和协方差都可以直接由每一组样本给出。

4.4 Responsibilities

定义 10.22 (Responsibility matrix)

记

$$\gamma_{il} = P(Y_i = l \mid \mathbf{X}_i = \mathbf{x}_i), \quad i = 1, \dots, n, \quad l = 1, \dots, K.$$

矩阵

$$\Gamma_{n \times K} = (\gamma_{il})$$

称为 responsibility matrix。每一行是样本 i 属于各个簇的后验概率，因此

$$0 \leq \gamma_{il} \leq 1, \quad \sum_{l=1}^K \gamma_{il} = 1.$$



命题 10.3 (Bayes 更新)

在当前参数 Θ 下，样本 i 属于第 l 个 component 的后验概率为

$$\gamma_{il} = \frac{\pi_l \phi_p(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l)}{\sum_{j=1}^K \pi_j \phi_p(\mathbf{x}_i; \boldsymbol{\mu}_j, \Sigma_j)}.$$



例 10.2 两簇一维情形 当 $K = 2, p = 1$ 时，设两个簇分别为 A, B ，则

$$P(Y_i = 1 \mid X_i = x_i) = \frac{f_1(x_i)\pi_1}{f_1(x_i)\pi_1 + f_2(x_i)\pi_2},$$

其中

$$f_1(x_i) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left\{-\frac{(x_i - \mu_1)^2}{2\sigma_1^2}\right\}.$$

因此硬标签 $I_{\{Y_i=1\}}$ 可以被软权重 γ_{i1} 代替。

4.5 EM algorithm for GMM

EM algorithm 在两个对象之间交替更新：

- 样本层面的 soft labels: $\Gamma = (\gamma_{il})$;
- 簇层面的总体参数: $\pi_l, \boldsymbol{\mu}_l, \Sigma_l$ 。

定义 10.23 (EM algorithm for Gaussian mixture)

初始化

$$\hat{\pi}^{(0)}, \quad \hat{\boldsymbol{\mu}}^{(0)}, \quad \hat{\Sigma}^{(0)}.$$

对 $t = 0, 1, \dots$ 重复如下两步。

1. **E-step.** 用当前参数估计 responsibility:

$$\hat{\gamma}_{il}^{(t+1)} = \frac{\hat{\pi}_l^{(t)} \phi_p(\mathbf{x}_i; \hat{\boldsymbol{\mu}}_l^{(t)}, \hat{\Sigma}_l^{(t)})}{\sum_{j=1}^K \hat{\pi}_j^{(t)} \phi_p(\mathbf{x}_i; \hat{\boldsymbol{\mu}}_j^{(t)}, \hat{\Sigma}_j^{(t)})}.$$

2. **M-step.** 令

$$\hat{n}_l^{(t+1)} = \sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}.$$

更新混合权重、均值和协方差：

$$\hat{\pi}_l^{(t+1)} = \frac{\hat{n}_l^{(t+1)}}{n},$$

$$\hat{\boldsymbol{\mu}}_l^{(t+1)} = \frac{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)} \mathbf{x}_i}{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}},$$

$$\hat{\Sigma}_l^{(t+1)} = \frac{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l^{(t+1)}) (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l^{(t+1)})'}{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}}, \quad l = 1, \dots, K.$$



注 M-step 中的均值和协方差是以 $\hat{\gamma}_{il}$ 为权重的加权估计。若所有 γ_{il} 都是 0 或 1，这些公式就退化为已知分类标签时的组内样本比例、样本均值和样本协方差估计。EM 每次迭代不会降低观测对数似然，但同 K -means 一样，通常只能保证收敛到局部最优。

4.6 Hard assignment 与 soft assignment 的比较

命题 10.4 (已知标签与软标签估计的对应)

若类别标签 Y_i 已观测，则第 l 组的 QDA/LDA 型参数估计为

$$\hat{\pi}_l = \frac{\sum_{i=1}^n I(Y_i = l)}{n},$$

$$\hat{\boldsymbol{\mu}}_l = \frac{\sum_{i=1}^n I(Y_i = l) \mathbf{x}_i}{\sum_{i=1}^n I(Y_i = l)}, \quad \hat{\Sigma}_l = \frac{\sum_{i=1}^n I(Y_i = l) (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l) (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l)'}{\sum_{i=1}^n I(Y_i = l)}.$$

在 model-based clustering 中，标签 Y_i 未观测，EM 用 soft assignment $\hat{\gamma}_{il}^{(t+1)}$ 替代 hard indicator $I(Y_i = l)$ ，从而得到

$$\hat{\pi}_l^{(t+1)} = \frac{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}}{n},$$

$$\hat{\boldsymbol{\mu}}_l^{(t+1)} = \frac{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)} \mathbf{x}_i}{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}}, \quad \hat{\Sigma}_l^{(t+1)} = \frac{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l^{(t+1)}) (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_l^{(t+1)})'}{\sum_{i=1}^n \hat{\gamma}_{il}^{(t+1)}}.$$



注 (EM 的统计解释) $\Gamma = (\gamma_{il})$ 不是模型参数，而是对未观测随机标签 Y_i 的估计。若 Y_i 已观测，则 Γ 的每一行只有一个元素为 1，其余元素为 0。因此 EM 可以理解为：用当前模型猜测未观测标签，再像有标签情形一样更新 $\pi_l, \boldsymbol{\mu}_l, \Sigma_l$ 。

4.7 EM algorithm 的一般形式

定义 10.24 (Complete-data log-likelihood)

记参数

$$\theta = (\pi, \boldsymbol{\mu}, \Sigma), \quad \delta_{il} = I(Y_i = l).$$

观测数据对数似然为

$$\ell(\theta) = \sum_{i=1}^n \log P(\mathbf{X}_i = \mathbf{x}_i \mid \pi, \boldsymbol{\mu}, \Sigma) = \sum_{i=1}^n \log \left\{ \sum_{l=1}^K f_l(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l) P(Y_i = l; \pi) \right\}.$$

若把未观测标签也看作完整数据, 则 complete-data log-likelihood 为

$$\begin{aligned}\ell(\delta, \theta) &= \ell(X, Y; \theta) \\ &= \sum_{i=1}^n \log \left\{ \prod_{l=1}^K (\pi_l f_l(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l))^{\delta_{il}} \right\} \\ &= \sum_{i=1}^n \sum_{l=1}^K \delta_{il} [\log \pi_l + \log f_l(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l)].\end{aligned}$$



命题 10.5 (EM 的两步)

设第 t 次迭代的参数为

$$\theta^{(t)} = (\pi^{(t)}, \boldsymbol{\mu}^{(t)}, \Sigma^{(t)}).$$

EM algorithm 重复如下两步:

1. **Expectation step.** 计算

$$\hat{\gamma}_{il}^{(t+1)} = \mathbb{E}(\delta_{il} | \theta^{(t)}, X), \quad i = 1, \dots, n, \quad l = 1, \dots, K.$$

2. **Maximization step.** 最大化条件期望的完整数据对数似然

$$\theta^{(t+1)} = \arg \max_{\theta} B(\theta; \theta^{(t)}),$$

其中

$$B(\theta; \theta^{(t)}) = \mathbb{E}_{\delta | \theta^{(t)}, X} \ell(\delta, \theta) = \sum_{i=1}^n \sum_{l=1}^K \hat{\gamma}_{il}^{(t+1)} [\log \pi_l + \log f_l(\mathbf{x}_i; \boldsymbol{\mu}_l, \Sigma_l)].$$



注 (EM algorithm) EM 中 E 表示 expectation, M 表示 maximization. 它是 majorization-minimization algorithm 的一个重要特例, 特别适合处理 “如果某些隐藏变量可观测, 估计就会很容易” 的问题。由 Jensen inequality 可说明其迭代具有单调性; 但与前述聚类算法一样, EM 通常只保证收敛到局部最优。

4.8 模型选择

定义 10.25 (AIC 与 BIC)

对于同一数据集上的候选模型, 可以使用 AIC, likelihood ratio, BIC 等准则选择拟合较好的模型。若 L 为 likelihood function, m 为需要估计的自由参数个数, n 为观测个数, 则

$$\text{BIC} = -2 \log L + \log(n)m,$$

$$\text{AIC} = -2 \log L + 2m.$$

在上述符号约定下, 较小的 AIC/BIC 表示更好的模型。



注 (Mclust 的符号约定) R package mclust 常用 Bayesian Information Criterion (BIC) 选择 Gaussian mixture model。需要注意: 有些教材和 mclust 输出使用相反号的 BIC 约定, 此时数值越大表示模型越好。比较模型时应先确认软件采用的符号定义。

5 聚类评价与总结 (Evaluation and Summary)

5.1 聚类结果评价 (Evaluation)

注 (为什么要评价聚类结果) 聚类评价主要回答两个问题:

1. 如何比较不同 clustering algorithms、不同聚类结果，或两个具体簇之间的差异；
2. 如何选择合适的簇数 K 或其他算法调节参数。

定义 10.26 (聚类评价指标)

聚类结果常用 numerical measures 可分为三类：

1. **External index**：有监督评价。将聚类结果与先验标签、专家标注或其他外部知识比较。常见形式包括 entropy-based index, pair-wise index, correlation index 等。
2. **Internal index**：无监督评价。不依赖外部标签，只根据数据和聚类结果本身衡量 clustering goodness。常见指标包括 within-cluster SSE, pseudo F statistic, pseudo T^2 statistic 等。
3. **Relative index**：直接比较若干聚类结果，通常用于同一算法在不同参数设置下的结果选择。实际使用中常借用 external 或 internal index，例如 entropy 或 SSE。



注 简言之，external index 关心“是否接近外部参考答案”，internal index 关心“数据自身是否支持这个分组”，relative index 关心“候选聚类方案中哪个更好”。

5.2 总结与实践建议

注 (本讲总结) Cluster analysis 根据对象之间的 similarity 对样本进行分组，常用于理解数据结构和总结信息。本讲讨论了三类重要方法：

1. hierarchical approach，例如 agglomerative clustering；
2. partitioning approach，例如 K -means；
3. model-based clustering，例如 Gaussian mixture model 与 EM algorithm。

注 (实践流程) 进行聚类分析时，算法本身只是流程的一部分。实际使用中通常需要：

1. **Pre-processing**：对变量作 normalization, log transformation, principal components 等变换，并检查 outliers。
2. **选择点间距离**：数值型数据可用 Euclidean distance, correlation distance 等；文本或离散数据可用 Jaccard, Hamming, edit distance 等。
3. **选择簇间距离**：在 hierarchical approach 中，不同 linkage 有不同偏好。Single linkage 能较自然地处理非椭圆形簇，但对噪声和离群点敏感；complete linkage 对噪声更稳健，但可能倾向于切开较大的簇。
4. **处理初始值敏感性**： K -means 对初始 centroids 敏感。若真实有 10 个簇而随机选择 10 个初始中心，则恰好每个真实簇选到一个中心的概率可能很小，例如

$$\frac{10!}{10^{10}} \approx 0.00036.$$